

Apresentação do TCC

**Abordagem de aprendizado profundo
para classificação de parkinson por
meio de sinais de voz**

Nome: André Luiz da Silva Junior RA: 201026091

Orientador: Profº Dr. Clayton Reginaldo Pereira

Sumário

- Introdução
- Objetivos
- Revisão Teórica
- Revisão Bibliográfica
- Datasets
- Treinamento
- Resultados
- Conclusão
- Referências

Introdução

- A doença de Parkinson é uma patologia neurológica crônica que afeta a capacidade do cérebro de controlar os movimentos corporais.
- Dificuldades na realização das atividades cotidianas.
- O uso de técnicas de deep learning tem sido usadas como uma abordagem para ajudar na detecção e diagnóstico do Parkinson.
- A doença de Parkinson causa uma vibração anormal nas cordas vocais, com a presença de ruído ou outras perturbações.
- A análise dos dados de sinais de voz de pacientes com Parkinson e indivíduos saudáveis, identifica padrões que possam ajudar no diagnóstico precoce da doença e poder diferenciar os indivíduos.

Objetivos

- Revisão da literatura.
- Desenvolver um modelos de deep learning e machining learning para a classificação dos sinais de voz.
- Treinar e validar os modelos.
- Analisar os resultados e identificar padrões nos sinais de voz que possam auxiliar no diagnóstico precoce.
- Avaliar a utilidade da aplicação do uso médico.

Revisão Teórica

-Doença de Parkinson


- degeneração dos neurônios cerebrais na substância negra, afetando a produção de dopamina.
- Sintomas incluem: Tremores involuntários em diversas partes do corpo, rigidez muscular, impactando a fluidez dos movimentos, lentidão nas ações motoras e desafio em manter a postura.
- Possíveis efeitos emocionais, como ansiedade e depressão, distúrbios do sono e desafios cognitivos.
- Abordagem multifacetada, envolvendo avaliações clínicas, exames neurológicos e procedimentos de diagnóstico complementares.

Revisão Teórica

-Machining Learning

- As redes neurais são inspiradas na estrutura do cérebro humano e são utilizadas em Inteligência Artificial e Aprendizado de Máquina.
- Realizam tarefas complexas como reconhecimento de padrões e tomada de decisões.
- Compostas por neurônios artificiais interconectados.
- Processamento realizado através de pesos, somas ponderadas e funções de ativação.

Redes Neurais Multicamadas




- Modelos avançados com várias camadas para tarefas complexas.
- Estrutura: Entrada, Camadas Ocultas e Saída.
- Treinamento iterativo ajusta pesos para minimizar a diferença entre previsões e saídas reais, com ajuste de pesos durante o treinamento para reduzir o erro da rede.
- Fundamental em reconhecimento de imagens e processamento de linguagem natural.

Redes Neurais Convolucionais

- Inspiradas no sistema visual humano, destacando-se em visão computacional.
- Contêm camadas de convolução, que aplicam operações de convolução às entradas.
- Possui uma fórmula envolvendo a combinação ponderada de pixels vizinhos.
- Nas camadas de agrupamento(Pooling) se reduz a dimensão espacial, preservando características essenciais.
- Empilhamento de camadas para aprender representações progressivamente complexas.
- Amplamente empregadas em reconhecimento facial, detecção de objetos e diagnóstico médico.

Redes Neurais Recorrentes

- Eficazes para dados sequenciais como séries temporais, texto e áudio.
- Conexões retroativas em seu próprio grafo com um ciclo temporal permite a influência de informações anteriores nas previsões atuais.
- Mantêm um estado oculto que reflete informações sobre o histórico da sequência.
- Cálculo do estado oculto: $h_t = f(W_h x + W_{hh} * h_{t-1} + b_h)$.
- Explosão do gradiente durante o treinamento.
- Estratégias como gradient clipping e arquiteturas avançadas (LSTMs, GRUs) para enfrentar o problema.
- LSTMs: Mecanismos de "portões" para capturar dependências temporais mais longas.
- GRUs: Simplificam a arquitetura das LSTMs, mantendo a capacidade de capturar dependências de longo prazo.



LSTM

Long Short-Term Memory, é um tipo de arquitetura de rede neural recorrente (RNN) projetada para superar limitações de redes neurais tradicionais ao lidar com dependências temporais em dados sequenciais. A principal característica das LSTMs é a introdução de células de memória, que são capazes de armazenar e acessar informações ao longo de sequências temporais.

Deep Learning

- Aprendizado hierárquico de representações
- Utilização em visão computacional, processamento de linguagem natural, jogos, biomedicina, entre outros.

Attention


- Imitação da atenção humana
- Aplicação em processamento de linguagem natural e visão computacional
- Seq2seq e mecanismo de atenção para tarefas como tradução e chat-bots.

Transformers

- Arquitetura revolucionária
- Mecanismo de atenção e autoatenção
- Amplamente adotado em PLN, visão computacional; BERT e GPT são modelos baseados em transformers.

Support Vector Machines

- Eficazes em classificação e regressão
- Hiperplano de decisão para separação de classes
- Truques de kernel para lidar com relações não lineares.



Árvore de Decisão

- Para classificação e regressão.
- Estrutura hierárquica imitando uma árvores de decisões com base em atributos.

Random Forest

- Conjunto de árvores de decisão.
- Redução de overfitting.
- Utilizado em diversas áreas, incluindo classificação de imagem, detecção de fraudes, bioinformática, processamento de linguagem natural, entre outras.

Regressão Logística

- Previsão de probabilidade em problemas binários.
- Modelo linear para análise de relação entre variáveis.

XGBoost

- Constrói um modelo preditivo a partir de um conjunto de modelos mais simples para melhorar a precisão da previsão.
- Eficiência computacional e controle de overfitting.

Naive Bayes

- Classificação baseada no teorema de Bayes, com base em informações prévias relacionadas a esse evento.
- Assume independência condicional entre os recursos
- Eficaz em lidar com conjuntos de dados de alta dimensão

k-Nearest Neighbors

- Classificação baseada na proximidade de vizinhos.
- Simplicidade e eficácia em diferentes tipos de dados.

Revisão Bibliográfica

Inteligência Artificial e Medicina

O artigo aborda o impacto da inteligência artificial (IA) na medicina, destacando melhorias nos diagnósticos e no suporte aos médicos. A dependência crescente de exames complementares e a adoção de tecnologias, como dispositivos vestíveis, refletem a era do big data na saúde.

A new approach: information gain algorithm-based k-nearest neighbors hybrid diagnostic system for Parkinson's disease

O artigo aborda o desenvolvimento de um sistema especializado para diagnosticar eficientemente estágios iniciais da doença de Parkinson com base em sinais de fala. Utilizando o Algoritmo de Ganho de Informação K-Nearest Neighbors e características extraídas por meio do método de Transformada Wavelet do Fator Q Sintonizável, o modelo alcançou uma precisão de classificação de quase 98% com 22 características selecionadas.

Revisão Bibliográfica

Early detection of Parkinson's disease from multiple signal speech: Based on Mandarin language datase

Este artigo tem como objetivo desenvolver um método de detecção automática de distúrbios de linguagem devido a disfunção dos órgãos vocais, com base em um conjunto de dados chinês recentemente coletado. Utilizando três algoritmos de seleção de características (LASSO, mRMR, Relief-F) e quatro classificadores (Naïve Bayes, K-Nearest Neighbor, Regressão Logística e Descida de Gradiente Estocástica), a abordagem proposta alcançou uma precisão de 75,76%, sensibilidade de 82,44%, especificidade de 73,15% e precisão de 76,57%.

A generic optimization and learning framework for Parkinson disease via speech and handwritten records

Este estudo propõe um quadro genérico para diagnosticar a doença de Parkinson, abordando imagens manuscritas e sinais de fala. Utilizando 8 redes neurais convolucionais (CNNs) pré-treinadas e 16 algoritmos de extração de características, ajustados por algoritmos de aprendizado de máquina e técnicas gráficas, os resultados indicam uma métrica de 99,75% para o conjunto de dados NewHandPD e métricas superiores a 99,94% para o conjunto de dados MDVR-KCL.

Revisão Bibliográfica

A Speech-Based Hybrid Decision Support System for Early Detection of Parkinson's Disease

Este artigo apresenta um sistema híbrido de detecção de Parkinson, utilizando dois conjuntos de dados de fala. Dezesete características acústicas foram extraídas, e o método de algoritmo genético foi aplicado para selecionar as oito características mais significativas. Quatro classificadores foram utilizados, destacando-se que a combinação de seleção de características baseada em algoritmo genético e o classificador de regressão logística alcançou 100% de precisão no conjunto de dados italiano e 90% no conjunto do King's College London


Early detection of Parkinson's disease using machine learning

Este artigo enfoca o emprego de técnicas de aprendizado de máquina na detecção precoce da doença de Parkinson por meio de dados de áudio MDVP. Quatro modelos de aprendizado de máquina, incluindo Máquina de Vetores de Suporte, Random Forest, K-Nearest Neighbors e Regressão Logística, foram treinados e comparados. Os resultados destacaram o Random Forest como o classificador mais eficaz, alcançando 91,83% de precisão e 0,95 de sensibilidade.

Datasets

Parkinson's Disease Data Set

Nesse conjunto de dados foram registradas medições de voz de 31 indivíduos, dos quais 23 foram diagnosticados com a doença de Parkinson. Cada coluna nesse conjunto de dados representa uma medida de voz específica, enquanto cada linha corresponde a uma das 195 gravações de voz realizadas com os pacientes, totalizando aproximadamente seis gravações por indivíduo.



Datasets

Parkinson's Disease Data Set


Alguns dos features importantes extraídos:

- MDVP:Fo(Hz): Frequência vocal média.
- MDVP:Fhi(Hz): Frequência vocal máxima.
- MDVP:Flo(Hz): Frequência vocal mínima.
- MDVP:Jitter(%)
- MDVP:Jitter(Abs)

Datasets

Parkinson's Disease (PD) classification

Foram reunidas informações de 188 pacientes diagnosticados com Parkinson, compreendendo 107 homens e 81 mulheres, com idades variando de 33 a 87 anos. O grupo de controle, composto por indivíduos saudáveis, inclui 64 participantes, dos quais 23 são homens e 41 são mulheres, com idades entre 41 e 82 anos. Durante a coleta, o microfone foi ajustado para uma taxa de amostragem de 44,1 KHz.



Datasets


Parkinson's Disease (PD) classification

Possui 755 features, representando diversas características, tais como informações de frequência temporal, coeficientes cepstrais de frequência mel (MFCCs), recursos derivados de transformada wavelet, características da dobra vocal e recursos TWQT.

Datasets

Mobile Device Voice Recordings at King's College London (MDVR-KCL) from both early and advanced Parkinson's disease patients and healthy controls

No total são 37 testes com os pacientes lendo textos, sendo 21 sem a doença e 16 com a doença de Parkinson, e 36 de diálogo espontâneo sendo 21 sem e 15 com a doença. As gravações são de alta qualidade com uma taxa de 44,1 kHz e uma profundidade de bits de 16 bits.



Datasets

Mobile Device Voice Recordings at King's College London (MDVR-KCL) from both early and advanced Parkinson's disease patients and healthy controls

Os arquivos vieram em formato .wav, então para facilitar o treino de modelos de deep learning, foram extraídos de todos os áudios as features: Signals , Fast Fourier Transform(fft), Filter Bank(fbank) e Mel-Frequency Cepstrum Coefficients(mfccs).


Treinamento

Parkinson's Disease Data Set

Foram selecionados as melhores features, com as melhores correlações para fazer o treinamento. Podemos ver no heatmap como fica a correlação.


Treinamento

Parkinson's Disease Data Set



Treinamento


Parkinson's Disease Data Set



Treinamento

Parkinson's Disease (PD) classification

Para o segundo dataset, as features foram selecionadas utilizando PCA, sendo alcançado a taxa de 95% em torno de 200 features



Treinamento

Parkinson's Disease (PD) classification

Porém, ao com um teste, verificamos que com 6 features já alcançamos uma boa acurácia.

Componentes	Acurácia
1	78.94736642105263
2	83.55263157894737
3	79.605263157869474
4	83.55263157894737
5	84.210526315786947
6	86.8421052631579
7	83.55263157894737
8	83.55263157894737
9	83.55263157894737
10	83.55263157894737
11	82.89473684210526
12	80.92105263157895
13	83.55263157894737
14	83.55263157894737
15	84.86842105263158
16	86.18421052631578
17	85.52631578947368
18	86.18421052631578
19	86.18421052631578
20	84.210526315786947


Treinamento

Primeiro e Segundo Dataset

Regressão Logística:

- Accuracy de Treino : 83.97
- Cross Validation Score : 82.63
- Accuracy de Teste : 92.31
- Precision : 91.43
- Recall : 100.0
- F1-Score : 95.52


Matriz de confusão



Regressão Logística:

- Accuracy de Treino : 81.62
- Cross Validation Score : 88.78
- Accuracy de Teste : 86.84
- Precision : 86.72
- Recall : 97.37
- F1-Score : 91.74

Matriz de confusão




Treinamento

Primeiro e Segundo Dataset

Support Vector Machine:

- Accuracy de Treino : 83.97
- Cross Validation Score : 83.21
- Accuracy de Teste : 92.31
- Precision : 91.43
- Recall : 100.0
- F1-Score : 95.52


Matriz de confusão



Support Vector Machine:

- Accuracy de Treino : 82.45
- Cross Validation Score : 88.78
- Accuracy de Teste : 84.21
- Precision : 84.89
- Recall : 97.37
- F1-Score : 90.24

Matriz de confusão




Treinamento

Primeiro e Segundo Dataset

K-Neighbors Classifier:

- Accuracy de Treino : 83.33
- Cross Validation Score : 76.21
- Accuracy de Teste : 89.74
- Precision : 91.18
- Recall : 96.88
- F1-Score : 93.94


Matriz de confusão



K-Neighbors Classifier:

- Accuracy de Treino : 89.87
- Cross Validation Score : 81.44
- Accuracy de Teste : 82.24
- Precision : 87.83
- Recall : 88.6
- F1-Score : 88.21

Matriz de confusão




Treinamento

Primeiro e Segundo Dataset

Random Forest:

- Accuracy de Treino : 100.0
- Cross Validation Score : 83.92
- Accuracy de Teste : 92.31
- Precision : 91.43
- Recall : 100.0
- F1-Score : 95.52


Matriz de confusão



Random Forest:

- Accuracy de Treino : 100.0
- Cross Validation Score : 81.97
- Accuracy de Teste : 82.89
- Precision : 86.67
- Recall : 91.23
- F1-Score : 88.89

Matriz de confusão




Treinamento

Primeiro e Segundo Dataset

Decision Tree:

- Accuracy de Treino : 100.0
- Cross Validation Score : 82.62
- Accuracy de Teste : 89.74
- Precision : 91.18
- Recall : 96.88
- F1-Score : 93.94


Matriz de confusão



Decision Tree:

- Accuracy de Treino : 100.0
- Cross Validation Score : 75.83
- Accuracy de Teste : 79.61
- Precision : 86.73
- Recall : 85.96
- F1-Score : 86.34

Matriz de confusão




Treinamento

Primeiro e Segundo Dataset

Naive Bayes:

- Accuracy de Treino : 73.88
- Cross Validation Score : 73.71
- Accuracy de Teste : 87.18
- Precision : 96.85
- Recall : 87.5
- F1-Score : 91.8


Matriz de confusão



Naive Bayes:

- Accuracy de Treino : 74.83
- Cross Validation Score : 75.15
- Accuracy de Teste : 75.8
- Precision : 77.94
- Recall : 92.98
- F1-Score : 84.8

Matriz de confusão




Treinamento

Primeiro e Segundo Dataset

XGBoost:

- Accuracy de Treino : 100.0
- Cross Validation Score : 81.33
- Accuracy de Teste : 92.31
- Precision : 91.43
- Recall : 100.0
- F1-Score : 95.52


Matriz de confusão



XGBoost:

- Accuracy de Treino : 94.54
- Cross Validation Score : 79.64
- Accuracy de Teste : 83.55
- Precision : 86.18
- Recall : 92.98
- F1-Score : 89.45

Matriz de confusão



Treinamento

Mobile Device Voice Recordings at King's College London (MDVR-KCL) from both early and advanced Parkinson's disease patients and healthy controls

No terceiro dataset foram utilizados todas as features extraídas dos áudios, para esse dataset a abordagem do treino foi a utilização de deep learning, com as técnicas de CNN e RNN. O batch size utilizado foi 32 e a learning rate de 0,01.

Treinamento

Mobile Device Voice Recordings at King's College London (MDVR-KCL) from both early and advanced Parkinson's disease patients and healthy controls

No RNN foi utilizado LSTM e foi utilizado 5 camadas, enquanto o CNN 7 camadas.

```
def get_conv_model():
    model = Sequential()
    model.add(Conv2D(16, (3, 3), activation='relu', strides = (1,1), padding = 'same', input_shape = input_shape))
    model.add(Conv2D(32, (3,3), activation='relu', strides = (1,1), padding = 'same', input_shape = input_shape))
    model.add(Conv2D(64, (3,3), activation='relu', strides = (1,1), padding = 'same', input_shape = input_shape))
    model.add(Conv2D(128, (3,3), activation='relu', strides = (1,1), padding = 'same', input_shape = input_shape))
    model.add(MaxPool2D((2,2)))
    model.add(Dropout(0.5))
    model.add(Flatten())
    model.add(Dense(128, activation='relu'))
    model.add(Dense(64, activation='relu'))
    model.add(Dense(10, activation='softmax'))
    model.summary()
    model.compile(loss='categorical_crossentropy', optimizer='adam', metrics=['acc'])
    return model
```

```
def get_recurrent_model():
    model = Sequential()
    model.add(LSTM(128, return_sequences=True, input_shape = input_shape))
    model.add(LSTM(128, return_sequences=True))
    model.add(Dropout(0.5))
    model.add(TimeDistributed(Dense(64, activation='relu')))
    model.add(TimeDistributed(Dense(32, activation='relu')))
    model.add(TimeDistributed(Dense(16, activation='relu')))
    model.add(TimeDistributed(Dense(8, activation='relu')))
    model.add(Flatten())
    model.add(Dense(10, activation='softmax'))
    model.summary()
    model.compile(loss='categorical_crossentropy', optimizer='adam', metrics=['acc'])
    return model
```


Treinamento

CNN

```
Epoch 1/10
5063/5063 [=====] - 90s 18ms/step - loss: 0.5927 - acc: 0.6732 - val_loss: 0.5599 - val_acc: 0.7083
Epoch 2/10
5063/5063 [=====] - 87s 17ms/step - loss: 0.4934 - acc: 0.7553 - val_loss: 0.4639 - val_acc: 0.7718
Epoch 3/10
5063/5063 [=====] - 88s 17ms/step - loss: 0.4428 - acc: 0.7863 - val_loss: 0.4004 - val_acc: 0.8075
Epoch 4/10
5063/5063 [=====] - 90s 18ms/step - loss: 0.4113 - acc: 0.8055 - val_loss: 0.3798 - val_acc: 0.8212
Epoch 5/10
5063/5063 [=====] - 90s 18ms/step - loss: 0.3880 - acc: 0.8182 - val_loss: 0.3706 - val_acc: 0.8301
Epoch 6/10
5063/5063 [=====] - 88s 17ms/step - loss: 0.3695 - acc: 0.8284 - val_loss: 0.3489 - val_acc: 0.8383
Epoch 7/10
5063/5063 [=====] - 89s 18ms/step - loss: 0.3514 - acc: 0.8374 - val_loss: 0.3298 - val_acc: 0.8494
Epoch 8/10
5063/5063 [=====] - 87s 17ms/step - loss: 0.3378 - acc: 0.8448 - val_loss: 0.3211 - val_acc: 0.8529
Epoch 9/10
5063/5063 [=====] - 91s 18ms/step - loss: 0.3246 - acc: 0.8519 - val_loss: 0.3123 - val_acc: 0.8593
Epoch 10/10
5063/5063 [=====] - 91s 18ms/step - loss: 0.3144 - acc: 0.8580 - val_loss: 0.2987 - val_acc: 0.8669
```


Treinamento

CNN



Treinamento

CNN




Treinamento

RNN

```
Epoch 1/10
5063/5063 [=====] - 58s 11ms/step - loss: 0.6590 - acc: 0.6019 - val_loss: 0.6468 - val_acc: 0.6063
Epoch 2/10
5063/5063 [=====] - 54s 11ms/step - loss: 0.6206 - acc: 0.6465 - val_loss: 0.6020 - val_acc: 0.6727
Epoch 3/10
5063/5063 [=====] - 54s 11ms/step - loss: 0.5878 - acc: 0.6754 - val_loss: 0.5550 - val_acc: 0.6977
Epoch 4/10
5063/5063 [=====] - 56s 11ms/step - loss: 0.5579 - acc: 0.6992 - val_loss: 0.5261 - val_acc: 0.7215
Epoch 5/10
5063/5063 [=====] - 55s 11ms/step - loss: 0.5348 - acc: 0.7171 - val_loss: 0.5223 - val_acc: 0.7261
Epoch 6/10
5063/5063 [=====] - 56s 11ms/step - loss: 0.5146 - acc: 0.7328 - val_loss: 0.4969 - val_acc: 0.7424
Epoch 7/10
5063/5063 [=====] - 55s 11ms/step - loss: 0.4963 - acc: 0.7463 - val_loss: 0.4750 - val_acc: 0.7625
Epoch 8/10
5063/5063 [=====] - 56s 11ms/step - loss: 0.4772 - acc: 0.7600 - val_loss: 0.4744 - val_acc: 0.7632
Epoch 9/10
5063/5063 [=====] - 58s 11ms/step - loss: 0.4623 - acc: 0.7700 - val_loss: 0.4574 - val_acc: 0.7693
Epoch 10/10
5063/5063 [=====] - 54s 11ms/step - loss: 0.4461 - acc: 0.7806 - val_loss: 0.4325 - val_acc: 0.7884
```


Treinamento

RNN



Treinamento

RNN



Resultados

Modelos	Acurácia
Regressão Logística	92.3076923076923
Support Vector Machine	92.3076923076923
K-Neighbors Classifier	89.74358974358975
Random Forest	92.3076923076923
Decision Tree	89.74358974358975
Naive Bayes	87.17948717948716
XGBoost	92.3076923076923

Modelos	Acurácia
Regressão Logística	86.8421052631579
Support Vector Machine	84.21052631578947
K-Neighbors Classifier	82.23684210526315
Random Forest	82.23684210526315
Decision Tree	79.60526315789474
Naive Bayes	75.00000000000000
XGBoost	83.55263157894737

Modelos	Acurácia
Convolutional Neural Network	81.53
Recurrent Neural Network	76.70

Conclusão

A análise da aplicação de métodos de machine learning na detecção de Parkinson revelou a eficácia e versatilidade dessas técnicas no contexto médico. A regressão logística se destacou durante o treinamento e avaliação de vários modelos em diferentes conjuntos de dados. Os resultados satisfatórios, especialmente em precisão e recall, indicam a capacidade discriminativa da regressão logística e outros modelos analisados. O estudo reforça a promessa e o potencial dos métodos de machine learning na detecção precoce de condições médicas, especialmente a doença de Parkinson, abrindo caminho para futuras pesquisas e aplicações práticas em prol da saúde e bem-estar da comunidade.

Referências

BISWAS, D. Parkinson's Disease (PD) classification. 2019. Disponível em: <<https://www.kaggle.com/datasets/dipayanbiswas/parkinsons-disease-speech-signal-features>>. Acesso em: 19/08/2023.

DANTAS, S. Pay attention - Explicando o mecanismo de atenção. 2019. Disponível em: <<https://lamfo-unb.github.io/2019/05/01/Pay-attention-Explicando-o-mecanismo-de-Atencao/>>. Acesso em: 19/08/2023.

DEVELOPERS scikit-learn. Decision Trees. 2023. Disponível em: <<https://scikit-learn.org/stable/modules/tree.html>>. Acesso em: 25/08/2023.

DEVELOPERS scikit-learn. Support Vector Machines. 2023. Disponível em: <<https://scikit-learn.org/stable/modules/svm.html>>. Acesso em: 21/08/2023.

DEVELOPERS xgboost. XGBoost Documentation. 2022. Disponível em: <<https://xgboost.readthedocs.io/en/stable/>>. Acesso em: 25/08/2023.

FONOFF, D. E. O que você precisa saber sobre a doença de Parkinson. 2020. Disponível em: <<https://www.erichfonoff.com.br/doenca-de-parkinson/>>. Acesso em: 19/08/2023.

GEEKSFORGEEKS. K-Nearest Neighbor(KNN) Algorithm. 2023. Disponível em: <<https://www.geeksforgeeks.org/k-nearest-neighbours/>>. Acesso em: 25/08/2023.

Referências

GOVINDU, S. P. A. Early detection of Parkinson's disease using machine learning. Procedia Computer Science, v. 218, p. 249–261, 2023. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S1877050923000078?via%3DiHub>>. Acesso em: 18/07/2023.

GUSMÃO, A. O que é Naive Bayes e como funciona esse algoritmo de classificação. 2023. Disponível em: <<https://rockcontent.com/br/blog/naive-bayes/>>. Acesso em: 25/08/2023.

IBM. O que são redes neurais convolucionais? 2023. Disponível em: <<https://www.ibm.com/br-pt/topics/convolutional-neural-networks>>. Acesso em: 19/08/2023.

IBM. What is random forest? 2023. Disponível em: <<https://www.ibm.com/topics/random-forest#:~:text=Random%20forest%20is%20a%20commonly,both%20classification%20and%20regression%20problems.>>. Acesso em: 21/08/2023.

IYODA, E. M. INTELIGÊNCIA COMPUTACIONAL NO PROJETO AUTOMÁTICO DE REDES NEURAIIS HÍBRIDAS E REDES NEUROFUZZY HETEROGÊNEAS. 2000.

Disponível em: <https://www.dca.fee.unicamp.br/~vonzuben/theses/emi_mest/cap2.pdf>. Acesso em: 19/08/2023.

JAEGER DHAVAL TRIVEDI, M. S. H. Mobile Device Voice Recordings at King's College London (MDVR-KCL) from both early and advanced Parkinson's disease patients and healthy controls. 2019. Disponível em: <<https://zenodo.org/records/2867216>>. Acesso em: 19/08/2023.

Referências

JANKOVIC, J. Parkinson's disease: clinical features and diagnosis. Journal of neurology, neurosurgery, and psychiatry, PubMed, v. 79(4), p. 368–376, 2008. Disponível em: <<https://pubmed.ncbi.nlm.nih.gov/18344392/>>. Acesso em: 07/04/2023.

JAYASWAL, V. Performance Metrics: Confusion matrix, Precision, Recall, and F1 Score. 2020. Disponível em: <<https://towardsdatascience.com/performance-metrics-confusion-matrix-precision-recall-and-f1-score-a8fe076a2262>>. Acesso em: 21/08/2023.

JONES, M. T. Um mergulho profundo nas redes neurais recorrentes. 2017. Disponível em: <[https://imasters.com.br/data/um-mergulho-profundo-nas-redes-neurais-recorrentes#:~:text=Uma%20rede%20neural%20recorrente%20\(RNN,alimenta%C3%A7%C3%A3o%20apenas%20para%20camadas%20subsequentes\).](https://imasters.com.br/data/um-mergulho-profundo-nas-redes-neurais-recorrentes#:~:text=Uma%20rede%20neural%20recorrente%20(RNN,alimenta%C3%A7%C3%A3o%20apenas%20para%20camadas%20subsequentes).>)>. Acesso em: 19/08/2023.

LAMBA TARUN GULATI, A. J. P. R. R. A Speech-Based Hybrid Decision Support System for Early Detection of Parkinson's Disease. Arab J Sci Eng, v. 48, p. 2247–2260, 2023. Disponível em: <<https://link.springer.com/article/10.1007/s13369-022-07249-8>>. Acesso em: 18/07/2023.

LOBO, L. C. Inteligência artificial e medicina. Revista Brasileira de Educação Médica, SciELO Brasil, v. 41, p. 185–193, 2017. Disponível em: <<https://www.scielo.br/j/rbem/a/f3kqKJjVQJxB4985fDMVb8b/?format=html>>. Acesso em: 07/04/2023.

MAXIME. What is a Transformer? 2019. Disponível em: <<https://medium.com/inside-machine-learning/what-is-a-transformer-d07dd1fbec04>>. Acesso em: 19/08/2023.

Referências

ORACLE. O que é Deep Learning? 2023. Disponível em: <<https://www.oracle.com/br/artificial-intelligence/machine-learning/what-is-deep-learning/>>. Acesso em: 19/08/2023.

SAÚDE, M. D. Doença de Parkinson. 2019. Disponível em: <<https://bvsms.saude.gov.br/doenca-de-parkinson/>>. Acesso em: 07/04/2023.

SAÚDE, M. D. A avaliação do paciente em cuidados paliativos. Biblioteca Virtual em Saúde Prevenção e Controle de Câncer, v. 1, p. 286, 2022. Disponível em: <https://www.inca.gov.br/sites/ufu.sti.inca.local/files/media/document/completo_serie_cuidados_paliativos_volume_1.pdf>. Acesso em: 18/07/2023.

SERVICES, A. W. O que é regressão logística? 2023. Disponível em: <<https://aws.amazon.com/pt/what-is/logistic-regression/#:~:text=A%20regress%C3%A3o%20log%C3%ADstica%20%C3%A9%20uma,resultados%2C%20como%20sim%20ou%20n%C3%A3o.>>. Acesso em: 21/08/2023.

SERVICES, A. W. O que é uma rede neural? 2023. Disponível em: <<https://aws.amazon.com/pt/what-is/neural-network/#:~:text=Uma%20rede%20neural%20%C3%A9%20um,camadas%2C%20semelhante%20ao%20c%C3%A9rebro%20humano.>>. Acesso em: 21/08/2023.

UKANI, V. Parkinson's Disease Data Set. 2020. Disponível em: <<https://www.kaggle.com/datasets/vikasukani/parkinsons-disease-data-set>>. Acesso em: 19/08/2023

Referências

WANG YAN FU, B. S. L. C. K. R. Z. C.-Y. L. . Q. Early detection of Parkinson's disease from multiple signal speech: Based on Mandarin language dataset. Front Aging Neurosci, v. 14, p. 1036588, 2022. Disponível em: <<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC9691375/>>. Acesso em: 18/07/2023.

WANG YAN FU, B. S. L. C. K. R. Z. C.-Y. L. Q. Early detection of Parkinson's disease from multiple signal speech: Based on Mandarin language dataset. Front Aging Neurosci, Front Aging Neurosci, v. 14, 2022. Disponível em: <<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC9691375/>>. Acesso em: 07/04/2023.

YOUSIF HOSSAM MAGDY BALAHA, A. Y. H. E. M. E.-G. N. R. A generic optimization and learning framework for Parkinson disease via speech and handwritten records. J Ambient Intell Human Comput, v. 14, p. 10673–10693, 2023. Disponível em: <<https://link.springer.com/article/10.1007/s12652-022-04342-6>>. Acesso em: 18/07/2023.

YüCELBA Ş, C. A new approach: information gain algorithm-based k-nearest neighbors hybrid diagnostic system for Parkinson's disease. Physical and Engineering Sciences in Medicine, v. 44, p. 511–524, 2021. Disponível em: <<https://doi.org/10.1007/s13246-021-01001-6>>. Acesso em: 18/07/2023.

ZAPAROLLI, D. A inteligência artificial chega à saúde. 2022. Disponível em: <<https://revistapesquisa.fapesp.br/a-inteligencia-artificial-chega-a-saude/>>. Acesso em: 19/08/2023.

Agradeco!