

Análise de acidentes de trânsito em Bauru-SP utilizando Ciência de Dados

Autor: Bruno Shinji Ito

Orientador: Profº Drº Higor Amario de Souza

Introdução

- Fatalidade no trânsito: um problema urbano de escala mundial e nacional, que está presente no município de Bauru
 - 1,25 milhões no mundo em 2021
 - 35.938 no Brasil em 2023
 - 6.124 no estado de São Paulo em 2024
 - 41 em Bauru em 2024
- Capacidade de Ciência de Dados para apoiar as decisões
- Falta de estudos para predição de fatalidade em Bauru

Justificativa

- Aspecto social
 - Plano Nacional de Redução de Mortes e Lesões no Trânsito (PNATRANS)
 - OMS
- Aspecto econômica
 - R\$ 449 milhões em 2024
- Aspecto tecnológica
 - Estratégia Federal do Governo Digital

Objetivos

- Geral
 - Analisar as ocorrências de acidentes de trânsito na cidade de Bauru através de técnicas de Ciência de Dados a fim de identificar possíveis padrões espaciais, demográficos e temporais.
- Específicos
 - Caracterizar o perfil mais suscetível e vulnerável a acidentes e fatalidade
 - Identificar os locais de maior incidência de acidentes através do mapeamento
 - Analisar a correlação entre as características dos acidentes e suas ocorrências
 - Predizer a fatalidade de um acidente através de algoritmos de Aprendizado de Máquina;

Metodologia

Fontes de Dados

- Acidentes
- Mapa
- Vítimas
- Condições meteorológicas

Metodologia

Ambiente de Desenvolvimento e Ferramentas

- Google Colaboratory
- Excel
- Python

Metodologia

Ambiente de Desenvolvimento e Ferramentas

Bibliotecas usadas em Python

- Manipulação e Análise de Dados
 - Pandas, GeoPandas e NumPy
- Visualização de Dados e Geração de Gráficos e Mapa
 - Matplotlib, Seaborn, Folium, OSMnx
- Desenvolvimento de modelos de Aprendizado de Máquina
 - Scikit-learn, Imblearn, XGBoost

Metodologia


Pré-processamento de Dados

- Filtragem dos Dados
- Tratamento de Dados
 - Dados Nulos
 - Eliminação, mediana ou interpolação
 - Correção na *String*
 - Coluna *horario*
 - Imputação Lógica
 - Dados inconsistentes após o Merge()

Metodologia

Análise Exploratória de Dados


- Fatalidade



Metodologia

Análise Exploratória de Dados


- Acidente



Metodologia

Análise Exploratória de Dados


- Acidente



Metodologia

Análise Exploratória de Dados


- Acidente



Metodologia

Análise Exploratória de Dados


- Temporal



Metodologia

Análise Exploratória de Dados


- Temporal



Metodologia

Análise Exploratória de Dados


- Temporal



Metodologia

Análise Exploratória de Dados


- Temporal



Metodologia

Análise Exploratória de Dados


- Temporal



Metodologia

Análise Exploratória de Dados


- Temporal



Metodologia

Análise Exploratória de Dados


- Espacial



Metodologia

Análise Exploratória de Dados


- Espacial



Metodologia

Análise Exploratória de Dados


- Vítimas



Metodologia

Análise Exploratória de Dados


- Vítimas



Metodologia

Engenharia de *Features*


- *Density Based Spatial Clustering of Applications with Noise* (DBSCAN)



Metodologia

Engenharia de *Features*

- DBSCAN



Metodologia

Engenharia de *Features*

- DBSCAN

zona_acidente	
-1	5840
1	497
3	274
10	260
40	242
4	176
22	166
103	152
14	129
64	126
60	125
25	107
53	103
93	101
7	97
27	97
0	90
37	88
20	81
59	80

Metodologia

Engenharia de *Features*

- Tipos de Via

```
mapa_tipo_via = {  
    'motorway': 'Autoestrada',  
    'trunk': 'Rodovia Principal',  
    'primary': 'Avenida Principal',  
    'secondary': 'Avenida Secundária',  
    'tertiary': 'Via Coletora',  
    'unclassified': 'Via Local',  
    'residential': 'Rua Residencial',  
    'service': 'Via de Serviço',  
    'motorway_link': 'Acesso de Autoestrada',  
    'trunk_link': 'Acesso de Rodovia',  
    'primary_link': 'Acesso de Avenida',  
    'secondary_link': 'Acesso de Avenida',  
    'tertiary_link': 'Acesso de Via',  
    'living_street': 'Área Residencial'  
}
```

Metodologia

Engenharia de *Features*

- Categorias de Profissão
 - 300 profissões listadas
 - Utilização de *dict*
 - Agrupadas em 19 categorias diferentes

Metodologia

Engenharia de *Features*

- Faixa Etária
 - Três subdivisões pela idade: *faixa_etaria_geral*, *faixa_etaria_especifica*, *faixa_etaria_demográfica*
 - *faixa_etaria_geral*: JOVEM (0–17), ADULTO (18–59), IDOSO (60+)
 - *faixa_etaria_especifica*: CRIANCA (0–11), ADOLESCENTE (12–17), JOVEM ADULTO (18–29), ADULTO (30–59), IDOSO (60–74), ANCIAO (75–89), VELHICE EXTREMA (90+)
 - *faixa_etaria_demográfica*: 0 (0–4), 1 (5–9), 2 (10–14), 3 (15–19), 4 (20–24), e assim sucessivamente

Metodologia

Engenharia de *Features*

- Faixa Etária
 - Três subdivisões: *faixa_etaria_geral*, *faixa_etaria_especifica*, *faixa_etaria_demografica*

idade	faixa_etaria_geral	faixa_etaria_especifica	faixa_etaria_demografica
16	JOVEM	ADOLESCENTE	3
25	ADULTO	JOVEM ADULTO	5
49	ADULTO	ADULTO	9
81	IDOSO	ANCIAO	16

Metodologia

Engenharia de *Features*


- Faixa Etária
 - Três subdivisões: *faixa_etaria_geral*, *faixa_etaria_especifica*, *faixa_etaria_demografica*

	idade	faixa_etaria_geral	faixa_etaria_especifica	faixa_etaria_demografica
0	45.0	ADULTO	ADULTO	9.0
1	28.0	ADULTO	JOVEM ADULTO	5.0
2	22.0	ADULTO	JOVEM ADULTO	4.0
3	16.0	JOVEM	ADOLESCENTE	3.0
4	27.0	ADULTO	JOVEM ADULTO	5.0
5	19.0	ADULTO	JOVEM ADULTO	3.0
6	40.0	ADULTO	ADULTO	8.0
7	31.0	ADULTO	ADULTO	6.0
8	19.0	ADULTO	JOVEM ADULTO	3.0
9	34.0	ADULTO	ADULTO	6.0

Metodologia

Engenharia de *Features*


- *Principal Component Analysis* (PCA)



Metodologia

Engenharia de *Features*

- *Principal Component Analysis* (PCA)




Metodologia

Implementação de Modelos de Aprendizado de Máquina

- Árvore de Decisão
- XGBoost
- Métricas de Avaliação

Resultados

Zonas de Acidente (*Hotspots*)



Resultados

Zonas de Accidente (*Hotspots*)

Zona	Víctimas
1	497
3	274
10	260
40	242
4	176
22	166
103	152
14	129

Resultados

Zonas de Acidente (*Hotspots*)

Zona	Vítimas	Vítimas Fatais	Fatalidade	Local
1	497	6	1,20%	Av. Nações Unidas (trecho entre Av. Rodrigues Alves e R. Ezequiel Ramos)
3	274	0	0%	Av. Rodrigues Alves e R. São Patrício (rotatória com a interseção Av. Eng. Hélio Police)
10	260	1	0,38%	Av. Castelo Branco e R. Felicíssimo Antônio Pereira (interseção com a Av. Ambleto Bertolucci)
40	242	5	2,07%	Av. Duque de Caxias e R. Dr. Lisboa Jr. (trecho entre R. Rubens Arruda e R. Azarias Leite)


Zonas de Accidente (*Hotspots*)

- [illegible]

Resultados

Zonas de Acidente (*Hotspots*)


- Zona 3



Resultados

Zonas de Acidente (*Hotspots*)


- Zona 10



Resultados

Zonas de Acidente (*Hotspots*)

- Zona 40



Resultados

Zonas de Acidente (*Hotspots*)

Zona	Vítimas	Vítimas Fatais	Fatalidade	Local
86	33	6	18,18%	Rodovia SP 225 – km 227 Rod. Cmte. João Ribeiro de Barros (Saída 226)
54	25	4	16,0%	Rodovia SP 294 – km 349 Rod. Cmte. João Ribeiro de Barros (Saída 348)
24	30	4	13,33%	Rodovia SP 300 – km 336 Rod. Marechal Rondon (Saída 336B)
95	17	2	11,76%	Rodovia SP 321 – km 344 Rod. Cesário José de Castilho (Antes da bifurcação)

Resultados

Zonas de Accidente (*Hotspots*)


- Zona 86



Resultados

Zonas de Acidente (*Hotspots*)


- Zona 54



Resultados

Zonas de Acidente (*Hotspots*)


- Zona 24



Resultados

Zonas de Acidente (*Hotspots*)

- Zona 95



Resultados

Desempenho da Árvore de Decisão e de XGBoost

- Escolha de maximizar determinada pontuação
- Busca de melhor combinação de hiperparâmetros utilizando *Random Search* e *Grid Search*

Resultados

Desempenho da Árvore de Decisão e de XGBoost

Hiperparâmetro	<i>Random Search</i>	<i>Grid Search</i>
<i>xgboost__learning_rate</i>	[0.05, 0.0625, 0.075, 0.0875, 0.1, 0.1125, 0.125]	[0.04, 0.045, 0.05, 0.055]
<i>xgboost__max_depth</i>	[2, 4, 6, 8, 10, 12]	[3, 4, 5]
<i>xgboost__colsample_bytree</i>	[0.5, 0.6, 0.7, 0.8, 0.9, 1.0]	[0.55, 0.65, 0.75, 0.85, 0.95]
<i>xgboost__subsample</i>	[0.5, 0.6, 0.7, 0.8, 0.9, 1.0]	[0.75, 0.85, 0.95]
<i>xgboost__n_estimators</i>	[50, 150, 250, 350, 450, 550, 650, 750, 850, 950]	[45, 60, 75, 90, 105]

Resultados


Desempenho da Árvore de Decisão e de XGBoost

Métrica	Árvore de Decisão	XGBoost <i>Random Search</i>	XGBoost <i>Grid Search</i>
Precisão	0,98	0,98	0,89
Recall	1,00	1,00	0,77
F1-Score	0,99	0,99	0,82

Métrica	Árvore de Decisão	XGBoost <i>Random Search</i>	XGBoost <i>Grid Search</i>
Precisão	0,66	0,93	0,86
Acurácia	0,98	0,79	0,80
Recall	0,74	0,74	0,64
F1-Score	0,70	0,83	0,73


Resultados

Desempenho da Árvore de Decisão e de XGBoost



Resultados

Desempenho da Árvore de Decisão e de XGBoost



Conclusão

- XGBoost com *Grid Search* teve o desempenho mais promissor
- Caracterização dos *hotspots* : alta incidência nas vias urbanas; alta fatalidade nas rodovias
- Diferentes condições espaciais, sociais e temporais que podem aumentar a fatalidade
- Possíveis aprimoramentos

Obrigado