

Explorando Abordagens sem Normalização para Inferência Eficiente em Grandes Modelos de Linguagem

Daniel Gomes Candido

Março de 2025

Orientadores: Prof. Dr. Leandro Aparecido Passos Junior
Prof. Me. Pedro Henrique Paiola

Por que Otimizar a Inferência em LLMs?

- **Contexto:** Modelos como BERT e GPT revolucionaram o PLN, mas têm alto custo computacional na inferência.
- **Problema:** Alta latência e uso de recursos limitam aplicações em tempo real e dispositivos de borda.
- **Foco:** Abordagens sem normalização (ex.: Dynamic Tanh - DyT) podem reduzir latência e custos, mantendo desempenho?
- **Relevância:** Torna a IA escalável e sustentável (ex.: chatbots, dispositivos edge).

Metas e Metodologia

Objetivo Geral

Avaliar abordagens sem normalização (DyT), em conjunto com técnicas já estabelecidas, na eficiência da inferência em LLMs.

Objetivos Específicos

1. Comparar DyT vs. normalização tradicional (latência, memória, precisão).
2. Integrar com paralelização em GPUs (ex.: batching contínuo, amostragem especulativa).
3. Testar viabilidade em cenários de tempo real e recursos limitados.

Método: Experimentos com LLaMA, PyTorch, GPUs; métricas como latência e throughput.

Onde Estamos

Avanços Atuais

- DyT (2025): Reduz tempo de inferência em 7,8% (Zhu et al.).
- Paralelização em GPUs: Até 23x de throughput com batching contínuo (Anyscale, 2023).
- Amostragem Especulativa: Aceleração de 2-2,5x (Leviathan et al., 2023).

Lacuna e Inovação

- *Lacuna*: Poucos estudos combinam métodos sem normalização com paralelização.
- *Inovação*: Integrar DyT com otimizações de ponta para reduzir latência em 15-20%.

Plano e Impacto

Cronograma (Fev-Out 2025)

- Fev-Abr: Revisão bibliográfica
- Abr-Jun: Implementação (Baseline + DyT)
- Mai-Jul: Integração de otimizações em GPU
- Jul-Set: Análise de dados
- Set-Out: Redação final

Impacto e Próximos Passos

- *Impacto Esperado:* LLMs mais rápidos e sustentáveis.
- *Próximos Passos:* Iniciar experimentos após aprovação (Maio 2025).