



1

Daniel Hideki Rocha Kanashiro
Prof. Dr. João Paulo Papa
Ms. Gabriel Lino Garcia

Construção e tradução de datasets multimodais na saúde: um estudo para casos de covid-19.



Sumário

- Introdução
- Fundamentação
- Materiais e métodos
- Resultados
- Conclusão



3

Introdução

A Covid-19 é uma doença causada pelo coronavírus da síndrome respiratória aguda grave 2, SARS-CoV-2.

Pertence à mesma família do SARS-CoV e MERS-CoV, a Coronaviridae, uma família de vírus já conhecida anteriormente; porém, com letalidade menor, de 2% a 3% em comparação aos estimados 10% do SARS-CoV e 40% do

MERS-CoV, respectivamente (SHI et al., 2020). Entretanto, a transmissão três vezes maior que a do SARS-CoV e dez vezes maior que a do MERS-CoV (JIANG; SHI, 2020).

O principal teste da doença, RT-PCR, tem 29% de falso negativo, podendo atrasar o diagnóstico e causar sequelas ou mesmo o óbito (AREVALO-RODRIGUEZ et al., 2020).



Introdução

Aprendizado de máquina é um modelo de inteligência artificial, se mostrou útil para a área de Medicina como um todo. No cenário da pandemia, por exemplo, foi usada para prever a interação entre moléculas de drogas e sua reação com doenças, como a covid-19 (ZHANG et al., 2022), ou para auxiliar no monitoramento de pacientes com a doença (BOUSSEN et al., 2022).

A *Multimodal Large Languages Model* (M-LLM), um modelo de aprendizado de máquina que se especializa em dados multimodais e se mostraram úteis para a área de Medicina como um todo (MOOR et al., 2023a). Modelos como Med-LLaVA (LI et al., 2023) é uma Visual Language Model, um M-LLM com foco em texto-imagem, que foi treinado para a Medicina geral enquanto ao trabalho por Tiu et al (2022), para a radiologia.



Problema e Justificativa

No que concerne a diagnóstico de covid-19, não há trabalhos que investiguem nem que se utilizem da multimodalidade. Um dos percalço advém da necessidade de um vasto conjunto de dados público. No Brasil, é escasso conjuntos como esse devido a restrições como a LGPD que dificulta a criação de novos repositório.

Yan et al (2023) indicam que modelos multimodais consistentemente superam as abordagens unimodais, podendo auxiliar no diagnóstico e complementar o RT-PCR com 29% de falso negativo.



6

Objetivos

Geral

Desenvolver um dataset multimodal estruturado em português, a partir de imagens e notas clínicas de pacientes para melhorar a eficácia de previsão de Covid-19 e avaliar como a multimodalidade afeta o resultado.



7

Objetivos

Específicos

- Coletar, estruturar e traduzir o dataset para o português de modo a estar pronta para o treinamento de modelos.
- Analisar a distribuição de amostras, identificando possíveis vieses e correção do dataset.
- Validar a base elaborada em um modelo de VLM para aferição do impacto da multimodalidade na predição da doença.
- Aperfeiçoar o modelo de VLM de acordo com o resultado da validação.
- Comparar o desempenho obtido por dados de uma única modalidade em relação à abordagem combinada



Fundamentação teórica



Aprendizado de máquina

O aprendizado de máquina é o campo da IA que se concentra em algoritmos capazes de aprender e realizar tarefas sem que sejam explicitamente programados. A sua precisão é dependente da quantidade, da qualidade e da boa distribuição dos dados (GONG et al., 2023).

Processamento de linguagem natural

O Processamento de Linguagem Natural (PLN) consiste no campo da IA que busca sistemas e modelos que consigam analisar, processar e gerar computacionalmente linguagem natural, ou seja, a linguagem falada por humanos e como eles realmente se comunicam.


A tokenização é o processo de segmentar um texto em unidades elementares, chamadas tokens. Um token é a menor unidade de significado para o modelo, tipicamente uma palavra, um número ou um sinal de pontuação (CASELI; NUNES, 2024).

ele gosta de sorvete, jogos e desenho



"ele" "gosta", "de", "sorvete", ",", "jogos", "e", "desenho"


O word embedding é uma representação vetorial densa onde cada token é mapeado como um vetor (ou um ponto) em um espaço vetorial de n-dimensões (CASELI; NUNES, 2024). Este vetor é denominado de vetor semântico.




$$\text{vetor}(\text{"rei"}) - \text{vetor}(\text{"homem"}) + \text{vetor}(\text{"mulher"}) \approx \text{vetor}(\text{"rainha"}).$$


LLM e Transformer

Em 2017, a arquitetura de aprendizado de máquina Transformer foi introduzida por pesquisadores do Google no artigo “Attention is All You Need” (VASWANI et al., 2017). Embora existam variações, a arquitetura canônica é composta por um encoder (codificador), um decoder (decodificador) e o mecanismo de atenção, que é seu principal componente.





$$PE(k, i) = \begin{cases} \sin\left(\frac{k}{n^{\frac{2i}{d}}}\right), & \text{se } i \text{ for par} \\ \cos\left(\frac{k}{n^{\frac{2i}{d}}}\right), & \text{se } i \text{ for ímpar} \end{cases}$$




Multi-head attention

$$Q = XW_q$$

$$K = XW_k$$


$$V = XW_v$$

$$\frac{QK^T}{\sqrt{d_k}}$$




$$\text{softmax}(x)_i = \frac{e^{x_i}}{\sum_{j=1}^N e^{x_j}}$$

$$Z = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$




Feed Forward


$$FFN(x) = \max(0, xW_1 + b_1)W_2 + b_2$$



Low Rank Adapter – LoRA



Visual Language Model – VLM



Materiais e métodos

Processamento de linguagem natural

A plataforma Kaggle será utilizada durante a experimentação inteira do trabalho. Esta plataforma online disponibiliza ambientes virtuais de desenvolvimento com notebooks na linguagem Python bem como datasets públicos. Sua escolha se deve ao fato de que também disponibiliza gratuitamente 30 horas semanais de GPUs como P100 ou duas T4.

O ambiente de desenvolvimento do trabalho contou com 57.6 GiB de armazenamento, 30 GiB de RAM e 2 GPUs T4 com 15 GiB de VRAM.

The Kaggle logo is displayed in a light blue, lowercase, sans-serif font. It consists of the word "kaggle" followed by a small "TM" trademark symbol.

Dataset

O dataset utilizado covid-chest-xray (Cohen et al., 2020) que coletou durante a pandemia imagens de raio-X e tomografias computadorizadas de 412 pacientes em 26 países. A cada imagem há também dados como teste de sangue, sobrevivência do paciente, intubação e uma nota clínica. Esta foi a primeira coleção pública de imagens radiológicas para covid-19.

O conjunto de dados não se limita apenas covid-19, incluindo também a identificação de diversas outras patologias. As categorias são definidas pela origem do patógeno: viral (incluindo covid-19 e outros 5 tipos), bacteriana (9 tipos), fúngica (2 tipos), além de casos de pneumonia lipoide, por aspiração e de origem desconhecida.



On January 19, 2020, a 35-year-old man presented to an urgent care clinic in Snohomish County, Washington, with a 4-day history of cough and subjective fever. Stable streaky opacities in the lung bases were visible, indicating likely atypical pneumonia; the opacities have steadily increased in density over time.

Left chest pain with increased work of breathing. Large left pleural effusion with associated left mid zone airspace opacity with air bronchograms. Right basal opacity and a small right pleural effusion. Left lower lobe consolidation and atelectasis. Moderate left pleural effusion extending to the oblique fissure. Very small right pleural effusion with minor atelectasis.



Women, 69 years old, has reported fever since one week treated with antibiotics without benefit. In the anamnesis, he does not report any noteworthy pathologies. PS temperature in the normal range (36.5 °), pO₂ 96%, eupnoic. The radiographic investigation shows a discrete increase in the peribronchovascular interstitium with associated some nuanced parenchymal thickenings at the base of both lungs. Cardiomedastinal shadow in the norm. Normo-expanded costophrenic sinuses

"On January 22, 2020, a 65-year-old man with a history of hypertension, type 2 diabetes, coronary heart disease for which a stent had been implanted, and lung cancer was admitted to the emergency department of Cho Ray Hospital, the referral hospital in Ho Chi Minh City, for low-grade fever and fatigue. He had become ill with fever on January 17, a total of 4 days after he and his wife had flown to Hanoi from the Wuchang district in Wuhan, where outbreaks of 2019-nCoV were occurring. He reported that he had not been exposed to a "wet market" (a market where dead and live animals are sold) in Wuhan. Chest radiographs obtained on admission showed an infiltrate in the upper lobe of the left lung"

- **Admissão:** "history of hypertension, type 2 diabetes, coronary heart disease for which a stent had been implanted, and lung cancer";
- **Sintomático:** "low-grade fever and fatigue";
- **Observação:** "Chest radiographs obtained on admission showed an infiltrate in the upper lobe of the left lung".

A execução do modelo se deu pelo uso das ferramentas Ollama e LangChain. O Ollama é uma plataforma que simplifica o download, a configuração e a execução de LLMs.

O LangChain, por sua vez, é um framework de desenvolvimento focado na criação de aplicações que utilizam LLMs. Ele atua como um gerenciador, sendo usado na pesquisa para estruturar a lógica da aplicação, manusear os prompts e facilitar a comunicação com o modelo que estava sendo executado via Ollama.



Métrica

- Verdadeiro Positivo (VP)
- Falso Positivo (FP)
- Verdadeiro Negativo (VN)
- Falso Negativo (FN)

$$\text{Acurácia} = \frac{VP + VN}{VP + VN + FP + FN}$$

$$\text{Precisão} = \frac{VP}{VP + FP}$$


$$\text{Recall} = \frac{VP}{VP + FN}$$

$$\text{F1-Score} = 2 \times \frac{\text{Acuracia} \times \text{Precisao}}{\text{Acuracia} + \text{Precisao}}$$

Resultados

Devido ao consumo intensivo de VRAM intrínseco aos Vision Language Model, o trabalho enfrentou dificuldades com o tamanho dos modelos e o processo de ajuste. Foi utilizado o framework de treino (SFTTrainer) e as bibliotecas trl e Unsloth focadas em otimização de performance e eficiência de memória, permitindo a aplicação do PEFT/LoRA. O tamanho do lote por dispositivo foi minimizado, sendo esta redução compensada pela aplicação de múltiplos passos de acumulação de gradiente. Dos modelos disponíveis no Unsloth, foi usado os modelos MedGemma e Qwen.


Qwen



Qwen

Status	Modalidade	Acurácia	Precisão	Recall	F1-Score
Treinado	Apenas Imagem	0.4776	0.7245	0.4128	0.5259
	Apenas Texto	0.5020	0.7049	0.5000	0.5850
	Ambas	0.5429	0.7143	0.5814	0.6410
Sem Treino	Apenas Imagem	0.3510	0.7826	0.1047	0.1846
	Apenas Texto	0.3633	0.7353	0.1453	0.2427
	Ambas	0.4163	0.7101	0.2849	0.4066


MedGemma



MedGemma

Status	Modalidade	Acurácia	Precisão	Recall	F1-Score
Treinado	Apenas Imagem	0.5959	0.7325	0.6686	0.6991
	Apenas Texto	0.5061	0.7684	0.4244	0.5468
	Ambas	0.6286	0.7120	0.7907	0.7493
Sem Treino	Apenas Imagem	0.5592	0.6905	0.6744	0.6824
	Apenas Texto	0.4327	0.6542	0.4070	0.5018
	Ambas	0.5469	0.6871	0.6512	0.6687


MedGemma em inglês



MedGemma em inglês

Status	Modalidade	Acurácia	Precisão	Recall	F1-Score
Treinado	Apenas Imagem	0.4507	0.5983	0.5000	0.5447
	Apenas Texto	0.3361	0.7368	0.0819	0.1474
	Ambas	0.5041	0.6786	0.5556	0.6109
Sem Treino	Apenas Imagem	0.5533	0.7013	0.6316	0.6646
	Apenas Texto	0.4139	0.6373	0.3801	0.4762
	Ambas	0.5697	0.6919	0.6959	0.6939

Qwen em inglês






Qwen em inglês

Status	Modalidade	Acurácia	Precisão	Recall	F1-Score
Treinado	Apenas Imagem	0.4713	0.7333	0.3860	0.5057
	Apenas Texto	0.3566	0.6750	0.1579	0.2559
	Ambas	0.4549	0.6610	0.4561	0.5398
Sem Treino	Apenas Imagem	0.3033	1.0000	0.0058	0.0116
	Apenas Texto	0.3566	0.7500	0.1228	0.2111
	Ambas	0.3443	0.7619	0.0936	0.1667

Devido ao baixo desempenho do treinamento em inglês, foi tentado o uso de múltiplos prompts para cada amostra de modo a diversificar o conjunto.

- You are a helpful medical assistant. Is there Covid-19 in this image? You may write out your final answer X in the format "Final Answer X" being X "Yes: Covid" or "No: no-Covid". Consider extra informations:
- Correlate the findings on this chest X-ray with the patient's symptoms and admission notes. Are these combined findings consistent with a COVID-19 diagnosis? Answer 'Yes: Covid' or 'No: no-Covid'.
- Is there Covid-19 in this image? Consider extra infos about the patient like admission (previous medical history), symptoms and observation (notes about image). You may write out your final answer X in the format "Final Answer X" being X "Yes: Covid" or "No: no-Covid".
- Analyze the following chest X-ray in conjunction with the patient's clinical information. Based on all the provided data, determine if the diagnosis is COVID-19. Respond only with 'Yes: Covid' or 'No: no-Covid'.


MedGemma em inglês



MedGemma em inglês

Modalidade	Acurácia	Precisão	Recall	F1-Score
Apenas Imagem	0.4549	0.7317	0.3509	0.4743
Apenas Texto	0.4303	0.6860	0.3450	0.4591
Ambas	0.4139	0.7593	0.2398	0.3644

Qwen em inglês



Qwen em inglês

Modalidade	Acurácia	Precisão	Recall	F1-Score
Apenas Imagem	0.4877	0.7447	0.4094	0.5283
Apenas Texto	0.4139	0.7917	0.2222	0.3470
Ambas	0.4754	0.6617	0.5146	0.5789

Conclusão

A abordagem multimodal apresentou um desempenho consistentemente superior quando comparada às análises unimodais (utilizando exclusivamente texto ou imagem). Isso demonstra que a fusão de diferentes tipos de dados permite ao modelo capturar padrões mais complexos e robustos, reforçando a viabilidade e a importância de investir em técnicas multimodais para o avanço do diagnóstico auxiliado por computador.

Trabalhos futuros

Considerando as limitações de processamento computacional deste estudo, sugere-se como melhoria futura investigar o impacto da multimodalidade em VLMs mais robustos. Adicionalmente, a validação dos resultados em repositórios com um volume de amostras superior ao utilizado neste trabalho seria de grande valia para testar a generalização dos modelos.

Recomenda-se também a investigação das causas do desempenho inferior observado nos modelos treinados em inglês, em comparação com os treinados em português.

Referências

- SHI, Y.; WANG, G.; CAI, X.; DENG, J.; ZHENG, L.; ZHU, H.; ZHENG, M.; YANG, B.; CHEN, Z. An overview of covid-19. *Journal of Zhejiang University-SCIENCE B, Springer*, v. 21, n. 5, p. 343–360, 2020.
- JIANG, S.; SHI, Z. L. The first disease x is caused by a highly transmissible acute respiratory syndrome coronavirus. *Virologica Sinica, Springer*, v. 35, n. 3, p. 263–265, 2020.
- AREVALO-RODRIGUEZ, I.; BUITRAGO-GARCIA, D.; SIMANCAS-RACINES, D.; ZAMBRANO-ACHIG, P.; CAMPO, R. D.; CIAPPONI, A.; SUED, O.; MARTINEZ-GARCÍA, L.; RUTJES, A. W.; LOW, N.; BOSSUYT, P. M.; PEREZ-MOLINA, J. A.; ZAMORA, J. False-negative results of initial rt-pcr assays for covid-19: a systematic review. *Plos One, Plos*, 2020.
- MOOR, M.; BANERJEE, O.; ABAD, Z. S. H.; KRUMHOLZ, H. M.; LESKOVEC, J.; TOPOL, E. J.; RAJPURKAR, P. Foundation models for generalist medical artificial intelligence. *Nature, Nature Publishing Group UK London*, v. 616, n. 7956, p. 259–265, 2023.
- LI, C.; CHEN, M.; WANG, J.; SITARAM, S.; XIE, X. Culturellm: Incorporating cultural differences into large language models. *Neural Information Processing Systems, NeurIPS*, 2024.
- YAN, K.; LI, T.; MARQUES, J. A. L.; GAO, J.; FONG, S. J. A review on multimodal machine learning in medical diagnostics. *Math. Biosci. Eng*, v. 20, n. 5, p. 8708–8726, 2023.

Referências

- GONG, Y.; LIU, G.; XUE, Y.; LI, R.; MENG, L. A survey on dataset quality in machine learning. Information and Software Technology, Elsevier, v. 162, p. 107268, 2023.
- VASWANI, A.; SHAZEER, N.; PARMAR, N.; USZKOREIT, J.; JONES, L.; GOMEZ, A. N.; KAISER, Ł.; POLOSUKHIN, I. Attention is all you need. Advances in neural information processing systems, v. 30, 2017.
- GOOGLE. MedGemma Hugging Face. 2025.
<<https://huggingface.co/collections/google/medgemma-release-680aade845f90bec6a3f60c4>>.
Accessed: [Insert Date Accessed, e.g., 2025-05-20].