

---

# **Aprendizado de Máquina Aplicado à Quantificação do Índice de Proliferação em Osteossarcomas Caninos**

Eduardo Alvaro Monteiro

---

Orientador: Prof. Dr. Clayton Reginaldo Pereira

14 de Novembro de 2025

Universidade Estadual Paulista “Júlio de Mesquita Filho” (UNESP)

Faculdade de Ciências (FC) / Departamento de Computação (DCo)

Bauru, SP - Brasil

# Sumário da Apresentação

**1 - Introdução**

**2 - Fundamentação teórica**

**3 - Metodologia**

**4 - Resultados**

**5 - Conclusão**

# Introdução


---

# Introdução

## O que é Osteossarcoma Canino (OSA) ?

- ▶ Neoplasia - Crescimento anormal e desordenado de células que formam um tumor
- ▶ Afeta cães de raças grandes e gigantes, principalmente entre os 5 e 9 anos de idade (FILHO et al., 2010)
- ▶ 80% dos casos de tumores malignos ósseos correspondem ao OSA (BRODEY; RISER, 1969)
- ▶ Alto potencial de metástase

Figura 1 - Regiões mais afetadas pelo OSA



Fonte: <https://www.revistasaudenews.com.br/post/2041/tudo-o-que-voce-precisa-saber-sobre-o-osteosarcoma-em-pets>

# Introdução

## Como é feito o Diagnóstico ?

- ▶ Observação de sinais clínicos, como dor, claudicação e aumento de volume ósseo.
- ▶ Radiografias revelam lesões ósseas típicas, e tomografia auxiliam na avaliação da extensão do tumor.
- ▶ A confirmação definitiva é obtida por biópsia, com análise histopatológica do tecido afetado.  
(MEUTEN, 2020)

Figura 2 - Comparação osso com OSA e saudável



Fonte: <https://www.pdsa.org.uk/pet-help-and-advice/pet-health-hub/conditions/osteosarcoma-bone-cancer-in-dogs>

## Como é feito o Prognóstico ?


- ▶ Mais do que a confirmação do diagnóstico, a análise histopatológica permite estimar a evolução e sobrevida do animal a partir da **obtenção do índice de proliferação de células**
- ▶ Quanto maior o índice proliferativo, maior o risco de ocorrerem metástases e maior a agressividade do tumor (SCHOLZEN; GERDES, 2000)
- ▶ Não tem cura, mas tratamentos podem prolongar a vida do animal - controlar a dor e retardar a metástase
- ▶ Influenciam a conduta médica - Cirurgia (amputação) e/ou quimioterapia

## Como identificar células em proliferação ?

- ▶ Ki-67 é uma proteína nuclear associada à proliferação celular e frequentemente utilizada como marcador para avaliar a taxa de crescimento celular ([SCHOLZEN; GERDES, 2000](#))
- ▶ Um nível elevado de expressão de Ki-67 geralmente está associado a um crescimento tumoral mais rápido e a um comportamento mais agressivo da neoplasia ([HORIMOTO et al., 2015](#))

## Preparação da Lâmina


Figura 3 - Lâmina de Controle Negativo



Fonte: Elaborado pelo autor

## Preparação da Lâmina


Figura 4 - Lâmina de Controle Positivo



Fonte: Elaborado pelo autor

## Preparação da Lâmina


Figura 5 - Lâmina com zoom de 200x



Fonte: Elaborado pelo autor

## Como funciona a análise histopatológica ?

Figura 6 - Células anotadas



Fonte: <https://roboflow.com>

## Como funciona a análise histopatológica ?

Fórmula 1 - Índice de proliferação

$$\text{Índice de proliferação} = \frac{\text{Quantidade de células em proliferação}}{\text{Quantidade de células totais}} * 100$$

## Problema

- ▶ Dependentes da disponibilidade dos patologistas
- ▶ Tempo demandado
- ▶ Subjetividade
- ▶ Sujeitos a variabilidade inter e intraobservador

# Introdução

## Justificativa

- ▶ Existência de um conjunto de características visuais típicas do OSA
- ▶ Evolução da patologia digital e digitalização de lâminas
- ▶ Embora trabalhos em OSA sejam limitados, pesquisas correlatas, com aplicações em câncer de pele (NAUTA et al., 2021), (BALAJI et al., 2023) e câncer de mama (JAGANATHAN et al., 2024), (BURRAI et al., 2023) a viabilidade da visão computacional aplicada

# Introdução

## Objetivo Geral

- ▶ Propor, validar e comparar duas rotinas computacionais para quantificar o índice de proliferação celular em OSA

## Objetivos específicos

- ▶ Criar uma base de dados anotada por especialistas
- ▶ Desenvolver e validar técnicas de processamento de imagens e aprendizado de máquina
- ▶ Comparar as duas abordagens

# Fundamentação Teórica

---

## Contagem de objetos


Figura 7 - Técnicas para contagem de objetos



Fonte: <https://www2.decom.ufop.br/imobilis/segmentacao-instancias/>

# Fundamentação Teórica - Máscaras Binárias

Figura 8 - Fluxograma Fundamentação Teórica



Fonte: Elaborado pelo autor

**Fundamentação Teórica**

---


**Processamento de imagens**

# Fundamentação Teórica - Processamento de imagens

## Representação de uma imagem

- ▶ No modelo RGB, a informação da cor está acoplada à informação da luminância
- ▶ Já o modelo HSV, desacopla a matiz (H - *Hue*) da saturação (Saturation - S), que indica a pureza da cor, e do valor (Value - V), que corresponde ao brilho (SZELISKI, 2022)

Figura 9 - Espaços de cor RGB e HSV



Fonte: <https://medium.com/neurosapiens/segmentation-and-classification-with-hsv-8f2406c62b39>

# Fundamentação Teórica - Processamento de imagens


## *Thresholding*

► A partir de um limiar  $T$ , particiona a imagem em *foreground* e *background*

► Fórmula 1 - *Thesholding* binário invertido

$$dst(x, y) = \begin{cases} 0 & \text{se } src(x, y) > T(x, y) \\ \text{Valor Máximo} & \text{se não} \end{cases}$$

Figura 10 - Exemplo *Thresholding*



Fonte: XING, Jiangwa; YANG, Pei; QINGGE, Letu. Automatic thresholding using a modified valley emphasis. IET Image processing, v. 14, n. 3, p. 536-544, 2020.


**Fundamentação Teórica**

---

**Aprendizado de máquina**

## Redes Neurais Convolucionais (CNN)

Figura 11 - Arquitetura CNN




Fonte: <https://www.sakurai.dev.br/cnn-mapreduce/>

# Fundamentação Teórica - Aprendizado de máquina

## U-Net

Figura 12 - Arquitetura U-Net



# Fundamentação Teórica

---

## Máscaras Binárias

# Fundamentação Teórica - Máscaras Binárias


## Análise de Componentes Conectados

► **Problema:** Pequenos rúidos

► **Solução:** Filtro de área

► Agrupa *pixels* adjacentes em objetos distintos (ROSENFELD; PFALTZ, 1966)

Figura 13 - Exemplo de *labelling*



Fonte: <https://gist.github.com/MarcWang/5f346375246e1cdb88dbe745b840cfaa>

# Fundamentação Teórica - Máscaras Binárias

## Operação Morfológica de Fechamento


► **Problema:** Falhas internas

► **Solução:** Filtro de preenchimento

Dilatação seguida por erosão,  
utilizando um elemento estruturante.

► (HARALICK; STERNBERG;  
ZHUANG, 1987)

Figura 14 - Exemplo de Operação de Fechamento



Fonte: Adaptado de <https://www.brunodorta.com.br/pdi/opera%C3%A7%C3%B5es-morfol%C3%B3gicas.html>

# Fundamentação Teórica - Máscaras Binárias


## Segmentação por Hierarquia e Contagem de objetos

- ▶ Algoritmo proposto por [Suzuki et al. \(1985\)](#)

- ▶ Opera sobre uma imagem binária para detectar pontos de início de contornos

- ▶ Capaz de determinar a relação de hierarquia e vizinhança entre os contornos detectados

Figura 15 - Exemplo de Segmentação Hierárquica



Fonte: Adaptado de <http://medium.com/analytics-vidhya/opencv-findcontours-detailed-guide-692ee19eeb18>

# Metodologia

---

## Construção da base de dados

- ▶ Parceria com veterinários da Faculdade de Medicina Veterinária e Zootecnia/UNESP, campus de Botucatu, São Paulo
- ▶ Responsáveis por duas etapas:
  1. Coleta e digitalização dos dados brutos
  2. Anotação das células

Figura 16 - Faculdade de Medicina Veterinária e Zootecnia




Fonte: <https://www.fmvz.unesp.br/#!/noticias/v/id::248/disciplina-gerenciamento-da-profissao-tocando-em-frente>

## Coleta e digitalização dos dados brutos

- ▶ Amostras foram resgatadas de arquivos físicos abrangendo o período de 2008 a 2025.
- ▶ Lâminas passaram por um rigoroso processo de preparação
- ▶ Digitalização das imagens com um scanner eletrônico em magnificação 200x


## Coleta e digitalização dos dados brutos

Figura 17 - Lâminas padrão “prata”



Fonte: Elaborado pelo autor


Figura 18 - Lâminas padrão “ouro”



Fonte: Elaborado pelo autor

## Anotação das células


Figura 5 - Lâmina com zoom de 200x



Fonte: Elaborado pelo autor

## Anotação das células

Figura 6 - Células anotadas



Fonte: <https://roboflow.com>

Fonte: Elaborado pelo autor


## Geração de máscaras binárias (ground truth)

► Download das labels no formato YOLOv8

► Script para “plotar” polígono na máscara

►  
0 0.08755551470588235 0.14295686274509803  
0.08064264705882354 0.14178692810457516  
0.07699908088235294 0.13357875816993464  
0.08006066176470587 0.11724281045751633  
0.0842704044117647 0.11111666666666667  
0.09192426470588234 0.11315882352941177  
0.09345514705882353 0.1288140522875817

Figura 19 - Máscara *ground truth* células em proliferação



Fonte: Elaborado pelo autor


## Geração de máscaras binárias (ground truth)

► Download das labels no formato YOLOv8

► Script para “plotar” polígono na máscara

►  
1 0.6982511029411764 0.2123169934640523  
0.6894889705882353 0.2097065359477124  
0.6892525735294118 0.1966872549019608  
0.6927976102941177 0.18492777777777777  
0.700124080882353 0.18492777777777777  
0.7057961397058824 0.18912777777777778  
0.7065051470588235 0.1962673202614379

Figura 20 - Máscara *ground truth* células saudáveis



Fonte: Elaborado pelo autor

## Composição da base de dados

Quadro 1 - Composição da base de dados

|                                 | Quantidade |
|---------------------------------|------------|
| Animais                         | 7          |
| Lâminas                         | 72         |
| Imagens rotuladas parcialmente  | 18         |
| Imagens rotuladas completamente | 1          |

Fonte: Elaborado pelo autor


# Metodologia

---

## Processamento de imagens

# Metodologia - Processamento de imagens

Figura 21 - Fluxograma Processamento de Imagens




Fonte: Elaborado pelo autor

# Metodologia - Processamento de imagens

## Conversão para HSV

- ▶ Script para análise de histogramas e valores individuais de pixel em HSV
- ▶  $H=129, S=15, V=60$  (mínimo) e  $H=190, S=90, V=170$  (máximo) para a cor marrom
- ▶  $H=120, S=55, V=115$  (mínimo) e  $H=130, S=180, V=180$  (máximo) para a cor azul

Figura 22 - Imagem original, canal H, S e V




Fonte: Elaborado pelo autor

# Metodologia - Processamento de imagens


## Isolamento das cores

Figura 23 - Células em proliferação isoladas



Fonte: Elaborado pelo autor

Figura 24 - Células saudáveis isoladas




Fonte: Elaborado pelo autor

# Metodologia - Processamento de imagens


## Filtro de área

Figura 25 - Células em proliferação filtradas



Fonte: Elaborado pelo autor

Figura 26 - Células saudáveis filtradas




Fonte: Elaborado pelo autor

# Metodologia - Processamento de imagens


## Filtro de preenchimento

Figura 27 - **Células em proliferação** preenchidas



Fonte: Elaborado pelo autor

Figura 28 - **Células saudáveis** preenchidas




Fonte: Elaborado pelo autor

# Metodologia - Processamento de imagens

## Segmentação hierárquica

- ▶ **296** células foram contadas pelos patologistas (*ground truth*)
- ▶ *Pipeline* de processamento de imagens encontrou **245**
- ▶ Erro absoluto de **51** células

Figura 29 - **Células em proliferação** segmentadas (**Pipeline**)




Fonte: Elaborado pelo autor

# Metodologia - Processamento de imagens

## Segmentação hierárquica

- ▶ **492** células foram contadas pelos patologistas (*ground truth*)
- ▶ *Pipeline* de processamento de imagens encontrou **596**
- ▶ Erro absoluto de **104** células

Figura 30 - **Células saudáveis** segmentadas (*Pipeline*)




Fonte: Elaborado pelo autor

# Metodologia - Processamento de imagens

## Segmentação hierárquica

- ▶ Índice de proliferação obtido pelos patologistas:  
**37,56%** (*ground truth*)
- ▶ Índice de proliferação obtido pela  
*Pipeline*: **29.13%**
- ▶ Erro absoluto de **8,43%**

Figura 31 - Células segmentadas (*Pipeline*)



Fonte: Elaborado pelo autor

## Métricas de desempenho

Fórmula 2 - Precisão

$$\text{Precisão} = \frac{TP}{TP + FP}$$

Fórmula 3 - *Recall*

$$\text{Recall} = \frac{TP}{TP + FN}$$


## Métricas células em proliferação

▶ 221 TP, 23 FP e 75 FN

▶ Precisão = 90,57%

▶ *Recall* = 74,66%

Figura 32 - Métricas células em proliferação (*Pipeline*)



Fonte: Elaborado pelo autor

# Metodologia - Processamento de imagens


## Métricas células saudáveis

▶ 374 TP, 222 FP e 118 FN

▶ Precisão = 62.75%

▶ *Recall* = 76,01%

Figura 33 - Métricas saudáveis (Pipeline)



Fonte: Elaborado pelo autor


**Metodologia**

---

**Aprendizado de Máquina**

# Metodologia - Aprendizado de Máquina


Figura 34 - Fluxograma Aprendizado de máquina



Fonte: Elaborado pelo autor


## *Data Augmentation*

Figura 35 - Imagem original




Fonte: Elaborado pelo autor

Figura 37 - *Flip* Horizontal




Fonte: Elaborado pelo autor

Figura 36 - *Flip* Vertical



Fonte: Elaborado pelo autor


Figura 38 - *Flip* Vertical e Horizontal



Fonte: Elaborado pelo autor

## *Data Augmentation*

Figura 39 - Máscara original



Fonte: Elaborado pelo autor

Figura 41 - *Flip* Horizontal




Fonte: Elaborado pelo autor

Figura 40 - *Flip* Vertical



Fonte: Elaborado pelo autor


Figura 42 - *Flip* Vertical e Horizontal



Fonte: Elaborado pelo autor

# Metodologia - Aprendizado de Máquina

## *Split* dos dados



→ 12 imagens (70%) → *Data Augmentation* → 48 imagens




→ 3 imagens (15%)



→ 3 imagens (15%)

## Predição pura do modelo treinado


Figura 43 - Predição pura



Fonte: Elaborado pelo autor

## Predição filtrada e preenchida

Figura 44 - Predição limpa




Fonte: Elaborado pelo autor

## Segmentação hierárquica

- ▶ **296** células foram contadas pelos patologistas (*ground truth*)
- ▶ Modelo treinado encontrou **255**
- ▶ Erro absoluto de **41** células

Figura 45 - **Células em proliferação** segmentadas (U-Net)



Fonte: Elaborado pelo autor


## Métricas células em proliferação

▶ 232 TP, 25 FP e 64 FN

▶ Precisão = 90%

▶ *Recall* = 78,3%

Figura 46 - Métricas células em proliferação (U-Net)



Fonte: Elaborado pelo autor

# Resultados

---

## Processamento de imagens

# Resultados - Processamento de Imagens

## Análise estatística dos resultados da *Pipeline*

- ▶ Todas as **18 imagens** da base de dados foram submetidas à contagem de células através da *Pipeline*

Quadro 2 - Resultados *Pipeline*


|               | Precisão | <i>Recall</i> |
|---------------|----------|---------------|
| Mediana       | 92,3     | 68.2          |
| Desvio padrão | 9,3      | 16.02         |

Fonte: Elaborado pelo autor

# Resultados - Processamento de Imagens

## Distribuição de Densidades dos valores de Precisão


Figura 47 - Precisão da *Pipeline*



Fonte: Elaborado pelo autor

## Distribuição de Densidades dos valores de *Recall*

Figura 48 - *Recall* da Pipeline



Fonte: Elaborado pelo autor

# Resultados

---


## Aprendizado de Máquina

# Resultados - Aprendizado de Máquina

## Treinamento

- ▶ Estabilização na época 20
- ▶ Early Stopping na Época 50 (*patience 10*)
- ▶ Sem sinal de *overfitting*

Figura 49 - Perda de Treinamento vs Perda de Validação



Fonte: Elaborado pelo autor

# Resultados - Aprendizado de Máquina

## Análise estatística dos resultados do modelo

- ▶ Todas as **3 imagens** do conjunto de teste foram submetidas à infêrencia do modelo treinado

Quadro 3 - Resultados U-Net

|               | Precisão | <i>Recall</i> |
|---------------|----------|---------------|
| Mediana       | 94,2     | 75,9          |
| Desvio padrão | 5,93     | 3,39          |

Fonte: Elaborado pelo autor

**Resultados**

---

**Comparativo**

## Resumo das métricas para a Figura 5

Quadro 4 - Resumo das métricas para a Figura 5


|          | Contagem | TP  | FP | FN | Precisão | <i>Recall</i> |
|----------|----------|-----|----|----|----------|---------------|
| Pipeline | 257      | 221 | 23 | 75 | 90,57%   | 74,66%        |
| U-Net    | 245      | 232 | 25 | 64 | 90%      | 78,3%         |

Fonte: Elaborado pelo autor

# Resultados - Comparativo


## Análise Qualitativa

Figura 29 - **Células em proliferação** segmentadas (*Pipeline*)



Fonte: Elaborado pelo autor

Figura 45 - **Células em proliferação** segmentadas (U-Net)




Fonte: Elaborado pelo autor

# Resultados - Comparativo


## Processamento de imagens

Figura 29 - Células em proliferação segmentadas (*Pipeline*)



Fonte: Elaborado pelo autor

Figura 31 - Métricas células em proliferação




Fonte: Elaborado pelo autor

# Resultados - Comparativo


## Aprendizado de máquina

Figura 45 - **Células em proliferação** segmentadas (U-Net)



Fonte: Elaborado pelo autor

Figura 46 - Métricas **células em proliferação** (U-Net)



Fonte: Elaborado pelo autor

# Conclusão

---

# Conclusão

## Principais pontos

- ▶ O objetivo do trabalho foi parcialmente alcançado
- ▶ A qualidade da preparação das lâminas é crítica para o processo
- ▶ Foram observadas boas métricas para as células em proliferação em ambas as abordagens

## Trabalhos futuros

- ▶ Expansão da base de dados
- ▶ Abordagens mais robustas para a separação de cores
- ▶ Aprimoramento das rotinas com a inclusão de técnicas de separação de aglomerados

Perguntas ?

Obrigado pela atenção!



RECOGNA  
LABORATORY