


AVALIAÇÃO DA VIABILIDADE DE SPIKING NEURAL NETWORKS EM DISPOSITIVOS MÓVEIS PARA DIAGNÓSTICO DE CÂNCER DE PELE

Aluno: Fábio Halben Guerra Leal
Orientador: Leandro Aparecido Passos Júnior

Introdução e Justificativa

- IA
- Redes Neurais Artificiais
- Problema energético
- SNNs
- Desvantagens
- Contexto médico
- Câncer de pele



The slide features a dark blue background. In the top-left corner, there is a decorative geometric shape composed of several triangles in shades of purple, pink, and blue. A similar, though less complex, decorative shape is located in the bottom-right corner. The main title 'Objetivo' is centered in a large, white, serif font.

Objetivo

Analisar a viabilidade de SNNs em dispositivos móveis para o diagnóstico de câncer de pele, comparando-as com modelos tradicionais de ANNs.

Para esse fim, serão realizadas comparações rigorosas entre um modelo SNN e outro ANN, ambos desenvolvidos especificamente para esta pesquisa.

Objetivos específicos

1

Pesquisar e comparar diferentes métodos de treinamento para cada tipo de rede neural (ANN e SNN), visando alcançar o melhor resultado possível. Se necessário, criar variações de uma ou ambas as redes para aprimorar a análise final.

2

Desenvolver e treinar tanto a ANN quanto a SNN.

3

Pesquisar e utilizar o melhor método de medir gasto energético possível.


Redes Neurais Artificiais

Convolucionais

- Neurônio Artificial
- Estrutura ANN
- Entrada Matricial
- Camada Convolutacional
- Camada de Pooling (max e average)




Neurônio Biológico



Fonte: (Kashu Yamazaki; Viet-Khoa Vo-Ho;
Darshan Bulsara; Ngan Le , 2022)

Spiking Neuron




Fonte: (Kashu Yamazaki; Viet-Khoa Vo-Ho;
Darshan Bulsara; Ngan Le , 2022)

Leaky Integrate and Fire

- Potencial da membrana
- Time steps
- Limiar
- “Leak”

- $$U[t] = \underbrace{\beta U[t-1]}_{\text{decaimento}} + \underbrace{W X[t]}_{\text{entrada}} - \underbrace{S_{\text{out}}[t-1]\theta}_{\text{reset}}.$$


- $$S_{\text{out}}[t] = \begin{cases} 1, & \text{if } U[t] > \theta \\ 0, & \text{caso contrário.} \end{cases}$$




Fonte: (ESHRAGHIAN et al., 2023)

Encoding em SNNs

- Na biologia
- MNIST
- $X \in \mathbb{R}^{m \times n}, X_{ij} \in [0, 1]$.
- O que é Encoding
- Abordagem “vídeo estático”




Fonte: https://raw.githubusercontent.com/jeshraghian/snntorch/refs/heads/master/docs/_static/img/examples/tutorial1/1_2_1_static.png




Encoding em SNNs

- Rate Coding
- Bernoulli
- Latency/Temporal Coding



Fonte: https://raw.githubusercontent.com/jeshraghian/snntorch/refs/heads/master/docs/_static/img/examples/tutorial1/1_2_1_static.png

Encoding em SNNs



Fonte: https://raw.githubusercontent.com/jeshraghian/snntorch/refs/heads/master/docs/_static/img/examples/tutorial1/1_2_3_spikeconv.png

STDP Learning


- Fenômeno original
- Versão Algorítmica

- $\Delta t = t_{\text{post}} - t_{\text{pre}}$

- $$STDP(\Delta t) = \Delta w = \begin{cases} A_+ \exp^*\left(\frac{\Delta t}{\tau_+}\right), & se \sim \Delta t \geq 2, \\ A_- \exp^*\left(\frac{\Delta t}{\tau_-}\right), & se \sim \Delta t \leq -2, \\ 0, & se \sim -2 < \Delta t < 2 = 0, \end{cases}$$

- $$w_{new} = \begin{cases} w_{old} + \sigma \Delta w (w_{max} - w_{old}), & se \Delta w > 0 \\ w_{new} + \sigma \Delta w (w_{old} - w_{min}), & se \Delta w \leq 0 \end{cases}$$


- Limitações



Fonte: (IAKYMCHUK et al., 2015)

Backpropagation em SNNs

- O que é backpropagation
- Não diferenciabilidade de spikes
- Gradiente dS/dU é 0 e no limiar ele tende ao infinito
- Backpropagation using spike times
- Calcular derivadas dos instantes de disparo em relação aos pesos
- Sensível a ruídos e variações temporais



Fonte: (ESHRAGHIAN et al., 2023)

Backpropagation em SNNs

- Variação de Backpropagation Through Time
- Gradiente da perda total em relação aos parâmetros treináveis dL/dW permite gradient descent para treino

- Influência imediata e influência interior


- Gradiente global:

$$\frac{\partial \mathcal{L}}{\partial W} = \sum_t \frac{\partial \mathcal{L}[t]}{\partial W} = \sum_t \sum_{s \leq t} \frac{\partial \mathcal{L}[t]}{\partial W[s]} \frac{\partial W[s]}{\partial W}.$$

- Dead neuron problem permanece

- Surrogate gradient

- Gradiente é substituído pela derivada de uma função contínua $dS/dU \leq d\tilde{S}/dU$




Fonte: (ESHRAGHIAN et al., 2023)

Conversão ANN-SNN

- Função de ativação de cada neurônio é mapeada para um coding (tipicamente rate)
- Ótimos resultados em datasets de imagens estáticas
- Desvantagens
- Métodos Constrain-Then-Train

Dataset


- Conjunto de imagens de diferentes datasets da ISIC, disponibilizado no Kaggle
- O conjunto de treino contém 5.000 imagens benignas e 4.605 imagens malignas
- O conjunto de teste contém 500 imagens benignas e 500 imagens malignas
- Todas as imagens do conjunto de dados têm resolução de 300×300 pixels



Pré-Processamento e Métricas


- Imagens em todos os modelos foram redimensionalizadas para 224x224 e transformadas para escala cinza
- Testes e experimentos foram realizadas no Kaggle com uma GPU Nvidia P100
- Zeus
- Acurácia, Precisão, Recall, F1-Score e F1-Macro
- Matriz de confusão

Modelo da CNN



Utilizou-se um batch de 128 elementos, o otimizador Adam com taxa de aprendizado de 1×10^{-4} e decaimento de peso de 1×10^{-5} . A função de perda adotada foi a Cross-Entropy Loss. O conjunto de treinamento foi dividido em treino e validação nas proporções de 70% e 30% respectivamente


Modelo da SNN




Utilizou-se um batch de 128 elementos, 10 time steps, o otimizador Adam com taxa de aprendizado de 1×10^{-4} . A função de perda adotada foi a Cross-Entropy Loss. O conjunto de treinamento foi dividido em treino e validação nas proporções de 70% e 30% respectivamente. As camadas LIF foram configuradas com $\beta = 0.8$.

Resultados da CNN

Acurácia: treino vs. validação





Loss: treino vs. validação



- 20 épocas de treinamento
- Melhor modelo selecionado apartir do f1-Macro
- Análise dos gráficos


Resultados da CNN




- 20 épocas de treinamento
- Melhor modelo selecionado a partir do f1-Macro
- Análise dos gráficos

Resultados da SNN

Acurácia: treino vs. validação





Loss: treino vs. validação



- 20 épocas de treinamento
- Melhor modelo selecionado a partir do f1-Macro
- Análise dos gráficos

Resultados da SNN



- 20 épocas de treinamento
- Melhor modelo selecionado a partir do f1-Macro
- Análise dos gráficos

Análise dos Resultados

	Accuracy	Precision	Recall	F1-Score	Energy per Epoch	Energy Consumption on Training	Energy Consumption on Testing
CNN	90.6%	0.918	0.896	0.9071	1 260 J	25 300 J	111 J
SNN	89.3%	0.960	0.8466	0.8997	–	–	–

- Análise da tabela
- Conversão e constrain-then-train
- Gasto da SNN e inferência (LEMAIRE et al., 2022)
- Trade off
- Viabilidade
- Hardware neuromórfico
- Complexidade
- Possíveis utilidades
- Conclusão

Obrigado!