
Investigação de Estratégias de Aprendizado Contínuo para Detecção de Objetos de Tráfego Urbano

Gabriel Cardoso Franco

Orientador: André Luis Debiasso Rossi

14 de novembro de 2025

Universidade Estadual Paulista “Júlio de Mesquita Filho” (UNESP)
Faculdade de Ciências (FC) / Departamento de Computação (DCo)
Bauru, SP - Brasil

Sumário da Apresentação

1. Introdução
2. Definição do Problema
3. Fundamentação Teórica
 - 3.1 Aprendizado Profundo em Visão Computacional
 - 3.2 Aprendizado Contínuo
4. Método Proposto
5. Experimentos
6. Conclusão

Introdução

- A Detecção de Objetos é um área da Visão Computacional capaz de identificar e classificar objetos. Atualmente, a maior parte dos algoritmos utilizados são Redes Neurais Convulocionais (CNNs).
- Esses algoritmos são treinados em Cenários Fechados, o qual um *Dataset* é utilizado para treinar esse modelo.

Definição do Problema

Definição do Problema

- Um modelo baseado em CNN caso seja exposto a um Cenário Aberto em que novas tarefas, classes ou domínios podem ser introduzidos sofrem de Esquecimento Catastrófico.
- No tráfego urbano, mesmo que não seja comum objetos considerados novidades, com o tempo podem surgir variação entre os veículos novos e os utilizados para treinamento desses algoritmos, afetando o desempenho.
- O aprendizado contínuo é uma técnica capaz de ensinar o modelo sem que ele perca o conhecimento previamente aprendido.

Fundamentação Teórica

- Classificação de Imagens: O modelo é treinado com um conjunto de dados rotulados no qual estão associados a uma classe disponível. A saída do algoritmo é a classe de uma ou múltiplas imagens.
- Segmentação: Possui como objetivo atribuir para cada pixel da imagem um rótulo das classes disponíveis. A saída é um mapa de segmentação em que cada pixel está associado a uma classe.

Visão Computacional

- Detecção de Objetos: É uma tarefa que localiza as instâncias em imagens e classificá-lo. A saída é uma caixa delimitadora e sua classe.



Figura 1: Imagem retirada do *Dataset Automotive*

Com o avanço das CNNs e com a criação do *Imagenet*, o uso dessa arquitetura se tornou o padrão para problemas de detecção de objetos. Posteriormente, foram criados os algoritmos do tipo *Region-based Convolutional Neural Network* (R-CNN), modelos de duas etapas para detecção de objetos

Aprendizado Profundo em Visão Computacional

O RCNN criou a categoria de CNNs de duas etapas para detecção de objetos sendo dividido na seguinte ordem:

- *Selective Search* para extração de características
- Máquinas de Vetores de Suporte para classificação das imagens




Figura 2: Representação da arquitetura RCNN

Sucessor do RCNN, o FastRCNN ganha velocidade com relação ao RCNN ao processar a imagem inteira em uma só vez com uma CNN e o *Roi Pooling* é utilizado para transformar as imagens em tamanhos fixos




Figura 3: Representação da arquitetura FastRCNN

As métricas mais utilizadas em detecção de objetos são o *Intersection over Union* (IOU), *Average precision* (AP) e *Average recall* (AR).


$$\text{IOU} = \frac{\text{área de intersecção}}{\text{área de união}} = \frac{\text{área de intersecção}}{\text{área de união}}$$


Figura 4: Representação do IOU

As métricas mais utilizadas em detecção de objetos são o *Intersection over Union* (IOU), *Average precision* (AP) e *Average recall* (AR).

$$AP = \frac{TP}{TP + FP} = \frac{TP}{\text{todas as detecções}}, \quad (1)$$

$$AR = \frac{TP}{TP + NP} = \frac{TP}{\text{todas as } ground\ truths}, \quad (2)$$

O aprendizado contínuo pode ser definido como a capacidade de um sistema incorporar novas tarefas, classes ou domínios aprendendo novos conhecimentos de forma incremental. Para isso, foram categorizados três maneiras de adquirir novos dados:

- Novas Instâncias
- Novas Classes
- Novas Instâncias e Classes

Aprendizado Contínuo

Um cenário de aprendizado contínuo representa o que um modelo aprenderá de novo, podendo ser categorizado com base em dois critérios: se a tarefa possui identificação e se precisar ser inferida, resultando em três categorias:

- Aprendizado Incremental de Tarefas
- Aprendizado Incremental de Domínio
- Aprendizado Incremental de Classes




Figura 5: Representação do *Dataset* MNIST

Os métodos de aprendizado contínuo representam como cada ciclo de treino será feito para mitigar as perdas do esquecimento catastrófico. Esses métodos possuem três categorias: *Replay*, Regulização e Isoamento de Parâmetros.

Métodos de Replay buscam diminuir o esquecimento catastrófico reprisando classes anteriores. Essas imagens podem ser do próprio *dataset* ou serem gerados artificialmente. Existem dois tipos de *Replay*:

- *Rehearsal*: iCaRL, *Experience Replay*, *Continual Prototype Evolution*
- *Pseudo-Rehearsal*: *Pseudo-Recursal*, *Deep Generative Replay*

Métodos de Regularização propõe diminuir o efeito catastrófico sem usar muita memória, diferente dos métodos de *Replay*. Esse método faz com que os parâmetros das CNNs aprendam novas informações sem perder os valores importantes para as tarefas anteriores. Esses métodos podem ser divididos em 2 categorias:

- Destilação de Conhecimento: *Encoder Based Lifelong Learning* e *Learn without Forgetting*
- Distribuição a priori: *Elastic Weight Consolidation (EWC)*, *Synaptic Intelligence*, *Incremental Moment Matching*

Métodos de Aprendizado Contínuo

A ideia principal do EWC é definir quais pesos são realmente importantes para a próxima tarefa sem perder o conhecimento previamente aprendido nas tarefas anteriores utilizando d




Figura 6: Representação do EWC

$$\mathcal{L}_{\text{EWC}}(\theta) = \mathcal{L}_B(\theta) + \frac{\lambda}{2} \sum_i F_i (\theta_i - \theta_{A,i}^*)^2. \quad (3)$$

- $L(\theta)$: função de perda total usada no treinamento com EWC.
- $L_B(\theta)$: função de perda da tarefa atual B .
- θ : vetor de parâmetros atuais da rede neural.
- θ_i : valor do parâmetro i após o treinamento na tarefa anterior.
- F_i : importância do parâmetro i para a tarefa anterior, estimada pela Informação de Fisher.
- λ : hiperparâmetro que controla o peso da regularização.
- i : índice dos parâmetros da rede, usado na soma $\sum_i$.

Métodos de isolamento de parâmetros os modelo dedica parâmetros distintos a cada tarefa para evitar esquecimento. A divisão desses métodos podem ser feito com base em como a arquitetura do modelo cresce:

- Arquitetura Estáticas: *PackNet* e *Hard Attention to the Task*
- Arquitetura Dinâmicas: *Expert Gate*

Método Proposto

Método Proposto

Para o treinamento das CNNs foi utilizado dois *datasets*, o *Automotive* e o *Rock, Papers, Scissors*.



Figura 7: Exemplo do *Dataset Automotive*

Método Proposto

Para o treinamento das CNNs foi utilizado dois *datasets*, o *Automotive* e o *Rock, Papers, Scissors*.



Figura 8: Exemplo do *Dataset Rock, Papers, Scissors*

Método Proposto

Como orquestrador, foi utilizado a biblioteca *Avalanche*, capaz de organizar as experiências e oferecer *plugins* utilizados nos experimentos.




Figura 9: Representação do Avalanche

Método Proposto

Como métodos, foi utilizando o EWC junto com o Replay. Esses métodos foram inspirados na competição *CLVision2022* em que foi instruídos aos participantes uma orquestração similar




Figura 10: Pipeline do treinamento

Experimentos

Primeiramente foi aplicado FastRCNN nos *Datasets Automotive* e *Rock, Papers, Scissors* sem nenhum método de aprendizado contínuo.

Tabela 1: Avaliação no *Dataset Automotive*.

Métrica	IoU	Resultado
<i>Average Precision</i> (AP)	0.50	0.234
<i>Average Precision</i> (AP)	0.75	0.107
<i>mean Average Precision</i> (mAP)	0.50:0.95	0.116
<i>mean Average Recall</i> (mAR)	0.50:0.95	0.151

Primeiramente foi aplicado FastRCNN nos *Datasets Automotive e Rock, Papers, Scissors* sem nenhum método de aprendizado contínuo.

Tabela 2: Avaliação no *Dataset Rock, Paper and Scissor*.

Métrica	IoU	Resultado
<i>Average Precision (AP)</i>	0.50	0.665
<i>Average Precision (AP)</i>	0.75	0.344
<i>mean Average Precision (mAP)</i>	0.50:0.95	0.315
<i>mean Average Recall (mAR)</i>	0.50:0.95	0.437

Após esses experimentos iniciais, foi treinado estes modelos com técnicas de aprendizado contínuo, entretanto, os resultados foram insatisfatórios o qual todos os experimentos nulos de precisão, indicando esquecimento catastrófico. Algumas hipóteses foram levantadas para justificar isso:

- Erros na implementação do EWC, o qual foi programado manualmente.
- Erro na expansão de classes do modelo.
- Falta de filtro no treinamento dos modelos.

Conclusão

Os resultados da pesquisa não foram satisfatórios para indicar uma melhora no esquecimento catastrófico. Entre os obstáculos no aprendizado contínuo podem ser citados a falta de um estado da arte definido, poucas bibliotecas dedicadas no assunto e uma literatura mais fraca em relação aos problemas de classificação.

Para trabalhos futuros, podem ser criado *benchmarks* dedicados a detecção de objetos e aprendizado contínuo e aplicações de aprendizado contínuo em outras áreas de estudo.

Perguntas?

Obrigado pela atenção!