

UTILIZAÇÃO DE ALGORITMOS BIOLOGICAMENTE PLAUSÍVEIS NO AUXÍLIO DE DIAGNÓSTICO DE INFECÇÕES FÚNGICAS E NEOPLASIAS PULMONARES EM EXAMES DE RAIO-X

Giuliano Gonzales

Prof. Orientador: Dr. Leandro Aparecido Passos Junior

Tópicos

1. Introdução
2. Fundamentação Teórica
3. Métodos e Modelos
4. Resultados
5. Conclusão e Trabalhos Futuros
6. Referências

Introdução

Contexto

Aprendizado de máquina está revolucionando o diagnóstico por imagem médica. Redes neurais convolucionais alcançando altas precisões em análises.

Desafio Energético

Setor de IA aponta para um consumo de 85-143 TWh anualmente (de Vries, 2023). Modelos profundos demandam alto custo computacional e energético.

Solução: SNNs

Redes Neurais de Picos consomem 14 vezes menos energia que DNNs em GPUs e 400 vezes menos em CPUs (GATTI; BARBATO; ZANDRON, 2025).

Introdução

Justificativa

- Escassez de pesquisas específicas sobre SNNs para neoplasias e infecções fúngicas pulmonares.
- Necessidade de equilibrar eficiência energética e acurácia diagnóstica.

Objetivo Geral

Aplicar e comparar SNNs com diferentes redes neurais para auxiliar diagnóstico de doenças pulmonares em raio-X, contribuindo para modelos que emulem o cérebro humano.

01

Preparar conjunto NIH Chest X-rays

02

Treinar modelos SNN

03

Avaliar e comparar com outros modelos de redes neurais

Fundamentação Teórica

Aprendizado de Máquina

Subcampo de IA focado em sistemas de reconhecimento de padrões em dados (rotulados ou não) sem instruções explícitas.

Redes Neurais de Picos

Operam com eventos binários (spikes). Simulam comunicação neuronal biológica com maior eficiência energética.




Redes Neurais Artificiais

Modelos inspirados em neurônios biológicos. Camadas sequenciais com pesos ajustáveis conforme o treinamento.

Redes Convolucionais

Trabalhar com dados estruturados através de camadas convolucionais com filtros detectam padrões locais (bordas, texturas). Eficazes em reconhecimento visual por imagem.



Estrutura das SNNs

As SNNs incorporam tempo como dimensão fundamental. Neurônios acumulam potencial e disparam quando excedem limiar, reiniciando após.

Codificação de Dados

- Taxa: intensidade gera mais picos
- Latência: intensidade influencia o tempo do primeiro pico
- Modulação delta: picos apenas em mudanças significativas

Treinamento

Utiliza-se gradientes substitutos para conseguir realizar a retropropagação no tempo (BPTT) durante o aprendizado e manter a plausibilidade biológica do modelo sem comprometer o processo de otimização, pois a função degrau é não diferenciável.

Métodos: Configuração e Dados



Hardware

AMD Ryzen 5 5500U, 8GB RAM, Windows 11. Bibliotecas: PyTorch, snntorch, torchvision, scikit-learn, Carbontracker.




Dataset

NIH Chest X-rays: 5 mil imagens (2GB) com diversas doenças. Classes utilizadas: Normal , Infecção , Neoplasia. Reformulado para binário: Normal e Infecção.




Hiperparâmetros

Taxa aprendizagem: 5×10^{-4} , batch size: 32, otimizador Adam, CrossEntropyLoss (com e sem pesos de classe).




Métodos: Dataset - NIH Chest X-rays (3 classes)


Total



Treino




Teste




Métodos: Dataset - NIH Chest X-rays (2 classes)


Total



Treino



Teste



Função de Perca (Loss)

Para conseguir melhores resultados com o desbalanceamento do dataset, foi realizado treinos com diferentes função de perca

Frequência Relativa

```
# Total samples
total = 402 + 208 + 402

# Frequência relativa inversa
w0 = total / (3 * 402)
w1 = total / (3 * 208)
w2 = total / (3 * 402)

# Tensor com pesos
weights = torch.tensor([w0, w1, w2], dtype=torch.float).to(device)

# Loss ponderado
loss = nn.CrossEntropyLoss(weight=weights)
```

CrossEntropyLoss (e Balanceada)

```
# Class-Balanced Loss
beta = 0.95
class_counts = [402, 101]
effective_num = [(1 - beta) / (1 - beta ** count) for count in class_counts]
weights = torch.tensor(effective_num, dtype=torch.float).to(device)
loss = nn.CrossEntropyLoss(weight=weights)
```

Focal Loss

```
class FocalLoss(nn.Module):
    def __init__(self, alpha=None, gamma=2.0, reduction='mean'):
        super(FocalLoss, self).__init__()
        self.alpha = alpha
        self.gamma = gamma
        self.reduction = reduction


    def forward(self, inputs, targets):
        ce_loss = F.cross_entropy(inputs, targets, reduction='none', weight=self.alpha)
        pt = torch.exp(-ce_loss)
        focal_loss = ((1 - pt) ** self.gamma) * ce_loss

        if self.reduction == 'mean':
            return focal_loss.mean()
        elif self.reduction == 'sum':
            return focal_loss.sum()
        else:
            return focal_loss

loss = FocalLoss(alpha=weights, gamma=2.0)
```

Foco nos exemplos difíceis de classificar


Modelos Desenvolvidos



Primeiros Modelos

SNN: 3 camadas totalmente conectadas.

CNN: 4 camadas com 1 convolucional, 1 camada oculta



Modelos Finais

LeNet: 8 camadas com 2 convoluções, 2 pooling e 2 camadas ocultas.

MLP: 3 camadas totalmente conectadas

Resultados: Desempenho de Classificação

Avaliação em conjunto com 3 classes (Normal, Infecção e Neoplasia) com métricas: acurácia, precisão, recall e F1-score.

Modelo	Função Loss	Épocas	Acurácia	F1-Score	Precisão	Recall
SNN	CrossEntropyLoss	4	79,79%	27%	33%	30%
SNN	CrossEntropyLoss balanceada	4	71,26%	33%	32%	35%
SNN	Focal Loss	4	79,92%	30%	27%	33%
ANN	Frequência relativa	4	12,60%	6%	6%	34%
ANN	CrossEntropyLoss balanceada	4	37,53%	27%	31%	27%
ANN	CrossEntropyLoss balanceada	8	78,22%	33%	34%	35%
ANN	CrossEntropyLoss balanceada	32	15,09%	15%	39%	41%
ANN	CrossEntropyLoss balanceada	50	67,19%	38%	39%	39%
ANN	CrossEntropyLoss	8	41,86%	30%	36%	39%
ANN	CrossEntropyLoss	16	47,77%	34%	38%	41%
ANN	CrossEntropyLoss	32	58,01%	34%	37%	38%
ANN	Focal Loss	50	62,47%	39%	39%	41%
DenseNet	Focal Loss	4	39,63%	30%	36%	38%
DenseNet	CrossEntropyLoss balanceada	4	47,77%	35%	38%	38%
DenseNet	CrossEntropyLoss balanceada	16	68,91%	38%	37%	39%
DenseNet	CrossEntropyLoss balanceada	32	68,11%	40%	41%	41%
DenseNet	CrossEntropyLoss	32	57,09%	38%	38%	41%


Fonte: Elaborada pelo Autor.

SNN alcançou maior acurácia (79,92%), porém com F1-score baixo (30%). Sendo a DenseNet com maior F1-score (40%)


Resultados: Matriz de Confusão

Avaliação em conjunto com 3 classes (Normal, Infecção e Neoplasia) com métricas: acurácia e F1-score


SNN - 79,95% - 30%



DenseNet - 68,11% - 40%



ANN - 62,47% - 39%



SNN tem mais acurácia, porém classificando apenas na classe 0 (normal), outros modelos já tiveram melhor desempenho

Resultados: Desempenho de Classificação

Avaliação em conjunto binário (Normal vs. Infecção) com métricas: acurácia, precisão, recall e F1-score.

Modelo	Função Loss	Épocas	Acurácia	F1-Score	Precisão	Recall
SNN	CrossEntropyLoss balanceada	32	67,46%	53%	54%	57%
SNN	CrossEntropyLoss balanceada	30	71,83%	55%	55%	58%
SNN	CrossEntropyLoss balanceada	30	66,62%	55%	57%	62%
SNN	CrossEntropyLoss balanceada	30	70,85%	55%	55%	60%
SNN	CrossEntropyLoss balanceada	30	75,21%	55%	55%	56%
SNN	CrossEntropyLoss balanceada	30	71,41%	56%	56%	60%
ANN	CrossEntropyLoss balanceada	32	72,68%	54%	54%	55%
ANN	CrossEntropyLoss balanceada	50	75,77%	58%	58%	60%
ANN	CrossEntropyLoss balanceada	100	75,49%	57%	57%	59%
ANN	CrossEntropyLoss balanceada	30	74,37%	58%	58%	61%
ANN	CrossEntropyLoss balanceada	30	70,42%	56%	56%	60%
DenseNet	CrossEntropyLoss (sem peso)	32	67,75%	56%	57%	63%
DenseNet	CrossEntropyLoss balanceada	32	79,01%	54%	54%	54%
DenseNet	CrossEntropyLoss balanceada	30	79,44%	58%	58%	58%
DenseNet	CrossEntropyLoss balanceada	30	72,25%	56%	56%	59%
CSNN	CrossEntropyLoss balanceada	25	58,03%	50%	55%	59%
CSNN	CrossEntropyLoss balanceada	23	77,61%	58%	57%	58%
CSNN	CrossEntropyLoss balanceada	30	79,89%	60%	59%	60%
CNN	CrossEntropyLoss balanceada	27	71,97%	58%	58%	63%


Fonte: Elaborada pelo Autor.

CSNN alcançou maior acurácia (79,89%) e F1-score (60%). Seguido da DenseNet com acurácia 79,44% e F1-score 58%


Resultados: Matriz de Confusão

Avaliação em conjunto binário (Normal vs. Infecção) com métricas: acurácia e F1-score


CSNN – 79,89% – 60%



DenseNet – 79,44% – 58%



CNN – 71,97% – 58%



SNN e DenseNet muito próximas e CNN com mais predições para doença

Resultados: Eficiência Energética



91%

Esparsidade SNN

Apenas 10% dos neurônios ativos em determinadas camadas.



16%

Atividade neural SNN

Queda de 16% na média de atividade neural da rede completa

Modelo	Média global	Esparsidade global	Primeira Camada		Última Camada	
			Média	Esparsidade	Média	Esparsidade
CNN	105,08	32,10%	6,00	0,00%	1,16	41,80%
CSNN	151,86	25,10%	5,69	5,10%	1,12	44,00%
<i>DenseNet</i>	10080,20	1,80%	61,20	4,40%	0,67	66,70%
ANN	108,68	81,00%	108,14	89,20%	0,54	72,90%
SNN	90,83	69,00%	89,77	91,00%	1,06	46,90%

Fonte: Elaborada pelo Autor.

SNNs demonstram eficiência energética superior em atividade neural, podendo-se ver o contraste com a DenseNet.

Resultados: Eficiência Energética

Resultados da medição de consumo energético em medidas de kWh, kgCO2eq e tempo de execução

Modelo	Função de Loss	Épocas	Treino		Inferência	
			Carbontracker (kWh)	Carbontracker (kgCO ₂ eq)	Carbontracker (kWh)	Tempo
ANN	CrossEntropyLoss balanceada	32	-	-	0.000029630871	0:00:02
ANN	CrossEntropyLoss balanceada	50	-	-	0.000028386935	0:00:02
ANN	CrossEntropyLoss balanceada	30	0.009917	0.000975283247380658	0.000029640869	0:00:02
ANN	CrossEntropyLoss balanceada	30	0.004550	0.000447479734372000	0.000029522889	0:00:02
CNN	CrossEntropyLoss balanceada	27	0.001766	0.000173643170005000	0.000039843019	0:01:00
DenseNet	CrossEntropyLoss balanceada	32	0.127062	0.012496264685296000	0.000948296974	0:01:01
DenseNet	CrossEntropyLoss balanceada	30	0.069903	0.006874788611399000	0.000964612530	0:01:02
CSNN	CrossEntropyLoss balanceada	25	0.078248	0.007695659847097000	0.000485522161	0:00:31
CSNN	CrossEntropyLoss balanceada	23	0.053412	0.005252987093970000	-	-
SNN	CrossEntropyLoss balanceada	30	0.068335	0.006720653408530000	0.000485522161	0:00:31
SNN	CrossEntropyLoss balanceada	30	0.184524	0.018147526425711000	0.000166853423	0:00:12
SNN	CrossEntropyLoss balanceada	30	0.121496	0.011949886484949000	0.000180512233	0:00:12
SNN	CrossEntropyLoss balanceada	30	0.032319	0.003178530941706000	-	-
SNN	CrossEntropyLoss balanceada	30	-	-	0.000189702733	0:00:12

Fonte: Elaborada pelo Autor.

Analizando na Inferência temos que ANN foram superiores, seguindo das SNNs e as CSNN foram superiores que a CNN em tempo de execução. As DenseNet reforçaram o alto consumo energético e de tempo.

Conclusão e Perspectivas Futuras

Principais apontamentos

1. As SNNs oferecem vantagens significativas em termos de eficiência energética, ainda que demandem avanços para melhorar as métricas F1-score e recall, que tiveram melhor desempenho no modelo convolucional (CSNN);
2. As ANNs e CNNs constituem uma alternativa viável quando associadas a técnicas de balanceamento de classes, mas apresentam custo energético mais elevado;
3. A DenseNet, apesar de robusto em desempenho, é o modelo com maior complexidade e consumo energético, o que pode limitar sua aplicação em cenários restritos em recursos computacionais.

Conclusão e Perspectivas Futuras

Impacto Prático

Algoritmos biologicamente plausíveis representam alternativa promissora e viável em ambientes com recursos limitados, conciliando acurácia diagnóstica com sustentabilidade energética em aplicações médicas.

Trabalhos Futuros

Explorar codificação temporal, novos modelos de neurônios pulsados, data augmentation e implementação em sistemas embarcados para maximizar eficiência.



Obrigado

Dúvidas?

Referências

de Vries, A. The growing energy footprint of artificial intelligence. Joule, v. 7, n. 10, p. 2191–2194, 2023. ISSN 2542–4351. Acesso em 26 de Março de 2025. Disponível em: <https://www.sciencedirect.com/science/article/pii/S2542435123003653>.

GARAIN, A.; BASU, A.; GIAMPAOLO, F.; VELASQUEZ, J. D.; SARKAR, R. Detection of covid-19 from ct scan images: A spiking neural network-based approach. Neural Computing and Applications, v. 33, p. 12591–12604, 2021. ISSN 19. Acesso em 26 de Março de 2025. Disponível em: <https://link.springer.com/article/10.1007/s00521-021-05910-1>.

GATTI, M.; BARBATO, J. A.; ZANDRON, C. Spiking neural network classification of x-ray chest images. Knowledge-Based Systems, v. 314, p. 113194, 2025. ISSN 0950–7051. Acesso em 26 de Março de 2025. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0950705125002412> >

PAULO, K. H. A. D. d. Inteligência artificial para auxílio no diagnóstico de infecções fúngicas e neoplasias pulmonares em radiografias torácicas. Universidade Estadual Paulista (Unesp), 2024. Acesso em 26 de Março de 2025. Disponível em: <https://dco-unesp-bauru.github.io/tcc-bcc-2024/KaioHDP/thesis-KaioHDP.pdf> .