



Uso De Aprendizado de Máquina Para Detecção De Ataques DDoS

Orientador: Prof Dr. Kelton Augusto Pontara da
Costa

Orientando: Gustavo Amaral Duarte Rego
RA: 201025817




Problemática



Ataques DDoS

- Ataques DDoS estão cada vez mais comuns e poderosos com o passar do tempo.
- Técnicas mais avançadas de detecção de ataques são necessárias conforme a escala aumenta.
- Redes neurais são utilizadas de forma recorrente para reconhecimento de padrões.

Largest known DDoS attacks



(CHAGANTI; BHUSHAN; RAVI, 2022)



Objetivos

- Construir um algoritmo capaz de detectar ataques DDoS com base em técnicas de Aprendizado de máquina .
- Analisar os resultados obtidos e testar a eficiência da rede neural.




Fundamentação Teórica



Ataques DDoS

- (HOQUE; BHATTACHARYYA; KALITA, 2015), Um ataque DDoS é um ataque coordenado que utiliza muitos *hosts* comprometidos.
- Objetivo de esgotar recursos de infraestrutura (Rede ou Hardware).
- É necessário um grande número de *hosts* para que o ataque seja eficiente.

Ataques DDoS




Ataques DDoS

DoS Attack



DDoS Attack






Aprendizado de Máquina

- Área da Inteligência Artificial voltada a criar algoritmos capazes de adquirir conhecimento.
- Tipos de algoritmos diferentes para aprendizado de máquina (*Support Vector Machines*, Redes Neurais Artificiais, entre outros).
- Redes Neurais Artificiais normalmente utilizam múltiplas camadas pois esses modelos conseguem discernir mais nuances entre a camada de entrada e saída.

Aprendizado de Máquina

- Redes Neurais Artificiais
 - Predizem um resultado baseado no treinamento.





Materiais e métodos



Materiais e métodos

- Hardware utilizado
 - Notebook pessoal
 - Intel Core i5 10300H
 - NVidia GTX 1650
 - 32GB RAM 3200MHz
 - 1TB SSD NVMe
 - Google Colab (free)



Materiais e métodos

- Software utilizado
 - Visual Studio Code - Jupyter



Materiais e métodos

- Foi selecionado o algoritmo de Multilayer Perceptron para a confecção do modelo.
- 1 camada de entrada com 64 neurônios, 1 camada intermediária com 32 neurônios e uma camada de saída para binarizar o resultado.





Materiais e métodos

- Conjunto de dados utilizado:
 - (DEVENDRA416, 2020), com 10 Milhões de amostras e 87 parâmetros.
 - Tráfego de rede rotulado com parâmetros que podem ser “DDoS” ou “benigno”.



Materiais e métodos

- Pré-processamento dos dados
 - O conjunto foi dividido em 5 subconjuntos diferentes, com 100 mil, 250 mil, 500 mil 1 Milhão e 10 Milhões de dados.





Materiais e métodos

- Pré-processamento dos dados
 - Por razões de armazenamento, foram escolhidos 4 parâmetros principais para o treinamento da rede.
 - IP de Destino
 - Tamanho médio dos pacotes
 - Pacotes Por Segundo

Materiais e métodos

- Pré-processamento dos dados















Análises e Resultados




Análises e resultados

- Com os 5 conjuntos de dados foi possível obter as seguintes curvas de acurácia e perda:








100k Lines / 10epoch



100k Lines / 10epoch







Análises e resultados

- Ao observar os gráficos anteriores, é possível inferir que a quantidade de dados impacta sim no resultado, porém, para o caso testado, não significativamente.
- Existe o ganho de 1% em termos de acurácia, porém para isso, foi necessário aumentar em 100 vezes a quantidade de dados.


10M Lines / 10epoch




10M Lines / 10epoch



100k Lines / 10epoch



100k Lines / 10epoch





Trabalhos futuros

- Utilização de outras técnicas de Aprendizado de Máquina para comparação;
- Modificar os parâmetros selecionados para avaliar como o modelo se ajusta;
- Expandir o escopo do modelo para reconhecimento de outros ataques cibernéticos;
- Testar o modelo em um ambiente real, com um tráfego do “ dia a dia”.



Referências

HOQUE, N.; BHATTACHARYYA, D. K.; KALITA, J. K. Botnet in ddos attacks: Trends and challenges. IEEE Communications Surveys Tutorials, v. 17, n. 4, p. 2242–2270, 2015. Disponível em: <https://ieeexplore.ieee.org/abstract/document/7160662>. Acesso em: 01 nov. 2023.


CHAGANTI, R.; BHUSHAN, B.; RAVI, V. The role of blockchain in ddos attacks mitigation: techniques, open challenges and future directions. 02 2022. Disponível em: https://www.researchgate.net/publication/358458534_The_role_of_Blockchain_in_DDoS_attacks_mitigation_techniques_open_challenges_and_future_directions. Acesso em: 02 set. 2023.

SHEN, B. W.; SETHI, G.; ZAKKA, K.; MOINDROTA, O.; DARDNER, R.; KULAL, S. CS231n Convolutional Neural Networks for Visual Recognition. 2020. Disponível em: <https://cs231n.github.io/neural-networks-3/>. Acesso em: 29 out. 2023.

Agradecimentos



Agradecimento



Agradecimentos

