

Adaptação do envenenamento Nightshade para arquivos de áudio

Aluno: Henrique Trivelato de Angelo

Orientador: Prof. Dr. Kelton Augusto Pontara

1. Introdução

2. Fundamentação Teórica

3. Metodologia

4. Experimentos

5. Conclusão

1. Introdução

Nos últimos anos, os computadores adquiriram as habilidades de gerar textos, imagens, áudios e vídeos de alta resolução e bastante fiéis à realidade.

- Isso é fruto da evolução das Inteligências Artificiais Generativas (IAGen)

ChatGPT, MetaAI e o DeepSeek são exemplos de IAGen muito conhecidos e utilizados no cotidiano.

No campo da ciência, a IAGen atua em diversas áreas, dentre elas:

- Educação ➡ desenvolvimento de ferramentas de aprendizagem de línguas estrangeiras (AI KAKU);
- Farmácia ➡ criar novos remédios a partir da simulação de diferentes combinações moleculares;
- Áudio-visual ➡ criar vozes para personagens fictícios.

Por outro lado, as IAGens também são capazes de modificar o conteúdo original de textos, imagens, áudios e vídeos de forma que as pessoas acreditem que o conteúdo falso seja a realidade.

- *Deepfake*

Destacam-se os seguintes casos de *deepfake*:

- Inserir o rosto de quaisquer mulheres em imagens ou vídeos pornográficos (SANTOS, 2024);
- Circulação de áudios falsos em grupos de Whatsapp durante o período eleitoral (QUEIROZ, 2024);
- Replicação de imagem e, ou, a voz de conhecidos em golpes para aumentar a suscetibilidade de pessoas realizarem grandes transferências monetárias (CHEN; MAGRAMO, 2024) e (MACHADO, 2024)

O que os nudes falsos em Itararé ensinam sobre o aumento de casos de deepfakes pornográficos em escolas

Pelo menos 40 pessoas, entre elas, 36 menores de 18 anos, foram vítimas de montagens pornográficas na cidade do interior de São Paulo. Casos semelhantes ocorreram em Maceió, Salvador e Cuiabá.

Por **Emily Santos**, g1

11/10/2024 05h04 · Atualizado há um ano

Fonte: G1



EM DESTAQUE COP30 em Belém Violência no Rio de Janeiro Colunas

Vídeos

POLÍTICA

IA pode ser uma ameaça no Brasil às vésperas da eleição

Gustavo Queiroz

12/08/2024

Para especialistas, vídeos manipulados são exemplos de como a inteligência artificial pode ser usada para prejudicar candidatos, tendo em vista o baixo custo e a capacidade de disseminar fake news e discurso de ódio.



Fonte: DW Brasil

World / Asia

Finance worker pays out \$25 million after video call with deepfake 'chief financial officer'



By Heather Chen and [Kathleen Magramo](#), CNN

🕒 2 min read · Published 2:31 AM EST, Sun February 4, 2024



Fonte: CNN World

'Eram meu rosto e minha voz, mas era golpe': como criminosos 'clonam pessoas' com inteligência artificial

Fonte: BBC News

O aumento de *deepfakes* está atrelado a dois fatores:

- o aumento de IAGens robustas disponíveis de forma online e gratuita;
Crescimento do número de pessoas que podem se tornar potenciais criadores de *deepfakes*;
- falta de proteção dos dados contra o *web scraping*;
 - O *web scraping* é responsável por coletar de forma autônoma imensa quantidade de dados na internet;
 - Essa coleta constante mantém a alta qualidade de geração da IAGen com o processo de *fine-tuning*;
 - Todos os textos, imagens, áudios e vídeos publicados na internet estão sujeitos ao *web scraping*;
 - Qualquer IAGen especializada em produção de *deepfake* estará apta para mudar o conteúdo de uma pessoa por outra a partir de:
 1. Mudança de voz;
 2. Troca de face;
 3. Alteração da fala (palavras ditas).

Diante da popularização das *deepfakes*, muitos estudos emergiram com o propósito de contrapor o uso irresponsável das IAGens para geração de *deepfakes*:

- analisar uma mídia (textos, imagens, áudios ou vídeos) e verificar se ela está adulterada (REISS; CAVIA; HOSHEN, 2023);
- criar uma proteção invisível em arquivos contra *web scraping* capaz de deteriorar o conhecimento de uma IAGen durante sua fase de treinamento
 - Proteção de imagens ➡ *Nightshade* (SHAN et al., 2024)
 - Proteção de áudios ➡ VenoMave (AGHAKHANI et al., 2024)
 ➡ WaveFuzz (GE et al., 2022)

Atualmente, não existe uma ferramenta versátil, eficiente e gratuita capaz de proteger quaisquer tipos de arquivos e dos mais diversos tamanhos contra *web scraping*.

O envenenamento *Nightshade* se destaca por:

- ser considerado o estado da arte no envenenamento de modelos de difusão texto-para-imagem;
- sua grande repercussão e adoção pela comunidade artística e tecnológica;

Amplamente discutida em plataformas como o *Reddit*

Assim, o *Nightshade* se torna um candidato ideal para estudos que proponham o aumento de seu campo de atuação para áudios e, ou, vídeos.

Objetivo:

O objetivo principal deste projeto é propor uma técnica de envenenamento direcionado, adaptada do algoritmo do *Nightshade* capaz de inserir perturbações adversariais imperceptíveis em segmentos de um sinal de áudio, visando corromper o treinamento de modelos TTS e, assim, proteger o conteúdo contra *scraping* de dados e clonagem de voz.

Objetivos específicos:

- Realizar um envenenamento em áudio como se fosse um problema de imagem;
- Efetuar mudanças mínimas na composição do ataque *Nightshade*;
- Determinar um modelo texto-para-fala (TTS) de difusão que será tanto o alvo do envenenamento direcionado quanto um componente integrado na arquitetura de ataque em áudio proposta;
- Verificar se a adaptação proposta para o *Nightshade* é de fato um envenenamento direcionado que irá afetar o desempenho do modelo TTS de difusão escolhido, impedindo que ele reproduza certas palavras;

2. Fundamentação Teórica

Modelos de difusão:

É uma classe de modelos generativos que ganhou destaque nos últimos anos por sua capacidade de gerar dados sintéticos de alta qualidade.

- Leitura automatizada com voz natural gerada por modelos TTS (LI et al., 2023; SHEN et al., 2023);
- Geração de efeitos de fundo personalizados (KREUK et al., 2023);
- Produção musical assistida por IA (ZHANG et al., 2024a);
- Recuperação forense de áudio degradado (ZHANG; JAYASURIYA; BERISHA, 2021);

Modelos de difusão:

A ideia matemática desses modelos é aprender a reconstruir imagens, áudios ou vídeos a partir de ruídos gaussianos.

- 1ª etapa: adicionar ruídos progressivamente a um dado (imagem, áudio ou vídeo) até que ele se torne puro ruído.

$$q(x_t|x_{t-1}) = \mathcal{N}(x_t; (\sqrt{1 - \beta_t})x_{t-1}, \beta_t \mathbb{I})$$

- 2ª etapa: partindo apenas de um dado sintético composto apenas por ruídos, retirar esses ruídos até reconstruir o dado original (o mais próximo possível).

Otimização de
parâmetros θ .




$$p_\theta(x_{t-1}|x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t))$$

$$\mathcal{L} = \mathbb{E}_q \left[\log \left(\frac{p_\theta(x_0 : T)}{q(x_1 : T|x_0)} \right) \right] = \mathbb{E}_q \left[-\log p(x_T) - \sum_{t \geq 1} \log \left(\frac{p_\theta(x_{t-1}|x_t)}{q(x_t|x_{t-1})} \right) \right]$$

Os **parâmetros ótimos** são aqueles que **aproximam p_θ de q** .


Modelos de difusão:

Figura 1 – Processo de difusão ao longo de T etapas



Fonte: Ho, Jain e Abbeel (2020).

Figura 2 – Processo de difusão reversa ao longo de T etapas



Fonte: Ho, Jain e Abbeel (2020).

Nightshade:

O *Nightshade* é uma técnica de **envenenamento direcionado** de modelos de texto-para-imagem que visa auxiliar artistas e pequenas empresas na **proteção de suas propriedades intelectuais contra o web scraping**.

- Disponível de forma gratuita pelo grupo “*The Glaze Project*”

Seu **alvo principal** são os modelos de **IA Gen de difusão**

- O LAION-Aesthetic é o conjunto de dados mais utilizado para treinar modelos de difusão de texto-para-imagem;
- Segundo os autores do *Nightshade*, esse conjunto de dados apresenta duas vulnerabilidades:

- Ele tem informações para uma vasta gama de conceitos, porém o número de imagens e descrições é bastante reduzido quando o foco é apenas um único conceito;

Todos os conceitos estão suscetíveis a envenenamentos.

- 0,2% de todos os dados engloba semanticamente 92% dos conceitos existentes.

Envenenar alguns conceitos é capaz espalhar o veneno para outros conceitos (sangramento).

Nightshade (algoritmo):

Adote que M_{TTI} é um modelo texto-para-imagem de difusão

- **Etapa 1:** Definir um conceito C que se deseja envenenar;
- **Etapa 2:** Definir o tamanho N_p do conjunto de imagens I_C do conceito C que sofrerão envenenamento;
- **Etapa 3:** A partir de um conjunto $Data_C$ que contém N imagens referentes ao conceito C , encontrar as N_p imagens mais próximas do texto $t_C = \text{“A photography of [C]”}$. Para isso, calcula-se a pontuação CLIP (semelhança de cossenos) entre os *embeddings* de imagem e texto do modelo M_{TTI} .

$$CLIP = \frac{\langle E_{img}(I_C), E_{text}(t_C) \rangle}{\|E_{img}(I_C)\| \cdot \|E_{text}(t_C)\|}$$

Selecione as 5000 imagens com maiores pontuações CLIP e, por fim, sorteie aleatoriamente N_p delas para compor o conjunto de imagens $Cand_p$ que serão envenenadas;

Nightshade (algoritmo):

- **Etapa 4:** Definir um conceito âncora A que seja diferente de C ;
- **Etapa 5:** Gerar uma imagem I_A do conceito âncora a partir do texto $t_A = \text{“A photograph of [A]”}$. Use o modelo M_{TTI} para isso. Ao final desse processo, serão obtidos N_p pares $\{I_C, I_A\}$. Os autores adotaram $M_{TTI} = \text{Stable Diffusion 2.1}$ de Rombach et al. (2022);
- **Etapa 6:** Para cada par $\{I_C, I_A\}$, gere a versão envenenada $I_p = I_C + \delta$ da imagem original I_C . Para isso, define-se a seguinte função de otimização

$$\min_{\delta} ||E_{img}(I_C + \delta) - E_{img}(I_A)||_2^2 + \alpha \cdot \max(||\delta||_{LPIPS} - p, 0)$$

- **Etapa 7:** Retreinar o modelo M_{TTI} do zero ou por *fine-tuning*. Trocar N_p pares originais $\{I_C, \text{prompt}\}$ por seus respectivos pares envenenados $\{I_p, \text{prompt}\}$

Nightshade (algoritmo):

Função de otimização definida na etapa 6

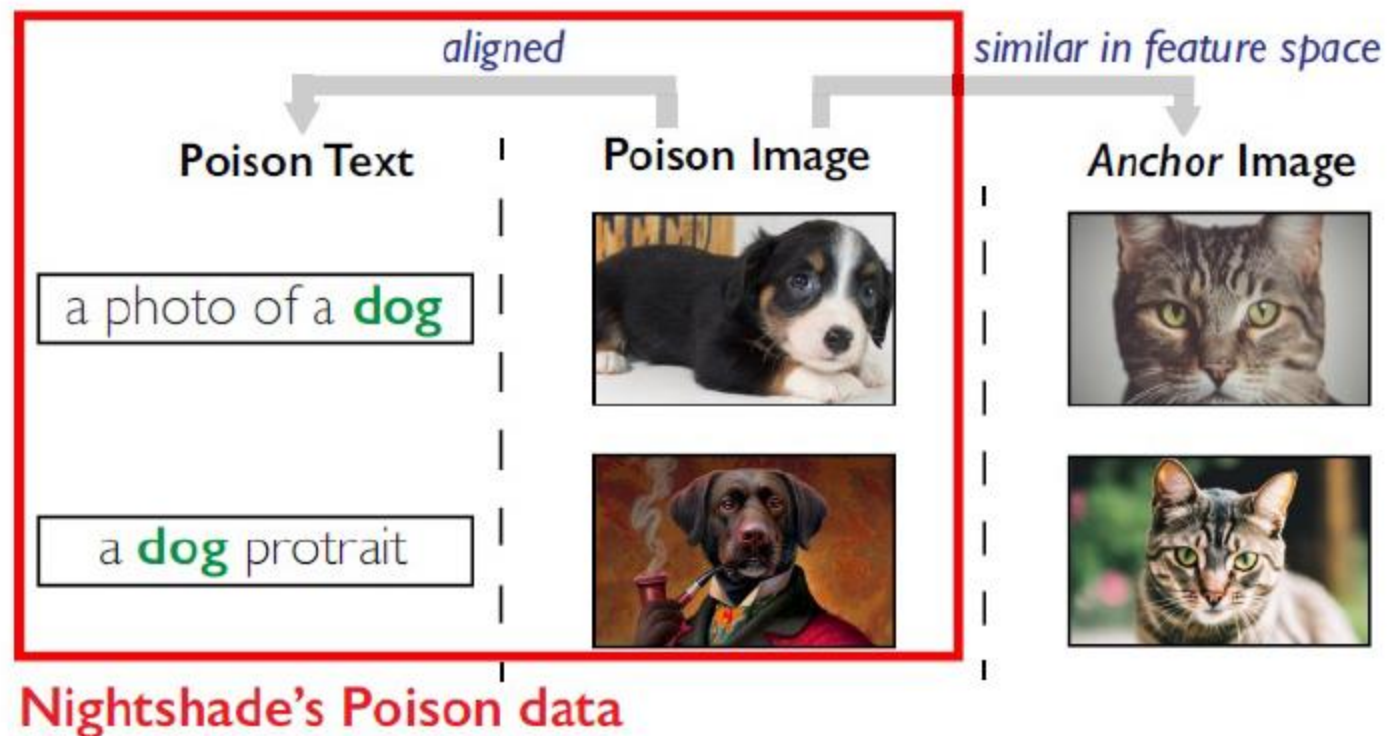
$$\min_{\delta} ||E_{img}(I_C + \delta) - E_{img}(I_A)||_2^2 + \alpha \cdot \max(||\delta||_{LPIPS} - p, 0)$$

em que:

- E_{img} é mesmo codificador de imagens definido na etapa 3;
- $D(\cdot)$ é uma função de distância válida para o espaço de características estabelecido pelo codificador E_{img} ;
- $||\delta||$ é a perturbação adicionada à imagem I_C ;
- p é o maior valor que a perturbação $||\delta||$ pode assumir.
- $||\delta||_{LPIPS} = LPIPS(I_C, I_p)$ é a métrica definida por Zhang et al. (2018).

Nightshade (ataque a um único conceito):


Figura 3 – Exemplo de imagens envenenadas e suas respectivas imagens âncoras



Fonte: Shan et al. (2024).

Nightshade (efeito sangramento):

Figura 4 – Exemplo de sangramento no ataque “dog” para “cat”



Fonte: Shan et al. (2024).

Nightshade (efeito sangramento):

Figura 5 – Envenenamento a partir de estilo artístico



Fonte: Shan et al. (2024).

Nightshade (ataque múltiplo):

Figura 6 – Envenenamento composto de “dog” e “fantasy art”

Poisoned #1:

Dog → Cat



Poisoned #2:

Fantasy art →
Impressionism



Output image:

*A dog in
fantasy art style*



Fonte: Shan et al. (2024).

Nightshade (ataque múltiplo):

Figura 7 – Degradação total do modelo



Fonte: Shan et al. (2024).

Áudio:

Os arquivos de áudio **carregam todas as informações** do som digitalizado por meio da representação **em forma de onda**.

- **Carece de interpretabilidade** (não é o formato ideal para que a máquina aprenda)

É possível obter **informações relevantes** sobre um áudio ao transformar a onda em um **espectograma de log-mel** (EL-KHASAWNEH et al., 2025).

1. Dividir o áudio em frames de mesmo tamanho;
2. Aplicar uma FFT (Transformada rápida de Fourier) em cada um dos frames;
3. Converter a escala Hertz para escala Mel (a partir dos filtros de mel);
4. Aplicar o logaritmo na base 10.

O espectograma de log-mel é uma “fotografia” do áudio que contém informações que sensibilizam a audição humana (LACERDA et al., 2021)

Logo, o uso de espectograma de log-mel é essencial para problemas que envolvam estudo da fala (ZHANG et al., 2023).

- Construção de modelos TTS e vocoders


Áudio (STFT e FFT):

Fórmula referente a STFT (Transformada de Fourier de curta duração)

$$X(n, k) = \sum_{a=0}^{A_f-1} x[a + nH] w[a] e^{-\frac{i2\pi kn}{N}}$$

- $X(n, k)$ é o valor do espectrograma no frame n e no intervalo de frequências k ;
- H distância entre os pontos (amostras) iniciais de dois frames sucessivos (em inglês, é conhecido como *hop length*);
- $x[a + nH]$ é o sinal de áudio original na a -ésima amostra do frame n ;
- $w[a]$ é a função janela aplicada na a -ésima amostra do frame n ;
- $e^{-\frac{i2\pi kn}{N}}$ é a função base da DFT.

Figura 11 – Visualização do processo de STFT




Fonte: Math Works (2025).

Áudio (escala mels):

Conversão Hertz para Mel

$$mel(f) = 2595 \log_{10} \left(1 + \frac{f}{700} \right)$$


Figura 12 – Relação logarítmica entre frequências em hertz e mels




Fonte: Stevens, Volkman e Newman (1937).

Áudio (espectograma de log-mel):

Figura 25 – Exemplo de áudio “four” do *Command Speechs*



(a) em formato de onda



(b) em espectograma de log-mel

Fonte: Elaborado pelo autor.

Áudio (perda de fase):

Quando o áudio é convertido da forma de onda para a forma de espectrograma de magnitude, **perde-se a informação referente à fase da onda.**

- Sem ela, não é possível retornar o espectrograma de magnitude para onda

Espectrograma $\longrightarrow X(n, k) = a + ib$ $\longrightarrow$ Subespaço vetorial é uma reta

Fase (ângulo) $\longrightarrow \theta(n, k) = \arctan\left(\frac{b}{a}\right)$

Espectrograma de magnitude $\longrightarrow |X(n, k)| = \sqrt{a^2 + b^2}$ $\longrightarrow$ Subespaço vetorial é uma circunferência (vários espectrogramas com mesma magnitude)

O algoritmo de Griffin-Lim (GRIFFIN, LIM; 1984) é um algoritmo que estima essa fase perdida, isto é, o espectrograma original.

Áudio (Griffim-Lim):


Dado um espectrograma de magnitude conhecido

$$S_{mag}(n, k)$$

Sortear um ângulo inicial no intervalo $[0, 2\pi]$

$$\hat{\theta}^{(0)} = \hat{\theta}^{(0)}(n, k)$$

Figura 14 – Espectrograma inicial $\hat{X}^{(0)}(n, k)$ com magnitude igual a $S_{mag}(n, k)$



Fonte: Adaptado de Hasegawa-Johnson (2023).

Áudio (Griffim-Lim):

Estima-se o espectrograma inicial

$$\hat{X}^{(0)}(n, k) = S_{mag}(n, k) e^{i\hat{\theta}^{(0)}}$$

Processo de intercalação de projeções entre dois conjuntos

$$\hat{X}^{(i+1)}(n, k) = P_C[P_A[\hat{\theta}^{(i)}]]$$

$$P_A[\hat{\theta}^{(i)}] = \hat{X}^{(i)}(n, k)$$

$$P_C[\hat{X}^{(i)}(n, k)] = \underbrace{STFT[iSTFT[\hat{X}^{(i)}(n, k)]]}_{\text{Forma de onda}}$$

Critério de parada da estimação


$$\frac{\|\hat{X}^{(i+1)} - \hat{X}^{(i)}\|_2}{\|\hat{X}^{(i)}\|_2} < \varepsilon$$

Forma de espectrograma

Onda estimada $\longrightarrow W_{res} = P_A[\hat{\theta}^{(i+1)}]$

Áudio (Griffin-Lim):

Figura 15 – Exemplo de execução do algoritmo de Griffin-Lim



Fonte: Adaptado de Hasegawa-Johnson (2023).


CLAP:

O CLAP é a versão do CLIP para áudio

- É um modelo que estima a proximidade entre um áudio e um texto;
- Utiliza a semelhança de cossenos;

O modelo treina, conjuntamente, um codificador para texto e outro para imagem (ambos geram vetores de características de mesmo tamanho)

Figura 16 – Calculando proximidade de um áudio em relação a uma lista de textos



Fonte: Wu* et al. (2023).

StyleTTS 2:

É um modelo de difusão de texto-para-fala (TTS) que, a partir de uma **breve amostra de áudio**, consegue **replicar a voz** de qualquer pessoa para **verbalizar** um texto arbitrário.

A qualidade de áudio sintetizado do **StyleTTS 2** para clonagem de voz superou o **Vall-E** (considerado um modelo TTS que compõe o estado da arte)

- 245 horas x 60000 horas de áudio para treinamento
- Inclusão de modelos pré-treinados que possuem vasta gama de conhecimento sobre a fala humana (BERT e WavLM) na arquitetura do StyleTTS 2

O **tempo gasto pelo StyleTTS 2** para criar áudios que soem naturais e expressivos é **metade** de um modelo TTS de CVAE (*Conditional Variational Auto Encoder*), como, por exemplo, o VITS.


- Proposição de um método de difusão de estilos (estilo é uma variável aleatória)

Treinamento é *end-to-end*, ou seja, **evita o treinamento individual de cada componente**

- Proposição de um método que estima a duração da fala a ser criada
- Treinamento adversarial das GANs (Gerador x Discriminador)

StyleTTS 2:

Figura 19 – Arquitetura de treinamento do StyleTTS 2



Fonte: Adaptada de Li et al. (2023).

Trabalhos Correlatos:

- Envenenamento de áudio:

- Venomave (AGHAKHANI et al., 2024)

Envenenamento em que **uma palavra específica de um áudio seja incorretamente transcrita como uma palavra alvo** (escolhida por quem efetua o ataque) sem realizar a troca de rótulos na amostra treino.

Utiliza uma **rede DNN-HMM** para transcrever o conteúdo do áudio em texto.

- A DNN traduz as características do áudio para fonemas;
- A HMM associa os frames do áudio a fonemas por meio de probabilidades.

- WaveFuzz (GE et al., 2022)

Envenenamento que insere pequenas quantidades de ruídos para diminuir a qualidade do áudio e, assim, fazer com que **modelos TTS baseados em atenção (*transformers*) e CNN** errem a transcrição do áudio.

Trabalhos Correlatos:

Tanto o Venomave quanto o WaveFuzz realizam o estudo do áudio a partir de:

1. MFCC (Coeficientes Cepstrais de Frequência Mel);
2. Usam o conjunto de dados ***Speech Commands***.

- *Áudios como imagens:*

(BAKHSHI; SINGH; KUMAR, 2023) e (PHAM et al., 2024) **destacam a importância dos espectogramas de mel** como representações eficazes para análise de áudios em diferentes contextos.

- detecção de violência em áudios;
- detecção de *deepfakes* em áudios;

3. Metodologia

Dataset:

O *dataset* escolhido para a realização da pesquisa foi **Speech Commands v0.02** de Warden (2018)

- Consiste em 105.829 enunciados de **áudio com um segundo de duração**;
- Cobre um vocabulário de 35 palavras **em inglês**;

Ideia do envenenamento:

- Imagem a ser envenenada  Espectograma de log-mel da palavra alvo
- Imagem âncora  Espectograma de log-mel da palavra âncora

A escolha desse *dataset* é reforçada por seu uso em outros trabalhos da área, como os ataques

- Venomave;
- WaveFuzz;

Bibliotecas Python:

- ***Einops***: facilita operações de tensores;
- ***Librosa***: análise, processamento e extração de características de áudio;
- ***Numpy***: arrays e matrizes multidimensionais de alta performance em conjunto com funções matemáticas que operam sobre eles;
- ***NLTK (Natural Language Toolkit)***: tokenização, stemming (radicalização), marcação de classe gramatical e análise de texto;
- ***OS***: interagir com sistema operacional, manipulando caminhos de arquivos, listando diretórios e navegando por pastas;
- ***PIL (Python Imaging Library)***: abertura, manipulação e salvamento de imagens;
- ***Pytorch***: framework de aprendizado profundo, que utiliza tensores com forte aceleração por GPU para permitir a construção e treinamento eficiente de redes neurais;

Adaptações realizadas no *Nightshade*:

A partir daqui serão adotadas as seguintes denominações:

- *PE*  Palavra que sofrerá envenenamento
- *PA*  Palavra âncora

Este trabalho propõe mudanças nas

- **Etapas 3:** seleção de áudios;
- **Etapas 5:** geração de áudios âncoras;
- **Etapas 6:** adequação do espectograma de log-mel para o formato de *input* do Stable Diffusion 2.1, adição de ruídos e geração de áudios envenenados;

Os modelos CLAP pré-treinado, StyleTTS 2 pré-treinado e o ataque *Nightshade* (que contém o Stable Diffusion 2.1 pré-treinado) estão disponíveis nos respectivos repositórios de seus autores no GitHub

Seleção de áudios (etapa 3):

Os áudios referentes à PE devem se adequar ao formato de entrada do CLAP

Taxa de amostragem: 16000 Hz  48000 Hz

CLAP  Comparar áudios com o texto “*A person saying [PE]*”

Pontuação CLAP ≤ 0.24 : descartar áudio

Pontuação CLAP > 0.24 : possível candidato



Mesmo critério do *Nightshade*

Sortear aleatoriamente N possíveis candidatos para compor a lista de candidatos a sofrer envenenamento (*cand_list*)

Observação: Os áudios da *cand_list* devem estar com suas taxas de amostragem originais (16000 Hz)

Geração de áudios âncoras (etapa 5):

O StyleTTS 2 gera um áudio âncora Aud_A distinto para cada áudio Aud_e na $cand_list$

- Um ataque é composto por N pares $\{Aud_e, Aud_A\}$

É importante destacar 2 problemas do modelo StyleTTS 2 e as soluções propostas neste trabalho para saná-las

Problema 1: Interrompe a pronúncia da última sílaba ao gerar áudio a partir de *prompts* curtos (exemplo: *strings* que são apenas uma palavra).

Solução: Adição de um espaço (“ ”) ao final da *string* de *PA* ($PA + “ ”$).

Problema 2: Os áudios do *Speech Commands* são curtos demais para servirem de áudios referências para o StyleTTS 2.

Solução: Criar áudios referências de 4 segundos a partir da concatenação de 4 áudios Aud_e .

Geração de áudios âncoras (etapa 5):

Figura 23 – Função que repete o áudio 4 vezes a para que ele tenha 4 segundos

```
wave, sr = librosa.load(audio_path, sr = 24000)

audio_4_seconds = np.tile(wave, reps = 4)    # Repeat audio 4 times
|      |      |      |      |      |      |      |      |      |      # to make it a 4-second audio
```

Fonte: Elaborado pelo autor.

Adequação do espectrograma para Stable Diffusion (etapa 6):

Figura 26 – Convertendo formato de onda para log espectrograma mel

```
mels = librosa.feature.melspectrogram(y = wave,  
                                       sr = sr,  
                                       n_mels = 80,  
                                       n_fft = 2048,  
                                       hop_length = 300,  
                                       win_length = 1200)  
  
mels = librosa.power_to_db(mels, ref = np.max)
```

Fonte: Elaborado pelo autor.

Adequação do espectrograma para Stable Diffusion (etapa 6):

Espectrograma de log_mel



Dimensão [80, 81]

Valores [-80, 0]

Espectrograma de log-mel na escala cinza

- Normalização Min-Max
- Multiplica por 255 (“pixelando”)



Dimensão [80, 81]

Valores [0, 1]



Dimensão [80, 81]

Valores [0, 255]

Espect de log-mel na escala cinza 512 x 512

- Cria imagem branca 512 x 512 (escala cinza)
- Acopla espectrograma 80 x 81 na imagem branca 512 x 512



Dimensão [512, 512]

Todos os pixels = 255




Dimensão [512, 512]

Valores [0, 255]

Adequação do espectrograma para Stable Diffusion (etapa 6):

Figura 29 – Acoplando o espectrograma de log-mel de um áudio “*bed*” na imagem M_{512}



Fonte: Elaborado pelo autor.

Na hora do recorte, ele preserva todos os ruídos inseridos [diferente do método `Image.resize()`]

Adequação do espectograma para Stable Diffusion (etapa 6):

Carregar acoplamento 512 x 512
como imagem RGB



Dimensão [512, 512, 3]

Valores [0, 255]

`Image.fromarray(M512).convert('RGB')`

Converter valores para o domínio [-1, 1]



Dimensão [512, 512, 3]

Valores [-1, 1]

$$M_{512_RGB[-1,1]} = \frac{M_{512_RGB[0,255]}}{127.5} - 1$$

Imagem 512 x 512 adequada pro *Stable Diffusion 2.1*

- *rearrange* do *Einops*



Dimensão [3, 512, 512]

Valores [-1, 1]

- Converter para tensor e *unsqueeze*



Dimensão [1, 3, 512, 512]

Valores [-1, 1]

- Converter para tipo *float* de 16 bits



Dimensão [1, 3, 512, 512]

Valores [-1, 1]

Adequação do espectrograma para *Stable Diffusion 2.1* (etapa 6):

Figura 30 – Código que converte imagem em escala cinza para o formato de *input* do *Stable Diffusion*

```
def img2tensor(cur_img):  
    cur_img = np.array(cur_img)  
  
    img = (cur_img / 127.5 - 1.0).astype(np.float32) # [0,255] to [-1,1]  
  
    img = rearrange(img, 'h w c -> c h w')  
  
    img = torch.tensor(img).unsqueeze(0) # shape [1,c,h,w]  
  
    return img  
  
def adequate_image_to_StableDiffusion_format(self, source_Mel512_path,  
| | | | | | | | | | target_Mel512_path, device):  
  
    # Loading source and target 512x512 mel-spectro  
    source_mel_img_512 = Image.open(source_Mel512_path).convert('RGB')  
    target_mel_img_512 = Image.open(target_Mel512_path).convert('RGB')  
  
    source_tensor = img2tensor(source_mel_img_512).to(device)  
    target_tensor = img2tensor(target_mel_img_512).to(device)  
  
    source_tensor = source_tensor.half()  
    target_tensor = target_tensor.half()  
  
    return source_tensor, target_tensor
```

Fonte: Elaborado pelo autor.

Adição de ruídos (etapa 6):

➤ Inicializar tensor de ruídos δ  Dimensão [1, 3, 512, 512] Todos valores = 0.1

➤ Criar tensor adversarial (imagem 512 x 512 com ruídos) $Te_{adv} = \delta + Te_E$

➤ Realizar otimização de ruídos que **aproxima a imagem envenenada da imagem âncora**

- Para $j = 1$ até 500 ($j_{fim} = 500$)

$$step^{(j)} = step^{(0)} - \left[\frac{(j-1)}{j_{fim}} \cdot 0.99 \cdot step^{(0)} \right]$$



A intensidade do ruído diminui a cada etapa

$$\mathcal{L} = ||Emb_{adv} - Emb_A||_2$$



Mede-se a distância entre a imagem envenenada e âncora no espaço latente do *Stable Diffusion*

$$\delta^{(j+1)} = \delta^{(j)} + torch.sign(gradiente) \cdot step^{(j)}$$



Adição ou retirada de ruído nos pixels da imagem do áudio Aud_E

Imagem 512 x 512 com ruído para áudio (etapa 6):

Figura 32 – Código referente à conversão do tensor $T_{e_{adv}}$ para a imagem $M_{512(adv)}$

```
def tensor2img(modifier):  
    # rescaling values from [-1,1] to [0,1]  
    cur_img = torch.clamp( (modifier.detach() + 1.0) / 2.0,  
                           min = 0.0,  
                           max = 1.0)  
  
    # back to image shape and pixels values in [0,255]  
    cur_img = 255. * rearrange(cur_img[0], 'c h w -> h w c').cpu().numpy()  
  
    # convert image values to integers  
    # and save image as Image Object  
    cur_img = Image.fromarray(cur_img.astype(np.uint8))  
  
    return cur_img
```

Fonte: Elaborado pelo autor.

Imagem 512 x 512 com ruído para áudio (etapa 6):

Figura 33 – Código referente à conversão da imagem $M_{512(adv)}$ em seu respectivo áudio envenenado

```
def convert_poisoned_img512_to_audio(poison_img_512, h_orig_mel, w_orig_mel,
                                     path_to_save_poison_audio, orig_ref, idx):

    img512 = np.array(poison_img_512)

    mel_img_cut = img512[:h_orig_mel, :w_orig_mel] # cutting spectrogram

    mel_img = Image.fromarray(mel_img_cut).convert('L')

    mel_img_float32 = np.array(mel_img).astype(np.float32)

    img_to_mels_db = scale_minmax(mel_img_float32, 0, 80).astype(np.float32) # turning to mel scale
    mels_db = (-1) * img_to_mels_db # mels are negative numbers or zero

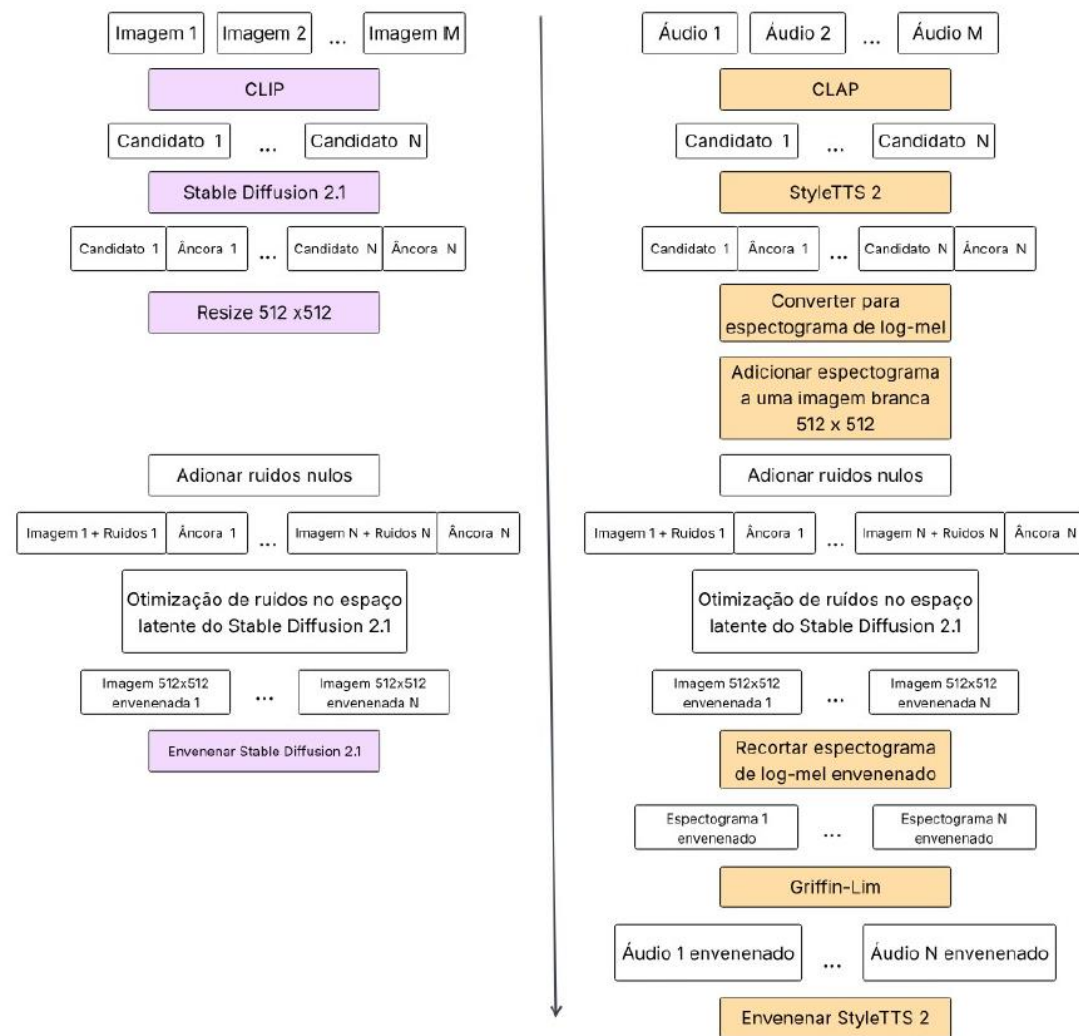
    mels_mag = librosa.db_to_power(mels_db) # Back to magnitude

    waveform = librosa.feature.inverse.mel_to_audio( # Griffin-Lim method
        mels_mag,
        sr = 24000,
        n_fft = 2048, # old samples 1024
        hop_length = 300 # old samples 512
    )

    # save audio
    sf.write(path_to_save_poison_audio + "{}/{}.wav".format(idx), waveform, 24000)
```

Fonte: Elaborado pelo autor.

Figura 34 – Diferenças entre o *Nightshade* original e o adaptado



Nightshade

Nightshade adaptado

Fonte: Elaborado pelo autor.

Fine-tuning com amostra envenenada:

Técnica de treinamento de redes neurais utilizada por agentes com:

- Recursos computacionais limitados;
- Poucos dados;

Amostras envenenadas devem ser divididas em:

- Amostras envenenadas de treinamento (90% dos áudios);
- Amostras envenenadas de teste (10% dos áudios).


Criar arquivos “train_list.txt” e “test_list.txt” que contenham:

- os nomes dos arquivos de áudios envenenados;
- a palavra PE em formato de fonema;
- Um número inteiro distinto para cada áudio (ID do falante).

Fine-tuning com amostra envenenada:

Técnica de treinamento de redes neurais utilizada por agentes com:

- Recursos computacionais limitados;
- Poucos dados;



1. Clonar vozes em questão de horas;
2. Facilitar propagação de *deepfakes*.

Amostras envenenadas devem ser divididas em:

- Amostras envenenadas de treinamento (90% dos áudios);
- Amostras envenenadas de teste (10% dos áudios).

Criar arquivos “train_list.txt” e “test_list.txt” que contenham:

- os nomes dos arquivos de áudios envenenados;
- a palavra PE em formato de fonema;
- Um número inteiro distinto para cada áudio (ID do falante).

Fine-tuning com amostra envenenada:

Hiperparâmetros do *fine-tuning*:

- batch size = 2;
- épocas = 100;

Finalizado o *fine-tuning* para um ataque (PE, PA), serão gerados dois arquivos:

- log
Extrair informações a respeito dos valores das funções de perda ao longo das épocas
- checkpoint
Contém os valores dos parâmetros do StyleTTS 2 envenenado - instanciados com *torch.load()*

***Fine-tuning* com amostra envenenada:**

Figura 36 – Método para converter texto em fonema

```
import nltk
nltk.download('punkt')
from nltk.tokenize import word_tokenize

import phonemizer
global_phonemizer = phonemizer.backend.EspeakBackend(language='en-us',
| | | | | | | | | | | | | | preserve_punctuation = True,
| | | | | | | | | | | | | | with_stress = True)

def text_to_phonemes(text):

    text = text.strip()
    ps = global_phonemizer.phonemize([text])
    ps = word_tokenize(ps[0])
    ps = ' '.join(ps)

    return ps
```

Fonte: Elaborado pelo autor.

Comando de terminal para realizar o *fine-tuning* de 1 ataque (PE, PA):

Accelerate launch --mixed_precision=fp16 --num_processes=1 train_finetune_accelerate.py --config_path <caminho do arquivo config.txt>

Figura 35 – Arquivo *train list.txt* para o ataque (no, yes)

train_list.txt

84.wav | n'ou | 1201

59.wav | n'ou | 1202

167.wav | n'ou | 1203

186.wav | n'ou | 1204

187.wav | n'ou | 1205

205.wav | n'ou | 1206

153.wav | n'ou | 1207

284.wav | n'ou | 1208

208.wav | n'ou | 1209

61.wav | n'ou | 1210

88.wav | n'ou | 1211

12.wav | n'ou | 1212

295.wav | n'ou | 1213

136.wav | n'ou | 1214

Fonte: Elaborado pelo autor.

Avaliando a eficácia do envenenamento:

Para cada ataque $[P_E, P_A]$

- Foram propostas 3 frases;
- Cada frase foi utilizada para gerar 3 áudios
 - ✓ 1 áudio gerado pelo StyleTTS 2 original (**sem envenenamento**);
 - ✓ 1 áudio gerado pelo StyleTTS 2 envenenado com **amostra de treinamento com 100 áudios envenenados**;
 - ✓ 1 áudio gerado pelo StyleTTS 2 envenenado com **amostra de treinamento com 300 áudios envenenados**.

Um total de 9 áudios gerados para cada ataque.

Questionário online  Cada participante irá avaliar 1 frase (3 áudios) por ataque

Avaliando a eficácia do envenenamento:

- Qualidade do áudio
 - MOS (*Mean Opinion Score*)

os participantes atribuirão uma nota de 1 a 5 para avaliar a qualidade do áudio

Nota 1 – áudio bastante ruidoso

Nota 5 – áudio soa como uma fala humana

cada modelo (StyleTTS 2 original e os envenenados) terá sua própria MOS

Se **MOS decresce para mais áudios envenenados no treinamento**, logo o envenenamento adaptado **degrada a qualidade de geração do StyleTTS 2**

- Verificação da troca de palavras
 - Pontuação CLAP;
 - Transcrição de áudios.

Avaliando a eficácia do envenenamento (pontuação CLAP):

$$Dif_{CLAP} = CLAP(PE, text_1) - CLAP(PE, text_2)$$

$text_1$ = “A person saying *PE*”

$text_2$ = “A person saying *PA*”

StyleTTS 2 original (sem envenenamento)  Diferença CLAP deve ser positiva

Conforme o **tamanho da amostra** de treinamento envenenada **umenta**, a **diferença CLAP** cai

- há indícios de que o StyleTTS 2 envenenado está **gerando a palavra *PA* a partir de um *prompt PE***

Avaliando a eficácia do envenenamento (transcrição de áudios):

Para cada frase de um ataque (PE, PA)

- Participante deve transcrever a frase que ele escutou no áudio;
- Se não entender, marcar como “Incompreensível”.

Comparar transcrições com frases originais e classifica-las em 3 grupos:

- Transcrições corretas (A);
- Transcrições erradas (E);
- Contéudo incompreensível (I);

$$A > E + I$$

Não houve troca, logo **envenenamento não é direcionado**

$$A \leq E + I \text{ e } E < I$$

envenenamento é destrutivo e não direcionado

$$A \leq E + I \text{ e } E > I$$

Houve troca, logo **envenenamento é direcionado**

Questionário online:

Para cada ataque (PE, PA), 1 das 3 frases é sorteada aleatoriamente para avaliação

Para cada frase sorteada, o participante deverá escutar 3 áudios gerados por:

- StyleTTS 2 original;
- StyleTTS 2 env com $N = 100$;
- StyleTTS 2 env com $N = 300$;

Figura 38 – Interface do questionário utilizado na avaliação humana

Fonte: Elaborado pelo autor.

4. Experimentos

Ambiente experimental:

Software:

- Sistema Operacional: Ubuntu 24.04 LTS 64 bits (desktop);
- Ambiente de desenvolvimento: Microsoft Visual Studio Code;
- Linguagem de programação: Python versão 3.12.

Hardware:

- Processador: Intel Core i7-12700F de 12^a geração;
- GPU: GeForce RTX 3060 Lite Hash Rate (12GB VRAM);
- Memória RAM: 64GB DDR4;
- Armazenamento: 2 TB HDD;

Ataques realizados:

Foram propostos pelo menos um ataque para todas as categorias presentes no *Speech Commands*;

O plano de avaliação consistia em usar dois tamanhos de amostra para cada ataque:

- $N = 100$ (1 minuto de áudios envenenados);
- $N = 300$ (5 minutos de áudios envenenados).

Os tamanhos escolhidos levaram em conta os seguintes critérios:

- São tamanhos adotados pelo trabalho original do *Nightshade*;
- Cenário de contaminação mais realista ao considerar ataques por *fine-tuning*;

Tipos de ataques:

Os ataques foram separados em dois grupos:

- Ataques não viáveis
 - Número insuficiente de candidatos:
etapa 3 – seleção de candidatos pelo CLAP
 - Impossibilidade de gerar áudios âncora:
etapa 5 – geração de áudios âncoras pelo StyleTTS 2
- Ataques viáveis

Todos aqueles que foram capazes de gerar amostras envenenadas de tamanhos $N = 100$ e $N = 300$ e, em seguida, efetuar o envenenamento do StyleTTS 2 pelo *fine-tuning*.

Número insuficiente de candidatos:

Tabela 5 – Comandos que apresentaram problema na etapa 3

Categoria do áudio	Número de áudios no <i>dataset</i>	Candidatos encontrados
<i>Bird</i>	2064	14
<i>Dog</i>	2128	80
<i>Follow</i>	1579	58
<i>Forward</i>	1557	47
<i>House</i>	2113	158
<i>Left</i>	3801	87
<i>Off</i>	3745	64
<i>One</i>	3890	152
<i>Right</i>	3778	82
<i>Up</i>	3723	19
<i>Visual</i>	1592	32

Fonte: Elaborada pelo autor.

11 das 35 categorias tem 90% de seus áudios descartados pelo CLAP (descarte de 31% dos ataques).

Segundo Wu* et al. (2023), esse problema ocorre devido ao **péssimo desempenho do CLAP em dados relacionados à fala humana**.

Impossibilidade de gerar áudio âncora:

O componente preditor de duração calcula qual deve ser o formato do *input* do componente decodificador

Se o componente codificador acústico de texto gerar um *embedding* de tamanho diferente:

- Geração do áudio âncora pelo StyleTTS 2 é interrompida;
- Amostras de áudios envenenados insuficientes (menores que $N = 100$ e $N = 300$).

Figura 39 – Problema de *padding* no envenenamento de “go” para “yes”

```
RuntimeError: Calculated padded input size per channel: (5 x 4).  
Kernel size: (5 x 5). Kernel size can't be greater than actual input size
```

Fonte: Elaborado pelo autor.

Impossibilidade de gerar áudio âncora:

Tabela 6 – Ataques que apresentaram problema na etapa 5

Ataques		Preditor de duração	Codificador acústico de texto	Número de pares (PE, PA) até erro
PE	PA			
<i>Cat</i>	<i>Dog</i>	(5x4)	(5x5)	147
<i>Eight</i>	<i>Paint</i>	(5x4)	(5x5)	73
<i>Go</i>	<i>Yes</i>	(5x4)	(5x5)	72
<i>Happy</i>	<i>Tree</i>	(5x3)	(5x5)	135
<i>Six</i>	<i>Seven</i>	(5x4)	(5x5)	92
<i>Two</i>	<i>Up</i>	(5x4)	(5x5)	157
<i>Yes</i>	<i>Off</i>	(5x4)	(5x5)	15
<i>Zero</i>	<i>Stop</i>	(5x3)	(5x5)	178

Fonte: Elaborada pelo autor.

Neste trabalho, o envenenamento está restrito apenas à uma palavra

- Geração de áudio pelo StyleTTS 2 fica **restrita à síntese de áudios com menos de 3 segundos de duração**

Segundo os autores do StyleTTS 2, seu modelo não possui garantia de bom desempenho para gerar áudios com duração menor que 3 segundos

Ataques viáveis:

Tabela 7 – Ataques viáveis

Ataques		Perda média		
PE	PA	Inicial	Fim da interação	Diferença
<i>Bed</i>	<i>Cat</i>	127.85	76.03	51.82
<i>Down</i>	<i>Right</i>	128.82	80.22	48.6
<i>Four</i>	<i>Five</i>	128.37	82.47	45.91
<i>Four</i>	<i>Happy</i>	121.26	68.02	53.23
<i>Nine</i>	<i>Five</i>	134.54	84.63	49.91
<i>Nine</i>	<i>Tiny</i>	126.24	70.98	55.26
<i>No</i>	<i>Yes</i>	117.4	69.19	48.21
<i>Stop</i>	<i>Go</i>	127	78.05	48.95
<i>Tree</i>	<i>Destroy</i>	117.12	60.21	56.91

Fonte: Elaborada pelo autor.

Ao todo, 9 ataques viáveis.

Ataques viáveis:

Tempo para se envenenar **um áudio de 1 segundo** → 2 minutos e 30 segundos

Tempo para se envenenar **amostra de áudios N = 100** → 3 horas e 20 minutos

Tempo para se envenenar **amostra de áudios N = 300** → 10 horas

Observação: Modelos de TTS são **treinados com amostras com horas de áudio**


Tempo estimado para se envenenar amostra de treinamento com **1 hora de áudios** → aproximadamente, 5 dias

Esse alto custo de tempo está **atrelado ao processo de otimização de ruídos de 500 interações**

- A aproximação dos áudios envenados (Aud_E) e âncora (Aud_A) começa a partir da interação 200

Ataques viáveis:

Figura 40 – Perda média obtida durante a fase de adição de ruídos no ataque (*bed*, *cat*)



Fonte: Elaborado pelo autor.

Esse comportamento se repete para os 9 ataques possíveis

A aproximação entre os espectrogramas de log-mel dos áudios alvo de envenenamento e âncora começa a ocorrer a partir da interação 200

Ataques viáveis:

A figura da esquerda dá indícios de que:


Qualidade de envenenados é **menor** do que os originais

A ser confirmada pelo estudo da MOS

A figura da direita mostra que:


Conceitos âncoras diferentes geram áudios envenenados diferentes

Figura 41 – Comparando as ondas originais e as envenenadas do áudio “bed”



Fonte: Elaborado pelo autor.

Figura 42 – Comparando onda do áudio “four” antes e depois do envenenamento com âncoras “five” e “happy”



Fonte: Elaborado pelo autor.

Ataques viáveis (funções de perda durante *fine-tuning*):

Analisar o comportamento da função de perda trará informação sobre 2 aspectos:

- Se a inserção de dados envenenados durante o *fine-tuning* provocará o **desaprendimento de informações do StyleTTS 2**;
- A **furtividade do ataque** perante avaliação humana.

Comportamento crescente e cheio de picos da função de perda:


- O *Nightshade* adaptado faz o StyleTTS 2 **desaprender informações**;
- O *Nightshade* adaptado é **facilmente detectável por avaliação humana** (não furtivo)

Problema: Redução na qualidade do áudio ou alteração do conteúdo semântico?

- Que tipo de desaprendimento está ocorrendo?

Será necessária observar as transcrições dos áudios


Ataques viáveis (funções de perda durante *fine-tuning*):



Fonte: Elaborado pelo autor.

StyleTTS 2 envenenado com amostra N = 100

O comportamento crescente da **perda do gerador** ocorre nos 9 ataques possíveis



Fonte: Elaborado pelo autor.

StyleTTS 2 envenenado com amostra N = 300

Nightshade adaptado não é furtivo

Nightshade adaptado provoca desaprendimento no StyleTTS 2

Ataques viáveis (respostas coletadas):

Neste trabalho, **36 pessoas** realizaram a avaliação dos áudios por meio do questionário online

As respostas coletadas foram organizadas em duas tabelas (para cada um dos 9 ataques):

- Uma que **contém a diferença CLAP e valor MOS** para os 3 modelos (original, env100 e env300);
- Outra que **contabiliza a quantidade de transcrições de áudio corretas (A), erradas (E) e incompreensíveis (I)** para as 3 frases de avaliação geradas por cada modelo

Optou-se por apresentar somente as transcrições erradas

- indicam se o *Nightshade* adaptado é dicerionado

Ataques viáveis (exemplo tabela):

Queda drástica do MOS e a prevalência de áudios incompreensíveis apontam para:

Envenenamento adaptado destrutivo

Pode ter relação com o uso do método de Griffin-Lim

- As múltiplas interações de projeções pode aumentar ruídos colocados no espectograma de log-mel do áudio (KONG; KIN; BAE, 2020)
- Ruídos de envenenamento são amplificados a ponto de abafarem a própria fala

Tabela 22 – Pontuação CLAP e MOS para o ataque (*stop, go*)

StyleTTS 2	Pontuação CLAP		Diferença CLAP	MOS
	Stop	Go		
Original	0.222	0.112	+0.110	4.33
Envenenado_100	0.339	0.218	+0.121	2.10
Envenenado_300	0.269	0.165	+0.104	1.82

Fonte: Elaborada pelo autor.

Tabela 23 – Número de acertos, erros e de incompreensão acerca da transcrição dos áudios gerados pelo StyleTTS 2 após o envenenamento (*stop, go*)

Transcrição do áudio	Original			Enve 100			Enve 300		
	A	E	I	A	E	I	A	E	I
<i>Stop stop stop</i>	16	0	0	16	0	0	16	0	0
<i>Can you stop this?</i>	10	0	0	2	1	7	0	2	8
<i>You can't stop now</i>	10	0	0	4	1	5	0	2	8

Fonte: Elaborada pelo autor.

As transcrições erradas registradas para esse ataque são:

- *Can you stop this?* : "tell don't stop us", "no don't stop don't", "stop dance stop dance";
- *You can't stop now* : "do don't stop down", "so don't stop don't".

Ataques viáveis (exemplo tabela):

Tabela 14 – Pontuação CLAP e MOS para o ataque (*four, happy*)

StyleTTS 2	Pontuação CLAP		Diferença CLAP	MOS
	<i>Four</i>	<i>Happy</i>		
Original	0.453	0.049	+0.404	4.66
Envenenado_100	0.444	0.057	+0.388	2.48
Envenenado_300	0.346	0.03	+0.316	1.91

Fonte: Elaborada pelo autor.

Queda drástica do MOS aponta para:

Envenenamento adaptado destrutivo

Tabela 15 – Número de acertos, erros e de incompreensão acerca da transcrição dos áudios gerados pelo StyleTTS 2 após o envenenamento (*four, happy*)

Transcrição do áudio	Original			Enve 100			Enve 300		
	A	E	I	A	E	I	A	E	I
<i>Three four five</i>	11	0	0	0	8	3	0	9	2
<i>I have four cards to trade</i>	10	6	0	5	8	3	1	8	7
<i>I scored a four in math class</i>	9	0	0	1	3	5	0	2	7

Fonte: Elaborada pelo autor.


Bastantes transcrições erradas apontam para:

Envenenamento adaptado direcionado

Ataques viáveis (exemplo tabela):

- *Three four five* : “three four four”, “four four four”, “through four ford”, “through four fourth”, “floor four ford”;
- *I have four cards to trade* : “i have four cars to trade”, “i have four chords to trade”, “i have four pour to trade”, “i have four horts to trade”, “i have four fours to trade”, “i have four fords to trade”, “i have four accords to trade”, “check out four chords to print”, “four four, this train”, “i have four cards to train”, “i have four cards to train”, “four fours to trade”, “i have four horse to threat”;
- *I scored a four in math class* : “four four, in the way”, “four four in my cloth”, “a four a four”, “my score are four in march watch”.

- Não houve troca de “four” por “happy”
- Outras palavras (diferentes de “four”) foram trocadas



**Envenenamento adaptado
não é direcionado**

Ataques viáveis (MOS negativo no StyleTTS 2 não envenenado):

Tabela 8 – Pontuação CLAP e MOS para o ataque (*bed, cat*)

StyleTTS 2	Pontuação CLAP		Diferença CLAP	MOS
	<i>Bed</i>	<i>Cat</i>		
Original	0.069	0.198	- 0.130	4.65
Envenenado_100	0.185	0.086	+0.099	2.75
Envenenado_300	0.134	0.144	- 0.010	1.27

Fonte: Elaborada pelo autor.

Tabela 10 – Pontuação CLAP e MOS para o ataque (*down, right*)

StyleTTS 2	Pontuação CLAP		Diferença CLAP	MOS
	<i>Down</i>	<i>Right</i>		
Original	0.185	0.23	- 0.044	4.27
Envenenado_100	0.243	0.251	- 0.007	2.15
Envenenado_300	0.302	0.282	+0.020	1.62

Fonte: Elaborada pelo autor.

Tabela 16 – Pontuação CLAP e MOS para o ataque (*nine, five*)

StyleTTS 2	Pontuação CLAP		Diferença CLAP	MOS
	<i>Nine</i>	<i>Five</i>		
Original	0.392	0.415	- 0.023	4.5
Envenenado_100	0.406	0.48	- 0.074	2.58
Envenenado_300	0.035	0.012	+0.023	1.43

Fonte: Elaborada pelo autor.

Tabela 20 – Pontuação CLAP e MOS para o ataque (*no, yes*)

StyleTTS 2	Pontuação CLAP		Diferença CLAP	MOS
	<i>No</i>	<i>Yes</i>		
Original	0.396	0.407	- 0.011	4.67
Envenenado_100	0.426	0.441	- 0.015	2.88
Envenenado_300	0.44	0.457	- 0.017	2.33

Fonte: Elaborada pelo autor.

Tabela 24 – Pontuação CLAP e MOS para o ataque (*tree, destroy*)

StyleTTS 2	Pontuação CLAP		Diferença CLAP	MOS
	<i>Tree</i>	<i>Destroy</i>		
Original	0.101	0.213	- 0.112	4.47
Envenenado_100	0.092	0.229	- 0.138	2.85
Envenenado_300	0.097	0.277	- 0.18	2.17

Fonte: Elaborada pelo autor.

O modelo CLAP escolhido para este trabalho **não é um bom avaliador para determinar se um envenenamento é direcionado ou não**

5. Conclusão

Conclusão:

Os principais resultados deste trabalho indicam que **a adaptação do Nightshade para áudio falhou** em seus objetivos, além de expor limitações nas ferramentas utilizadas:

Falha no ataque direcionado:

Não trocou palavras-alvo;

Degradou severamente a qualidade geral do StyleTTS 2.

- Rápido decrescimento dos valores MOS;
- Transcrições de áudios incompreensíveis.

Falha na furtividade:

O ataque é facilmente detectado pela percepção humana.

- Crescimento da função de perda do gerador (componente do StyleTTS 2).

Conclusão:

Custo Computacional:

A adaptação proposta demora 10 horas para envenenar 5 minutos de áudio;

Com estimativa de 5 dias para envenenar 1 hora de áudio.

- GPU GeForce RTX 3060 LTS.

Limitação do CLAP:

O modelo CLAP pré-treinado de Wu* et al. (2023) mostrou-se ineficiente para a fala humana.

- Não encontrou candidatos suficientes em 11 de 35 categorias do *Speech Commands*;
- Valores negativos da “diferença CLAP” para áudios gerados pelo StyleTTS 2 não envenenado.

Conclusão:

Limitação do StyleTTS 2:

O modelo StyleTTS 2 de Li et al. (2023) confirmou sua inconsistência com áudios de curta duração (3 segundos ou menos).

- O preditor de duração gerou matrizes incompatíveis;
- 8 ataques foram descartados;

Limitação do Griffin-Lim:

As observações de Kong, Kin e Bae (2020) sugerem que o Griffin-Lim foi o agente causador da alta distorção nos áudios.

- Amplificação do efeito das perturbações adversariais durante a síntese do áudio em forma de onda;

Conclusão:

Em suma, a adaptação proposta do *Nightshade* para envenenamento de áudios falhou em atingir seus objetivos.

O método adaptado mostrou-se:


- destrutivo;
- detectável;
- não direcionado;

Conclusão:

Em suma, a adaptação proposta do *Nightshade* para envenenamento de áudios falhou em atingir seus objetivos.

O método adaptado mostrou-se:

- destrutivo;
- detectável;
- não direcionado;




Resultados opostos aqueles
obtidos pelo *Nightshade* original

Conclusão:

Em suma, a adaptação proposta do *Nightshade* para envenenamento de áudios falhou em atingir seus objetivos.

O método adaptado mostrou-se:

- destrutivo;
- detectável;
- não direcionado;



Resultados opostos aqueles
obtidos pelo *Nightshade* original

Dessa forma, conclui-se que o alto custo computacional e as inadequações das ferramentas escolhidas (CLAP, StyleTTS 2 e Griffin-Lim) foram os fatores que impediram o êxito da abordagem.

Trabalhos futuros:

- Retreinar o modelo CLAP apenas com fala humana e suas transcrições;
- Trocar o algoritmo de Griffin-Lim por *vocoders*, sugestão de (KONG; KIN; BAE, 2020);
- Explorar outros modelos TTS de código aberto para geração de áudios âncoras;
- Testar envenenamento em frases completas – aplicando o ataque a palavras específicas dentro de um contexto, ao invés de palavras isoladas;
- Investigar os fundamentos legais e éticos da “autodefesa de dados” – definindo (i) quais os agentes sociais têm o direito de aplicar o envenenamento e (ii) em quais circunstâncias essa ação é considerada uma proteção legítima;
- Analisar o impacto social e de segurança de um ataque de envenenamento bem-sucedido a partir de casos reais;
- Discutir políticas de governança para a pesquisa em segurança de IA;

Referências

- AGHAKHANI, H.; SCHÖNHERR, L.; EISENHOFER, T.; KOLOSSA, D.; HOLZ, T.; KRUEGEL, C.; VIGNA, G. *VenoMave: Targeted Poisoning Against Speech Recognition*. 2023. Disponível em: <https://arxiv.org/abs/2010.10682>. Acesso em: 20 out. 2025.
- ALLEN, J. B.; RABINER, L. R. A unified approach to short-time fourier analysis and synthesis. *Proceedings of the IEEE*, IEEE, New York, v. 65, n. 11, p. 1558–1564, 1977.
- ALMUJALLY, N. A.; KHAN, D.; MUDAWI, A.; ALONAZI, A.; ALAZEB, A.; ALGARNI, A.; LIU, H. Biosensor-driven iot wearables for accurate body motion tracking and localization. *Sensors*, v. 24, n. 10, p. 3032, 2024. Disponível em: <https://www.mdpi.com/1424-8220/24/10/3032>. Acesso em: 20 out. 2025.
- BAKHSI, A.; SINGH, S.; KUMAR, A. Violence detection in real-life audio signals using lightweight deep neural networks. *Procedia Computer Science*, v. 187, p. 122–129, 2023. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1877050923009274>. Acesso em: 20 out. 2025.
- BHUVANAGIRI, K. K.; KOPPARAPU, S. K. *Modified Mel Filter Bank to Compute MFCC of Subsampled Speech*. 2014. Disponível em: <https://arxiv.org/abs/1410.7382>. Acesso em: 20 out. 2025.
- CHEN, G.; FENG, S.-w.; KIM, W.-h.; QU, S.; LIU, T.; YIN, X.-c. BadTTS: a backdoor attack against text-to-speech models. In: *Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. Toronto: IEEE, 2021. p. 2660–2664.

CHEN, H.; MAGRAMO, K. *Finance worker pays out \$25 million after video call with deepfake 'chief financial officer'*. 2024. CNN World. Asia. Disponível em: <https://edition.cnn.com/2024/02/04/asia/deepfake-cfo-scam-hong-kong-intl-hnk/index.html>. Acesso em: 19 out. 2025.

CIAPESSONI, G. G. *Mel-frequency filterbank*. 2017. Documentação da biblioteca pyfilterbank. Disponível em: <https://siggigue.github.io/pyfilterbank/melbank.html>. Acesso em: 3 out. 2025.

COLLINS, K. *Game Sound: An introduction to the history, theory, and practice of video game music and sound design*. Cambridge: The MIT Press, 2008. ISBN 978-0262270694.

Damien's Blog. *Blog 6 - The properties of Digital Images VS those of Digital Audio*. 2012. Disponível em: <https://damienoleary.wordpress.com/2012/11/18/blog-6-the-properties-of-digital-images-vs-those-of-digital-audio/>. Acesso em: 30 set. 2025.

Digital Audio Wiki. *Bit Depth*. 2014. Disponível em: https://digital-audio.fandom.com/wiki/Bit_Depth. Acesso em: 30 set. 2025.

Digital Sound & Music. *Mathematics and Algorithms for Aliasing*. s.d. Disponível em: <https://digitalsoundandmusic.com/5-3-4-mathematics-and-algorithms-for-aliasing/>. Acesso em: 30 set. 2025.

- DONAHUE, C.; MCAULEY, J.; PUCKETTE, M. *Adversarial Audio Synthesis*. 2019. Disponível em: <https://arxiv.org/abs/1802.04208>. Acesso em: 20 out. 2025.
- EL-KHASAWNEH, M.; AL-ADWAN, M. A. S.; SMADI, M. A.; AL-ZOUBI, R. An overview of quantum computing and its impact on communication systems. *Journal of Combinatorial Optimization*, Springer US, v. 49, 2025.
- GANGWAL, A.; ANSARI, A.; AHMAD, I.; AZAD, A. K.; KUMARASAMY, V.; SUBRAMANIYAN, V.; WONG, L. S. Generative artificial intelligence in drug discovery: basic framework, recent advances, challenges, and opportunities. *Frontiers in Pharmacology*, v. 15, p. 1331062, 2024. ISSN 1663-9812.
- GAYED, J. M.; CARLON, M. K. J.; ORIOLA, A. M.; CROSS, J. S. Exploring an ai-based writing assistant's impact on english language learners. *Computers and Education: Artificial Intelligence*, v. 3, p. 100055, 2022. ISSN 2666-920X.
- GE, Y.; WANG, Q.; ZHANG, J.; ZHOU, J.; ZHANG, Y.; SHEN, C. *WaveFuzz: A Clean-Label Poisoning Attack to Protect Your Voice*. 2022. Disponível em: <https://arxiv.org/abs/2203.13497>. Acesso em: 20 out. 2025.
- GRIFFIN, D. W.; LIM, J. S. Signal estimation from modified short-time fourier transform. *IEEE Transactions on Acoustics, Speech, and Signal Processing*, v. 32, n. 2, p. 236–243, 1984.
- GUO, Z.; LANG, J.; HUANG, S.; GAO, Y.; DING, X. *A Comprehensive Review on Noise Control of Diffusion Model*. 2025. Disponível em: <https://arxiv.org/abs/2502.04669>. Acesso em: 20 out. 2025.

- HASEGAWA-JOHNSON, M. *Lecture 6: Griffin-Lim Algorithm*. 2023. Notas de aula. Material da disciplina ECE 417: Multimedia Signal Processing, Outono de 2023. Disponível em: <https://courses.grainger.illinois.edu/ece417/fa2023/lectures.html>. Acesso em: 20 out. 2025.
- HO, J.; JAIN, A.; ABBEEL, P. *Denoising Diffusion Probabilistic Models*. 2020. Disponível em: <https://arxiv.org/abs/2006.11239>. Acesso em: 20 out. 2025.
- HUANG, C.-W.; LIM, J. H.; COURVILLE, A. *A Variational Perspective on Diffusion-Based Generative Models and Score Matching*. 2021. Disponível em: <https://arxiv.org/abs/2106.02808>. Acesso em: 20 out. 2025.
- HUBER, D. M. *Modern Recording Techniques*. 9. ed. New York: Routledge, 2017. ISBN 978-1138954373.
- ITO, K.; JOHNSON, L. *The LJ Speech Dataset*. 2017. Disponível em: <https://keithito.com/LJ-Speech-Dataset/>. Acesso em: 20 out. 2025.
- KARRAS, T.; AITTALA, M.; AILA, T.; LAINE, S. *Elucidating the Design Space of Diffusion-Based Generative Models*. 2022. Disponível em: <https://arxiv.org/abs/2206.00364>. Acesso em: 20 out. 2025.
- KIM, J.; KONG, J.; SON, J. *Conditional Variational Autoencoder with Adversarial Learning for End-to-End Text-to-Speech*. 2021. Disponível em: <https://arxiv.org/abs/2106.06103>. Acesso em: 20 out. 2025.

KONG, J.; KIM, J.; BAE, J. *HiFi-GAN: Generative Adversarial Networks for Efficient and High Fidelity Speech Synthesis*. 2020. Disponível em: <https://arxiv.org/abs/2010.05646>.

KREUK, F.; SYNNAEVE, G.; POLYAK, A.; SINGER, U.; DÉFOSSEZ, A.; COPET, J.; PARIKH, D.; TAIGMAN, Y.; ADI, Y. *AudioGen: Textually Guided Audio Generation*. 2023. Disponível em: <https://arxiv.org/abs/2209.15352>.

LACERDA, T.; MIRANDA, P.; CÂMARA, A.; FURTADO, A. Deep learning and mel-spectrograms for physical violence detection in audio. In: *Anais do XVIII Encontro Nacional de Inteligência Artificial e Computacional*. Porto Alegre, RS, Brasil: SBC, 2021. p. 268–279. ISSN 2763-9061. Disponível em: <https://sol.sbc.org.br/index.php/eniac/article/view/18259>. Acesso em: 30 set. 2025.

LATHI, B. P.; DING, Z. *Modern Digital and Analog Communication Systems*. 5. ed. New York: Oxford University Press, 2018. ISBN 978-0190686840.

LI, Y. A.; HAN, C.; MESGARANI, N. *StyleTTS: A Style-Based Generative Model for Natural and Diverse Text-to-Speech Synthesis*. 2023. Disponível em: <https://arxiv.org/abs/2205.15439>. Acesso em: 20 out. 2025.

LI, Y. A.; HAN, C.; RAGHAVAN, V. S.; MISCHLER, G.; MESGARANI, N. *StyleTTS 2: Towards Human-Level Text-to-Speech through Style Diffusion and Adversarial Training with Large Speech Language Models*. 2023. Disponível em: <https://arxiv.org/abs/2306.07691>. Acesso em: 20 out 2025.

LU, C.; ZHOU, Y.; BAO, F.; CHEN, J.; LI, C.; ZHU, J. *DPM-Solver: A Fast ODE Solver for Diffusion Probabilistic Model Sampling in Around 10 Steps*. 2022. Disponível em: <https://arxiv.org/abs/2206.00927>. Acesso em: 20 out. 2025.

MACHADO, S. 'Eram meu rosto e minha voz, mas era golpe': como criminosos 'clonam pessoas' com inteligência artificial. 2024. BBC NEWS Brasil. Disponível em: <https://www.bbc.com/portuguese/articles/cd1jv45dq3go>. Acesso em: 19 out. 2025.

MASUYAMA, Y.; UENO, N.; ONO, N. *Signal Reconstruction from Mel-spectrogram Based on Bi-level Consistency of Full-band Magnitude and Phase*. 2023. Disponível em: <https://arxiv.org/abs/2307.12232>. Acesso em: 20 out. 2025.

Math Works. *Short-time Fourier transform*. 2025. Disponível em: <https://www.mathworks.com/help/dsp/ref/dsp.stft.html>. Acesso em: 2 out. 2025.

NGUYEN, T. T.; NGUYEN, Q. V. H.; NGUYEN, D. T.; NGUYEN, D. T.; HUYNH-THE, T.; NAHAVANDI, S.; NGUYEN, T. T.; PHAM, Q.-V.; NGUYEN, C. M. Deep learning for deepfakes creation and detection: A survey. *Computer Vision and Image Understanding*, Elsevier BV, v. 223, p. 103525, out. 2022. ISSN 1077-3142.

OPPENHEIM, A. V.; SCHAFER, R. W. Processamento em tempo discreto de sinais. In: _____. 3. ed. São Paulo: Pearson Education do Brasil, 2012. cap. 9, p. 694–811. ISBN 978-8581431024.

PHAM, L.; LAM, P.; NGUYEN, T.; NGUYEN, H.; SCHINDLER, A. *Deepfake Audio Detection Using Spectrogram-based Feature and Ensemble of Deep Learning Models*. 2024. ArXiv preprint. Disponível em: <https://arxiv.org/abs/2407.01777>.

- POHLMANN, K. C. *Principles of Digital Audio*. 6. ed. New York: McGraw-Hill, 2010. ISBN 978-0071663472.
- QUEIROZ, G. 'Deepfake' de voz e desinformação em áudio se espalham pelo WhatsApp e desafiam checagem nas eleições. 2024. DW Brasil. Disponível em: <https://www.dw.com/pt-br/uso-de-ia-pode-ser-uma-amea%C3%A7a-no-brasil-%C3%A0s-v%C3%A9speras-da-elei%C3%A7%C3%A3o/a-69891136>. Acesso em: 19 out. 2025.
- RADFORD, A.; KIM, J. W.; HALLACY, C.; RAMESH, A.; GOH, G.; AGARWAL, S.; SASTRY, G.; ASKELL, A.; MISHKIN, P.; CLARK, J.; KRUEGER, G.; SUTSKEVER, I. *Learning Transferable Visual Models From Natural Language Supervision*. 2021. Disponível em: <https://arxiv.org/abs/2103.00020>. Acesso em: 20 out. 2025.
- REISS, T.; CAVIA, B.; HOSHEN, Y. *Detecting Deepfakes Without Seeing Any*. 2023. Disponível em: <https://arxiv.org/abs/2311.01458>. Acesso em: 20 out. 2025.
- ROMBACH, R.; BLATTMANN, A.; LORENZ, D.; ESSER, P.; OMMER, B. *High-Resolution Image Synthesis with Latent Diffusion Models*. 2022. Disponível em: <https://arxiv.org/abs/2112.10752>. Acesso em: 20 out. 2025.
- SANTOS, E. *O que os nudes falsos em Itararé ensinam sobre o aumento de casos de deepfakes pornográficos em escolas*. 2024. G1. Disponível em: <https://g1.globo.com/educacao/noticia/2024/10/11/o-que-os-nudes-falsos-em-itarare-ensinam-sobre-o-aumento-de-casos-de-deepfakes-pornograficos-em-escolas.ghtml>. Acesso em: 19 out. 2025.

SCHUHMANN, C.; BEAUMONT, R.; VENCU, R.; GORDON, C.; WIGHTMAN, R.; CHERTI, M.; COOMBES, T.; KATTA, A.; MULLIS, C.; WORTSMAN, M.; SCHRAMOWSKI, P.; KUNDURTHY, S.; CROWSON, K.; SCHMIDT, L.; KACZMARCZYK, R.; JITSEV, J. *LAION-5B: An open large-scale dataset for training next generation image-text models*. 2022. Disponível em: <https://arxiv.org/abs/2210.08402>. Acesso em: 1 set. 2025.

SHAN, S.; DING, W.; PASSANANTI, J.; WU, S.; ZHENG, H.; ZHAO, B. Y. *Nightshade: Prompt-Specific Poisoning Attacks on Text-to-Image Generative Models*. 2024. Disponível em: <https://arxiv.org/abs/2310.13828>. Acesso em: 1 set. 2025.

SHEN, K.; JU, Z.; TAN, X.; LIU, Y.; LENG, Y.; HE, L.; QIN, T.; ZHAO, S.; BIAN, J. *NaturalSpeech 2: Latent Diffusion Models are Natural and Zero-Shot Speech and Singing Synthesizers*. 2023. Disponível em: <https://arxiv.org/abs/2304.09116>. Acesso em: 20 out. 2025.

SKLAR, B. *Digital Communications: Fundamentals and Applications*. 2. ed. [S.l.]: Prentice Hall, 2001. ISBN 978-0130847881.

SOHL-DICKSTEIN, J.; WEISS, E. A.; MAHESWARANATHAN, N.; GANGULI, S. *Deep Unsupervised Learning using Nonequilibrium Thermodynamics*. 2015. Disponível em: <https://arxiv.org/abs/1503.03585>. Acesso em: 20 out. 2025.

SONG, Y.; SOHL-DICKSTEIN, J.; KINGMA, D. P.; KUMAR, A.; ERMON, S.; POOLE, B. *Score-Based Generative Modeling through Stochastic Differential Equations*. 2021. Disponível em: <https://arxiv.org/abs/2011.13456>. Acesso em: 20 out. 2025.

STEVENS, S. S.; VOLKMANN, J.; NEWMAN, E. B. A scale for the measurement of the psychological magnitude of pitch. *The Journal of the Acoustical Society of America*, v. 8, n. 3, p. 185–190, 1937.

VASWANI, A.; SHAZEER, N.; PARMAR, N.; USZKOREIT, J.; JONES, L.; GOMEZ, A. N.; KAISER, L.; POLOSUKHIN, I. *Attention Is All You Need*. 2017. Disponível em: <https://arxiv.org/abs/1706.03762>. Acesso em: 20 out. 2025.

WANG, C.; CHEN, S.; WU, Y.; ZHANG, Z.; ZHOU, L.; LIU, S.; CHEN, Z.; LIU, Y.; WANG, H.; LI, J.; HE, L.; ZHAO, S.; WEI, F. *Neural Codec Language Models are Zero-Shot Text to Speech Synthesizers*. 2023. Disponível em: <https://arxiv.org/abs/2301.02111>. Acesso em: 20 out. 2025.

WANG, R.; CAO, Y.; HAN, K.; WONG, K.-Y. K. A survey on 3d human avatar modeling – from reconstruction to generation. 2024. Disponível em: <https://arxiv.org/abs/2406.04253>. Acesso em: 25 out. 2024.

WARDEN, P. *Speech Commands: A Dataset for Limited-Vocabulary Speech Recognition*. 2018. Disponível em: <https://arxiv.org/abs/1804.03209>. Acesso em: 20 out. 2025.

WATKINSON, J. *The Art of Digital Audio*. 3. ed. Oxford: Focal Press, 2001. ISBN 978-0240515878.

WU*, Y.; CHEN*, K.; ZHANG*, T.; HUI*, Y.; BERG-KIRKPATRICK, T.; DUBNOV, S. *Large-scale Contrastive Language-Audio Pretraining with Feature Fusion and Keyword-to-Caption Augmentation*. 2023. Disponível em: <https://arxiv.org/abs/2211.06687>. Acesso em: 31 aug. 2025.

YAMAGISHI, J.; VEAUX, C.; MACDONALD, K. Cstr vctk corpus: English multi-speaker corpus for cstr voice cloning toolkit (version 0.92). In: . [S.l.: s.n.], 2019. Disponível em: <https://api.semanticscholar.org/CorpusID:213060286>. Acesso em: 20 out. 2025.

ZEN, H.; DANG, V.; CLARK, R.; ZHANG, Y.; WEISS, R. J.; JIA, Y.; CHEN, Z.; WU, Y. *LibriTTS: A Corpus Derived from LibriSpeech for Text-to-Speech*. 2019. Disponível em: <https://arxiv.org/abs/1904.02882>. Acesso em: 19 out. 2025.

ZHANG, C.; ZHANG, C.; ZHENG, S.; ZHANG, M.; QAMAR, M.; BAE, S.-H.; KWEON, I. S. *A Survey on Audio Diffusion Models: Text To Speech Synthesis and Enhancement in Generative AI*. 2023. Disponível em: <https://arxiv.org/abs/2303.13336>. Acesso em: 30 set. 2025.

ZHANG, J.; JAYASURIYA, S.; BERISHA, V. Restoring degraded speech via a modified diffusion model. In: *Interspeech 2021*. ISCA, 2021. p. 221–225. Disponível em: <http://dx.doi.org/10.21437/Interspeech.2021-1889>.

ZHANG, R.; ISOLA, P.; EFROS, A. A.; SHECHTMAN, E.; WANG, O. The unreasonable effectiveness of deep features as a perceptual metric. 2018. Disponível em: <http://arxiv.org/abs/1801.03924>. Acesso em: 12 set. 2025.

ZHANG, Y.; IKEMIYA, Y.; XIA, G.; MURATA, N.; MARTÍNEZ-RAMÍREZ, M. A.; LIAO, W.-H.; MITSUFUJI, Y.; DIXON, S. *MusicMagus: Zero-Shot Text-to-Music Editing via Diffusion Models*. 2024. Disponível em: <https://arxiv.org/abs/2402.06178>. Acesso em: 16 set. 2025. Disponível em: <https://arxiv.org/abs/2402.06178>.

Obrigado pela atenção!