

---

# Uso de aprendizado de máquina para detecção de faces falsas geradas por inteligência artificial

---

João Pedro Vieira Rodrigues, 201022613

Orientador: Prof. Dr. Kelton Augusto Pontara da Costa

Bacharelado em Ciência da Computação - UNESP / Bauru

---

# INTRODUÇÃO


---

# PROBLEMA

O avanço da inteligência artificial permitiu a criação de rostos falsos através de algoritmos, acarretando problemas como:



CRIAÇÃO DE  
NOTÍCIAS  
FALSAS



ATAQUES CIBERNÉTICOS



CRIAÇÃO DE  
PERFIS  
FALSOS

# JUSTIFICATIVA

## Principais motivações do trabalho:

- Área da segurança digital em alta
- O aprendizado de máquina é uma alternativa para resolver o problema

# OBJETIVOS

- **Objetivo Geral:**

Avaliar o desempenho da Capsule Neural Network na classificação de faces falsas.

- **Objetivos Específicos**

1. Estudar e implementar a Capsule Neural Network
2. Treinar essa rede para reconhecer faces falsas e verdadeiras
3. Interpretar os dados gerados pelo treinamento
4. Comparação do seu desempenho com outras técnicas

---

# FUNDAMENTAÇÃO TEÓRICA


---

# GENERATIVE ADVERSARIAL NETWORK

- Publicado em 2014 por Ian Goodfellow no artigo "*Generative Adversarial Network*"
- Algoritmo utilizado para criação das imagens falsas do banco de dados

# GENERATIVE ADVERSARIAL NETWORK

- Representação de uma GAN




# CAPSULE NEURAL NETWORK

- Proposta em 2017 no artigo "*Dynamic routing between capsules*"
- Utiliza o conceito de cápsulas para extração de características de uma imagem

# CAPSULE NEURAL NETWORK

- Representação da CapsNet




# FUNÇÃO DE ATIVAÇÃO

**Sigmoid:**

Fórmula:

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$



# MÉTRICAS DE AVALIAÇÃO

As métricas utilizadas no trabalho foram a acurácia e precisão

Acurácia

$$\frac{VP + VN}{VP + VN + FN + FP}$$

Precisão

$$\frac{VP}{VP + FP}$$

---

# METODOLOGIA

---

# BANCO DE DADOS

**Banco de dados de 140 mil imagens de rostos falsos e verdadeiros do site Kaggle**

- 70 mil rostos falsos criados pela Style-GAN
- 70 mil rostos verdadeiros retirados do site Flickr

# BANCO DE DADOS



**Imagem falsa**



**Imagem real**

# TREINAMENTO, VALIDAÇÃO E TESTE

As imagens foram divididas de acordo com a tabela:

|                    | <b>Rostos Reais</b> | <b>Rostos Falsos</b> |
|--------------------|---------------------|----------------------|
| <b>Treinamento</b> | 50 mil imagens      | 50 mil imagens       |
| <b>Validação</b>   | 10 mil imagens      | 10 mil imagens       |
| <b>Teste</b>       | 10 mil imagens      | 10 mil imagens       |

---

# RESULTADOS

---


# TREINAMENTO E VALIDAÇÃO

| Época | Perda de Treinamento | Perda de Validação | Acurácia |
|-------|----------------------|--------------------|----------|
| 1     | 0.0348               | 0.0257             | 0.7316   |
| 2     | 0.0236               | 0.0215             | 0.7939   |
| 3     | 0.0202               | 0.0196             | 0.8201   |
| 4     | 0.0182               | 0.0189             | 0.8304   |
| 5     | 0.0166               | 0.0164             | 0.8602   |
| 6     | 0.0155               | 0.0154             | 0.8745   |
| 7     | 0.0145               | 0.0150             | 0.8798   |
| 8     | 0.0137               | 0.0174             | 0.8380   |
| 9     | 0.0130               | 0.0138             | 0.8951   |
| 10    | 0.0124               | 0.0139             | 0.8918   |
| 11    | 0.0119               | 0.0136             | 0.8972   |
| 12    | 0.0114               | 0.0127             | 0.9063   |
| 13    | 0.0110               | 0.0128             | 0.9072   |
| 14    | 0.0106               | 0.0124             | 0.9098   |
| 15    | 0.0102               | 0.0127             | 0.9091   |
| 16    | 0.0099               | 0.0129             | 0.9055   |
| 17    | 0.0097               | 0.0126             | 0.9114   |
| 18    | 0.0094               | 0.0120             | 0.9101   |
| 19    | 0.0092               | 0.0117             | 0.9170   |
| 20    | 0.0090               | 0.0117             | 0.9159   |
| 21    | 0.0087               | 0.0120             | 0.9123   |
| 22    | 0.0085               | 0.0117             | 0.9166   |
| 23    | 0.0083               | 0.0116             | 0.9144   |
| 24    | 0.0081               | 0.0114             | 0.9207   |
| 25    | 0.0080               | 0.0116             | 0.9164   |

- Época com menor perda de treinamento: 25
- Época com menor perda de validação: 24
- Época com a melhor acurácia: 24


# TREINAMENTO E VALIDAÇÃO

Gráfico das acurácias durante as épocas



# TREINAMENTO E VALIDAÇÃO

Gráfico das perdas durante as épocas



# TESTE

## Matriz de confusão

|            |          | Valor Predito |          |
|------------|----------|---------------|----------|
|            |          | Positivo      | Negativo |
| Valor Real | Positivo | 8649          | 976      |
| Valor Real | Negativo | 650           | 9725     |

## Métricas

*Precisão* = 93.01%

*Acurácia* = 91.87%

# COMPARAÇÃO

Comparação da CapsNet com as técnicas do artigo  
(WANG; ZARGHAMI; CUI, 2021)


| Modelos  | Acurácia | Precisão |
|----------|----------|----------|
| CapsNet  | 91.87    | 93.01    |
| Res-Net  | 98.67    | 99.12    |
| Gram-Net | 98.71    | 98.98    |
| LBP-Net  | 98.58    | 98.96    |

---


# CONCLUSÃO

---

# TRABALHOS FUTUROS



**Qualidade da  
imagem**



**Banco de dados  
diferente**

# REFERÊNCIAS

GOODFELLOW, I. J.; POUGET-ABADIE, J.; MIRZA, M.; XU, B.; WARDE-FARLEY, D.; OZAIR, S.; COURVILLE, A.; BENGIO, Y. GENERATIVE ADVERSARIAL NETWORKS. 2014.

WANG, Y.; ZARGHAMI, V.; CUI, S. FAKE FACE DETECTION USING LOCAL BINARY PATTERN AND ENSEMBLE MODELING. IN: 2021 IEEE INTERNATIONAL CONFERENCE ON IMAGE PROCESSING (ICIP). [S.L.: S.N.], 2021. P. 3917-3921

SABOUR, S.; FROSST, N.; HINTON, G. E. DYNAMIC ROUTING BETWEEN CAPSULES. 2017.

OBRIGADO