

Inteligência Artificial para auxílio no diagnóstico de infecções fúngicas e neoplasias pulmonares em radiografias torácicas

Kaio Henrique Avelino Domeni de Paulo

Orientador: João Paulo Papa

Coorientador: Marcel Koenigkam Santos

UNIVERSIDADE ESTADUAL PAULISTA “JÚLIO DE MESQUITA FILHO” (UNESP)
FACULDADE DE CIÊNCIAS (FC) / DEPARTAMENTO DE COMPUTAÇÃO (DCO)
BAURU, SP - BRASIL

Tópicos da Apresentação

1. Introdução
2. Fundamentação Teórica
3. Materiais e Métodos
4. Resultados e Discussão
5. Aplicação CAD
6. Conclusões
7. Referências

Introdução

UNIVERSIDADE ESTADUAL PAULISTA “JÚLIO DE MESQUITA FILHO” (UNESP)
FACULDADE DE CIÊNCIAS (FC) / DEPARTAMENTO DE COMPUTAÇÃO (DCO)
BAURU, SP - BRASIL

Introdução

Exame de Radiografia

O exame de radiografia (RX) do tórax representa na maioria das situações o primeiro exame radiológico na avaliação das doenças torácicas e pulmonares devido à sua disponibilidade, baixo custo e por ser simples do ponto de vista tecnológico (WADA; RODRIGUES; SANTOS, 2019).


Mesmo sendo considerado um exame simples, é necessário um profissional experiente para interpretar corretamente um RX de tórax e segundo (AZEVEDO-MARQUES, 2001), profissionais da área enfrentam dificuldades devido a fatores como baixa qualidade de imagem, fadiga visual, distração e a própria natureza minuciosa das análises.

Introdução

Doenças Broncopulmonares

Grande parte das doenças broncopulmonares se apresentam no RX como opacidades. O presente estudo teve como foco as **infecções fúngicas**, que apesar de incomuns, apresentam alta morbimortalidade principalmente de indivíduos imunossuprimidos (SILVA, 2010) e a **neoplasia**, lesão relacionada ao crescimento anormal das células (EAGEN; LEWIS, 1977).

RX do tórax de paciente com Coccidioidomicose. Consolidação na região pulmonar inferior direita (seta)



Fonte: CBR – tórax, 2ª edição

Introdução

Detecção automática de doenças pulmonares

O uso de aprendizado de máquina vem sendo utilizado para detecção automática de doenças broncopulmonares.

Na literatura, há vários trabalhos que tratam sobre o uso de Redes Neurais Convolucionais (CNN, do inglês "*convolutional neural network*") para detecção de doenças como tuberculose e pneumonias virais ou bacterianas (LAKHANI; SUNDARAM, 2017), mas há uma escassez de trabalhos que tratem sobre infecções fúngicas e neoplasia pulmonar na radiografia.

Introdução

Detecção automática de doenças pulmonares

WANG, F.; LI, X.; WEN, R.; LUO, H.; LIU, D.; QI, S.; JING, Y.; WANG, P.; DENG, G.; HUANG, C.; DU, T.; WANG, L.; LIANG, H.; WANG, J.; LIU, C. **Pneumonia-Plus: a deep learning model for the classification of bacterial, fungal, and viral pneumonia based on CT tomography**. Springer Science and Business Media LLC, 2023

ANGELINI, E.; SHAH, A. **Using Artificial Intelligence in Fungal Lung Disease: CPA CT Imaging as an Example**. Springer Science and Business Media LLC, 2021.

Técnicas de detecção automática são bem consolidadas quando se trata do exame de Tomografia Computadorizada, mas esse exame é mais complexo e caro quando comparado ao RX.

Introdução

Justificativa e Objetivo

Em casos de infecção de pacientes imunossuprimidos, é desejável que o diagnóstico seja rápido para um tratamento mais específico e não pode ser invasivo (GUILLAMET et al., 2018), tornando métodos mais simples como o exame de RX a forma mais segura de se obter um diagnóstico.

O objetivo do estudo é desenvolver e verificar a aplicabilidade de um modelo de CNN aplicado ao auxílio diagnóstico em imagens de RX do tórax, com foco na detecção e classificação das infecções fúngicas e neoplasia.

Fundamentação Teórica

UNIVERSIDADE ESTADUAL PAULISTA “JÚLIO DE MESQUITA FILHO” (UNESP)
FACULDADE DE CIÊNCIAS (FC) / DEPARTAMENTO DE COMPUTAÇÃO (DCO)
BAURU, SP - BRASIL

Fundamentação Teórica

Aprendizado de Máquina


O aprendizado de máquina é um campo da Inteligência Artificial (IA) que se concentra em criar algoritmos capazes de aprender e melhorar automaticamente a partir de dados, sem a necessidade de serem explicitamente programados para cada tarefa específica.

Historicamente, o campo começou a ganhar forma com as primeiras tentativas de criar programas que imitassem o comportamento humano em situações específicas, como o jogo de xadrez, desenvolvido por Alan Turing e Dietrich Prinz na década de 1950 (SHINDE; SHAH, 2018).

Fundamentação Teórica

Redes Neurais Convolucionais


CNNs são uma classe de redes neurais artificiais amplamente utilizadas em tarefas de aprendizado de máquina, especialmente no campo da visão computacional. Inspiradas pela estrutura do córtex humano, as CNNs são projetadas para processar dados com estrutura de matriz, como imagens (HE et al., 2015a).



Fundamentação Teórica

Redes Neurais Convolucionais


02



Fundamentação Teórica

ResNet


A ResNet (Residual Network) é um tipo de rede neural profunda que utiliza conexões residuais (ou "atalhos") para facilitar o treinamento de redes com muitas camadas (HE et al., 2015).



Fundamentação Teórica

ResNet


02



Fundamentação Teórica

Ensemble

02



Fundamentação Teórica

Ensemble

Uma vantagem do *ensemble learning* é a melhoria da acurácia, robustez e generalização do modelo, especialmente em cenários onde há ruído nos dados ou os dados são altamente complexos. A combinação de múltiplos modelos, cada um capturando diferentes padrões dos dados, gera um sistema capaz de realizar previsões mais precisas.


Materiais e Métodos

UNIVERSIDADE ESTADUAL PAULISTA “JÚLIO DE MESQUITA FILHO” (UNESP)
FACULDADE DE CIÊNCIAS (FC) / DEPARTAMENTO DE COMPUTAÇÃO (DCO)
BAURU, SP - BRASIL

Materiais e Métodos

Base de Dados

A avaliação foi feita sobre os dados coletados de pacientes do Hospital das Clínicas da Faculdade de Medicina de Ribeirão Preto (HCFMRP-USP). Após a seleção, a base continha 376 exames de RX de pacientes com infecção fúngica e neoplasia e 333 exames de RX de pacientes saudáveis.



Apresentado por Kaio Henrique Avelino Domeni de Paulo

Materiais e Métodos

Base de Dados

03

Fungal



Neoplasia



Normal



Fungal



Neoplasia




Normal



Materiais e Métodos

Conversão dos dados





A biblioteca **Pydicom** do Python foi utilizada para converter as imagens recebidas no formato DICOM para o formato PNG.

Materiais e Métodos

Pré-processamento

Exames com *Data Augmentation*









03

Materiais e Métodos

Pré-processamento

Exames com Normalização



03

Materiais e Métodos

Pré-processamento

Exames com CLAHE



03

Materiais e Métodos

Configuração Experimental

Os experimentos foram conduzidos em um notebook com um processador Intel(R) Core(TM) i7-10750H, 16GB de RAM DDR4, uma GPU Nvidia GTX 1660 Ti com 6GB de VRAM e Sistema Operacional Windows 10.


Durante o treinamento, um batch de 32 elementos foi utilizado, em conjunto com uma taxa de aprendizado de 1×10^{-3} associada ao otimizador Adam. O monitoramento do modelo foi feito sobre a *loss* no conjunto de validação, com uma paciência de 20 épocas.



Materiais e Métodos

Métricas de Avaliação

- Acurácia;
- Precisão;
- *Recall*;
- F1 score;
- Matriz de Confusão;
- *Softmax Loss*.



Materiais e Métodos

Métricas de Avaliação


[1.2%, 97.4%, 2.4%] -> *Loss baixa*

[38.7%, 58.2%, 3.1%] -> *Loss alta*

Materiais e Métodos

Modelo Proposto

03




Resultados e Discussão

UNIVERSIDADE ESTADUAL PAULISTA “JÚLIO DE MESQUITA FILHO” (UNESP)
FACULDADE DE CIÊNCIAS (FC) / DEPARTAMENTO DE COMPUTAÇÃO (DCO)
BAURU, SP - BRASIL

Resultados e Discussão

Modelos com 2 classes



S/F: Saudável e Fungos

F/N: Fungos e Neoplasia

S/N: Saudável e Neoplasia

Resultados e Discussão

Modelos com 2 classes

Evolução da Acurácia, *Loss* e F1 Score do modelo ao longo de 60 épocas nos conjuntos de treino e validação.



Resultados e Discussão

Modelos com 2 classes


Métricas obtidas ao avaliar os modelos no conjunto de teste.

Modelo/Desempenho no Teste	Acurácia	Loss	Precisão	Recall	F1 Score
ResNet (normais e fungos)	88,64%	0,3883	88,64%	88,64%	88,64%
ResNet (normais e neoplasia)	86,27%	0,8627	86,27%	86,27%	86,27%
ResNet (fungos e neoplasia)	71,43%	1,2308	71,43%	71,43%	71,43%
Ensemble dos modelos	60,16%	0,9433	69,64%	30,47%	42,39%

Resultados e Discussão

Modelos com 2 classes

Matriz de confusão do modelo com *ensemble* no conjunto de teste.



Resultados e Discussão


Modelos com 3 classes

Métricas obtidas ao avaliar as redes neurais no conjunto de teste.


Modelo/Desempenho no Teste	Acurácia	Loss	Precisão	Recall	F1 Score	Pré-processamento
DenseNet	56,00%	3,2343	56,00%	56,00%	56,00%	<i>Data Augmentation + normalização</i>
LeNet	53,00%	0,9537	66,67%	26,00%	37,41%	<i>Data Augmentation</i>
ResNet-50	66,00%	2,5387	66,00%	66,00%	66,00%	<i>Data Augmentation</i>
<i>ResNet-101</i>	74,14%	1,1069	74,78%	74,14%	74,46%	Normalização
<i>ResNet-152</i>	83,10%	1,6195	83,10%	83,10%	83,10%	<i>Data Augmentation</i>
<i>VGG-19</i>	67,00%	0,7442	72,09%	62,00%	66,67%	<i>Data Augmentation</i>

Resultados e Discussão

Primeiro *Ensemble*




Evolução da Acurácia, *Loss* e F1 Score ao longo de 80 épocas nos conjunto de treino e validação do *Ensemble Model 1*.



Resultados e Discussão

Primeiro *Ensemble*

Matriz de confusão do primeiro modelo com *ensemble*.



Resultados e Discussão


Modelo Final

Para a elaboração do modelo proposto, foi utilizado o discutido anteriormente e uma ResNet-152. Ambas as redes foram congeladas e, novamente, as camadas densas e de *dropout* foram adicionadas após a realização da média ponderada das probabilidades dos modelos. No total, o modelo conta com mais de 236 milhões de parâmetros congelados e 115 parâmetros para serem treinados.

Resultados e Discussão

Modelo Final


Evolução da Acurácia, *Loss* e F1 Score ao longo de 80 épocas nos conjuntos de treino e validação do modelo final com duplo *ensemble*.



Resultados e Discussão

Modelo Final

Matriz de confusão do modelo final com duplo *ensemble*.



Apresentado por Kaio Henrique Avelino Domeni de Paulo

Resultados e Discussão

Modelo Final

Métricas obtidas ao avaliar os modelos utilizando o conjunto de teste.


Modelo/Desempenho no Teste	Acurácia	Loss	Precisão	Recall	F1 Score
ResNet-101	74,14%	1,1069	74,78%	74,14%	74,46%
ResNet-152	83,10%	1,6195	83,10%	83,10%	83,10%
Ensemble Model 1	85,16%	0,466	86,40%	84,38%	85,38%
Modelo Final	86,72%	0,4325	86,72%	86,72%	86,72%

Aplicação de Auxílio ao Diagnóstico

UNIVERSIDADE ESTADUAL PAULISTA “JÚLIO DE MESQUITA FILHO” (UNESP)
FACULDADE DE CIÊNCIAS (FC) / DEPARTAMENTO DE COMPUTAÇÃO (DCO)
BAURU, SP - BRASIL

Aplicação Funcionamento

05




Aplicação

Ferramentas



Aplicação


Telas - Menu



Aplicação

Telas - Diagnóstico


05



Aplicação

Telas - Diagnóstico


05



Aplicação

Telas - Diagnóstico


05



Aplicação

Telas - Créditos

05



Conclusões

UNIVERSIDADE ESTADUAL PAULISTA “JÚLIO DE MESQUITA FILHO” (UNESP)
FACULDADE DE CIÊNCIAS (FC) / DEPARTAMENTO DE COMPUTAÇÃO (DCO)
BAURU, SP - BRASIL

Conclusão

Considerações

Neste trabalho, foi proposto um modelo de CNN com ensemble duplo para classificar imagens de RX do tórax. Combinando métodos já estabelecidos no campo do aprendizado de máquina e processamento de imagens, a abordagem se mostrou promissora para lidar com o problema multiclasse apresentado, principalmente considerando as limitações do dataset para aplicação de CNNs de aprendizado profundo.

Conclusão

Trabalhos Futuros

Trabalhos futuros podem explorar mais a fundo a proposta de aplicar *ensemble* sobre uma rede que já foi treinada com esse tipo de aprendizado. Além disso, o modelo pode ser testado com mais classes para que seja testada sua capacidade de generalização e técnicas de mapas de calor podem ser utilizadas para entender quais fatores na imagem são essências para a tomada de decisão do modelo, além de auxiliar o profissional de saúde a identificar áreas de interesse quando a imagem é carregada na aplicação desenvolvida.

Referências

AZEVEDO-MARQUES, P. M. de. Diagnóstico auxiliado por computador na radiologia. Radiologia Brasileira, v. 34, n. 5, p. 285–293, 2001.

EAGEN, J. W.; LEWIS, E. J. Glomerulopathies of neoplasia. Kidney International, v. 11, n. 5, p. 297–306, 1977. ISSN 0085-2538. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0085253815317397>.

GUILLAMET, C. V.; HSU, J. L.; DHILLON, G.; GUILLAMET, R. V. Pulmonary infections in immunocompromised hosts. Journal of Thoracic Imaging, v. 33, n. 5, p. 295–305, 2018.

HE, K.; ZHANG, X.; REN, S.; SUN, J. Deep residual learning for image recognition. arXiv, 2015. Disponível em: <https://arxiv.org/abs/1512.03385>.

Referências

LAKHANI, P.; SUNDARAM, B. Deep learning at chest radiography: Automated classification of pulmonary tuberculosis by using convolutional neural networks. *Radiology*, v. 284, n. 2, p. 574–582, 2017.

SHINDE, P. P.; SHAH, S. A review of machine learning and deep learning applications. In: 2018 Fourth International Conference on Computing Communication Control and Automation (ICCUBEA). [S.l.: s.n.], 2018. p. 1–6.

SILVA, R. F. e. Capítulo 8 - infecções fúngicas em imunocomprometidos. *Jornal Brasileiro de Pneumologia*, v. 36, n. 1, p. 142–147, 2010.

WADA, D. T.; RODRIGUES, J. A. H.; SANTOS, M. K. Aspectos técnicos e roteiro de análise da radiografia de tórax. *Medicina (Ribeirão Preto)*, v. 52, n. 1, p. 5–15, 2019.

Dúvidas?

UNIVERSIDADE ESTADUAL PAULISTA “JÚLIO DE MESQUITA FILHO” (UNESP)
FACULDADE DE CIÊNCIAS (FC) / DEPARTAMENTO DE COMPUTAÇÃO (DCO)
BAURU, SP - BRASIL

Sessão de agradecimentos :3

UNIVERSIDADE ESTADUAL PAULISTA “JÚLIO DE MESQUITA FILHO” (UNESP)
FACULDADE DE CIÊNCIAS (FC) / DEPARTAMENTO DE COMPUTAÇÃO (DCO)
BAURU, SP - BRASIL





**Intankável
a UNESP**

