

REDUÇÃO DE RUÍDO EM IMAGENS VIA GEOMETRIA FRACTAL

Leonardo Koosuke Azuma

November 15, 2025

- Introdução
- Fundamentação
- Metodologia
- Experimentação e resultados
- Conclusão

- O processamento de imagens é uma ferramenta cada vez mais utilizada em diversas áreas do conhecimento (medicina, indústria, exploração geológica).
- Garantir uma boa qualidade de imagem é fundamental para a obtenção de resultados precisos e confiáveis.
- Os fractais, devido às suas características de autossimilaridade, multi-escala e detalhes "infinitos", podem ser úteis nesses casos.

- Alterar o cálculo da distância entre dois sub-blocos do algoritmo fractal
- Analisar e compara o desempenho do algoritmo

O conceito de geometria fractal foi introduzido por Benoit Mandelbrot em 1975. Essa geometria é voltada para o estudo de objetos irregulares e fragmentados, que apresentam características semelhantes em todas as escalas.

Espaço

Um espaço X é um conjunto, e os pontos deste espaço são chamados de elementos do conjunto.

Espaço Métrico

Um espaço métrico (X, d) é um conjunto X com uma função

$$d : X \times X \rightarrow \mathbb{R}$$

que mede a distância entre dois elementos $x, y \in X$.

A métrica d deve satisfazer quatro propriedades:

- 1 $d(x, y) = d(y, x) \quad \forall x, y \in X$ (Simetria)
- 2 $0 < d < \infty$ se $x \neq y$ (Positividade)
- 3 $d(x, x) = 0 \quad \forall x \in X$ (Identidade)
- 4 $d(x, z) \leq d(x, y) + d(y, z) \quad \forall x, y, z \in X$ (Desigualdade triangular)

Um exemplo é o espaço métrico $\mathbb{R}^2$ com $d(p_1, p_2) = |x_1 - y_1| + |x_2 - y_2|$ (distância de Manhattan).

Espaço métrico completo

Um espaço métrico (X, d) é dito completo se toda sequência de Cauchy em X possui um limite $x \in X$.

Compacto



Seja (X, d) um espaço métrico completo, então, um subconjunto $S \subset X$ é compacto se, e somente se, é fechado e totalmente limitado.

Fundamentação

Geometria Fractal

Existem diversas possibilidades para se gerar um fractal; porém, neste trabalho serão utilizados os Sistemas de Funções Iteradas (IFS).

Uma forma simples de visualizar essa construção é por meio de uma copiadora especial, que reduz a entrada e a replica em diferentes partes do papel. Dessa forma, ao retroalimentá-la, gera-se o fractal por IFS.



Espaço de Hausdorff

Seja (X, d) um espaço métrico completo. É definido $\mathcal{H}(X)$ como o espaço, o qual os pontos são os subconjuntos compactos não vazios de X

Distância de $x \in X, e B \in (X)$

$$d(x, B) = \min\{d(x, y) | y \in B\}.$$

Distância de $A, B \in (X)$

$$d(A, B) = \max\{d(x, B) | x \in A\}.$$

Espaço de Hausdorff

Seja (X, d) um espaço métrico completo. É definido $\mathcal{H}(X)$ como o espaço, o qual os pontos são os subconjuntos compactos não vazios de X

Distância de $x \in X, e B \in (X)$



$$d(x, B) = \min\{d(x, y) | y \in B\}.$$

Distância de $A, B \in (X)$

$$d(A, B) = \max\{d(x, B) | x \in A\}.$$

Fundamentação

Geometria Fractal



Seja (X, d) um espaço métrico completo. Então $(\mathcal{H}(X), h)$ é um espaço métrico completo. Dessa forma se $\{A_n \in \mathcal{H}(X)\}_{n=1}^{\infty}$ é uma sequência de Cauchy, então:

$$A = \lim_{n \rightarrow \infty} A_n \in \mathcal{H}(X).$$

Os IFS são construídos a partir de transformações afins que são em $\mathbb{R}^n$

$$w(x) = Ax + b$$

onde A é uma matrix $n \times n$ e b é um vetor em $\mathbb{R}^n$. De forma que o termo Ax representa uma transformação linear, podendo incluir: rotação; reflexão; cisalhamento; ou escala, enquanto b realiza uma translação.

Contração

Uma transformação $f : X \rightarrow X$ definida em um espaço métrico (X, d) é uma contração se existe uma constante s , de modo que $0 \leq s < 1$, tal que:

$$d(f(x), f(y)) \leq s \cdot d(x, y), \quad \forall x, y \in X.$$


Mapeamento Contrativo

Seja $f : X \rightarrow X$ uma contração em um espaço métrico completo (X, d) . Logo f possui um único ponto fixo $x_f \in X$, e para qualquer ponto $x \in X$ a sequência $f^{\circ n}(x) : n = 0, 1, 2, \dots$, onde $f^{\circ n}(x)$ denota a aplicação iterada de f sobre x n vezes, isto é:

$$f^{\circ n}(x) = f(f(\dots f(x)\dots))$$

converge para x_f , isto é:

$$\lim_{n \rightarrow \infty} f^{\circ n}(x) = x_f$$



Dessa forma, um Sistema de Funções Iteradas (IFS) é definido como:

$$W : \mathcal{H}(X) \rightarrow \mathcal{H}(X)$$

$$W(B) = \bigcup_{n=1}^N w_n(B).$$

$$W : \mathcal{H}(X) \rightarrow \mathcal{H}(X)$$

$$W(B) = \bigcup_{n=1}^N w_n(B)$$

Além disso, o operador possui um único ponto fixo (atrator) $A \in \mathcal{H}(X)$:

$$A = W(A) = \bigcup_{n=1}^N w_n(A)$$

Fundamentação

Algoritmo Determinístico

- Ideia: computar a sequência de iterações $A_n = W^n(A)$, começando a partir de um conjunto inicial A_0 .
- Como o atrator é independente do conjunto inicial, podemos começar com qualquer A_0 .

Algorithm 1: Algoritmo determinístico

Data: Conjunto inicial compacto $A_0 \in \mathcal{H}(X)$; funções contrativas $\{w_1, w_2, \dots, w_N\}$; número de iterações K .

Result: Aproximação do atrator A_K .

$A \leftarrow A_0$;

for $k \leftarrow 1$ **to** K **do**

$A \leftarrow \bigcup_{n=1}^N w_n(A)$;

return A ;

Complexidade $O(N^K)$, onde N é o número de iterações e K é a quantidade de transformações afins.

Fundamentação

Algoritmo Determinístico



- Uma imagem digital pode ser definida como uma função bidimensional $f(x, y)$, em que x e y representam as coordenadas espaciais no plano, sendo esses valores finitos e discretos.
- $f(x, y)$ representa uma pequena região retangular denominada pixel, que é a menor unidade da imagem capaz de armazenar informação da intensidade.
- Ruído é qualquer qualquer modificação indesejada no sinal da imagem $\eta(x, y)$.

Seja $g(x, y)$ a imagem degradada e $f(x, y)$ a imagem original.

- Um ruído pode ser aditivo, caso $g(x, y) = f(x, y) + \eta(x, y)$.
- Um ruído pode ser multiplicativo, caso $g(x, y) = f(x, y) \cdot \eta(x, y)$.
- O ruído multiplicativo pode ser transformado em aditivo:

$$\log(g(x, y)) = \log(f(x, y)) + \log(\eta(x, y))$$

- Um ruído também pode não pertencer a nenhuma dessas duas categorias.



- O ruído Gaussiano é um tipo de sinal aditivo que possui sua função de densidade de probabilidade igual a distribuição normal.

$$P(g) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(g-\mu)^2}{2\sigma^2}}$$

- Causado por fontes naturais, como a vibração térmica de átomos e a natureza discreta da radiação de objetos quentes.

Fundamentação

Ruído Gaussiano





- Apenas alguns pixels da imagem são afetados, que assumem ou o valor 0 (mínimo) ou 255 (máximo).
- Acontece por causa de falhas no processo de conversão analógico para digital, ou por erros de transmissão.

$$P(g) = \begin{cases} p_1, & \text{se } g = 0, \\ p_2, & \text{se } g = 255, \\ 0, & \text{caso contrário,} \end{cases}$$

Fundamentação

Ruído Sal e Pimenta





- Mesma probabilidade de ocorrência para todos os valores dentro de um intervalo definido, resultando em variações igualmente prováveis.
- Ocorre quando dados analógicos são convertidos em dados digitais.

$$P(g) = \begin{cases} \frac{1}{b-a}, & \text{se } a \leq g \leq b, \\ 0, & \text{caso contrário,} \end{cases}$$

Fundamentação

Ruído Uniforme





- Segue a função de densidade de probabilidade igual a distribuição Gamma.
- Presente em imagens geradas por laser.

$$P(g) = \begin{cases} \frac{a^b g^{b-1} e^{-ag}}{(b-1)!}, & \text{se } g \geq 0 \\ 0, & \text{se } g < 0 \end{cases}$$

Fundamentação



Ruído Gamma



- Ruído espacialmente dependente, ou seja, depende da posição do pixel.
- Ocorre quando há interferências eletrônicas no processo de aquisição da imagem.

Fundamentação

Ruído Periódico





- Ruído multiplicativo.
- Acontece devido à utilização de luz coerente ou efeitos atmosféricos durante o processo de aquisição da imagem.

$$F(g) = \frac{g^{\alpha-1} e^{-\frac{g}{a}}}{(\alpha - 1)! a^\alpha}$$

Fundamentação

Ruído speckle



- Erro Médio Quadrático (MSE):

$$MSE = \frac{1}{N} \sum_{i=1}^N (I_i - J_i)^2$$

- Razão do Sinal-Ruído de Pico (PSNR):

$$PSNR = 10 \log_{10} \frac{MAX_I^2}{MSE}$$

- Índice de Similaridade Estrutural (SSIM):

$$SSIM(x, y) = \frac{(2\mu_x\mu_y + c_1)(2\sigma_{xy} + c_2)}{(\mu_x^2 + \mu_y^2 + c_1)(\sigma_x^2 + \sigma_y^2 + c_2)}$$


- O algoritmo Block-Matching and 3D Filtering (BM3D) é amplamente reconhecido, sendo referência devido ao seu elevado desempenho na redução de ruído e na preservação de detalhes.
- Também é utilizado como base de comparação para novos algoritmos, por causa sua robustez em diferentes casos de ruído.

- As imagens do mundo real possuem autossimilaridade local.
- Observação: o uso da codificação fractal reduz o ruído na imagem, pois a adição do ruído na imagem resulta na redução da autossimilaridade existente.

- Problema inverso: achar o melhor IFS que gera um determinado atrator.
- Ideia: Dividir a imagem em blocos não sobrepostos de tamanho r (Blocos de imagem) R_i ; e em blocos de tamanho $2r$ (Blocos de domínio) D_i , de forma que pode-se aplicar uma transformação $w_i(D_j) = R_k$.
- Observação: Os blocos não precisam ser um quadrado.
- Caso sejam um quadrado as transformações w_i podem ser: contração; rotação de 90° , 180° ou 270° ; reflexão horizontal, vertical ou diagonal. (8 transformações possíveis).

Fundamentação

Algoritmo Fractal



- Para ajustar a intensidade dos pixels

$$\phi(t) = \alpha t + \beta$$

$$\alpha = \frac{n \sum_{m=1}^n x_m y_m - (\sum_{m=1}^n x_m)(\sum_{m=1}^n y_m)}{n \sum_{m=1}^n x_m^2 - (\sum_{m=1}^n x_m)^2}$$

$$\beta = \frac{1}{n} \sum_{m=1}^n y_m - \alpha \frac{1}{n} \sum_{m=1}^n x_m$$


Passos do algoritmo:

- 1 Dividir a imagem original em blocos de imagem R_i e blocos de domínio D_i , sendo que cada bloco D_i possui o dobro do tamanho de R_i ;
- 2 Para cada bloco de intervalo R_i , buscar o bloco de domínio D_i que, ao se aplicar uma das oito possíveis transformações geométricas e uma transformação de brilho e contraste ϕ , minimize o Erro Médio Quadrático (MSE) entre R_i e $w_j(D_i)$.

Fundamentação

Algoritmo Fractal

Imagem inicial



iteração 1



iteração 2




iteração 9



Metodologia

Passos



- ① Modificação no Algoritmo
- ② Conjunto de Imagens
- ③ Execução dos Testes e Métricas

Algorithm 2: Padrão

Data: Imagem com $X \in \mathbb{R}^2$, coordenadas do bloco de imagem (r_i, r_j) , tamanho do bloco de domínio $domain_size$, passo do domínio $domain_step$

Result: Transformação para (r_i, r_j)

$best_mse \leftarrow \infty$;

$best_transformation \leftarrow \emptyset$;

for $d_i \leftarrow 0$ to $h - domain_size$ step $domain_step$ do
 for $d_j \leftarrow 0$ to $w - domain_size$ step $domain_step$

 do

$D_k \leftarrow (d_i, d_j)$;

 for $i \leftarrow 0$ to 7 do

$domain_transformation \leftarrow w_i(D_k)$;

$new_mse \leftarrow$

$mse((r_i, r_j), domain_transformation)$;

 if $new_mse < best_mse$ then

$best_transformation \leftarrow$

(D_k, w_i) ;

$best_mse \leftarrow new_mse$

return $best_transformation$;

Algorithm 3: Modificado

Data: Imagem com $X \in \mathbb{R}^2$, coordenadas do bloco de imagem (r_i, r_j) , tamanho do bloco de domínio $domain_size$, passo do domínio $domain_step$

Result: Transformação para (r_i, r_j)

$best_ssim \leftarrow -\infty$;

$best_transformation \leftarrow \emptyset$;

for $d_i \leftarrow 0$ to $h - domain_size$ step $domain_step$ do
 for $d_j \leftarrow 0$ to $w - domain_size$ step $domain_step$

 do

$D_k \leftarrow (d_i, d_j)$;

 for $i \leftarrow 0$ to 7 do

$domain_transformation \leftarrow w_i(D_k)$;

$new_ssim \leftarrow$

$ssim((r_i, r_j), domain_transformation)$;

 if $new_ssim > best_ssim$ then

$best_transformation \leftarrow$

(D_k, w_i) ;

$best_ssim \leftarrow new_ssim$

return $best_transformation$;

- Conjunto usado: Signal and Image Processing Institute (USC-SIPI), da University of Southern California (WEBER, 2018)
- Imagens com diferentes tipos de textura, complexidade e contraste
- Imagens coloridas foram convertidas para escala de cinza
- Todas as imagens eram quadradas, porém algumas tem o tamanho de 1024×1024 que foram convertidas para 512×512
- Os ruídos aplicados foram os mesmos da fundamentação, antes de aplicar foram feito a normalização (os parâmetros utilizados são entre 0 e 1)

- Métricas utilizadas: MSE, PSNR, SSIM
- Cada ruído foi testado em 4 intensidades diferentes
- Após aplicar os algoritmos para cada imagem foi calculada a média aritmética

$$m = \frac{1}{n} \sum_{i=1}^n m_i$$

- Os parâmetros utilizados foram: tamanho do bloco de domínio = 32, tamanho do bloco de imagem = 16, deslocamento da varredura = 32 (ideal seria 1)

Experimentação e Resultados

Ruído Gaussiano $\sigma = 0.08$




Figure: Resultados das métricas MSE, PSNR e SSIM para ruído Gaussiano com $\sigma = 0.08$.

Resultados das métricas

Ruído Gaussiano com $\sigma = 0.12$




Figure: Resultados das métricas MSE, PSNR e SSIM para ruído Gaussiano com $\sigma = 0.12$.

Resultados das métricas

Ruído Gaussiano com $\sigma = 0.156$




Figure: Resultados das métricas MSE, PSNR e SSIM para ruído Gaussiano com $\sigma = 0.156$.

Resultados das métricas

Ruído Gaussiano com $\sigma = 0.20$




Figure: Resultados das métricas MSE, PSNR e SSIM para ruído Gaussiano com $\sigma = 0.20$.

Resultados das métricas

Ruído Gaussiano

Table: Comparação das medias para o ruído Gaussiano.

Parâmetro	Algoritmo Fractal			Algoritmo Fractal Modificado			BM3D		
	MSE	PSNR	SSIM	MSE	PSNR	SSIM	MSE	PSNR	SSIM
$\sigma = 0.08$	365.425	25.2033	0.641585	506.711	23.2698	0.570362	63.1261	31.8643	0.841708
$\sigma = 0.12$	389.448	24.7106	0.615056	536.421	22.9289	0.553044	90.4337	29.5731	0.788233
$\sigma = 0.156$	417.167	24.1848	0.591438	558.667	22.627	0.539987	110.508	28.9191	0.781444

Resultados das métricas

Ruído Sal e Pimenta com $p_1 = 0.02$ e $p_2 = 0.02$




Figure: Resultados das métricas MSE, PSNR e SSIM para ruído Sal e Pimenta com $p_1 = 0.02$ e $p_2 = 0.02$.

Resultados das métricas

Ruído Sal e Pimenta com $p_1 = 0.04$ e $p_2 = 0.04$




Figure: Resultados das métricas MSE, PSNR e SSIM para ruído Sal e Pimenta com $p_1 = 0.04$ e $p_2 = 0.04$.

Resultados das métricas

Ruído Sal e Pimenta com $p_1 = 0.08$ e $p_2 = 0.08$




Figure: Resultados das métricas MSE, PSNR e SSIM para ruído Sal e Pimenta com $p_1 = 0.08$ e $p_2 = 0.08$.

Resultados das métricas

Ruído Sal e Pimenta com $p_1 = 0.16$ e $p_2 = 0.16$




Figure: Resultados das métricas MSE, PSNR e SSIM para ruído Sal e Pimenta com $p_1 = 0.16$ e $p_2 = 0.16$.

Resultados das métricas

Ruído Sal e Pimenta

Table: Comparação das medias para o ruído Sal e Pimenta.

Parâmetro	Algoritmo Fractal			Algoritmo Fractal Modificado			BM3D		
	MSE	PSNR	SSIM	MSE	PSNR	SSIM	MSE	PSNR	SSIM
$p_1 = 0.02$ $p_2 = 0.02$	385.001	24.7183	0.614905	517.568	23.2646	0.573223	546.89	23.6124	0.595644
$p_1 = 0.04$ $p_2 = 0.04$	447.273	23.8669	0.581256	562.23	22.6868	0.556031	1488.92	16.4887	0.260426
$p_1 = 0.08$ $p_2 = 0.08$	562.763	22.4076	0.536197	656.29	21.6021	0.521546	2645.74	14.1355	0.160226
$p_1 = 0.16$ $p_2 = 0.16$	829.993	20.2845	0.487674	904.38	19.9192	0.482821	1563.6	20.0311	0.407954

Resultados das métricas

Ruído Uniforme com $a = 0.05$ e $b = 0.05$




Figure: Resultados das métricas MSE, PSNR e SSIM para ruído Uniforme com $a = 0.05$ e $b = 0.05$.

Resultados das métricas

Ruído Uniforme com $a = 0.1$ e $b = 0.1$




Figure: Resultados das métricas MSE, PSNR e SSIM para ruído Uniforme com $a = 0.1$ e $b = 0.1$.

Resultados das métricas

Ruído Uniforme com $a = 0.15$ e $b = 0.15$




Figure: Resultados das métricas MSE, PSNR e SSIM para ruído Uniforme com $a = 0.15$ e $b = 0.15$.

Resultados das métricas

Ruído Uniforme com $a = 0.2$ e $b = 0.2$




Figure: Resultados das métricas MSE, PSNR e SSIM para ruído Uniforme com $a = 0.2$ e $b = 0.2$.

Table: Comparação das medias para ruído Uniforme.

Parâmetro	Algoritmo Fractal			Algoritmo Fractal Modificado			BM3D		
	MSE	PSNR	SSIM	MSE	PSNR	SSIM	MSE	PSNR	SSIM
$a = 0.05$ $b = 0.05$	350.069	25.6121	0.6706	474.613	23.6318	0.590128	22.5594	36.1787	0.920236
$a = 0.10$ $b = 0.10$	357.826	25.398	0.655072	493.473	23.3947	0.578982	40.8846	33.4391	0.877954
$a = 0.15$ $b = 0.15$	370.588	25.114	0.636836	510.028	23.1908	0.566864	60.532	31.6962	0.842569
$a = 0.20$ $b = 0.20$	386.76	24.732	0.616733	540.917	22.93	0.552967	80.926	30.3197	0.811921

Resultados das métricas

Ruído Gama com $a = 2$ e $b = 0.035$




Figure: Resultados das métricas MSE, PSNR e SSIM para ruído Gama com $a = 2$ e $b = 0.035$.

Resultados das métricas

Ruído Gama com $a = 3$ e $b = 0.035$




Figure: Resultados das métricas MSE, PSNR e SSIM para ruído Gama com $a = 3$ e $b = 0.035$.

Resultados das métricas

Ruído Gama com $a = 3$ e $b = 0.045$




Figure: Resultados das métricas MSE, PSNR e SSIM para ruído Gama com $a = 3$ e $b = 0.045$.

Resultados das métricas

Ruído Gama com $a = 4$ e $b = 0.065$




Figure: Resultados das métricas MSE, PSNR e SSIM para ruído Gama com $a = 4$ e $b = 0.065$.

Resultados das métricas

Ruído Gama

Table: Comparação das medias para ruído Gama.

Parâmetro	Algoritmo Fractal			Algoritmo Fractal Modificado			BM3D		
	MSE	PSNR	SSIM	MSE	PSNR	SSIM	MSE	PSNR	SSIM
$a = 2$ $b = 0.035$	619.68	21.075	0.642692	760.25	20.1936	0.566172	295.149	23.6369	0.868233
$a = 3$ $b = 0.035$	981.245	18.6341	0.624626	1116.98	18.0806	0.551897	650.132	20.2119	0.836146
$a = 3$ $b = 0.045$	650.132	20.2119	0.836146	1510.93	16.5506	0.539969	1057.18	18.1002	0.797313
$a = 4$ $b = 0.065$	3856.53	12.3842	0.546195	3989.96	12.2203	0.494841	3586.51	12.8316	0.663677

Resultados das métricas

Ruído Periódico

Função: $f_1(x, y) = 0.125 \sin(10\pi(0.5x - y))$




Figure: Resultados das métricas MSE, PSNR e SSIM para ruído Periódico com

Resultados das métricas

Ruído Periódico

Função: $f_2(x, y) = 0.125 \sin(20\pi(0.5x - y)) + 0.0625 \sin(50\pi(x - y))$




Figure: Resultados das métricas MSE, PSNR e SSIM para ruído Periódico com 🔍🔄📄

Resultados das métricas

Ruído Periódico

Função: $f_3(x, y) = 0.125 \sin(20\pi(0.5x - y)) + 0.125 \sin(50\pi(x - y))$







Figure: Resultados das métricas MSE, PSNR e SSIM para ruído Periódico com 🔍🔍🔍

Resultados das métricas

Ruído Periódico

Função: $f_4(x, y) =$

$$0.15 \sin(20\pi(0.5x - y)) + 0.15 \sin(50\pi(x - y)) + 0.05 \sin(80\pi(x - y))$$



Resultados das métricas

Ruído Periódico

Table: Comparação das medias para ruído Periódico.

Parâmetro	Algoritmo Fractal			Algoritmo Fractal Modificado			BM3D		
	MSE	PSNR	SSIM	MSE	PSNR	SSIM	MSE	PSNR	SSIM
f_1	813.393	19.5738	0.586121	940.465	19.0489	0.486254	499.657	21.1829	0.849769
f_2	499.657	21.1829	0.849769	882.222	19.3575	0.395882	639.63	20.1072	0.60429
f_3	889.779	19.1027	0.365118	931.689	19.0925	0.360213	1098.56	17.7495	0.381946
f_4	1114.73	17.9943	0.309477	1119.93	18.1714	0.313372	1701.76	15.8425	0.309921

Resultados das métricas

Parâmetros: $a = 100$, $\alpha = \frac{1}{100}$




Figure: Resultados das métricas MSE, PSNR e SSIM para ruído uniforme com $a = 100$ e $\alpha = \frac{1}{100}$.

Resultados das métricas

Parâmetros: $a = 50$, $\alpha = \frac{1}{50}$




Figure: Resultados das métricas MSE, PSNR e SSIM para ruído uniforme com $a = 50$ e $\alpha = \frac{1}{50}$.

Resultados das métricas

Ruído Speckle com $a = 25$




Figure: Resultados das métricas MSE, PSNR e SSIM para ruído uniforme com $a = 25$ e $\alpha = \frac{1}{25}$.

Resultados das métricas

Ruído Speckle com $a = 10$




Figure: Resultados das métricas MSE, PSNR e SSIM para ruído uniforme com $a = 10$ e $\alpha = \frac{1}{10}$.

Resultados das métricas

Ruído Speckle

Table: Comparação das medias para ruído *Speckle*.

Parâmetro	Algoritmo Fractal			Algoritmo Fractal Modificado			BM3D		
	MSE	PSNR	SSIM	MSE	PSNR	SSIM	MSE	PSNR	SSIM
$a = 100$ $\alpha = \frac{1}{100}$	359.556	25.4495	0.661162	496.453	23.4595	0.584105	58.1168	31.9935	0.866421
$a = 50$ $\alpha = \frac{1}{50}$	370.583	25.2353	0.649549	514.775	23.2937	0.576113	87.4786	30.0937	0.823797
$a = 25$ $\alpha = \frac{1}{25}$	398.265	24.8327	0.631221	547.942	23.018	0.565492	133.386	28.1848	0.773359
$a = 10$ $\alpha = \frac{1}{10}$	483.133	23.8591	0.596692	617.363	22.4317	0.547454	239.591	25.5638	0.700682

Resultados Tempo de Execução


O tempo de execução do algoritmo BM3D não foi incluída, uma vez que foi utilizada uma biblioteca em Python.

Table: Tempo de execução dos algoritmos fractais.

Parâmetro	Algoritmo Fractal	Algoritmo Fractal Modificado
	Tempo	Tempo
$N = 32, M = 16, step = 32$	24.398s	1m3.016s
$N = 32, M = 16, step = 16$	1m26.195s	3m56.143s

- A modificação na métrica do MSE para o SSIM entre os blocos no algoritmo fractal apresenta uma piora na qualidade da restauração da imagem e no tempo de execução.
- O algoritmo BM3D é superior na maioria das ocasiões.

Conclusão



É possível que haja uma melhora significativa no algoritmo fractal caso haja uma forma de resolver o problema de determinar um Sistema de Funções Iteradas (IFS) mais eficiente.

- [1] Yusra Al Najjar. “Comparative analysis of image quality assessment metrics: MSE, PSNR, SSIM and FSIM”. In: *International Journal of Science and Research (IJSR)* 13.3 (2024), pp. 110–114.
- [2] Ruy Madsen Barbosa. *Descobrimos a Geometria Fractal-para a sala de aula*. Autêntica, 2016.
- [3] Michael F Barnsley. *Fractals everywhere*. Academic press, 2014.
- [4] Charles Bonchelet. “Chapter 7 - Image Noise Models”. In: *The Essential Guide to Image Processing*. Ed. by Al Bovik. Boston: Academic Press, 2009, pp. 143–167. ISBN: 978-0-12-374457-9. DOI: <https://doi.org/10.1016/B978-0-12-374457-9.00007-X>. URL: <https://www.sciencedirect.com/science/article/pii/B978012374457900007X>.

Referências II

- [5] Ajay Kumar Boyat and Brijendra Kumar Joshi. “A review paper: noise models in digital image processing”. In: *arXiv preprint arXiv:1505.03489* (2015).
- [6] MCCS CARVALHO and A SILVA. “Fractais: uma breve introdução”. In: *Edição Própria* (1986).
- [7] Kostadin Dabov et al. “Image denoising with block-matching and 3D filtering”. In: *Image processing: algorithms and systems, neural networks, and machine learning*. Vol. 6064. SPIE. 2006, pp. 354–365.
- [8] Hygino Hugueros Domingues. *Espaços métricos e introdução à topologia*. Atual, 1982.
- [9] Yuval Fisher. “Fractal image compression”. In: *Fractals* 2.03 (1994), pp. 347–361.

- [10] Mohsen Ghazel, George H Freeman, and Edward R Vrscay. “Fractal image denoising”. In: *IEEE Transactions on image processing* 12.12 (2003), pp. 1560–1578.
- [11] Rafael C Gonzalez and Richard C Woods. *Processamento digital de imagens*. Pearson Educación, 2009.
- [12] T. Hamano, K. Tokuda, and M. Kaneko. “Image restoration based on estimation of fractal structure”. In: *Proceedings of Digital Processing Applications (TENCON '96)*. Vol. 1. 1996, 311–316 vol.1. DOI: 10.1109/TENCON.1996.608831.
- [13] ImageMagick Studio LLC. *ImageMagick*. Version 7.1.1. Jan. 4, 2024. URL: <https://imagemagick.org>.
- [14] Bernd Jähne. *Digital image processing*. Springer, 2005.
- [15] *Keras Documentation*. Disponível em: <https://keras.io/>. Acesso em 22 de Outubro de 2018. 2018.

- [16] Zhaoming Kong, Xiaowei Yang, and Lifang He. “A comprehensive comparison of multi-dimensional image denoising methods”. In: *arXiv preprint arXiv:2011.03462* (2020).
- [17] Benoit B Mandelbrot. “Fractal geometry: what is it, and what does it do?” In: *Proceedings of the Royal Society of London. A. Mathematical and Physical Sciences* 423.1864 (1989), pp. 3–16.
- [18] Maria MP Petrou and Costas Petrou. *Image processing: the fundamentals*. John Wiley & Sons, 2010.
- [19] L. M. Rocha, F. A. M. Cappabianco, and A. X. Falcão. “Data clustering as an optimum-path forest problem with applications in image analysis”. In: *International Journal of Imaging Systems and Technology* 19.2 (2009), pp. 50–68.

- [20] Umme Sara, Morium Akter, and Mohammad Shorif Uddin. “Image quality assessment through FSIM, SSIM, MSE and PSNR—a comparative study”. In: *Journal of Computer and Communications* 7.3 (2019), pp. 8–18.
- [21] Juan Song et al. “Exploring the Role of Fractal Geometry in Engineering Image Processing Based on Similarity and Symmetry: A Review”. In: *Symmetry* 16.12 (2024), p. 1658.
- [22] Michael Stonebraker et al. “DBMS Research at a Crossroads: The Vienna Update”. In: *VLDB '93 Proceedings of the 19th International Conference on Very Large Data Bases*. Morgan Kaufmann Publishers Inc., 1993, pp. 688–692.

- [23] Allan G. Weber. *The USC-SIPI Image Database: Version 6*. Tech. rep. USC-SIPI Report #432. Acesso em: 18 out. 2025. Los Angeles, CA, USA: Signal and Image Processing Institute, Ming Hsieh Department of Electrical Engineering, University of Southern California, 2018. URL: <https://sipi.usc.edu/database/>.