

ANÁLISE COMPARATIVA DE DIFERENTES MÉTODOS DE APRENDIZADO POR REFORÇO APLICADAS AO MAHJONG

Luciano Henrique Arendt Rodrigues

Orientador: Prof. Dr. André Luis Debiasso Rossi



UNESP - BAURU | 2025



CRONOGRAMA




Tabela 2 – Cronograma de execução (em meses).

Atividades	04	05	06	07	08	09	10
Etapa 1							
Etapa 2							
Etapa 3							
Etapa 4							
Etapa 5							
Etapa 6							
Etapa 7							
Etapa 8							


- Etapa 1: Estudo bibliográfico.
- Etapa 2: Escolher o tipo da rede neural;
- Etapa 3: Escolher os métodos de AR para treinamento da rede;
- Etapa 4: Implementar e treinar agentes utilizando as políticas selecionadas;

REDE NEURAL: CNN



- CNNs vão além de imagens
 - Embora conhecidas pelo sucesso em visão computacional, CNNs também se destacam em tarefas estruturadas.
 - No AlphaGo, CNNs foram usadas para interpretar o tabuleiro como uma matriz, aprendendo padrões espaciais complexos e estratégias.
- Amplamente utilizada na literatura
 - Suphx – Microsoft Asia.
 - “Building a Computer Mahjong Player via Deep Convolutional Neural Networks” – Universidade de Tokyo.
- O estado do jogo pode ser modelado como matrizes multicanais

AlphaGo




MÉTODOS

- Métodos baseados em política:
 - Ex: PPO (Proximal Policy Optimization)
 - Aprendem diretamente a política $\pi(a | s)$, usando gradientes para melhorá-la.
 - Suportam ações contínuas e políticas estocásticas.
 - PPO é robusto e eficiente em ambientes complexos com grandes espaços de estados.



中

發



MÉTODOS

- Métodos baseados em valores:
 - Ex: Q-Learning
 - Aprendem uma função $Q(s,a)$ que estima a recompensa esperada ao tomar a ação a no estado s .
 - A política é implícita, escolhendo a melhor ação com base na função Q .
 - Simples e eficaz para espaços discretos, como ações em jogos de turno.



中

發



Q-LEARNING

- Q-function:
 - Cadeia de Markov.
 - Entropia da mão.
 - Esperança da mão.
 - MLP.



$$BasePoints = fu \times 2^{2+han}$$



MÉTODOS

- Métodos ator-crítico
 - Ex: A2C (Advantage Actor-Critic)
 - Combinam o melhor dos dois mundos:
 - O ator aprende a política.
 - O crítico estima o valor da ação.
 - Permite atualizações mais estáveis e eficientes, reduzindo variância.



REPRESENTAÇÃO MATRICIAL



	1	2	3	4	5	6	7	8	9
Bamboo									
Character									
Dot									
Honor									


REPRESENTAÇÃO MATRICIAL




Hands
4 channels



Fulus
68 channels







PYMAHJONG



- pymahjong é um ambiente simulado open-source em Python para estudo de IA de decisão, baseado no Mahjong Japonês.
- O ambiente foi apresentado no artigo de pesquisa "Variational Oracle Guiding for Reinforcement Learning".
- Disponível em duas versões:
 - **Single-agent:** estilo OpenAI Gym, agente enfrenta 3 oponentes pré-treinados
 - **Multi-agent:** 4 agentes jogam entre si; cada passo requer ação do jogador atual (`env.get_current_player_id()`)



PYMAHJONG



- `env = pymahjong.MahjongEnv()`
- `env.reset(oya=1, game_wind="south", seed=1234) #episode`
- `curr_pid = env.get_curr_player_id() #multiagente`
- `valid_actions = env.get_valid_actions() # List[int] of valid actions`
- `executor_obs = env.get_obs(curr_pid)`
- `oracle_obs = env.get_oracle_obs(curr_pid)`
- `action = decision_model(executor_obs, valid_actions)`
- `obs, reward, done, _ = env.step(curr_pid, action)`
- `if env.is_over():`
 - `print("result:", np.array(env.get_payoffs()))`



Action index	Explanation		
0	Discard Character 1		
1	Discard Character 2		
2	Discard Character 3		
3	Discard Character 4		
4	Discard Character 5 (non-Red Dora with higher priority)	27	Discard East Wind
5	Discard Character 6	28	Discard South Wind
6	Discard Character 7	29	Discard West Wind
7	Discard Character 8	30	Discard North Wind
8	Discard Character 9	31	Discard White Dragon Tile (Haku)
9	Discard Dot 1	32	Discard Green Dragon Tile (Hatsu)
10	Discard Dot 2	33	Discard Red Dragon Tile (Chu)
11	Discard Dot 3	34	Chi (the picked up tile is the smallest in the meld)
12	Discard Dot 4	35	Chi (the picked up tile is the middle in the meld)
13	Discard Dot 5 (non-Red Dora with higher priority)	36	Chi (the picked up tile is the largest in the meld)
14	Discard Dot 6	37	Pon
15	Discard Dot 7	38	An-Kan
16	Discard Dot 8	39	Kan
17	Discard Dot 9	40	Ka-Kan
18	Discard Bamboo 1	41	Riichi
19	Discard Bamboo 2	42	Ron
20	Discard Bamboo 3	43	Tsumo
21	Discard Bamboo 4	44	Restart the game with Kyushukyuha
22	Discard Bamboo 5 (non-Red Dora with higher priority)	45	Not to response (when Chi, Pon, Kan, Ron, etc. is possible)
23	Discard Bamboo 6	46	Not to Riichi (When Riichi is possible)
24	Discard Bamboo 7		
25	Discard Bamboo 8		
26	Discard Bamboo 9		

OBRIGADO!

**ALGUMA
DUVIDA?**

