




Ferramenta de Detecção de ► Phishing Usando Aprendizado de Máquina

Marina Rijo de Oliveira RA: 191025501
Profº Dr. Kelton Augusto Pontara da Costa

► TABLE OF CONTENTS

01

INTRODUÇÃO

02

FUNDAMENTAÇÃO

03

METODOLOGIA

04

RESULTADOS

05

CONCLUSÃO

06

REFERÊNCIAS



► INTRODUÇÃO

01

► INTRODUÇÃO



RESUMO

Detectar *phishing* é uma das grandes dificuldades da área da segurança da informação na atualidade. Associar aprendizado de máquina à uma interface gráfica simplificada pode ser um grande passo em direção à um avanço nessa frente.



OBJETIVO

Desenvolver uma aplicação com interface gráfica simples que utiliza algoritmos de aprendizado de máquina encadeados como mecanismo de detecção de *links* de *phishing*.



► FUNDAMENTAÇÃO O 02

► PHISHING

DEFINIÇÃO

Phishing é um conceito definido como o uso de técnicas de engenharia social, associada à clonagem da identidade visual de páginas confiáveis para captar dados sensíveis das vítimas.

DIFICULDADES

Essa modalidade de crime se aproveita do crescente alcance da tecnologia, e da falta de conhecimento e familiaridade das pessoas com a internet, para extrair informações sensíveis como login, senha, dados bancários, etc.

► APRENDIZADO DE MÁQUINA

DEFINIÇÃO

Uma área das Ciências da Computação que objetiva o desenvolvimento de sistemas que conseguem aprender a identificar padrões e tomar decisões.

APRENDIZADO SUPERVISIONADO

É uma vertente do aprendizado de máquina, definida como algoritmos que recebem dados já classificados para treinar modelos, com o intuito de identificar e categorizar novas entradas.

▶ ALGORITMOS UTILIZADOS

ÁRVORE DE DECISÃO

Utiliza-se de uma série de questionamentos e validações hierárquicas para classificar novos dados.

XGBOOST

Modelo do tipo *ensemble* que utiliza *boosting* por gradiente para combinar modelos, corrigindo os erros obtidos a cada iteração.

FLORESTA ALEATÓRIA

Modelo do tipo *ensemble*, utiliza-se de diversas árvores de decisão diferentes associadas para obter resultados mais precisos.

CATBOOST

Semelhante ao XGBoost, porém otimizado para o uso de variáveis categóricas.

EXTRA TREES

Uma variação do floresta aleatória, utiliza o conjunto de dados inteiro e aleatoriza os nós das sub-árvores.

REGRESSÃO LOGÍSTICA

É um modelo estatístico linear muito utilizado para problemas de classificação binária.

▶ AVALIAÇÃO DOS MODELOS

TP VERDADEIRO POSITIVO

A entrada é verdadeira e é classificada como verdadeira.

TN VERDADEIRO NEGATIVO

A entrada é falsa e é classificada como falsa.

FP FALSO POSITIVO

A entrada é falsa e é classificada como verdadeira.

FN FALSO NEGATIVO

A entrada é verdadeira e é classificada como falsa.

► MÉTRICAS

ACURÁCIA

Define a porcentagem de resultados classificados corretamente.

$$\text{Acurácia} = \frac{TP + TN}{TP + FP + TN + FN}$$

PRECISÃO

Define a porcentagem de resultados do tipo verdadeiro positivo.

$$\text{Precisão} = \frac{TP}{TP + FP}$$

► MÉTRICAS

MATRIZ DE CONFUSÃO

Uma matriz de duas dimensões que representa os resultados da classificação binária de um modelo.

		Classe Prevista	
		POSITIVO	NEGATIVO
Classe Verdadeira	POSITIVO	TP	FP
	NEGATIVO	FN	TN



► **METODOLOGIA**

03

► FERRAMENTAS

PYTHON

Linguagem de programação interpretada, muito utilizada na área de ciência de dados. Facilita o desenvolvimento por ser bem simples e possuir diversas bibliotecas voltadas para a área

SCIKIT-LEARN

PANDAS

MATPLOTLIB

XGBOOST

CATBOOST

► FERRAMENTAS

GOOGLE COLAB

Ambiente de programação disponibilizado pela Google, possibilitando o desenvolvimento de scripts de maneira remota.

Foi utilizado para o treinamento e avaliação dos modelos.

STREAMLIT

Framework em Python que facilita o desenvolvimento de páginas web.

Auxilia na criação da interface gráfica de forma simples, abstraindo conceitos de HTML e CSS.

► CONJUNTO DE DADOS

Foram seleccionados dois conjuntos de dados durante o projeto, um elaborado por Vrbančič, Fister e Podgorelec em 2020 e outro elaborado por Prasad e Chandra em 2024.

Devido à natureza do projeto e à diversas dificuldades com o *dataset* mais novo, o desenvolvimento foi feito com base no elaborado em 2020.

Este conjunto é composto por 88.647 entradas, divididas da seguinte forma:

LEGÍTIMAS

58.000

PHISHING

30.647

► CONJUNTO DE DADOS

O conjunto original possui 112 características, sendo uma delas a classificação em relação à legitimidade da página em questão.

Foram selecionadas 41 dessas características para o treinamento dos modelos, sendo divididas entre atributos baseados no endereço completo e no domínio do endereço

ENDEREÇO COMPLETO

Características obtidas a partir do *link* completo.

DOMÍNIO DO ENDEREÇO

Características obtidas exclusivamente a partir do domínio do *link*.

▶ CLASSIFICAÇÃO DOS MODELOS

O *dataset* foi dividido em 70% das entradas para treinamento e 30% para testes.

Os modelos foram classificados e ordenados com base na acurácia, precisão e tempo de execução médio.

**ÁRVORE DE
DECISÃO**



XGBOOST



**REGRESSÃO
LÓGICA**



**FLORESTA
ALEATÓRIA**



EXTRA TREES




CATBOOST

► DESENVOLVIMENTO DA APLICAÇÃO

A aplicação recebe um endereço web a ser validado, extrai as informações necessárias para obter uma classificação dos modelos e executa os algoritmos de forma orquestrada, a fim de obter uma maior eficiência, acionando apenas os modelos necessários.

TELA INICIAL



Validador de site

Coloque o endereço do site que deseja validar na caixa de texto abaixo

siteparavalidar.com

Validar

Recarregar Página

► DESENVOLVIMENTO DA APLICAÇÃO

TELA DE PÁGINA SEGURA

Validador de site

Site Seguro

O site foi validado e pode ser acessado sem riscos à segurança

Recarregar Página

► DESENVOLVIMENTO DA APLICAÇÃO

TELA DE PÁGINA DUVIDOSA

Validador de site

Site Duvidoso

O site foi avaliado e pode ser acessado com cautela, pois pode oferecer riscos à segurança

Recarregar Página

► DESENVOLVIMENTO DA APLICAÇÃO

TELA DE PÁGINA PERIGOSA

Validador de site

Site Perigoso

O site foi avaliado e não deve ser acessado por apresentar riscos altíssimos à segurança

Recarregar Página



► **RESULTADOS**

04

▶ ÁRVORE DE DECISÃO

RESULTADOS OBTIDOS

ACURÁCIA	PRECISÃO	EXECUÇÃO
92,42%	92,53%	1,1 segundos

		Classe Prevista	
		POSITIVO	NEGATIVO
Classe Verdadeira	POSITIVO	7747	1399
	NEGATIVO	641	16808

► XGBOOST

RESULTADOS OBTIDOS

ACURÁCIA	PRECISÃO	EXECUÇÃO
92,92%	90,85%	1,63 segundos

		Classe Prevista	
		POSITIVO	NEGATIVO
Classe Verdadeira	POSITIVO	8077	1069
	NEGATIVO	813	16636

► REGRESSÃO LOGÍSTICA

RESULTADOS OBTIDOS

ACURÁCIA	PRECISÃO	EXECUÇÃO
89,39%	88,63%	5,91 segundos

		Classe Prevista	
		POSITIVO	NEGATIVO
Classe Verdadeira	POSITIVO	7256	1890
	NEGATIVO	913	16518

► FLORESTA ALEATÓRIA

RESULTADOS OBTIDOS

ACURÁCIA	PRECISÃO	EXECUÇÃO
93,45%	91,99%	6,77 segundos

		Classe Prevista	
		POSITIVO	NEGATIVO
Classe Verdadeira	POSITIVO	8114	1032
	NEGATIVO	705	16744

▶ EXTRA TREES

RESULTADOS OBTIDOS

ACURÁCIA	PRECISÃO	EXECUÇÃO
93,41%	93,87%	8,35 segundos

		Classe Prevista	
		POSITIVO	NEGATIVO
Classe Verdadeira	POSITIVO	8059	1087
	NEGATIVO	676	16773

► CATBOOST

RESULTADOS OBTIDOS

ACURÁCIA	PRECISÃO	EXECUÇÃO
93,32%	91,63%	22,7 segundos

Classe Prevista		
Classe Verdadeira	POSITIVO	NEGATIVO
	8110	1036
	741	16708

► RESULTADOS GERAIS

	ACURÁCIA	PRECISÃO	EXECUÇÃO
ÁRVORE DE DECISÃO	92,42%	92,53%	1,1 segundos
XGBOOST	92,92%	90,85%	1,63 segundos
REGRESSÃO LOGÍSTICA	89,39%	88,63%	5,91 segundos
FLORESTA ALEATÓRIA	93,45%	91,99%	6,77 segundos
EXTRA TREES	93,41%	93,87%	8,35 segundos
CATBOOST	93,32%	91,63%	22,7 segundos



► CONCLUSÃO

05

► CONCLUSÃO

OBJETIVOS ALCANÇADOS

Este projeto objetiva o desenvolvimento de uma aplicação que auxilia na prevenção de ataques de *phishing*. A aplicação foi construída e seguiu sua principal diretiva, ser simples de usar.

DIFICULDADES ENCONTRADAS

Devido às alterações necessárias ao conjunto de dados, os resultados da aplicação não são tão acurados e precisos quanto os resultados obtidos nos testes.

TRABALHOS FUTUROS

Futuros trabalhos podem construir um *dataset* mais robusto dedicado a essa abordagem, melhorando a precisão e acurácia dos modelos.



► **REFERÊNCIAS**

06

► REFERÊNCIAS

- ALEROUD, A.; ZHOU, L. Phishing environments, techniques, and countermeasures: A survey. Computers & Security, Elsevier, v. 68, p. 160-196, 2017.
- ALKHALIL, Z.; HEWAGE, C.; NAWAF, L.; KHAN, I. Phishing attacks: A recent comprehensive study and a new anatomy. Frontiers in Computer Science, Frontiers Media SA, v. 3, p. 563060, 2021.
- COUTINHO, V. M. Detecção de páginas de phishing utilizando aprendizado de máquina. 2023.
- FAWCETT, T. An introduction to roc analysis. Pattern recognition letters, Elsevier, v. 27, n. 8, p. 861-874, 2006.
- IBRAHIM, A. A.; RIDWAN, R. L.; MUHAMMED, M. M.; ABDULAZIZ, R. O.; SAHEED, G. A. Comparison of the catboost classifier with other machine learning methods. International Journal of Advanced Computer Science and Applications, v. 11, 2020. Disponível em: <<https://api.semanticscholar.org/CorpusID:232846952>>.
- KRAMER, O.; KRAMER, O. Scikit-learn. Machine learning for evolution strategies, Springer, p. 45-53, 2016.
- MCKINNEY, W. et al. pandas: a foundational python library for data analysis and statistics. Python for high performance and scientific computing, Seattle, v. 14, n. 9, p. 1-9, 2011.
- MONTAGNER, A. S.; WESTPHALL, C. M. Uma breve análise sobre phishing. Revista ComInG-Communications and Innovations Gazette, v. 6, n. 1, p. 46-56, 2022.

► REFERÊNCIAS

- MÜLLER, A. C.; GUIDO, S. Introduction to machine learning with Python: a guide for data scientists. [S.l.]: "O'Reilly Media, Inc.", 2016.
- PRASAD, A.; CHANDRA, S. PhiUSIIL Phishing URL (Website). 2024. UCI Machine Learning Repository. DOI: <https://doi.org/10.1016/j.cose.2023.103545>.
- RESNICK, N. E.; BASTOS-FILHO, C. J. A. Aplicação de aprendizado de máquinas para detecção de urls phishing. Revista de Engenharia e Pesquisa Aplicada, v. 9, n. 1, p. 41-49, 2024.
- SOUZA, J. A.; MASCARENHAS, D. M. Detecção de ataques de phishing em tempo real utilizando algoritmos de aprendizado de máquina. In: SBC. Anais Estendidos do XXIII Simpósio Brasileiro em Segurança da Informação e de Sistemas Computacionais. [S.l.], 2023. p. 165-176.
- STREAMLIT. Streamlit documentation. 2024. Disponível em: <<https://docs.streamlit.io/>>. Acesso em: 3 abr. 2024.
- VRBANČIČ, G.; FISTER, I.; PODGORELEC, V. Datasets for phishing websites detection. Data in Brief, v. 33, p. 106438, 2020. ISSN 2352-3409. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S2352340920313202>>.