
Diagnóstico automático de AVC pós-trauma com base na face de pacientes utilizando redes neurais em grafos.

Nicolas Barbosa Gomes

Orientador: João Paulo Papa

Coorientador: Mateus Roder

Universidade Estadual Paulista “Júlio de Mesquita Filho” (UNESP)
Faculdade de Ciências (FC) / Departamento de Computação (DCo)
Bauru, SP – Brasil

Sumário da Apresentação


- ❑ Introdução
- ❑ Objetivos
- ❑ Fundamentação Teórica
- ❑ Trabalhos Correlatos
- ❑ Metodologia
- ❑ Experimentação e Resultados
- ❑ Aplicação Desenvolvida
- ❑ Considerações Finais

Introdução

- **Acidente vascular cerebral (AVC):** Ocorre quando os vasos que transportam o sangue internamente ao cérebro se rompem ou ficam obstruídos.
- **AVC isquêmico:** Obstrução do fluxo sanguíneo em uma artéria do cérebro. (85% dos casos)
- **AVC hemorrágico:** Rompimento de um vaso interno ao cérebro (ligado a quadros de hipertensão arterial).

Introdução

Figura 1: Diferença entre os tipos de AVC



Fonte: [Adaptado do Instituto do Coração de Santa Maria](#)

Introdução


- **Casos no ano:** Entre 10,3 a 16,9 milhões de casos, dos quais 5,9 milhões resultam em fatalidades.
- **Casos que necessitam de tratamento:** Anualmente entre 25,7 e 33,0 milhões de pessoas necessitam de terapias para lidar com as sequelas do AVC (LAPCHAK; ZHANG, 2017).
- **Preocupação global:** uma vez que, com o envelhecimento da população mais casos tendem a ocorrer (LAPCHAK; ZHANG, 2017).
- **Sequelas:** como déficits motores, atrofia muscular e paralisia facial.

Introdução

- **Paralisia facial:** Músculos da região facial enfraquecidos, prejudicando a capacidade de produzir fala (40% dos pacientes) e atividades simples como comer e beber, tornam-se mais desafiadoras.
- **Tratamento:** É necessário o tratamento dos pacientes, para que as capacidades perdidas sejam restauradas.
- **Construção de ferramentas que façam o monitoramento automatizado do tratamento e de forma acessível.**

Introdução

Figura 1: Musculatura Orofacial.



Fonte: Adaptado do site aomcollab.

Objetivos


- Introduzir um modelo profundo baseado em grafos que identifique com base na imagem o comprometimento orofacial resultante de AVC.




Pré-processar o dataset.



Cortar as imagens com o rosto centralizado.



Extrair pontos da face e formar um grafo.




Treinar e validar o modelo de Redes Neurais.



Desenvolvimento da aplicação.


Fundamentação Teórica - Redes Neurais

- Classificação em um problema simples de aprendizado de máquina.




Fundamentação Teórica - Redes Neurais

- Classificação em um problema mais complexo de aprendizado de máquina.



Trabalhos Correlatos

Figura 2: Pontos selecionadas por Bandini et al. (2018).



Fonte: Adaptada de (Bandini et al. 2018).


Quadro 1: Principais pontos do trabalho de Bandini et al. (2018).

Objetivo	Detectar danos a face causados pelo AVC.
Extrator de pontos	Supervised Descent Method e IntelFT.
Algoritmo utilizado	SVM e Regressão Logística.
Dados utilizados	Vídeos
Acurácia do modelo	87%

Fonte: Elaborado pelo autor.

Trabalhos Correlatos

Figura 3: Características selecionadas por Parra-Dominguez, Sanchez-Yanez e Garcia-Capulin (2021).



Fonte: Adaptada de Parra-Dominguez, Sanchez-Yanez e Garcia-Capulin (2021).


Quadro 2: Principais pontos do trabalho de Parra-Dominguez, Sanchez-Yanez e Garcia-Capulin (2021).

Objetivo	Detectar paralisia facial causada por AVC.
Extrator de pontos	MEEShape
Algoritmo utilizado	MLP
Dados utilizados	Imagens ou Frames
Acurácia do modelo	97,22%

Fonte: Elaborado pelo autor.

Trabalhos Correlatos

Figura 4: Características selecionadas por Gomes et al. (2023).



Fonte: Adaptada de Gomes et al. (2023).

Quadro 3: Principais pontos do trabalho de Gomes et al. (2023).

Objetivo	Detectar ELA com um grafo de pontos faciais.
Extrator de pontos	FAN
Algoritmo utilizado	FPG (Redes Neurais em Grafos)
Dados utilizados	Vídeos
Acurácia do modelo	82%


Fonte: Elaborado pelo autor.

Metodologia - Conjunto de Dados


Quadro 4: Número de repetições do conjunto de dados.

Tarefa	Sub-Tarefa	Descrição	HC	AVC
Falada	PA	Repetição da sílaba '/pa/', o mais rápido possível em uma única respiração.	884	533
	BBP	Repetição da sentença "Buy Bobby a Puppy".	111	104
	PATAKA	Repetição da palavra '/pataka/' o mais rápido possível em uma única respiração.	275	163
Não falada	SPREAD	Sorrir com os lábios fechados.	59	62
	KISS	Fingir que vai beijar um bebê.	57	62
	OPEN	Máxima abertura da mandíbula e da boca.	55	61
	BLOW	Fingir que vai soprar uma vela.	39	44
	BIGSMILE	Abrir um sorriso largo.	15	16
	BROW	Erguer as sobrancelhas.	20	37

Metodologia - Conjunto de Dados



OPEN




BIGSMILE




BLOW



KISS



BROW



SPREAD



Metodologia - Pré-processamento dos dados



Metodologia - Pré-processamento dos dados

Figura 5: Frames da repetição selecionados.

VÍDEO DA REPETIÇÃO




FRAMES CENTRAIS SELECIONADOS

Fonte: Elaborada pelo autor.

Selectiona-se 15 frames centrais da repetição

Metodologia - Pré-processamento dos dados


Figura 6: Pré-processamento dos frames



Fonte: Elaborada pelo autor.


Metodologia - Pré-processamento dos dados

Figura 7: Rotação para normalização das coordenadas.




Metodologia - Pré-processamento dos dados

Figura 8: Formação do grafo.




Metodologia - Classificação e Validação

Figura 9: Classificação da repetição e do indivíduo.



Metodologia - Modelo Proposto


Figura 10: Modelo Proposto.



Fonte: Elaborada pelo autor.

Fundamentação Teórica - Redes Neurais em Grafos

Figura 11: Redes Neurais em Grafos.



Fonte: Elaborada pelo autor.

Fundamentação Teórica - Redes Neurais em Grafos

$$\mathbf{h}_u^{k+1} = \textit{Atualiza}^k (\mathbf{h}_u^k, \textit{Agrega}_u^k (\{\mathbf{h}_v^k, \forall v \in \mathcal{N}(u)\})).$$

Equação 1

GCN

$$\mathbf{h}_u^k = \sigma \left(\mathbf{W}^k \sum_{v \in \mathcal{N}(u) \cup \{u\}} \frac{\mathbf{h}_v^{(k-1)}}{\sqrt{|\mathcal{N}(u)| |\mathcal{N}(v)|}} \right).$$

Equação 2

GAT

$$\mathbf{h}_u^k = \sigma \left(\sum_{v \in \mathcal{N}(u)} \alpha_{v \rightarrow u}^k \mathbf{W}^k \mathbf{h}_v^{(k-1)} \right).$$

Equação 3

Metodologia - Modelo Proposto

Quadro 4: Número de repetições do conjunto de dados.


Hiperparâmetros	FPG-GCN	FPG-GAT
Taxa de Aprendizado	0,001	0,0001
Tamanho do mini-batch	16	16
Tamanho das camadas ocultas	128	64
Taxa de dropout	0,1	0,2

Fonte: Elaborada pelo autor.

`ReduceLROnPlateau(optimizer, 'min', patience=5, min_lr=1e-5, factor=0.9, threshold=0.1)`

Metodologia - Validação

Figura 12: Frames da repetição selecionados.



Experimentação e Resultados

- Além da acurácia foram calculadas a especificidade e sensibilidade.
- VN: Verdadeiro Negativo
- VP: Verdadeiro Positivo
- FN: Falso Negativo
- FP: Falso Positivo

$$Especificidade = \frac{VN}{VN + FP}$$

Equação 4

$$Sensibilidade = \frac{VP}{VP + FN}$$

Equação 5

Experimentação e Resultados

Quadro 5: Resultados do modelo FPG-GAT para cada tarefa selecionada.

TAREFA	Classificação (GAT)	Acurácia	Especificidade	Sensibilidade
SPREAD	Repetição	38,04%	40,13%	36,45%
	Indivíduo	40,00%	45,45%	35,71%
KISS	Repetição	53,02%	38,88%	63,56%
	Indivíduo	52,00%	36,36%	64,29%
OPEN	Repetição	52,99%	46,86%	57,43%
	Indivíduo	64,00%	54,54%	71,43%
BLOW	Repetição	42,53%	25,56%	53,74%
	Indivíduo	44,44%	28,57%	54,54%
BIGSMILE	Repetição	72,01%	87,74%	57,26%
	Indivíduo	83,33%	100,00%	66,67%
BROW	Repetição	87,94%	86,77%	88,57%
	Indivíduo	90,91%	75,00%	100,00%

Fonte: Elaborada pelo autor.

Experimentação e Resultados


Quadro 6: Resultados do modelo FPG-GCN para cada tarefa selecionada.

TAREFA	Classificação (GCN)	Acurácia	Especificidade	Sensibilidade
SPREAD	Repetição	31,19%	23,67%	36,95%
	Indivíduo	32,00%	18,18%	42,86%
KISS	Repetição	50,60%	37,86%	60,10%
	Indivíduo	48,00%	36,36%	57,14%
OPEN	Repetição	51,88%	36,48%	63,03%
	Indivíduo	52,00%	36,36%	64,29%
BLOW	Repetição	45,23%	26,80%	57,41%
	Indivíduo	50,00%	14,29%	72,73%
BIGSMILE	Repetição	91,78%	88,82%	94,56%
	Indivíduo	100,00%	100,00%	100,00%
BROW	Repetição	36,36%	25,00%	42,86%
	Indivíduo	37,20%	29,19%	41,54%

Fonte: Elaborada pelo autor.

Experimentação e Resultados


Figura 13: Umap dos nós do grafo.



Fonte: Elaborada pelo autor.

Experimentação e Resultados


Figura 14: Umap dos nós do grafo, evidenciando as melhores tarefas



Fonte: Elaborada pelo autor.

Comparação com os trabalhos de referência


Figura 15: Comparação da Acurácia com os modelos referência.



Fonte: Elaborada pelo autor.

Comparação com os trabalhos de referência

Figura 16: Comparação da Acurácia com modelos de ML simples.



Fonte: Elaborada pelo autor.

Explicação dos modelos


Figura 17: Explicabilidade da CNN.



Fonte: Adaptada de Understand your Algorithm with Grad-CAM.

Explicação dos modelos

Figura 18: Explicabilidade dos modelos.




Grad-Cam para Redes em Grafos

Fonte: Elaborada pelo autor.


Aplicação Desenvolvida

Figura 19: Diagrama do funcionamento da aplicação.



Fonte: Elaborada pelo autor.

Aplicação



Considerações Finais e Trabalhos Futuros

- Validar em um banco de dados maior.
- Profissional médico especialista na doença ajudaria na interpretação dos pontos analisados, assim como dos resultados obtidos.
- Testar o modelo para pacientes com outros tipos de doença que causam paralisia na face, como a paralisia cerebral ou tumores cerebrais.
- Continuidade do desenvolvimento da ferramenta proposta.

Isso é tudo pessoal !

Muito Obrigado!

Referências

PARRA-DOMINGUEZ, G. S.; SANCHEZ-YANEZ, R. E.; GARCIA-CAPULIN, C. H. Facial paralysis detection on images using key point analysis. *Applied Sciences*, MDPI, 48 v. 11, n. 5, p. 2435, 2021. Disponível em: <https://www.mdpi.com/2076-3417/11/5/2435>. Acesso em: 22 set. 2023.

PECUNDO, A. M.; ABU, P. A.; ALAMPAY, R. Amyotrophic lateral sclerosis and post-stroke orofacial impairment video-based multi-class classification. In: *Proceedings of the 2022 5th Artificial Intelligence and Cloud Computing Conference*. [s.n.], 2022. p. 150–157. Disponível em: <https://dl.acm.org/doi/10.1145/3582099.3582123>. Acesso em: 2 nov. 2023.

LAPCHAK, P. A.; ZHANG, J. H. The high cost of stroke and stroke cytoprotection research. *Translational stroke research*, Springer, v. 8, p. 307–317, 2017. Disponível em: <https://link.springer.com/article/10.1007/s12975-016-0518-y>. Acesso em: 28 set. 2023.

GOMES, N. B.; YOSHIDA, A.; RODER, M.; OLIVEIRA, G. C. de; PAPA, J. P. Facial point graphs for amyotrophic lateral sclerosis identification. *arXiv preprint arXiv:2307.12159*, 2023. Disponível em: <https://arxiv.org/abs/2307.12159>. Acesso em: 5 set. 2023.

Referências

PARRA-DOMINGUEZ, G. S.; SANCHEZ-YANEZ, R. E.; GARCIA-CAPULIN, C. H. Facial paralysis detection on images using key point analysis. *Applied Sciences*, MDPI, 48 v. 11, n. 5, p. 2435, 2021. Disponível em: <https://www.mdpi.com/2076-3417/11/5/2435>. Acesso em: 22 set. 2023.

PECUNDO, A. M.; ABU, P. A.; ALAMPAY, R. Amyotrophic lateral sclerosis and post-stroke orofacial impairment video-based multi-class classification. In: *Proceedings of the 2022 5th Artificial Intelligence and Cloud Computing Conference*. [s.n.], 2022. p. 150–157. Disponível em: <https://dl.acm.org/doi/10.1145/3582099.3582123>. Acesso em: 2 nov. 2023.

LAPCHAK, P. A.; ZHANG, J. H. The high cost of stroke and stroke cytoprotection research. *Translational stroke research*, Springer, v. 8, p. 307–317, 2017. Disponível em: <https://link.springer.com/article/10.1007/s12975-016-0518-y>. Acesso em: 28 set. 2023.

GOMES, N. B.; YOSHIDA, A.; RODER, M.; OLIVEIRA, G. C. de; PAPA, J. P. Facial point graphs for amyotrophic lateral sclerosis identification. *arXiv preprint arXiv:2307.12159*, 2023. Disponível em: <https://arxiv.org/abs/2307.12159>. Acesso em: 5 set. 2023.

Agradecimentos

