



Desenvolvimento de uma Aplicação para Análise de Desempenho de Grandes Modelos de Linguagem

Orientanda: Nicole Barbosa Gomes

Orientador: Prof Dr. João Paulo Papa



Índice



01

Introdução

02

Fundamentação Teórica

03

Metodologia

04

Resultados

05

Considerações Finais





01

Introdução




Introdução

- necessidade humana de comunicação
- evolução das máquinas
- novo desafio: gerar comunicação com os computadores





Introdução

- comunicação intuitiva
- processamento de linguagem natural
- redes neurais artificiais são essenciais
- criação dos transformers



Introdução

- transformers
- large language models
- versões diferentes do mesmo tipo de modelo



Problemática

- linguagens são complexas
 - palavras dependem do contexto
 - variações culturais
- pode ser difícil escolher um dos LLMs



Justificativa


- grande número de aplicações para modelos desse tipo
- gerar respostas cada vez mais naturais
 - envolvem o usuário



Objetivos

- possibilitar a avaliação da influência que as características dos diferentes modelos têm nos resultados gerados por eles
- site que gera respostas a partir de instruções do usuário
- usuário pode escolher o melhor resultado

Instrução


A light yellow rectangular box with rounded corners, containing four horizontal lines representing text input.

entrada



Modelo de
linguagem

Texto gerado

A light purple rectangular box with rounded corners, containing four horizontal lines representing generated text.

saída






02

Fundamentação Teórica




Redes Neurais Artificiais

- estruturas que podem resolver problemas mais complexos
- baseadas nas redes do cérebro humano
- caracterizadas por unidades menores capazes de passar informações adiante




Redes Neurais Artificiais

- aprendizado auto-supervisionado
- um dos métodos utilizados para treinar a rede
 - diminui o problema da limitação de quantidade de dados rotulados
 - produz representações descritivas dos dados
 - usado para modelos de linguagem



Transformers

- mecanismos de atenção
 - identificar dependências entre palavras
 - entender contexto
- distribuir espécies de pesos (atenção) para partes da sentença
 - grau de relação entre as palavras




Processamento de Linguagem Natural

→ objetivo do campo é analisar e estudar a capacidade dos humanos e das máquinas de interagirem diretamente

→ dificuldades


- regras implícitas
- conhecimento de mundo obtido por humanos
- ambiguidade

→ contexto resolve boa parte dos problemas




Large Language Models

- modelos de linguagem
 - baseados em distribuições probabilísticas
 - capazes de prever palavras em uma sequência
- treinados com grandes quantidades de dados
- usam, em sua maioria, os *transformers* em sua estrutura
 - ótima interpretação de contexto
- se diferenciam pelas características usadas para o pré-treinamento
 - corpos de texto utilizados



Prompt Design

- gerar melhores respostas
- construir entradas a fim de atingir resultados mais precisos
- aumenta a eficácia dos LLMs





03

Metodologia






Ferramentas

→ Figma

- criação de um protótipo





Ferramentas

- ➔ Visual Studio Code
 - desenvolvimento do código

```
1 <?php
2
3
4 if (isset($_POST['submit'])) {
5     include_once('respostas.php');
6
7     $entrada = addslashes($_POST['entrada-info']);
8     $info_tam_entrada = $_POST['tam-entrada-info'];
9     $info_modelo = $_POST['info-modelo'];
10    $resposta = addslashes($_POST['info-tam-resposta']);
11    $tam_resposta = $_POST['info-tam-resposta'];
12    $tempo_resposta = $_POST['tempo-resposta'];
13    $temperatura = $_POST['temperatura-info'];
14    $tokens = $_POST['tokens-info'];
15    $empresa_modelo = $_POST['info-empresa-modelo'];
16    $justificativa = addslashes($_POST['justificativa-usuario']);
17
18    $result = mysqli_query($conexao,
19        "INSERT INTO feedback
20        (entrada, tamanho_entrada, temperatura, maximo_tokens, empresa_modelo,
21        modelo_resposta, tamanho_resposta, tempo_resposta, justificativa_usuario)
22        VALUES
23        ('$entrada', '$info_tam_entrada', '$temperatura', '$tokens', '$empresa_modelo',
24        '$info_modelo', '$resposta', '$tam_resposta', '$tempo_resposta', '$justificativa')");
25 }
26
27 <!DOCTYPE html>
28 <html lang="pt-br">
29 <head>
30     <title>TryLang</title>
31     <meta charset="UTF-8">
32     <meta name="author" content="Nicola">
33     <meta name="description" content="Aplicação com o objetivo de comparar grandes modelos de linguagem">
34     <meta name="keywords" content="TLE, IA, modelos de linguagem">
35     <meta name="viewport" content="width=device-width, initial-scale=1.0">
36
37     <link rel="stylesheet" href="estilo/style.css">
```






Ferramentas

→ XAMPP

- testar a aplicação localmente






Ferramentas

→ MySQL Workbench

- armazenar as informações capturadas pela aplicação





Linguagens Utilizadas



HTML



CSS



JavaScript




PHP




Modelos

- escolhidos com base na confiabilidade das empresas e na capacidade de seguirem instruções
- permitir que o usuário compare modelos de diferentes empresas
- aplicação registra as opiniões do usuário e ajuda na criação de um panorama maior das performances






Modelos



- um modelo mais poderoso e um menos
- usuário pode escolher um modelo de cada empresa para as comparações



Desenvolvimento do Protótipo




- para cada seção, foi criada uma imagem com o layout planejado
- facilitou a criação do site



Desenvolvimento da Aplicação

- a estrutura básica foi desenvolvida através do uso de HTML
- o estilo foi alterado através do CSS
- conferir atividades aos elementos da aplicação
 - uso de javascript



escolha dos modelos



link externo





Desenvolvimento da Aplicação

- para usar os modelos, as APIs foram necessárias
- geração de chaves
- usadas no código

MySQL
Workbench

criação de conexão

criação de database


criação de tabela

- conexão com o banco de dados
 - para que os dados processados pelo site fossem armazenados
 - envio feito através do PHP e de comandos SQL
- configuração do MySQL Workbench



Desenvolvimento da Aplicação

- produção das seções do site
- seções introdutórias





Desenvolvimento da Aplicação

- produção das seções do site
- seções introdutórias

as empresas por trás dos modelos

responsáveis por criar os modelos utilizados

sobre a empresa

OpenAI



[VER MAIS](#)

sobre a empresa

Co:here



[VER MAIS](#)

sobre a empresa

AI21



[VER MAIS](#)





Desenvolvimento da Aplicação

- área destinada à descrição dos modelos
- usuário pode escolher os que serão usados para as comparações



[SAIBA MAIS](#)

sobre os modelos

é possível escolher um modelo de cada empresa para as comparações de resultados

text-davinci-003 OpenAI "pode realizar tarefas com melhor qualidade, maior saída e consistência do que os modelos curie, babbage, ou ada" saiba mais usar modelo	text-davinci-002 OpenAI "possui capacidades similares ao text-davinci-003, mas é treinado com fine-tuning supervisionado" saiba mais usar modelo	jurassic 2 - mid AI21 "oferece aprimorada capacidade de geração de texto, realizando tarefas de linguagem com um maior grau de complexidade" saiba mais usar modelo
jurassic 2 - ultra AI21 "é uma escolha ideal para a maioria das complexas tarefas de processamento de linguagem e aplicações de geração de texto"	command Co:here "modelo conversacional, capaz de seguir instruções, que realiza tarefas de linguagem com alta qualidade e confiabilidade."	command-light Co:here "um modelo que representa uma versão menor e mais rápida do command. Quase tão capaz quanto, mas muito mais rápido"





Desenvolvimento da Aplicação

- incentivar o usuário a usar os princípios de *prompt design*
- *prompts* pré-definidos para exemplificar as dicas oferecidas



APRENDA

como escrever as instruções

detalhar objetivo

se a finalidade do usuário é obter um texto escrito de maneira sarcástica, ou comercial a fim de atrair clientes para seu estabelecimento, o modelo pode gerar textos que correspondam a essas necessidades

[ver exemplo](#)

especificar formato

o formato desejado no texto final também deve ser especificado. Por exemplo, se o objetivo for obter um texto escrito no formato de notícia jornalística ou um poema. O usuário deve especificar tais detalhes

[ver exemplo](#)

definir tamanhos

o tamanho do texto deve ser determinado a fim de direcionar o modelo de linguagem. Caso o texto for pequeno ou apenas uma frase, o usuário deve incluir essa informação em sua instrução

[ver exemplo](#)





Desenvolvimento da Aplicação

- incentivar o usuário a usar os princípios de *prompt design*
- *prompts* pré-definidos para exemplificar as dicas oferecidas

detalhar objetivo

se a finalidade do usuário é obter um texto escrito de maneira sarcástica, ou comercial a fim de atrair clientes para seu estabelecimento, o modelo pode gerar textos que correspondam a essas necessidades

[ver exemplo](#)

Digite uma entrada:

escreva um texto sobre o mascote de um supermercado, um super-herói cujo poder é encontrar os melhores preços. O objetivo do texto deve ser atrair clientes a conhecerem o novo estabelecimento chamado 'Super Barato'



Desenvolvimento da Aplicação

- seção dedicada a alterar as propriedades dos modelos
- temperatura e quantidade máxima de *tokens*

The screenshot shows a web application interface with a light purple background. At the top, there is a button labeled "PERSONALIZE". Below it, the heading "propriedades" is displayed in a large, bold, dark blue font. The interface contains two main sections, each with a title, a descriptive paragraph, and a "ler mais" button.

temperatura

"A temperatura é um parâmetro importante que determina a "criatividade" do modelo de linguagem. Um valor mais alto de temperatura pode gerar respostas mais criativas, mas também pode levar a respostas menos precisas ou confusas."

[ler mais](#)

quantidade máxima de tokens

"Os tokens podem ser considerados como pedaços de palavras. Eles não são formados a partir do início ou fim das palavras de um texto, mas podem incluir espaços ou, até mesmo, sub-palavras. A seguinte relação pode ser útil: 1 token equivale a, aproximadamente, 4 caracteres ou 3/4 de palavra."

[ler mais](#)

At the bottom of the interface, there is a dark blue button labeled "alterar" (partially visible as "altera") and a white button.





Desenvolvimento da Aplicação

- seção dedicada a alterar as propriedades dos modelos
- temperatura e quantidade máxima de *tokens*

The screenshot shows a web application interface with a light blue background. At the top, there is a white header bar with a small logo on the left and a dark blue button labeled "ler mais" on the right. Below the header, the main content area is divided into two sections. On the left, there is a dark blue rectangular box with the text "altere os valores" in white. On the right, there is a white rectangular box containing two input fields. The first input field is labeled "temperatura:" and the second is labeled "quantidade máxima de tokens:". Below these input fields, there are two dark blue buttons: "aplicar mudanças" and "voltar ao padrão".



Desenvolvimento da Aplicação

- comparação dos modelos
- escolha dos modelos

...

Digite uma entrada:

escreva uma instrução...

gerar respostas

text-davinci-003 ▾ OpenAI

command ▾ Cohere

jurassic 2 - ultra ▾ AI21

limpar respostas



Desenvolvimento da Aplicação

- usuário insere uma entrada
 - tanto ela, quanto a temperatura e a quantidade máxima de *tokens* são enviadas como parâmetros para a API da empresa

Digite uma entrada:

escreva uma instrução...

gerar respostas

- quando o usuário gera as respostas, as requisições são enviadas as APIs das empresas
- quando as respostas forem devolvidas, elas são apresentadas no espaço específico da empresa

text-davinci-003

OpenAI



Desenvolvimento da Aplicação

- informações sobre a entrada e saída do usuário
- usuário pode escrever justificativa

Informações da entrada	Informações da saída			
Tamanho da entrada: 214	☐ Resposta 1	Modelo: text-davinci-003	Quantidade de caracteres: 733	Tempo de resposta: 7,717 s
Temperatura: padrão	☒ Resposta 2	Modelo: command	Quantidade de caracteres: 834	Tempo de resposta: 15,903 s
Máximo de tokens: padrão	☐ Resposta 3	Modelo: j2-ultra	Quantidade de caracteres: 503	Tempo de resposta: 5,164 s

por que foi a melhor resposta?

digite aqui...

Enviar



Desenvolvimento da Aplicação

- maior quantidade de respostas
- restrições para o envio ao banco de dados


Informações da entrada	Informações da saída			
Tamanho da entrada: 214	☐ Resposta 1	Modelo: text-davinci-003	Quantidade de caracteres: 733	Tempo de resposta: 7,717 s
Temperatura: padrão	☒ Resposta 2	Modelo: command	Quantidade de caracteres: 834	Tempo de resposta: 15,903 s
Máximo de tokens: padrão	☐ Resposta 3	Modelo: j2-ultra	Quantidade de caracteres: 503	Tempo de resposta: 5,164 s

por que foi a melhor resposta?

digite aqui...

Enviar

Desenvolvimento da Aplicação





04

Resultados





Análise dos Resultados

- aplicação hospedada localmente
- coleta de dados em grande escala
- para ilustrar o funcionamento, uma pesquisa foi feita
 - divulgada em menor escala
- MySQL Workbench permite que os dados armazenados sejam exportados
- outros aplicativos podem ser usados para a análise





Experimento

- na pesquisa, perguntas foram usadas para entender as opiniões dos usuários sobre as respostas fornecidas pelos modelos
- duas perguntas foram necessárias para comparar somente os modelos mais poderosos e, depois, os menos poderosos de cada empresa

Escolha a melhor resposta para a instrução: *

"escreva um slogan, em português, para uma livraria"

- ☐ "Leia mais, viva melhor: a melhor livraria para você!"
- ☐ "Porto das leituras que vale a pena"
- ☐ "Vivendo a vida através das palavras"

Escolha a melhor resposta para a instrução: *

"escreva uma pequena descrição, em português, sobre uma nova livraria chamada Livraria do Saber"

- ☐ A Livraria do Saber é uma livraria especializada em livros de auto-ajuda, desenvolvimento pessoal e espiritualidade. Oferecemos um ambiente tranquilo e acolhedor para que você possa explorar e aprender sobre os diversos tópicos abordados em nossos livros.

- ☐ A new library called "Livraria do Saber" is coming to town! It is a book haven, where readers can find a vast collection of titles to explore, learn, and be inspired by. The library is modern and sleek, with a welcoming atmosphere that encourages patrons to stay and read for hours. The staff is knowledgeable and friendly, always on hand to help visitors find the perfect book. Livraria do Saber is a great addition to the community, and I can't wait to visit!

- ☐ Livraria do Saber é uma nova livraria especializada em livros de ciência, tecnologia, filosofia, ciências humanas e outros temas que tratam do conhecimento humano. Tem uma seleção de livros de qualidade, publicados em português e em inglês, e oferece um ambiente acolhedor e confortável para os clientes lerem e pesquisarem. A livraria também oferece serviços adicionais, como aulas de leitura e pré-sala de leitura, para aumentar a experiência dos clientes e ajudá-los a encontrar livros



Experimento


- no total, 24 respostas foram obtidas
- respostas exportadas para uma planilha, assim como aconteceria através do MySQL Workbench
- as outras características das respostas geradas foram adicionadas a planilha para fazer as comparações

entrada	tamanho_entrada	temperatura	maximo_tokens	empresa_modelo	modelo	
"escreva uma pequena descrição, em português, sobre uma nova livreria chamada Livreria do Saber"	96	0.5	2048	OpenAI	text-davinci-002	A Livreria do Saber é uma livreria espec
"escreva uma pequena descrição, em português, sobre uma nova livreria chamada Livreria do Saber"	96	0.7	200	AI21 Studios	j2-mid	Livraria do Saber é uma nova livreria es
"escreva uma pequena descrição, em português, sobre uma nova livreria chamada Livreria do Saber"	96	0.8	200	AI21 Studios	j2-mid	Livraria do Saber é uma nova livreria es
"escreva uma pequena descrição, em português, sobre uma nova livreria chamada Livreria do Saber"	96	0.9	200	AI21 Studios	j2-mid	Livraria do Saber é uma nova livreria es
"escreva uma pequena descrição, em português, sobre uma nova livreria chamada Livreria do Saber"	96	0.10	200	AI21 Studios	j2-mid	Livraria do Saber é uma nova livreria es
"escreva uma pequena descrição, em português, sobre uma nova livreria chamada Livreria do Saber"	96	0.11	200	AI21 Studios	j2-mid	Livraria do Saber é uma nova livreria es
"escreva uma pequena descrição, em português, sobre uma nova livreria chamada Livreria do Saber"	96	0.5	2048	OpenAI	text-davinci-002	A Livreria do Saber é uma livreria espec
"escreva uma pequena descrição, em português, sobre uma nova livreria chamada Livreria do Saber"	96	0.7	200	AI21 Studios	j2-mid	Livraria do Saber é uma nova livreria es
"escreva uma pequena descrição, em português, sobre uma nova livreria chamada Livreria do Saber"	96	0.7	200	AI21 Studios	j2-mid	Livraria do Saber é uma nova livreria es
"escreva uma pequena descrição, em português, sobre uma nova livreria chamada Livreria do Saber"	96	0.7	200	AI21 Studios	j2-mid	Livraria do Saber é uma nova livreria es
"escreva uma pequena descrição, em português, sobre uma nova livreria chamada Livreria do Saber"	96	0.5	2048	OpenAI	text-davinci-002	A Livreria do Saber é uma livreria espec
"escreva uma pequena descrição, em português, sobre uma nova livreria chamada Livreria do Saber"	96	0.7	200	AI21 Studios	j2-mid	Livraria do Saber é uma nova livreria es
"escreva uma pequena descrição, em português, sobre uma nova livreria chamada Livreria do Saber"	96	0.7	200	AI21 Studios	j2-mid	Livraria do Saber é uma nova livreria es
"escreva uma pequena descrição, em português, sobre uma nova livreria chamada Livreria do Saber"	96	0.7	200	AI21 Studios	j2-mid	Livraria do Saber é uma nova livreria es
"escreva uma pequena descrição, em português, sobre uma nova livreria chamada Livreria do Saber"	96	0.7	200	AI21 Studios	j2-mid	Livraria do Saber é uma nova livreria es
"escreva uma pequena descrição, em português, sobre uma nova livreria chamada Livreria do Saber"	96	0.7	200	AI21 Studios	j2-mid	Livraria do Saber é uma nova livreria es
"escreva uma pequena descrição, em português, sobre uma nova livreria chamada Livreria do Saber"	96	0.5	2048	OpenAI	text-davinci-002	A Livreria do Saber é uma livreria espec
"escreva uma pequena descrição, em português, sobre uma nova livreria chamada Livreria do Saber"	96	0.7	200	AI21 Studios	j2-mid	Livraria do Saber é uma nova livreria es



Resultados


- para a instrução “escreva um slogan, em português, para uma livraria”, as relações das respostas escolhidas é a seguinte:





Resultados


- para a instrução “escreva um slogan, em português, para uma livraria”, as relações das empresas escolhidas é a seguinte:





Resultados


- para a instrução “escreva um slogan, em português, para uma livraria”, as relações dos tempos das respostas escolhidas é a seguinte:





Resultados


- para a instrução “escreva uma pequena descrição, em português, sobre uma nova livraria chamada Livraria do Saber”, as relações das respostas escolhidas é a seguinte:





Resultados


- para a instrução “escreva uma pequena descrição, em português, sobre uma nova livraria chamada Livraria do Saber”, as relações das empresas escolhidas é a seguinte:





Resultados

- para a instrução “escreva uma pequena descrição, em português, sobre uma nova livraria chamada Livraria do Saber”, as relações dos tempos das respostas escolhidas é a seguinte:





Resultados

→ também é interessante analisar os tamanhos das respostas escolhidas:





05

Considerações Finais





Considerações Finais

- os LLMs abriram portas para aplicações antes não imagináveis
- o site desenvolvido busca ajudar nas escolhas de modelos para certas tarefas, através dos dados fornecidos pelos usuários
- a aplicação recebeu meios para enviar e receber informações, e armazená-las de maneira segura
- os dados salvos podem ser usados de várias maneiras
- o site pode ser usado tanto para consultar modelos, quanto para contribuir para um estudo maior da capacidade de cada um deles
- ambiente interativo e intuitivo





Trabalhos Futuros

- hospedar o site na internet e disponibilizar a aplicação para uso
- aumentar a quantidade de modelos utilizados
- aumentar a quantidade de empresas, criadoras de LLMs, escolhidas para fazer parte do projeto
- promover a coleta de dados em maior escala
- analisar os dados coletados e gerar um panorama maior dos desempenhos dos modelos





BAHETI, P. A newbie-friendly guide to transfer learning. 2021. Disponível em: <https://www.v7labs.com/blog/transfer-learning-guide>. Acesso em: 15 novembro 2023.

BALESTRIERO, R.; IBRAHIM, M.; SOBAL, V.; MORCOS, A.; SHEKHAR, S.; GOLDSTEIN, T.; BORDES, F.; BARDES, A.; MIALON, G.; TIAN, Y. et al. A cookbook of self-supervised learning. 2023. Acesso em: 15 novembro 2023.

BANANE, M.; ERRAISSI, A. A comprehensive study of natural language processing techniques based on big data. 2022. Disponível em: <https://ieeexplore.ieee.org/abstract/document/9765270/>. Acesso em: 15 novembro 2023.

CARDON, A.; MÜLLER, D. N.; NAVAUX, P. Introdução às redes neurais artificiais. 1994. Disponível em: https://www.academia.edu/download/60901380/intro_rna20191014-14353-doa3qp.pdf. Acesso em: 15 novembro 2023.

JIANG, E.; OLSON, K.; TOH, E.; MOLINA, A.; DONSBACH, A.; TERRY, M.; CAI, C. J. Promptmaker: Prompt-based prototyping with large language models. 2022. Disponível em: <https://dl.acm.org/doi/pdf/10.1145/3491101.3503564>. Acesso em: 15 novembro 2023.

TUNSTALL, L.; WERRA, L. V.; WOLF, T. Natural language processing with transformers. 2022. Disponível em: <https://books.google.com/books?hl=pt-BR&lr=&id=nzxbEAAAQBAJ&oi=fnd&pg=PP1&dq=Natural+language+processing+with+transformers&ots=sTwmlWq3NB&sig=-10AmBD6LroEyoWvI3OV9iijUPY>. Acesso em: 15 novembro 2023.

OZDEMIR, S. Quick start guide to large language models: Strategies and best practices for using chatgpt and other llms. 2023. Acesso em: 15 novembro 2023.





Obrigada!

