





Construção de


Agente Inteligente

para resolução de questões de

vestibular



Sofia Azevedo Rosa
Prof. Dr. João Paulo Papa
Me. Pedro Henrique Paiola



Cronograma

- 1. Introdução**
- 2. Fundamentação Teórica**
- 3. Metodologia**
- 4. Experimentos e resultados**
- 5. Conclusão**

Introdução

Introdução

- Grandes modelos de linguagem (LLMs) apresentam grande habilidade para diversos tipos de tarefas.
- Apesar disso, **limitam-se** em tarefas que exigem **cálculo matemático** ou **precisão factual**.
- Diversas abordagens buscam mitigar essas limitações
- Uso dos LLMs como base para a construção de **agentes inteligentes** para resolver problemas mais complexos

Introdução

Problema

- Contexto explorado: questões de vestibulares brasileiros
- Apesar de seu grande potencial, grandes modelos de linguagem apresentam grandes limitações que são refletidas em sua capacidade na resolução de questões de vestibular (Nunes et. al, 2023)

Introdução

Justificativa

- Apesar dos avanços dos LLMs, seu uso isolado ainda falha em lógica e matemática; transformá-los em agentes capazes de usar ferramentas externas surge como caminho promissor para melhorar o desempenho em questões de vestibular.

Introdução

Objetivos

Desenvolver um agente inteligente baseado em um modelo de linguagem que seja capaz de responder questões de vestibular com maior acurácia

- Analisar a capacidade dos LLMs utilizados de forma isolada;
- Integrar os LLMs com ferramentas externas;
- Projetar e implementar o fluxo de funcionamento do agente;
- Avaliar o agente desenvolvido;

Fundamentação Teórica

Fundamentação Teórica

Avanços e Limitações dos LLMs

- Os modelos de linguagem como conhecemos hoje são construídos a partir da arquitetura **Transformer**
- Arquitetura revolucionária: os mecanismos de **atenção** permitem a análise de várias palavras simultaneamente e a interpretação da **relação entre elas**. (VASWANI et al., 2023)

Fundamentação Teórica

Avanços e Limitações dos LLMs

- A partir do surgimento da arquitetura, a evolução dos modelos de linguagem foi marcada por grande aumento de **escala**, em quantidade de **dados de treinamento** e em **número de parâmetros**
- O aumento da escala possibilitou o surgimento de **capacidades emergentes**, como as capacidades generalistas
- O que faz um modelo ser “large” (de grande escala)?


Fundamentação Teórica

Avanços e Limitações dos LLMs

- A principal limitação atual dos LLMs é conhecida na literatura por **alucinação**.
- Modelo de linguagem pode gerar informações **factualmente incorretas** ou **fora de contexto** com grande confiança, como se fossem informações verdadeiras.
- As causas geralmente estão nos dados de **treinamento**: grande quantidades de dados, que podem ser enviesados ou defasados.

Inconsistência com a entrada do usuário


Me recomende uma boa receita para um café da tarde saudável.



Claro: para um café da manhã completo e saudável, podemos fazer um pão com ovo...

Inconsistência com o Contexto


Quando foi lançado o primeiro telefone celular?



Em 1990. Por isso, dizem que os anos 80 marcaram o início da mobilidade...

Inconsistência factual

Qual é o estado brasileiro que não tem a letra "a" no nome?



O estado que não tem a letra "a" no nome é o Pernambuco

Tipos de alucinação (ZHANG et al., 2023)

Fundamentação Teórica

Avanços e Limitações dos LLMs

- Outra limitação dos LLMs é a sua dificuldade em interpretar e resolver problemas que envolvem **raciocínio matemático**.
- É uma limitação **intrínseca**: os LLMs não possuem nativamente a capacidade de raciocínio estruturado, são treinados para prever palavras em uma sequência com base em padrões de linguagem.
- Os dados utilizados no seu treinamento podem mudar sua capacidade lógica (AHN et al., 2024)

Fundamentação Teórica

Avanços e Limitações dos LLMs

- Algumas estratégias já foram estabelecidas para mitigar essas limitações dos LLMs:
 - Engenharia de *prompt* (*few-shot* e *Chain-of-Thought*)
 - *Retrieval-Augmented Generation*
 - Uso de ferramentas externas

Prompt Original

Analise o sentimento transmitido pela frase.
Classifique em "Positivo" ou "Negativo".

Frase: "Esse aplicativo é péssimo."

Prompt de Few Shot

Analise o sentimento transmitido pela frase.
Classifique em "Positivo" ou "Negativo".

Exemplos:

- Frase: "Foi um ótimo filme!"
Classificação: Positivo.
- Frase: "Isso tem um sabor ruim."
Classificação: Negativo.
- Frase: "Não gostei da ideia"
Classificação: Negativo
- Frase: "Achei a música muito legal"
Classificação: Positivo

Frase: "Esse aplicativo é péssimo."

Prompt de COT

Analise o sentimento transmitido pela frase.
Classifique em "Positivo" ou "Negativo".

Exemplos:

Frase: "Foi um ótimo filme!"

Análise: A palavra 'ótimo' expressa avaliação positiva

Classificação: Positivo.

Frase: "Isso tem um sabor ruim."

Análise: A palavra 'ruim' denota insatisfação.

Classificação: Negativo.

Frase: "Não gostei da ideia"

Análise: A expressão 'não gostei' denota insatisfação.

Classificação: Negativo

Frase: "Achei a música muito legal"

Análise: A palavra 'legal' expressa aprovação.

Classificação: Positivo

Frase: "Esse aplicativo é péssimo."

**Engenharia de Prompt
(BROWN et al., 2020) (WEI et al., 2023)**



Quem foi o líder que governou a França após a Revolução Francesa?


Busca Semântica

Base de Documentos

Após a instabilidade política na França, o jovem general Napoleão Bonaparte assumiu o poder por meio do golpe de Estado de 18 Brumário, em 1799. ✓

A Revolução Industrial do século XVIII foi marcada pela invenção da máquina a vapor por James Watt... ✗

A Revolução Industrial do século XVIII foi marcada pela invenção da máquina a vapor por James Watt... ✗



O líder que governou a França após a Revolução Francesa foi Napoleão Bonaparte.

RAG
(Lewis et al., 2021)

Fundamentação Teórica


Agentes Inteligentes e Baseados em LLMs

- Um **agente inteligente**, na IA clássica, é uma entidade capaz de **perceber** seus arredores por meio de sensores e **agir** por meio de atuadores (RUSSELL; NORVIG, 2009)
- Os agentes possuem quatro características principais: autonomia, reatividade, pró-atividade e habilidade social (Wooldridge; Jennings, 1995)

Fundamentação Teórica

Agentes Inteligentes e Baseados em LLMs

- Os LLMs são capazes de agir como **componente central** dos agentes, a partir da expansão de seu espaço de percepção - no caso de entradas multimodais - e ação, por meio da utilização de ferramentas



Agentes baseados em LLM (Xi et al, 2023)

Fundamentação Teórica

Trabalhos relacionados

- Evaluating GPT-3.5 and GPT-4 Models on Brazilian University Admission Exams (Nunes et al., 2023)
- Enhancing Large Language Model Performance on ENEM Math Questions Using Retrieval-Augmented Generation (Superbi et al., 2024)

Fundamentação Teórica


Trabalhos relacionados

- MathChat: Converse to Tackle Challenging Math Problems with LLM Agents (WU et al., 2024)
- Physics Reasoner: Knowledge-Augmented Reasoning for Solving Physics Problems with Large Language Models (PANG et al., 2024)

Metodologia

Metodologia

Modelos de Linguagem



Llama 3.1

8 bilhões de parâmetros
(GRATTAFIORI et al., 2024)



Mistral

7 bilhões de parâmetros
(JIANG et al., 2023)

Metodologia

Datasets

- **BLUEX** (ALMEIDA et al., 2023) - Questões da USP e Unicamp dos anos de 2018 a 2024
- **Enem Challenge** (SILVEIRA; MAUÁ, 2017) - Questões do ENEM de 2009 a 2017

Metodologia

Agente - Ferramentas


- **Wolfram Alpha:** API de um serviço de conhecimento computacional; utilizado como **calculadora** para o agente;
- **Wikipédia:** API de enciclopédia online, retorna artigos a partir de uma *query*.

Metodologia

Agente - Arquitetura

- Composta por nós interligados, cada um com uma determinada função
- A ideia é forçar etapas intermediárias durante a resolução
- Supervisor: coordena o fluxo geral
- Roteador: determina os próximos passos a partir do supervisor
- Nós de ferramentas: determinam as chamadas das APIs
- Executor: executa as chamadas das APIs
- Conclusor: define a resposta final a partir do supervisor
- Contingência: caso a resolução exija muitas etapas, responde diretamente


Arquitetura do Agente



Metodologia

Avaliação

- **Avaliação quantitativa** - avaliar a acurácia do agente na resolução das questões, de forma geral e de forma específica por matéria e por categoria
- **Avaliação qualitativa** - avaliar **alguns casos** completos, verificando o raciocínio e o uso de ferramentas



Experimentos e Resultados

Experimentos e Resultados

Experimentos iniciais com LLMs

- Uso direto dos modelos de linguagem para a resolução das questões
- Estabelecimento de base de comparação
- 242 questões da USP; 279 questões da Unicamp; 218 questões do ENEM;

Tabela 1 – Performance dos modelos *Mistral* e *Llama 3.1* na resolução direta de questões dos vestibulares

ENEM			
Modelo	Acertos	Erros	Acurácia (%)
Mistral	122	96	55,96
Llama 3.1	134	84	61,47
USP			
Modelo	Acertos	Erros	Acurácia (%)
Mistral	123	119	50,83
Llama 3.1	139	103	57,44
Unicamp			
Modelo	Acertos	Erros	Acurácia (%)
Mistral	140	139	50,18
Llama 3.1	145	134	51,97

Tabela 2 – Performance dos modelos Mistral e Llama 3.1 por matéria nas questões dos vestibulares USP e Unicamp

USP						
	Mistral			Llama 3.1		
	Total de Perguntas	Acertos	Acurácia (%)	Total de Perguntas	Acertos	Acurácia (%)
Biologia	17	8	47,06	17	11	64,70
Filosofia	10	8	80,00	10	8	80,00
Física	18	5	27,78	18	5	27,78
Geografia	25	13	52,00	25	16	64,00
História	49	31	63,26	49	36	73,46
Inglês	28	22	78,57	28	25	89,28
Matemática	29	6	20,69	29	6	20,69
Português	70	32	45,71	70	34	48,57
Química	15	8	53,33	15	9	60,00
Unicamp						
	Mistral			Llama 3.1		
	Total de Perguntas	Acertos	Acurácia (%)	Total de Perguntas	Acertos	Acurácia (%)
Biologia	29	17	58,62	29	19	65,51
Filosofia	6	5	83,33	6	5	83,33
Física	31	7	22,58	31	9	29,03
Geografia	30	20	66,67	30	19	63,33
História	47	39	82,98	47	40	85,10
Inglês	21	11	52,38	21	10	47,62
Matemática	59	17	28,81	59	16	27,12
Português	60	33	55,00	60	32	53,33
Química	16	6	37,50	16	6	37,50

Experimentos e Resultados

Experimentos com os Agentes

- Dois agentes, cada um coordenado por um dos modelos
- Mesmas questões dos testes iniciais
- Possibilidade de o agente não responder (resposta como “-”): esse caso foi considerado erro na contagem de acurácia

Tabela 4 – Performance dos agentes baseados nos modelos Mistral e Llama 3.1 nas questões de vestibular

ENEM						
Modelo	Acertos	Erros	Não respondidas	Acurácia (%)	Quantidade de passos média	Redirecionamentos
Mistral	74	123	21	33,94	6,07	0
Llama 3.1	114	83	21	52,29	15,45	1
USP						
Modelo	Acertos	Erros	Não respondidas	Acurácia (%)	Quantidade de passos média	Redirecionamentos
Mistral	55	167	20	22,73	6,79	0
Llama 3.1	74	150	18	30,58	16,28	0
Unicamp						
Modelo	Acertos	Erros	Não respondidas	Acurácia (%)	Quantidade de passos média	Redirecionamentos
Mistral	70	174	35	25,09	6,74	0
Llama 3.1	84	159	36	30,11	16,21	2

Tabela 5 – Performance por matéria dos agentes baseados nos modelos Mistral e Llama 3.1 nas questões da USP e Unicamp

	USP					
	Mistral			Llama 3.1		
	Total de Perguntas	Acertos	Acurácia (%)	Total de Perguntas	Acertos	Acurácia (%)
Biologia	17	4	23,53	17	3	17,64
Filosofia	10	3	30,00	10	2	20,00
Física	18	6	33,33	18	3	16,67
Geografia	25	7	28,00	25	7	28,00
História	49	11	22,45	49	24	48,98
Inglês	28	12	42,86	28	12	42,85
Matemática	29	6	20,69	29	7	24,13
Português	70	10	14,28	70	18	25,71
Química	15	3	20,00	15	4	26,67
	Unicamp					
	Mistral			Llama 3.1		
	Total de Perguntas	Acertos	Acurácia (%)	Total de Perguntas	Acertos	Acurácia (%)
Biologia	29	13	44,83	29	12	41,38
Filosofia	6	3	50,00	6	3	50,00
Física	31	5	16,13	31	5	16,13
Geografia	30	10	33,33	30	11	36,67
História	47	16	34,04	47	17	36,17
Inglês	21	4	19,05	21	6	28,57
Matemática	59	12	20,34	59	6	10,17
Química	16	3	18,75	16	2	12,50
Português	60	25	41,67	60	13	21,67

Questão e alternativas

Um recipiente de 30 litros contém uma solução de 14 partes de álcool e 1 parte de água. Quantos litros de água devem ser adicionados para que se tenha uma solução com 70% de álcool?

a) 8 litros. b) 10 litros. c) 12 litros. d) 14 litros.

Exemplo 2 - Execução do agente

Supervisor

Passo 1: Primeiramente, precisamos entender a composição atual da solução no recipiente de 30 litros. A solução contém 14 partes de álcool e 1 parte de água. Para saber quanto é essa "parte", precisamos calcular o volume total dessas partes.

Utilizar calculadora: $(14 + 1) / 15 = ???$

Essa expressão nos dá a fração do recipiente que representa cada uma das partes da solução atual.

Passo 2: Em seguida, precisamos saber quanto é cada parte na solução atual para entender melhor como está composta a solução e facilitar os cálculos subsequentes. Entendo que o volume de cada parte é igualmente representado, então podemos usar o resultado do passo anterior para calcular.

Utilizar calculadora: $(14 + 1) * 30 / 15 = ???$

Esse cálculo nos dá a quantidade em litros que representa 14 partes da solução no recipiente. Agora sabemos que cada parte é igualmente representada por esse volume.

Passo 3: Agora precisamos calcular quanto álcool e água há na solução atual para entendermos a composição correta, pois a pergunta fala em uma solução com "70

Utilizar calculadora: $(14/15) * 30 = ???$ (álcool) Utilizar calculadora: $(1/15) * 30 = ???$ (água)

Passo 4: A pergunta fala em adicionar água para que a solução tenha 70

Utilizar calculadora: $(14/15) * \text{novo_volume} = 0,7 * \text{novo_volume}$

Exemplo 2 - Execução do agente

Roteador

Roteando para <Calculator> com instruções: $(14 + 1) / 15 = ???$ Utilizar calculadora:
 $(14 + 1) * 30 / 15 = ???$

Calculator

Tool call: {expression: '(14 + 1) / 15'} Tool call: {expression: '(14 + 1) * 30 / 15'}

Executor

1 30

Exemplo 2 - Execução do agente

Experimentos e Resultados

Experimentos com os Agentes

- Os resultados quantitativos mostram uma grande queda da acurácia
- Porém, os exemplos demonstram alguma capacidade de construção de raciocínio com base na questão
- Possíveis problemas: ferramenta da wikipédia; tamanho dos modelos

Pergunta e alternativas

Borboleta, lula e avestruz têm como principal excreta nitrogenado, respectivamente,
a) ácido úrico, amônia e ácido úrico. b) ácido úrico, ureia e amônia. c) amônia, ácido úrico e amônia. d) amônia, ureia e ácido úrico. e) ureia, amônia e ácido úrico.

Exemplo 3 - Execução do agente

Supervisor

Passo 1: Verificar o tipo de excreta produzida por borboleta, lula e avestruz.
Utilizar Wikipedia para buscar sobre os sistemas excretórios de cada um desses animais.
(Por favor, aguarde a minha resposta após utilizar as ferramentas.)

Roteador

Roteando para <wikipedia> com instruções: Buscar sobre os sistemas excretórios de borboleta, lula e avestruz na Wikipédia.

Wikipedia

Tool call: {name: wikipedia, args: {query: 'Sistemas excretórios da borboleta, lagarta e avestruz'}}

Executor

No good Wikipedia Search Result was found

Exemplo 3 - Execução do agente

Experimentos e Resultados

Experimentos com os Agentes

- Para explorar as hipóteses, foi realizado um experimento adicional, com o modelo GPT-4.1 mini
- Modelo fechado, pago por token
- Diferencial: grande janela de contexto (entende contextos maiores, com mais tokens)

Tabela 7 – Performance do modelo GPT 4.1 Mini

	Modelo		Agente				
	Acertos	Acurácia (%)	Acertos	Erros	Sem resposta	Acurácia (%)	Média de passos
ENEM	180	82,57	148	21	49	67,89	14,26
USP	188	77,68	159	27	56	65,70	15,15
Unicamp	201	72,04	185	39	55	66,30	16,28
USP - Matérias							
	Total de Questões	Acertos	Acurácia (%)	Total de Questões	Acertos	Erros	Acurácia (%)
Biologia	17	14	82,35	17	11	3	64,70
Filosofia	10	10	100	10	4	2	40,00
Física	18	14	77,78	18	17	1	94,44
Geografia	25	21	84,00	25	16	5	64,00
História	49	45	91,84	49	32	5	65,31
Inglês	28	27	96,42	28	20	3	71,43
Matemática	29	8	27,59	29	24	2	82,76
Português	70	55	78,57	70	34	7	48,57
Química	15	12	80,00	15	12	0	80,00
Unicamp - Matérias							
	Total de Questões	Acertos	Acurácia (%)	Total de Questões	Acertos	Erros	Acurácia (%)
Biologia	29	27	93,10	29	22	3	75,86
Filosofia	6	6	100	6	3	0	50,00
Física	31	16	51,61	31	31	0	100
Geografia	30	27	90,00	30	20	3	66,67
História	47	46	97,87	47	30	4	63,83
Inglês	21	19	90,47	21	11	4	52,38
Matemática	59	24	40,68	59	52	3	88,13
Português	60	46	76,67	60	21	18	35,00
Química	16	9	56,25	16	8	6	50,00

Tabela 8 – Comparação da performance do GPT 4.1 Mini com Mistral e Llama 3.1

Modelo	Acurácia (%)		
	Enem	USP	Unicamp
Mistral	55,96	50,83	50,18
Llama 3.1	61,47	57,44	51,97
GPT 4.1 Mini	82,57	77,68	72,04
Agente	Acurácia (%)		
	Enem	USP	Unicamp
Mistral	33,94	22,73	25,09
Llama 3.1	52,29	30,58	30,11
GPT 4.1 Mini	67,89	65,70	66,30

Experimentos e Resultados

Experimentos com os Agentes

Os resultados desse último experimento demonstrou duas coisas importantes que fortalecem as hipóteses apresentadas:

1. O tamanho do modelo fez diferença na performance do agente na resolução das questões;
2. O agente se saiu pior nas questões das matérias de humanas do que seu modelo utilizado de forma direta, mas melhor nas matérias de exatas.

Conclusão

Conclusão

- Foi validado que a organização de um fluxo de agente não garante por si só ganhos de desempenho na tarefa de resolução de questões de vestibular;
- Esse ganho de desempenho depende de diversos fatores, dentre eles o tamanho do modelo coordenador do agente e a utilização de ferramentas especializadas

Conclusão

Como trabalhos futuros, são propostos:

- A melhoria das ferramentas externas utilizadas e, inclusive, a exploração de estratégias de RAG para a sua construção;
- A utilização de LLMs menores como coordenadores de agentes inteligentes de outra forma, como em fluxos de menos etapas e com sumarização de informações dentre as etapas;



Obrigada!