
Question-Answering com Modelos de Linguagem baseada na abordagem de estudo com flashcards

Vinicius Casimiro da Silveira

11 de novembro de 2025

Universidade Estadual Paulista "Júlio de Mesquita Filho" (UNESP)
Faculdade de Ciências (FC) / Departamento de Computação (DCo)
Bauru, SP - Brasil

Sumário da Apresentação

1. Introdução
2. Fundamentação Teórica
3. Metodologia
4. Experimentos
5. Resultados e discussão
6. Conclusão

Introdução

- Grandes Modelos de Linguagem (LLMs) são poderosos, mas seu conhecimento é preso ao treinamento;
- Eles têm tendência a alucinar, ou seja, produzir informações desatualizadas, imprecisas ou falsas;
- Isso compromete a confiabilidade em tarefas de *Question-Answering* (QA), onde a precisão é fundamental.
- Uma das soluções básicas é injetar conhecimento externo utilizando *Retrieval-Augmented Generation* (RAG) (LEWIS et al., 2020).

Integrar um mecanismo de recuperação de informação ao LLM, o RAG.

Funcionamento:

1. Documentos externos são segmentados em fragmentos de texto, ou *chunks*.
2. Dada uma pergunta, o sistema recupera os *chunks* mais relevantes.
3. Os fragmentos são injetados como contexto para o LLM formular a resposta.

Vantagens: Permite atualizar o conhecimento sem retreinamento e oferece rastreabilidade.

Problema: A abordagem tradicional de RAG pode ser ineficiente, dada características como:

- **Ruído Contextual:** *Chunks* de texto podem conter muita informação irrelevante junto com a informação essencial (ZHONG et al., 2025).
- **Lost in the Middle:** Informações cruciais no meio de contextos longos são frequentemente ignoradas pelo modelo (LIU et al., 2023).

A Prática de Recuperação (*retrieval practice*), o princípio por trás dos flashcards, é uma das estratégias mais eficazes para a consolidação da memória humana (ROEDIGER HENRY L.; BUTLER, 2011).

Hipótese: Estruturar a base de conhecimento do RAG como Flashcards (Pergunta-Resposta) pode otimizar a recuperação, alinhar a IA à cognição e melhorar a eficiência.

Objetivo Geral

Investigar o impacto da estruturação de conhecimento em **flashcards** na otimização do desempenho (acurácia e eficiência) de sistemas de RAG aplicados a tarefas de *question answering*.

Objetivos Específicos


1. Gerar sinteticamente um conjunto de *flashcards* a partir de materiais escolhidos;
2. Adaptar bancos de dados afim de filtrar apenas as questões das matérias escolhidas, assegurando a correspondência entre perguntas e contextos conceituais relacionados ao domínio temático escolhido;
3. Implementar e comparar a performance (acurácia) e o custo computacional (*tokens*) de três configurações:
 - (A) LLM Puro
 - (B) RAG Tradicional
 - (C) RAG com Flashcards
4. Analisar os benefícios e limitações da abordagem proposta.

Fundamentação Teórica

A base dos modelos é a arquitetura **Transformer** (VASWANI et al., 2023) que incorpora o mecanismo de *self-attention*.

- Permite paralelização massiva;
- Captura de dependências de longo alcance no texto.

Figura 1: Arquitetura Transformer



Fonte: (VASWANI et al., 2023)

Quando o número de parâmetros aumenta de forma exponencial, dezenas ou centenas de bilhões, segundo Wei et al. (2022), os modelos adquirem **capacidades emergentes**.

- Habilidades inexistentes em modelos menores que não são comportamentos esperados;
- Modelos pequenos (SLMs) necessitam de *fine-tuning* para manifestação de tais capacidades;

- Conhecimento estático e limitado apenas aos dados de treinamento;
- Desencadeamento de obsolescência do conhecimento;
- Propensão de gerar informações falsas, ou seja, alucinar (ZHANG et al., 2025).

O objetivo do QA é fornecer respostas diretas, precisas e semanticamente adequadas em linguagem natural (HIRSCHMAN; GAIZAUSKAS, 2001).

Tipos de QA:

- **Fechado:** A resposta é buscada em bancos de dados específicos;
- **Aberto:** A resposta é dada a partir de dados semiestruturados como campos de texto ou na internet;
- **Abstrativo:** A resposta integra tanto informações externas recuperadas quanto o conhecimento paramétrico do modelo.


Proposto por Lewis et al. (2020) para resolver a lacuna do LLM. Separa o raciocínio do conhecimento.

Como funciona:

- Combina a **Memória Paramétrica**, dados do LLM, com uma **Memória Não Paramétrica**, uma base de conhecimento externa e recuperável;
- **1. Recuperador:** Busca documentos relevantes;
- **2. Gerador (LLM):** Gera a resposta usando os documentos como contexto.

Vantagens: Reduz alucinações, permite conhecimento atualizado sem necessidade de retreinar e melhora a rastreabilidade.

Figura 2: Arquitetura RAG



Fonte: Elaborado pelo autor

- O RAG, embora poderoso, depende totalmente da qualidade da recuperação.
- O método padrão, *chunking*, sofre com a organização do conhecimento.

As duas limitações principais

1. "Lost in the Middle" (LIU et al., 2023):

- A atenção do LLM não é uniforme.
- Informações no **meio** de contextos longos são subutilizadas ou ignoradas.

2. Problema da Granularidade (ZHANG et al., 2025):

- *Chunks* muito longos → diluem os conceitos (ruído).
- *Chunks* muito curtos → perdem coesão semântica.

O campo da prática de recuperação, estuda os efeitos do estudo a memória, em relação as técnicas de aprendizagem aplicadas.

Segundo Roediger Henry L. e Butler (2011), a aprendizagem não ocorre apenas durante os momentos de estudo passivo, mas é substancialmente reforçada durante o processo ativo de recuperação da informação.

O uso de *flashcards* é uma das metodologias mais conhecidas no campo da prática de recuperação.

O trabalho de (RAINA; GALES, 2024) propõe a estruturação de bases do conhecimento em unidades atômicas de conhecimento.

Dessa maneira, um paralelo entre os *flashcards* em conjunto com dados específicos, podem incorporar bases estruturadas de maneira coesa.

Metodologia

Modelo de linguagem utilizado para geração: **Phi-4** (ABDIN et al., 2024).

- SLM da família Phi da Microsoft;
- 14 bilhões de parâmetros;

Justificativa da escolha

O Phi-4 tem uma quantidade reduzida de parâmetros, de forma que seu custo de inferência é menor e mais viável.

A base de questões BLUEX (ALMEIDA et al., 2023) foi o *dataset* escolhido dada a quantidade de questões e facilidade de análise, dados seus campos descritivos.

- Vestibulares da Unicamp e USP, datadas entre 2018 e 2024;
- Rótulo de matéria abordada em cada questão;

O *dataset* passou por uma filtragem, afim de remover questões fora do escopo de matéria e avaliação.

Dessa maneira, os campos principais e que serão utilizados são:

- `question`: O enunciado textual principal da questão.
- `id`: Um identificador único, composto pelo nome do vestibular, o ano e o número da questão.
- `alternative`: Um objeto ou lista contendo os textos das alternativas de múltipla escolha.
- `answer`: A chave, exemplo 'A', 'B', entre outros, que identifica a alternativa correta.

Critérios de Exclusão

- **Domínios de Alta Subjetividade (Ex: Português):**
 - A avaliação dependeria da interpretação interna do LLM, e não do contexto factual fornecido pelo RAG.
- **Domínios de Ciências Exatas (Ex: Matemática, Física):**
 - Limitações conhecidas dos LLMs em raciocínio simbólico. O erro seria do LLM, não do RAG, invalidando a comparação.


Critério de Inclusão

- **Domínios de Densidade Factual (Ex: Biologia, História):**
 - Ricos em terminologias, definições, processos e correlações.
 - Ideal para ser estruturado em flashcards e testar a **eficiência da recuperação de fatos**.

Dessa maneira, as disciplinas de Geografia, Biologia e História foram selecionadas.

A 2ª Edição dos Cadernos dos Cursinhos Pré-Universitários da Universidade Estadual Paulista “Júlio de Mesquita Filho”, foram utilizados, mais especificamente os resortes para as matérias de biologia (CALDEIRA, 2016) e geografia e história (ALMEIDA; MAGNONI, 2016).

Figura 3: Capa dos livros *Ciências da Natureza: Biologia*, volume 3. e *Ciências humanas: filosofia, geografia, história e sociologia*, volume 6.



Fonte: Unesp. Disponível em:

⟨https://www2.unesp.br/porta#!/servico_ses/materiais-didaticos⟩. Acesso em: 19 out. 2025.


Três grupos diferentes foram abordados:

1. Grupo A: LLM Puro;
2. Grupo B: Rag tradicional;
3. Grupo C: Rag com flashcards.

Estratégias de indexação: Grupo A

- Grupo de Controle (Baseline).
- O pipeline de RAG é **desativado**.
- **Execução:**
 - O modelo (Phi-4) recebe a consulta (pergunta + alternativas).
 - Responde usando apenas sua memória interna.
- **Objetivo:** Isolar a capacidade intrínseca do LLM e medir seu conhecimento "interno" sobre os tópicos.

Figura 4: Estrutura utilizada como *baseline*



Fonte: Elaborada pelo autor.

- Comparação padrão da indústria.
- O texto integral do corpus foi processado por **chunking** e armazenado num banco vetorial.
- **Parâmetros do Chunking:**
 - **Chunk Size (Tamanho):** Define o comprimento máximo de cada fragmento de texto.
 - **Chunk Overlap (Sobreposição):** Uma porção final de um fragmento é repetida no início do seguinte, para mitigar a perda de contexto nas bordas.
- **Objetivo:** Simular um sistema RAG convencional para comparar com a hipótese proposta.

Estratégias de indexação: Grupo C

- Representa a **hipótese central** do trabalho.
- O conhecimento foi organizado em flashcards, compostos por pares Pergunta-Resposta, onde apenas as perguntas foram armazenadas e as respostas foram adicionadas quando o contexto era recuperado, como mostra a figura 5.

Figura 5: Estrutura utilizada para os flashcards

```
1 class Flashcard(BaseModel):
2     id: int
3     front: str = Field(description="A pergunta clara e objetiva de até 100
      ↳ caracteres")
4     back: str = Field(description="A resposta direta e objetiva para a
      ↳ pergunta")
5
6     def __str__(self):
7         return f"""
8         Flashcard {self.id}:
9         Question: {self.front}
10        Answer: {self.back}
11
12        """
```

Fonte: Código do autor.

- Os flashcards foram criados pelo próprio Phi-4 seguindo a pipeline na figura 6:

Figura 6: Diagrama do pipeline de geração sintética de *flashcards*.

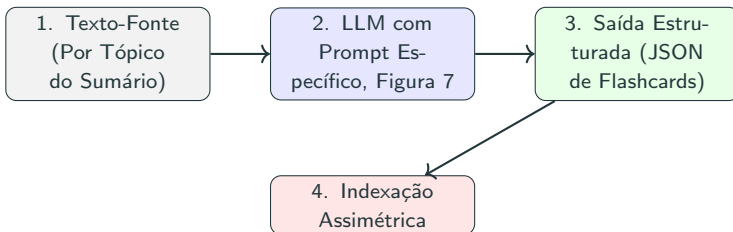


Figura 7: Prompt de sistema e de usuário para a geração dos flashcards.

```
"""
Você é um criador de flashcards educacionais. Sua tarefa é gerar flash-
cards a partir do tema fornecido utilizando apenas o contexto dado.

---

{format_instructions}

Cada flashcard deve seguir o seguinte formato:

- Pergunta: clara, objetiva e de até 100 caracteres.
- Resposta: a resposta direta e objetiva para a pergunta.

Gere ao menos {n_de_cartões} flashcards sobre o seguinte tema: {tema}.
Certifique-se de que as perguntas cubram conceitos fundamentais, aplica-
ções práticas e curiosidades importantes.
"""
```

Fonte: Código do autor. O campo `format_instructions` instrui o LLM a formatar a saída como JSON.

Configuração da arquitetura RAG

Os mesmos modelos de *embedding* foram utilizados em ambas abordagens de RAG, de forma que a separação de *tokens* seja a mesma.

As unidades de texto foram assim, convertidos em vetores e armazenados num banco de dados vetorial específico para cada aplicação.

Para a recuperação dos dados, uma busca por similaridade semântica é realizada. Utilizando o cálculo de similaridade de cossenos (Equação ??), uma distância geométrica entre o vetor da pergunta e os vetores armazenados é calculada, sendo retornada as k ocorrências mais próx.

- A tarefa de **Múltipla Escolha (MCQA)** foi selecionada para garantir uma avaliação objetiva e quantitativa.
 - Permite o uso de uma métrica de sucesso inequívoca: **Acurácia**;
 - Evita a avaliação qualitativa e subjetiva de um texto gerado (QA Aberto).
- **Extração da Resposta:**
 - Para cada questão, o LLM foi instruído a retornar o seu pensamento juntamente de uma saída estruturada que corresponde a **apenas a letra** da alternativa correta (ex: 'a').
 - Isso permitiu a comparação direta e automática com o gabarito.

1. Acurácia

Percentual de questões onde a alternativa escolhida pelo LLM coincidiu com o gabarito do dataset BLUEX.

$$\text{Acurácia} = \frac{\text{Respostas Corretas}}{\text{Total de Questões}}$$

2. Custo Computacional

Registro do **número médio de tokens** (entrada + saída) por consulta, para avaliar a eficiência de cada abordagem.

Experimentos

Parâmetros dos grupos de teste

- O Phi4 foi utilizado como modelo gerador;
- A sua temperatura foi zerada;

Todos os grupos seguiram a mesma estrutura de resposta, conforme indicado pela tabela 1.

Tabela 1: tabela gerado a partir das respostas da LLM

Campo	Descrição
question_id	Identificador da questão no BLUEX.
LLM_response	Resposta dada pela LLM geradora.
LLM_alternative	Alternativa escolhida pela LLM geradora.
retrieved_docs	Documentos recuperados ou vazio.
response_metadata	Metadados da resposta (modelo gerador, <i>timestamp</i> , etc.).
usage_metadata	Metadados de uso (quantidade de tokens na entrada, saída e total).

Parâmetros dos grupos de teste

Além disso, os grupos receberam prompts padrões para a tarefa de MCQA. De forma que instrua o modelo sobre o seu papel e a tarefa exigida. (Figuras 8 e 9)

Figura 8: Prompt de sistema e de usuário para geração de respostas, grupo A.

Prompt de Sistema (Grupo A)

```
"""
```

```
System:
```

```
Você é um estudante que está realizando o vestibular, assim, sempre que  
lê uma pergunta responde em português e com alguma das alternativas se-  
guindo as instruções
```

```
Human:
```

```
pergunta: {query}
```

```
{format_instructions}
```

```
"""
```

Parâmetros dos grupos de teste

Figura 9: Prompt de sistema e de usuário para geração de respostas, grupo B e C.

Prompt de Sistema (Grupos B e C)

```
"""
```

```
System:
```

```
Você é um estudante que está realizando o vestibular, assim, sempre que  
lê uma pergunta responde em português e com alguma das alternativas se-  
guindo as instruções
```

```
Human:
```

```
pergunta: {query}
```

```
Documentos: {documentos_relevantes}
```

```
{format_instructions}
```

```
"""
```

O LLM foi instruído a responder às questões sem receber qualquer contexto externo, medindo assim seu conhecimento interno.

O conteúdo textual extraído dos cadernos Caldeira (2016), Almeida e Magnoni (2016) foi processado a partir de (*chunking*). Os hiperparâmetros desta configuração foram definidos empiricamente, conforme detalhado abaixo:

- Tamanho do Fragmento (*chunk_size*): **800 caracteres**;
- Sobreposição (*chunk_overlap*): **80 caracteres**;
- Recuperação (*top-k*): $k = 3$.

A base de conhecimento foi indexada seguindo a estrutura dos *flashcards*, onde apenas a pergunta do cartão é indexada e a resposta é guardada em um dicionário separado. Utilizando o Phi-4, cada tópico das matérias tiveram 5 *flashcards* específicos.

Durante a inferência, o sistema recupera os $k = 3$ *flashcards* cujas *perguntas* são semanticamente mais similares à consulta de entrada. O *retriever* então retorna o conteúdo completo (a "resposta" armazenada nos metadados) desses *flashcards* para serem usados como contexto pelo LLM.

Resultados e discussão

Resultados quantitativos (Acurácia)

A Tabela 2 apresenta a acurácia final obtida por cada um dos três grupos experimentais após a execução sobre o *dataset* de 293 questões.

Tabela 2: Comparativo de Acurácia no *dataset* BLUEX (MCQA).

Grupo Experimental	Acurácia (%)	Ganho vs. LLM-Puro (p.p.)
A (LLM-Puro)	82,94%	N/A
B (RAG-tradicional)	88,74%	+5,80 p.p.
C (RAG-Flashcards)	84,30%	+1,36 p.p.

p.p. = pontos percentuais

Resultados quantitativos (Custo computacional)

A Tabela 3 compara o custo médio de *tokens* por consulta para cada grupo.

Tabela 3: Comparativo de Custo Computacional (Média de *Tokens* por Consulta).

Grupo Experimental	Tokens		
	Entrada	Saída	Média
A (LLM-Puro)	226.075	90.828	1.081, 58
B (RAG-tradicional)	763.218	103.331	2.957, 51
C (RAG-Flashcards)	235.208	108.771	1.173, 99

Resultados quantitativos (Custo computacional)

A Tabela 4 detalha o custo por resposta correta, que analisa a eficiência do sistema em relação à sua acurácia.

Tabela 4: Análise de Custo-Benefício (*Tokens* por Resposta Correta).

Grupo Experimental	Acurácia (%)	Custo por Resposta Correta
A (LLM-Puro)	82,94%	1.304,13 <i>tokens</i>
B (RAG-Traducional)	88,74%	3.332,88 <i>tokens</i>
C (RAG-Flashcards)	84,30%	1.392,63 <i>tokens</i>

Observação Inicial

Ambas as abordagens RAG superaram o LLM Puro, validando a técnica.

Hipótese de Acurácia Não Confirmada

A hipótese principal (de que flashcards otimizariam a acurácia) **não foi confirmada** neste cenário.

- RAG Tradicional (88,74%) superou o RAG Flashcards (84,30%).

Principais motivos

- A baseline (LLM Puro) acertou **82,94%** das questões sozinho, sem RAG;
- O modelo Phi-4 demonstrou **forte conhecimento paramétrico** sobre os domínio;
- A tarefa de **MCQA** facilitou o acerto via conhecimento paramétrico, diminuindo a dependência do contexto RAG.

Hipótese de Eficiência Fortemente Validada

O RAG com Flashcards atingiu seu desempenho utilizando **apenas 39,69%** do custo computacional do RAG Tradicional.

- O RAG Tradicional teve melhor acurácia absoluta: injetou um contexto longo e caro (2.958 tokens) para ganhar +4,4 p.p.
- O RAG Flashcards (Grupo C) obteve um desempenho próximo ao RAG Tradicional, mas com **41,6% do custo**.

Custo por Resposta Correta

- RAG Tradicional: **3.333 tokens** por acerto (Ineficiente, 2.73x mais caro que o Puro).
- RAG Flashcards: **1.393 tokens** por acerto (Equilibrado).
- LLM Puro: **1.304 tokens** por acerto (Baseline).

Conclusão

Conclusão: A Contribuição do TCC

- A hipótese de acurácia não foi validada *neste cenário* (MCQA), devido ao alto conhecimento paramétrico do modelo Phi-4.
- A hipótese de otimização foi **fortemente validada**:
 - A abordagem RAG-Flashcards atingiu um desempenho próximo ao RAG-Tradicional (diferença de 4,4 p.p.) com **apenas 39,69% do custo computacional**.

Contribuição Principal

Este trabalho validou empiricamente que a organização do conhecimento é um pilar fundamental para a **eficiência** dos sistemas RAG.

A abordagem de Flashcards, inspirada na cognição, provou ser um caminho para criar sistemas de IA com um **balanço de custo-benefício muito superior**.

- **Amostra** e domínio educacional específicos.
- **MCQA** não captura totalmente tarefas abertas e raciocínio longo.
- **Ausência** de teste de significância estatística para pequenas diferenças de acurácia.

- Com base nas limitações identificadas (MCQA e conhecimento paramétrico), os próximos passos devem testar a hipótese em cenários mais rigorosos:
- **Avaliação com QA Aberto (Geração de Texto):**
 - Forçar o modelo a depender **inteiramente** do contexto recuperado, eliminando a ajuda das alternativas de múltipla escolha.
- **Domínios de Conhecimento Especializado:**
 - Aplicar em domínios privados (ex: documentos jurídicos, manuais técnicos), onde o conhecimento paramétrico do LLM é baixo ou nulo.
- **Hibridização de Técnicas:**
 - Aplicar a **indexação assimétrica** (Pergunta-Resposta) aos *chunks* tradicionais (gerar uma "pergunta" para cada *chunk*), unindo a eficiência da proposta com a cobertura dos documentos longos.

Referências

 ABDIN, M.; ANEJA, J.; BEHL, H.; BUBECK, S.; ELDAN, R.; GUNASEKAR, S.; HARRISON, M.; HEWETT, R. J.; JAVAHERIPI, M.; KAUFFMANN, P.; LEE, J. R.; LEE, Y. T.; LI, Y.; LIU, W.; MENDES, C. C. T.; NGUYEN, A.; PRICE, E.; ROSA, G. de; SAARIKIVI, O.; SALIM, A.; SHAH, S.; WANG, X.; WARD, R.; WU, Y.; YU, D.; ZHANG, C.; ZHANG, Y. *Phi-4 Technical Report*. 2024. Disponível em: <<https://arxiv.org/abs/2412.08905>>.

 ALMEIDA, L. L. de; MAGNONI, M. d. G. M. *Ciências humanas : filosofia, geografia, história e sociologia (Cadernos dos Cursinhos Pré-Universitários da UNESP, Vol. 6)*. São Paulo, SP, Brasil: Universidade Estadual Paulista “Júlio de Mesquita Filho” – Pró-Reitoria de Extensão (PROEX), 2016. 2ª edição. Disponível em: <https://www2.unesp.br/Home/servico_ses/caderno_biologia.pdf>.

 ALMEIDA, T. S.; LAITZ, T.; BONÁS, G. K.; NOGUEIRA, R. *BLUEX: A benchmark based on Brazilian Leading Universities Entrance eXams*. 2023.

 CALDEIRA, A. M. d. A. *Ciências da Natureza – Biologia (Cadernos dos Cursinhos Pré-Universitários da UNESP, Vol. 3)*. São Paulo, SP, Brasil: Universidade Estadual Paulista “Júlio de Mesquita Filho” – Pró-Reitoria de Extensão (PROEX), 2016. 2ª edição. Disponível em: [〈https://www2.unesp.br/Home/servico_ses/caderno_biologia.pdf〉](https://www2.unesp.br/Home/servico_ses/caderno_biologia.pdf).

 HIRSCHMAN, L.; GAIZAUSKAS, R. Natural language question answering: The view from here. *Natural Language Engineering*, v. 7, p. 275 – 300, 12 2001.

 LEWIS, P.; PEREZ, E.; PIKTUS, A.; PETRONI, F.; KARPUKHIN, V.; GOYAL, N.; KÜTTLER, H.; LEWIS, M.; YIH, W.-t.; ROCKTÄSCHEL, T.; RIEDEL, S.; KIELA, D. Retrieval-augmented generation for knowledge-intensive nlp tasks. In: *Proceedings of the 34th International Conference on Neural Information Processing Systems*. Red Hook, NY, USA: Curran Associates Inc., 2020. (NIPS '20). ISBN 9781713829546.

 LIU, N. F.; LIN, K.; HEWITT, J.; PARANJAPE, A.; BEVILACQUA, M.; PETRONI, F.; LIANG, P. *Lost in the Middle: How Language Models Use Long Contexts*. 2023. Disponível em: [〈https://arxiv.org/abs/2307.03172〉](https://arxiv.org/abs/2307.03172).

 RAINA, V.; GALES, M. *Question-Based Retrieval using Atomic Units for Enterprise RAG*. 2024. Disponível em: [⟨https://arxiv.org/abs/2405.12363⟩](https://arxiv.org/abs/2405.12363).

 ROEDIGER HENRY L., I.; BUTLER, A. C. The critical role of retrieval practice in long-term retention. *Trends in Cognitive Sciences*, Elsevier, v. 15, n. 1, p. 20–27, jan. 2011. ISSN 1364-6613. Disponível em: [⟨https://doi.org/10.1016/j.tics.2010.09.003⟩](https://doi.org/10.1016/j.tics.2010.09.003).

 VASWANI, A.; SHAZEER, N.; PARMAR, N.; USZKOREIT, J.; JONES, L.; GOMEZ, A. N.; KAISER, L.; POLOSUKHIN, I. *Attention Is All You Need*. 2023. Disponível em: [⟨https://arxiv.org/abs/1706.03762⟩](https://arxiv.org/abs/1706.03762).

 WEI, J.; TAY, Y.; BOMMASANI, R.; RAFFEL, C.; ZOPH, B.; BORGEAUD, S.; YOGATAMA, D.; BOSMA, M.; ZHOU, D.; METZLER, D.; CHI, E. H.; HASHIMOTO, T.; VINYALS, O.; LIANG, P.; DEAN, J.; FEDUS, W. *Emergent Abilities of Large Language Models*. 2022. Disponível em: [⟨https://arxiv.org/abs/2206.07682⟩](https://arxiv.org/abs/2206.07682).

 ZHANG, Y.; LI, Y.; CUI, L.; CAI, D.; LIU, L.; FU, T.; HUANG, X.; ZHAO, E.; ZHANG, Y.; XU, C.; CHEN, Y.; WANG, L.; LUU, A. T.; BI, W.; SHI, F.; SHI, S. *Siren's Song in the AI Ocean: A Survey on Hallucination in Large Language Models*. 2025. Disponível em: [⟨https://arxiv.org/abs/2309.01219⟩](https://arxiv.org/abs/2309.01219).

 ZHONG, Z.; LIU, H.; CUI, X.; ZHANG, X.; QIN, Z. *Mix-of-Granularity: Optimize the Chunking Granularity for Retrieval-Augmented Generation*. 2025. Disponível em: [⟨https://arxiv.org/abs/2406.00456⟩](https://arxiv.org/abs/2406.00456).

Obrigado pela atenção!

Perguntas?