

UNIVERSIDADE ESTADUAL PAULISTA "JÚLIO DE MESQUITA FILHO"

FACULDADE DE CIÊNCIAS - CAMPUS BAURU

DEPARTAMENTO DE COMPUTAÇÃO

BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

DANIEL HIDEKI ROCHA KANASHIRO

**CONSTRUÇÃO E TRADUÇÃO DE DATASETS MULTIMODAIS NA
SAÚDE: UM ESTUDO PARA CASOS DE COVID-19**

BAURU

Novembro/2025

DANIEL HIDEKI ROCHA KANASHIRO

CONSTRUÇÃO E TRADUÇÃO DE DATASETS MULTIMODAIS NA SAÚDE: UM ESTUDO PARA CASOS DE COVID-19

Trabalho de Conclusão de Curso do Curso de
Bacharelado em Ciência da Computação da Uni-
versidade Estadual Paulista “Júlio de Mesquita
Filho”, Faculdade de Ciências, Campus Bauru.
Orientador: Prof. Dr. João Paulo Papa
Coorientador: Prof. Me. Gabriel Lino Garcia

BAURU
Novembro/2025

Daniel Hideki Rocha Kanashiro CONSTRUÇÃO E TRADUÇÃO DE DATA-SETS MULTIMODAIS NA SAÚDE: UM ESTUDO PARA CASOS DE COVID-19/ Daniel Hideki Rocha Kanashiro. – Bauru, Novembro/2025- 54 p. : il.; tabs.

Orientador: Prof. Dr. João Paulo Papa

Coorientador: Prof. Me. Gabriel Lino Garcia

Trabalho de Conclusão de Curso – Universidade Estadual Paulista “Júlio de Mesquita Filho”

Faculdade de Ciências

Bacharelado em Ciência da Computação, Novembro/2025.

1. Multimodal 2. covid-19 3. VLM 4. Aprendizado de máquina 5. Radiografia

Daniel Hideki Rocha Kanashiro

CONSTRUÇÃO E TRADUÇÃO DE DATASETS MULTIMODAIS NA SAÚDE: UM ESTUDO PARA CASOS DE COVID-19

Trabalho de Conclusão de Curso do Curso de
Bacharelado em Ciência da Computação da Uni-
versidade Estadual Paulista "Júlio de Mesquita
Filho", Faculdade de Ciências, Campus Bauru.

Banca Examinadora

Prof. Dr. João Paulo Papa

Orientador

Departamento de Computação

Faculdade de Ciências

Universidade Estadual Paulista "Júlio de
Mesquita Filho"

**Profa. Dra. Simone das Graças
Domingues Prado**

Departamento de Computação

Faculdade de Ciências

Universidade Estadual Paulista "Júlio de
Mesquita Filho"

Prof. Dr. Douglas Rodrigues

Departamento de Computação

Faculdade de Ciências

Universidade Estadual Paulista "Júlio de
Mesquita Filho"

Bauru, 11 de novembro de 2025.

Dedico este trabalho a meus pais e meu tio que sempre estiveram ao meu lado e deram todo apoio que necessitei.

Agradecimentos

Faço aqui meus agradecimentos a todos que estiveram comigo nesta jornada. Aos meus pais, pilares em minha vida, tenho profunda gratidão por sempre me ensinarem o que é certo e o que é errado, por me ensinarem a ter disciplina, a buscar o crescimento e a me acolherem amorosamente quando precisei, mesmo com minhas imperfeições. Agradeço à minha tia Rose por sempre me encorajar nos estudos, à minha tia Regina por sempre ser tão amável e cuidar de mim, à minha tia Sirlene por sempre se importar comigo e me lembrar de que tenho com quem contar, e aos meus primos Giulia, Geovana, Danielzinho, Kayo e Leo com quem compartilhei tantos momentos especiais, por sempre estarem ao meu lado. Ao meu tio Mário, a razão de eu ter chegado onde estou, não posso descrever em palavras como me sinto grato por você ter tornado um distante sonho em realidade. Obrigado por ser a porta que me permitiu atravessar esta jornada. Espero que eu possa retribuir a vocês tudo, mesmo que seja incalculável o que fizeram por mim.

Conheci pessoas incríveis durante estes anos de aprendizagem. Levarei para a vida os momentos e as desventuras que passamos juntos. Christian, Fábio, Franco, Henrique, Leonardo, Luana, Luciano, Sofia, Vinícius e Yoshio, agradeço a cada um de vocês pelas risadas e por compartilharem comigo esta jornada ao decorrer de bons e longos anos. E, ao Kaio, meu veterano mesmo após o fim, agradeço pelos seus conselhos, reflexões e ideias que você expôs a mim.

Ao professor Papa, sou profundamente grato por ter me acolhido durante a minha graduação. A oportunidade de ter pesquisado junto do laboratório Recogna e da Petrobras em minha Iniciação Científica foi transformadora. Ao Lino e ao João Renato, agradeço por terem me aguentado durante todo o processo da elaboração deste trabalho e terem paciência comigo. Sem vocês, seria impossível ter chegado a este resultado.

E, sobretudo, agradeço a Deus por me dar forças quando achei que ia falhar e por alinhar o meu caminho para que eu chegasse até aqui. Mesmo nos momentos mais sombrios, o Senhor se fez presente na minha vida.

*Todo o que ama a disciplina ama o conhecimento,
mas aquele que odeia a repreensão é tolo.*

Provérbios 12:1

Resumo

A covid-19 é uma doença de fácil transmissão e capaz de deixar sequelas em seus infectados. Com o devido tratamento e diagnóstico precoce, as chances de sequelas e sintomas graves caem. Algumas estratégias são utilizadas para a celeridade da detecção, dentre elas, modelos de Aprendizado de Máquina treinados para avaliar unicamente imagem de raio-X, por exemplo, e realizar o diagnóstico baseado na imagem. Já os Grandes Modelos de Linguagem Multimodais são capazes de compreender dados de modalidades diferentes conjuntamente, como imagem e texto. Neste trabalho, propõe-se avaliar o uso de multimodalidade para diagnóstico de covid-19 e a averiguação do impacto que a multimodalidade causa no resultado obtido. Para isso, foi traduzido um *dataset* multimodal de covid-19 e avaliado o desempenho de dois modelos usando este *dataset* em uma análise multimodal e unimodais.

Palavras-chave: Multimodal, covid-19, VLM, Aprendizado de máquina, Radiografia.

Abstract

Covid-19 is an easily transmitted disease capable of leaving sequelae in those infected. With proper treatment and early diagnosis, the chances of sequelae and severe symptoms decrease. Some strategies are used to accelerate detection, among them, Machine Learning models trained to evaluate solely X-ray images, for example, and perform the diagnosis based on the image. Multimodal Large Language Models, on the other hand, are capable of understanding data from different modalities jointly, such as image and text. This work proposes the use of multimodality for covid-19 diagnosis and an investigation into the impact of multimodality on the obtained results. For this purpose, a multimodal covid-19 dataset was translated and the performance of two models using this dataset with multimodal and unimodals perspective was evaluated.

Keywords: Multimodal, covid-19, VLM, Machine Learning, Radiography.

Lista de figuras

Figura 1 – Exemplo de raio-X do tórax de um paciente.	16
Figura 2 – Exemplo clássico de <i>word embedding</i>	23
Figura 3 – Exemplo de uma RNA.	24
Figura 4 – Arquitetura Transformer	26
Figura 5 – Matrizes LoRA A e B	29
Figura 6 – Esquema do VLM com <i>backbone</i>	30
Figura 7 – Mosaico com exemplos de raios-X e suas notas	32
Figura 8 – <i>Pipeline</i> do pré-processamento dos dados	33
Figura 9 – Exemplo de extração	36
Figura 10 – Comparação das matrizes de confusão do Qwen.	40
Figura 11 – Gráfico de perda por épocas do Qwen.	41
Figura 12 – Comparação das matrizes de confusão do MedGemma.	42
Figura 13 – Gráfico de perda por épocas do Qwen.	43
Figura 14 – Comparação das matrizes de confusão do Qwen em inglês.	44
Figura 15 – Comparação das matrizes de confusão do MedGemma em inglês.	45
Figura 16 – Comparação da função peso no MedGemma usando um único <i>prompt</i> contra múltiplos em inglês.	47
Figura 17 – Comparação da função peso no Qwen usando um único <i>prompt</i> contra múltiplos em inglês.	48

Lista de quadros

Lista de tabelas

Tabela 1 – Total de pacientes com e sem covid-19 por região bem como quantos foram por RT-PCR.	32
Tabela 2 – Métricas de Avaliação para o Modelo Qwen	40
Tabela 3 – Métricas de Avaliação para o Modelo Medgemma	41
Tabela 4 – Métricas de Avaliação para o Qwen em inglês	43
Tabela 5 – Métricas de Avaliação para o Medgemma em inglês	45
Tabela 6 – Métricas de Avaliação para o Medgemma com múltiplos <i>prompts</i>	46
Tabela 7 – Métricas de Avaliação para o Qwen com múltiplos <i>prompts</i>	47

Lista de abreviaturas e siglas

RT-PCR	<i>Reverse Transcriptase-Polymerase Chain Reaction</i>
AM	Aprendizado de máquina
LLM	<i>Large Language Model</i>
M-LLM	<i>Multimodal Large Language Model</i>
VLM	<i>Visual Language Model</i>
PLN	Processamento de Linguagem Natural
TTR	<i>Type-Token Ratio</i>
BPE	<i>Byte Pair Encoding</i>
FFN	<i>Feed Forward Network</i>
ReLU	<i>Rectified Linear Unit</i>
PEFT	<i>Parameter-Efficient Fine-Tuning</i>
LoRA	<i>Low Rank Adapter</i>

Sumário

1	INTRODUÇÃO	14
1.1	Problema	17
1.2	Justificativa	17
1.3	Objetivos	18
1.3.1	Objetivo geral	18
1.3.2	Objetivos específicos	18
2	FUNDAMENTAÇÃO TEÓRICA	20
2.1	Aprendizado de máquina	20
2.2	Processamento de Linguagem Natural	21
2.2.1	Token	21
2.2.1.1	Subpalavras como tokens	22
2.2.2	<i>Word embedding</i>	22
2.3	LLM e <i>Transformer</i>	23
2.4	Ajuste fino e LoRA	28
2.5	<i>Visual Language Model</i>	29
3	MATERIAIS E MÉTODOS	31
3.1	Ambiente de execução	31
3.2	<i>Dataset</i>	31
3.2.1	Pré-tratamento dos dados	31
3.3	Configuração experimental	37
3.4	Métricas	37
4	RESULTADOS	39
4.1	Em português	39
4.2	Em inglês	43
5	CONCLUSÃO	49
	REFERÊNCIAS	50

1 Introdução

Em 31 de dezembro de 2019, autoridades de saúde de Wuhan, China, relataram casos de uma pneumonia de tipo desconhecido, identificados no *Hubei Hospital of Integrated Traditional Chinese and Western Medicine* (LUPTON; WILLIS, 2021). Mais tarde, seria denominada covid-19, uma doença causada pelo coronavírus da síndrome respiratória aguda grave 2, SARS-CoV-2. Pertence à mesma família do SARS-CoV e MERS-CoV, a *Coronaviridae*, uma família de vírus já conhecida anteriormente; porém, com letalidade menor, de 2% a 3% em comparação aos estimados 10% do SARS-CoV e 40% do MERS-CoV, respectivamente (SHI et al., 2020). Sintomas incluem dor de cabeça, febre, tosse, dor de garganta e perda do paladar ou do olfato (HUANG et al., 2023), mas seu maior perigo reside em sua fácil transmissão, que chega a ser três vezes maior que a do SARS-CoV e dez vezes maior que a do MERS-CoV (JIANG; SHI, 2020).

Para a confirmação da doença, o teste de referência, ou padrão-ouro, é o *Reverse Transcriptase-Polymerase Chain Reaction*, o RT-PCR. Este teste detecta e quantifica o material genético (RNA) do vírus em uma amostra. Por sua alta sensibilidade na detecção de moléculas, agilidade em relação ao resultado e versatilidade para diferentes patógenos, é o melhor teste disponível para diagnosticar rapidamente patógenos de alta transmissibilidade e letalidade. Entretanto, sua precisão não é perfeita, exibindo uma taxa de falso negativo de 29% (AREVALO-RODRIGUEZ et al., 2020). Esta imprecisão decorre de inúmeras variáveis, como a falta de material celular na coleta ou erros na execução do método de extração ou do método em si, acarretando falsos negativos e testes inconclusivos (YANG et al., 2020). Consequentemente, um eventual diagnóstico tardio, ocasionado por essas falhas, aumenta as chances de sequelas em detrimento das chances de cura (NALBANDIAN; DESAI; WAN, 2023).

Diante das limitações dos testes diagnósticos convencionais, como a taxa de falso negativo do RT-PCR, e necessidade de diagnósticos precisos em larga escala, a comunidade científica voltou-se para abordagens computacionais. Dentre as abordagens adotadas, o Aprendizado de máquina (em inglês *Machine Learning*, AM) se destacou como uma abordagem promissora para superar esses desafios (HEIDARI et al., 2022). Essencialmente, essa classe de modelos de inteligência artificial (IA) é composta por algoritmos que encontra padrões em um conjunto de dados de treinamento e, a partir deste aprendizado, é capaz de fazer previsões e inferências sobre dados novos. No cenário da pandemia, por exemplo, foi usada para prever a interação entre moléculas de drogas e sua reação com doenças, como a covid-19 (ZHANG et al., 2022), ou para auxiliar no monitoramento de pacientes com a doença (BOUSSEN et al., 2022).

Para um diagnóstico mais preciso de covid-19, vale-se da análise de dados não estru-

turados, como as notas clínicas e os prontuários médicos, pois contêm informações valiosas para a classificação correta. Nesse ponto, os Grandes Modelos de Linguagem (em inglês *Large Language Models*, LLMs) se sobressaem (ZHOU et al., 2025). Esses modelos de AM são desenvolvidos especificamente para compreender e gerar texto em linguagem humana, podendo ser adaptados, através da técnica de ajuste fino (*fine-tuning*), para tarefas específicas como a predição de diagnósticos com base em relatos clínicos, demonstrando um potencial significativo para auxiliar na tomada de decisão médica (SINGHAL et al., 2023). O *Clinical Prediction with Large Language Models*, CPLLM, (SHOHAM; RAPPOPORT, 2024), por exemplo, é um LLM treinado para prever se um paciente possui uma doença baseada no histórico médico dele e em um texto de referência descrevendo a doença a ser diagnosticada.

Todavia, para um diagnóstico mais preciso e tratamento adequado é necessário o contexto mais completo possível. Isto é, a análise conjunta de dados do paciente como imagens (raio-X, tomografia computadorizada), dados temporais ou ônicos, além do convencional texto. Na Figura 1, por exemplo, há o raio-X do tórax de um paciente suspeito de haver contraído covid-19, obtido no covid-chest-xray (COHEN et al., 2020), um *dataset* composto por raios-X e notas clínicas que é base para este trabalho. Junto a imagem, há associado uma nota clínica escrita por um especialista ou um técnico que pode conter o histórico médico, a descrição dos sintomas que o paciente apresentou e uma análise da imagem.


A nota clínica referente a Figura 1 em tradução própria:

Em 22 de janeiro de 2020, um homem de 65 anos com histórico de hipertensão, diabetes tipo 2, doença arterial coronária para a qual um estente fora implantado e câncer no pulmão foi admitido para o departamento de urgência do Hospital *Ho Chi Minh City*, devido a uma febre baixa e fadiga. Ele havia ficado doente com febre em 17 de janeiro, um total de 4 dias depois que ele e a esposa haviam viajado para Hanoi do distrito de Wuchang em Wuhan, onde surtos de 2019-nCoV ocorreram. Ele relatou que ele não havia sido exposto a um 'wet market' (um mercado onde animais vivos e mortos são vendidos) em Wuhan. Radiografias do peito obtidas na admissão mostraram uma infiltração no lobo superior do pulmão esquerdo"¹.

Analisando a nota, há informações relevantes para a interpretação do raio-X e para o diagnóstico: o paciente possui sintomas de febre e fadiga; histórico de hipertensão, doença arterial coronária e câncer de pulmão; e, por fim, que há infiltração e onde está localizada.

¹ Trecho original: *On January 22, 2020, a 65-year-old man with a history of hypertension, type 2 diabetes, coronary heart disease for which a stent had been implanted, and lung cancer was admitted to the emergency department of Cho Ray Hospital, the referral hospital in Ho Chi Minh City, for low-grade fever and fatigue. He had become ill with fever on January 17, a total of 4 days after he and his wife had flown to Hanoi from the Wuchang district in Wuhan, where outbreaks of 2019-nCoV were occurring. He reported that he had not been exposed to a "wet market" (a market where dead and live animals are sold) in Wuhan. Chest radiographs obtained on admission showed an infiltrate in the upper lobe of the left lung.*

Figura 1 – Exemplo de raio-X do tórax de um paciente.



Fonte: [Cohen et al. \(2020\)](#) .

Apesar de sua eficiência no campo textual, o LLM, limitado a uma única modalidade de informação, é incapaz de analisar conjuntamente a nota e a imagem. Assim, surge o *Multimodal Large Language Model*, M-LLM, um LLM estendido que processa mais de uma modalidade de dado ([ALSAAD et al., 2024](#)), podendo captar estas informações em formatos distintos, como a nota clínica e imagem, para prover auxílio para tomada de decisões melhores ou, até mesmo, predizer o diagnóstico ([MOOR et al., 2023a](#)). [Tiu et al. \(2022\)](#), por exemplo, desenvolveram um M-LLM capaz de analisar raios-X e encontrar patologias para condições clínicas gerais. O Med-LLaVA ([LI et al., 2023](#)) ou o Med-Flamingo ([MOOR et al., 2023b](#)) se utilizam de dados visuais como imagem de raio-X para determinar se há a presença de uma determinada patologia ou condição qualquer. Neste caso de M-LLM específica de imagem-texto, o modelo é chamado de Modelo de Linguagem de Visão (em inglês *Visual Language Model*, VLM).

Portanto, este trabalho propõe a avaliação do impacto da multimodalidade (imagem e texto) na performance da predição de diagnóstico de covid-19, utilizando VLM e o *dataset* covid-chest-xray.

1.1 Problema

Para o bom desempenho e treinamento adequado, um conjunto de dados vasto e bem distribuído é primordial (YU et al., 2024). Contudo, a obtenção de tais recursos representa um desafio significativo, que se torna particularmente acentuado no domínio médico, onde a integração de diferentes modalidades (como imagens radiológicas e notas clínicas textuais) para o mesmo caso é complexa e escassa. No caso de covid-19, há poucos *datasets* públicos em português, como o divulgado pelo Ministério da Saúde do Brasil, que fornece dados textuais clínicos de covid-19 e outras gripes²; bem como o Hospital Albert Einstein, coletado internamente pela instituição sobre pacientes com covid-19³; e o de imagens de tomografias computadorizadas coletadas nos hospitais da região de São Paulo realizado por Soares et al. (2020).

Esta realidade brasileira deve-se a uma confluência de fatores. A Lei Geral de Proteção de Dados (LGPD) impõe rigorosos requisitos para a coleta, o tratamento e o compartilhamento de dados de saúde, criando barreiras regulatórias e legais para a formação de repositórios públicos (SOUSA; OLIVEIRA, 2024). Como consequência, observa-se uma notória carência de *datasets* multimodais em língua portuguesa para a covid-19, o que limita a pesquisa e o desenvolvimento de modelos adaptados à realidade linguística e clínica local. Paralelamente a essa escassez de recursos de dados, identifica-se uma lacuna na literatura científica. Embora a aplicação de modelos multimodais para o diagnóstico médico seja uma área de pesquisa crescente, com avanços notáveis como o Med-LLaVA (LI et al., 2023) e o Med-Flamingo (MOOR et al., 2023b), os estudos existentes apresentam limitações. Tais pesquisas tendem a focar em condições clínicas gerais, sem aprofundar na aplicação para a covid-19, ou os trabalhos que investigam a covid-19 focam majoritariamente na análise unimodal de imagens.

1.2 Justificativa

A pandemia de covid-19 impôs desafios sem precedentes aos sistemas de saúde globais, evidenciando a necessidade crítica de diagnósticos rápidos e precisos para o manejo clínico eficaz e o controle da disseminação viral. Conforme abordado, o teste padrão-ouro, RT-PCR, embora sensível, apresenta uma taxa de falso negativo de até 29%, o que pode retardar o início do tratamento, deixando-o fora da janela da primeira semana do início dos sintomas, onde é mais efetivo em aliviá-los e encurtar o ciclo viral (HUNG et al., 2020). Nesse cenário, abordagens computacionais, em especial as de IA, emergiram como poderosas ferramentas. Yan et al. (2023) em seus estudos comparativos indicam que modelos multimodais consistentemente

² Disponível em: <<https://www.kaggle.com/datasets/cprete/covid19-open-datasets-for-brazil/data>> Acesso em: 18 de novembro de 2025.

³ Disponível em: <<https://www.kaggle.com/datasets/einsteindata4u/covid19>> Acesso em: 18 de novembro de 2025.

superam as abordagens unimodais, apesar de requererem uma modelagem e uma construção de dados mais acuradas.

Diante desse quadro, os VLMs surgem como um paradigma emergente e adequado para essa tarefa, visto que são projetados para processar e integrar dados visuais (como raios-X) e textuais (como laudos ou históricos clínicos). No entanto, um dos principais entraves para a aplicação e o avanço dessas técnicas na área médica é precisamente a carência de conjuntos de dados robustos, específicos e, crucialmente, em língua portuguesa. A disponibilidade de dados de alta qualidade é uma condição indispensável para o treinamento e a validação de VLMs eficazes, e a sua falta representa um gargalo significativo no contexto nacional.

Dessa forma, este trabalho busca a criação e a estruturação de um dataset multimodal imagem-texto em português para o diagnóstico de covid-19, estruturando e traduzindo o dataset em inglês *covid-chestxray-dataset* (COHEN et al., 2020), oferecendo um material raro e essencial para a comunidade científica brasileira e viabilizando futuras pesquisas. Além do mais, utilizando o *dataset* covid-chest-xray para treinar e avaliar um VLM, o trabalho investiga o impacto da multimodalidade, buscando quantificar o ganho de desempenho em relação a abordagens unimodais.

1.3 Objetivos

Segue os objetivo geral e específicos que norteiam este trabalho.

1.3.1 Objetivo geral

Desenvolver um *dataset* multimodal estruturado em português, a partir de imagens e notas clínicas de pacientes para melhorar a eficácia de previsão de covid-19 e avaliar como a multimodalidade afeta o resultado.

1.3.2 Objetivos específicos

- a) Coletar, estruturar e traduzir do *dataset features* para o português de modo a estar pronto para o treinamento de modelos.
- b) Analisar a distribuição de amostras, identificando possíveis vieses e correção do *dataset* como na nota já revelar qual é o diagnóstico ou região de onde as amostras vieram, enviesando para um determinado local.
- c) Validar a base elaborada em um modelo de VLM para aferição do impacto da multimodalidade na predição da doença.
- d) Aperfeiçoar o modelo de VLM de acordo com o resultado da validação.

- e) Comparar o desempenho obtido por dados de uma única modalidade em relação à abordagem combinada

2 Fundamentação Teórica

Neste capítulo, serão abordados e explicados os conceitos primordiais para a elaboração deste trabalho.

2.1 Aprendizado de máquina

Em 1950, o pesquisador Alan Turing propôs em seu artigo histórico que máquinas poderiam aprender e criou seu Teste de Turing para examinar o desempenho delas ([TURING, 2009](#)). Posteriormente, em 1959, Arthur Samuel cunhou o termo “aprendizado de máquina”, em seu trabalho que desenvolveu um sistema que aprendia a jogar damas autonomamente e melhorava progressivamente com base em suas experiências ([SAMUEL, 1959a](#)). O aprendizado de máquina foi, então, concebido como o campo da inteligência artificial que se concentra em algoritmos capazes de aprender e realizar tarefas sem que sejam explicitamente programados. Isto é, eles analisam grandes volumes de dados, extraem características relevantes (*features*) e constroem um modelo matemático capaz de generalizar o conhecimento adquirido. A capacidade de um modelo de AM realizar tarefas como predição, classificação ou agrupamento de dados está intrinsecamente ligada aos dados utilizados em sua fase de aprendizado, conhecida como treinamento. A sua precisão é dependente da quantidade, da qualidade e da boa distribuição dos dados ([GONG et al., 2023](#)).

Dentro do AM, há três grandes categorias: supervisionado, não supervisionado e por reforço ([BISHOP, 2006](#)). O primeiro se refere aos modelos que são treinados com dados rotulados, isto é, que possuem uma classificação. Sua tarefa é categorizar uma amostra com o rótulo correto. O segundo se refere aos modelos que usam dados sem rótulo, de modo a buscar nos dados similaridades e, dependendo de qual técnica está sendo usada, ele pode agrupá-los com base nas similaridades encontradas ou reduzir a dimensionalidade do conjunto de dados, ou seja, reduzir o conjunto às características que realmente influenciam o resultado. Por fim, o terceiro se refere a modelos que estão imersos em um ambiente no qual é necessária uma série de tomadas de decisão. Toda vez que o modelo toma uma ação naquele ambiente, ele é recompensado ou punido. Deste modo, o algoritmo busca, a cada decisão, a melhor recompensa esperada, assim como no sistema desenvolvido por [Samuel \(1959b\)](#).

Na área da medicina, um diagnóstico preciso é vital para o direcionamento do tratamento. Tarefas diagnósticas, como a interpretação de uma tomografia computadorizada para identificar uma patologia, são essencialmente problemas de classificação. Nesse contexto, o aprendizado supervisionado se apresenta como a abordagem ideal, pois os modelos são treinados para reconhecer padrões em dados rotulados. Portanto, este trabalho empregará o aprendizado supervisionado, pois será treinados VLMs de modo a serem capazes de classificar pacientes

como “positivo” ou “negativo” para covid-19, com base em seus dados clínicos e laboratoriais.

2.2 Processamento de Linguagem Natural

O Processamento de Linguagem Natural (PLN) consiste no campo da IA que busca sistemas e modelos que consigam analisar, processar e gerar computacionalmente linguagem natural, ou seja, a linguagem falada por humanos e como eles realmente se comunicam. A compreensão plena de uma frase é algo complexo de se obter computacionalmente, visto que ela possui um nível léxico (a composição de caracteres), um nível sintático (a organização da frase e seus elementos) e um nível semântico (o significado dos elementos). Quando alguém diz, por exemplo, “João foi ao banco”, pode-se entender que João foi a um assento (se o contexto for um parque) ou a uma agência de uma instituição financeira (se o contexto envolver boletos ou finanças). Neste caso, a ambiguidade do texto provém da polissemia do termo, uma ambiguidade léxica, mas poderia vir do nível sintático ou do nível semântico (ORTEGA-MARTÍN et al., 2023).

À primeira vista, este problema parece computacionalmente complexo de realizar, porém o PLN propõe métodos e ferramentas que superem problemas característicos da linguagem natural, como o da ambiguidade.

2.2.1 Token

A tokenização é o processo de segmentar um texto em unidades elementares, chamadas tokens. Um token é a menor unidade de significado para o modelo, tipicamente uma palavra, um número ou um sinal de pontuação (CASELI; NUNES, 2024). Por exemplo, na frase “ele gosta de sorvete, jogos e desenhos”, a tokenização resultaria em oito tokens distintos: [“ele”, “gosta”, “de”, “sorvete”, “,”, “jogos”, “e”, “desenhos”]. Note que a vírgula, mesmo adjacente a “sorvete”, é tratada como um token separado. Estratégias de tokenização mais avançadas também podem lidar com contração como em “João foi ao parque”. Neste caso, “ao” é separado nos tokens da preposição “a” e do artigo “o”.

Enquanto um token é cada ocorrência individual em um texto, um *type* representa a classe única da palavra. A relação entre esses dois conceitos é fundamental para medir a diversidade lexical de um texto. A riqueza de termos únicos é frequentemente avaliada pela razão da quantidade de *types* pela de tokens (*Type-Token Ratio*, TTR). Um valor de TTR mais próximo de 1 indica uma maior variedade de palavras e, conseqüentemente, uma maior riqueza vocabular, enquanto um valor mais baixo sugere uma maior repetição dos mesmos termos.

2.2.1.1 Subpalavras como tokens

Também é possível tokenizar palavras em seções, chamadas de subpalavras. Nesta abordagem, fragmentam-se as palavras em cadeias de caracteres menores. Sua vantagem consiste em reduzir o tamanho dos elementos guardados, sem prejudicar o tamanho do vocabulário compreendido.

Existem vários algoritmos para a tokenização como o *SentencePiece* (KUDO; RICHARDSON, 2018), o *WordPiece*, usado no BERT (DEVLIN et al., 2019), e o *Byte Pair Encoding* (BPE), usado na família de modelos GPT.

No BPE, é procurado o par de símbolos adjacentes com mais ocorrência em um corpus e é então substituído por um novo e único token. O processo é iterado no corpus modificado com o novo token até que o vocabulário chegue a um tamanho pré-definido (ZOUHAR et al., 2023).

2.2.2 Word embedding


Após a tokenização, torna-se necessário converter os tokens textuais em um formato numérico que os modelos de aprendizado de máquina possam processar. Uma abordagem inicial para essa conversão foi a representação *one-hot*, onde cada token é mapeado para um vetor esparso de dimensão V (o tamanho total do vocabulário), composto inteiramente por zeros, exceto por um '1' na posição correspondente ao índice daquele token. No entanto, a dimensionalidade V pode ser extremamente alta, gerando vetores gigantescos e esparsos, e sem conseguir representar propriamente a semântica da palavra.

Para isso, há o *word embedding*, uma representação vetorial densa onde cada token é mapeado como um vetor (ou um ponto) em um espaço vetorial de n -dimensões (CASELI; NUNES, 2024). Este vetor é denominado de vetor semântico. Nesta representação, é possível facilmente agrupar palavras com a mesma ideia ou ideias parecidas (i.e. “frio” e “gelado”), distanciar conceitos opostos (“forte” e “fraco” estariam diametralmente opostos) e aproximar palavras que se relacionam sem necessariamente terem a mesma ideia (“relógio” e “hora”, por exemplo, se correlacionam, mas não são a mesma coisa, portanto estariam em dimensões próximas).

Outro atributo relevante é a habilidade de fazer operações vetoriais análogas para buscar outras palavras. O exemplo clássico, ilustrado na Figura 2, mostra que a relação vetorial entre “rei” e “homem” é similar à que existe entre “rainha” e “mulher”. Matematicamente, isso se traduz na operação: $\text{vetor}(\text{“rei”}) - \text{vetor}(\text{“homem”}) + \text{vetor}(\text{“mulher”}) \approx \text{vetor}(\text{“rainha”})$.

Para calcular a proximidade entre dois vetores de palavras nesse espaço, a métrica mais comum é a similaridade de cossenos, mostrada na Equação 2.1. Ela mede o cosseno do ângulo entre dois vetores. Em corpora (coletânea de textos usado no treinamento) não tão diversos ou em pouca quantidade, pode haver palavras com baixíssima frequência, o que afeta

Figura 2 – Exemplo clássico de *word embedding*.



Fonte: Elaborada pelo autor

métricas como a distância euclidiana. Entretanto, a similaridade de cossenos é eficaz por focar na orientação dos vetores (direção do significado) em vez de sua magnitude, que é influenciada pela frequência. Matematicamente, ela é dada pelo produto escalar de um vetor a e de um vetor b dividido pelo produto de seus módulos.

$$\cos(\theta) = \frac{a \cdot b}{\|a\| \|b\|} = \frac{\sum_{i=1}^n a_i b_i}{\sqrt{\sum_{i=1}^n a_i^2} \sqrt{\sum_{i=1}^n b_i^2}} \quad (2.1)$$


2.3 LLM e *Transformer*

O aprendizado profundo (*Deep Learning* em inglês) é uma subárea de AM que se baseia em Redes Neurais Artificiais (RNAs), modelos computacionais inspirados na estrutura e funcionamento do cérebro humano, projetados para aprender a partir de dados. Elas consistem em unidades de processamento interconectadas, chamadas neurônios artificiais, organizadas em camadas (entrada, oculta e saída). Ao serem treinadas com grandes volumes de exemplos, as redes ajustam a força das conexões entre esses neurônios para identificar padrões complexos por meio de múltiplas camadas (arquiteturas profundas). O objetivo central é aprender representações hierárquicas de dados (BISHOP, 2006). A Figura 3 representa uma rede com dois nós na camada de entrada, três nós na camada oculta e dois na camada de saída.

O cálculo em uma RNA, processo chamado de *Forward Pass*, inicia com os dados x na camada de entrada. Para cada neurônio i de uma camada, calcula-se a pré-ativação a_i , que é a soma ponderada das saídas z_j da camada anterior multiplicadas por seus respectivos pesos w_{ij} , mais um viés b_i (Equação 2.2).

$$a_i = \sum_{j=1}^M (w_{ij} \cdot z_j) + b_i \quad (2.2)$$

Figura 3 – Exemplo de uma RNA.



Fonte: elaborado pelo autor

O valor a_i (onde M é o número de neurônios da camada anterior) passa então por uma função de ativação g não-linear (e.g. tangente hiperbólica ou *ReLU*), que produz a saída final z_i do neurônio (Equação 2.3). Esta não-linearidade permite que o modelo aprenda funções mais complexas.

$$z_i = g(a_i) \quad (2.3)$$

A função de perda L (*loss function*) quantifica o erro do modelo. Há várias formas de obtê-la, porém, o tipo da tarefa determina qual método será empregado. Para as tarefas de regressão, em que se procura prever um valor a partir de uma base de outros valores, utiliza-se comumente o Erro Quadrático Médio (*Mean Square Error*, MSE), dado pelo quadrado da diferença entre o resultado esperado e o resultado obtido (Equação 2.4, em que N é o número de amostras e i a amostra). Para classificação, a Entropia Cruzada Binária (*Binary Cross Entropy*, BCE) é a escolha padrão em casos que há apenas duas classes (Equação 2.5, em que p é a probabilidade de pertencer a uma classe).

$$L = \sum_{i=1}^N (y_{esperado}^i - y_{obtido}^i)^2 \quad (2.4)$$

$$L = \sum_{i=1}^N (y_i \log(p_i) + (1 - y_i) \log(1 - p_i)) \quad (2.5)$$

Esta perda é usada no cálculo de parâmetros dos pesos e dos vieses durante o treinamento (processo de *backpropagation*). Essencialmente, ele calcula o gradiente, ou a derivada, da função de perda em relação a cada parâmetro. Esses gradientes indicam a direção e a magnitude do ajuste necessário em cada peso para reduzir o erro geral. Um algoritmo de otimização, como

o gradiente descendente, usa então esses gradientes para atualizar os parâmetros e é controlada por um hiperparâmetro η (taxa de aprendizagem que controla a magnitude da atualização). O ciclo se repete até que o modelo atinja um nível de precisão aceitável. As Equações 2.6 e 2.7 mostram a atualização dos parâmetros no *backpropagation*.

$$w' = w - \frac{\partial L}{\partial w} \quad (2.6)$$

$$b' = b - \frac{\partial L}{\partial b} \quad (2.7)$$

Dentro do aprendizado profundo, há a categoria de LLM, um modelo de linguagem generativa que apreende quantidades abismais de informações para compreender e gerar respostas para uma entrada. Com esta base aprendida, é possível ainda realizar diversas tarefas sem precisar passar por um novo treinamento em seus parâmetros, mas usando comandos em linguagem natural (*prompts*), propriedade chamada de aprendizado em contexto (*in-context learning*). Sua arquitetura é baseada nos *transformers*.


Em 2017, a arquitetura de aprendizado profundo *Transformer* foi introduzida por pesquisadores do Google no artigo “Attention is All You Need” (VASWANI et al., 2017). Embora existam variações, a arquitetura canônica é composta por um *encoder* (codificador), um *decoder* (decodificador) e o mecanismo de atenção, que é seu principal componente. A arquitetura completa é representada na Figura 4.

Esta arquitetura começa pelo pré-tratamento das sentenças, onde é realizada a tokenização da entrada e da saída ajustadas. Isto é, adiciona-se ao fim da entrada um token especial $\langle eos \rangle$ (fim da sentença) e no início da sentença de saída um token especial $\langle bos \rangle$ (início da sentença). Se porventura ocorrer um *type* desconhecido pelo modelo (uma palavra que não esteja mapeada no vocabulário), os modelos como os da família GPT usam o BPE para tokenizar em subpalavras, de modo a conseguir representá-la com tokens já conhecidos.

Em seguida, ocorre o *embedding* e o *positional encoding* (codificação posicional). Sem esta última etapa, o modelo não seria capaz de compreender a ordem dos tokens nem a importância dela na análise sintática e semântica (e.g. “aranha preda inseto” e “inseto preda aranha” seriam a mesma coisa). O *positional encoding* usa uma função senoidal para gerar um vetor de número de dimensões igual ao do modelo para mapear a ordem dos tokens. Ela pode ser descrita pela Equação 2.8, uma função que intercala seno e cosseno de acordo com a paridade de i , onde i representa a posição no vetor posicional, k a posição do token na sentença original, d o número de dimensões do modelo e n um valor arbitrário (10.000 é o número usado pelos autores do artigo original).

$$PE(k, i) = \begin{cases} \sin\left(\frac{k}{n^{\frac{d}{4}}}\right), & \text{se } i \text{ for par} \\ \cos\left(\frac{k}{n^{\frac{d}{4}}}\right), & \text{se } i \text{ for ímpar} \end{cases} \quad (2.8)$$

Figura 4 – Arquitetura Transformer



Fonte: [Vaswani et al. \(2017\)](#).

Ao final do cálculo, o vetor posicional é somado ao vetor semântico, de modo a permitir que a distância calculada entre duas palavras seja relativa e não influencie o significado semântico base.

Após o *embedding*, vem o *encoder*, um componente que, na verdade, é composto de seis *subencoders* que processam a sentença de entrada (agora em vetores) na primeira subcamada, a de *Multi-Head Attention* (Atenção de Múltiplas Cabeças), o grande diferencial do modelo. De modo geral, este mecanismo permite que o sistema compreenda a relação que um token a ser analisado tem com o resto da sentença, gerando três matrizes: Q (*Query* ou consulta), K (*Key* ou chave) e V (*Value* ou valor). Cada matriz é obtida através do produto da matriz de entrada X (combinação de *embeddings* e codificação posicional) com uma matriz de pesos (W_q, W_k, W_v) calculada durante o treinamento, exemplificado nas Equações 2.9, 2.10 e 2.11.

$$Q = XW_q \quad (2.9)$$

$$K = XW_k \quad (2.10)$$

$$V = XW_v \quad (2.11)$$

Em seguida, calcula-se a matriz de atenção Z . Primeiro, computa-se o produto escalar entre a matriz Q e a transposta de K (K^T), seguido da normalização. Esta etapa consiste em dividir o produto pela raiz quadrada da dimensão d_k (a dimensão dos vetores de chave), o que serve para manter o cálculo estável. Então, os resultados (placar de atenção) passam pela função *softmax* (Equação 2.12), transformando-os em probabilidades (pesos). Por fim, esta matriz de pesos é multiplicada pela matriz V . O cálculo pode ser simplificado pela Equação 2.13.

A função *softmax* (Equação 2.12) converte um vetor de números reais em um vetor de probabilidades, onde x é o vetor de entrada, x_i o i -ésimo elemento, e N o número total de tokens na sequência.

$$\text{softmax}(x)_i = \frac{e^{x_i}}{\sum_{j=1}^N e^{x_j}} \quad (2.12)$$

$$Z = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (2.13)$$

Na arquitetura de Vaswani et al. (2017), o *multi-head attention* consiste em oito mecanismos de atenção (descritos acima) executados em paralelo. Esta abordagem se deve a muitas frases terem interpretações complexas ou à polissemia, possibilitando inúmeras interpretações. Deste modo, a multiplicidade permite ao modelo compreender melhor todas as possibilidades. Para passar para a próxima camada, é preciso ainda concatenar os vetores Z paralelos e multiplicá-lo (o vetor concatenado) por uma matriz de pesos adicionais definida no treinamento.

Os vetores processados são adicionados à representação original de antes do processamento (conexão residual). Desta forma, o modelo evita o fenômeno de esquecimento, impedindo que o modelo perca informações, pois o gradiente zera durante multiplicações de valores entre 0 e 1. Posteriormente, passam pelo *Feed Forward Network* (FFN), uma rede neural unidirecional. A rede FFN é composta por duas transformações lineares (duas camadas totalmente conectadas) com uma função de ativação ReLU (*Rectified Linear Unit*) entre elas. A primeira camada linear tipicamente expande a dimensionalidade do vetor de entrada (de d_{model} para uma dimensão interna d_{ff} , que no artigo original (VASWANI et al., 2017) é 2048, enquanto d_{model} é 512). A função ReLU introduz a não linearidade, permitindo que o modelo aprenda funções mais complexas. A segunda camada linear projeta o vetor de volta à sua dimensão original d_{model} . A operação completa pode ser descrita pela Equação 2.14, onde x é o vetor de entrada da camada, e W_1 , W_2 , b_1 e b_2 são matrizes de pesos e vieses aprendidos durante o treinamento. O vetor resultante, então, é repassado novamente para outro *subencoder* mais cinco vezes, repetindo o processo.

$$FFN(x) = \max(0, xW_1 + b_1)W_2 + b_2 \quad (2.14)$$

O *decoder* é similar ao *encoder*, porém com duas alterações principais. A primeira é que a camada de atenção é o *Masked Multi-Head Attention*. Em princípio, é igual à sua contraparte do *encoder*, mas aplica-se uma máscara para impedir que o modelo saiba os tokens futuros da sentença de saída, já que o objetivo é justamente a predição do próximo token. A segunda é a presença de uma segunda subcamada de atenção, que recebe como entrada K e V do *encoder*, enquanto o Q advém da subcamada anterior (a de atenção mascarada).

Por fim, o vetor final passa por uma camada linear totalmente conectada que resulta em um vetor (*logits*) de mesmo tamanho do vocabulário. Cada posição contém uma pontuação para cada palavra do vocabulário, que são convertidas em probabilidades. Para isso, é novamente usada a função *softmax*. Após essa última camada, o modelo enfim gera uma sequência inteira nova de palavras.

Em suma, os transformers permitiram que os LLMs pudessem processar quantidades colossais de informações de maneira eficiente e necessário para criar modelos com bilhões de parâmetros, capazes de entender e gerar linguagem com a fluidez e complexidade que definem os LLMs modernos.


2.4 Ajuste fino e LoRA

O ajuste fino (*fine-tuning* em inglês) consiste em treinar um modelo pré-treinado em um conjunto de dados menor e específico em um domínio (PARTHASARATHY et al., 2024). O conhecimento prévio do modelo é aproveitado e novos conhecimentos são construídos com base no que já existe.

O *Parameter-Efficient Fine-Tuning*, PEFT, por sua vez, propõe métodos de ajuste fino em que apenas alguns parâmetros sejam novamente treinados enquanto o resto se mantém inalterados (ou congelados). A queda de quantidade nos parâmetros a serem alterados, torna a especialização do modelo em processo muito menos caro computacionalmente e demorado.

O tipo de PEFT usado no trabalho será o *Low-Rank Adaptation*, LoRA (HU et al., 2021). Este modelo não altera os pesos originais nem os vieses, mas adiciona uma camada de adaptadores no modelo em que será realizado o treinamento. Dado que a matriz de pesos do modelo tenha dimensões d por d , o LoRA, ao invés de usar uma segunda matriz de pesos d por d , ele a decompõe em uma matriz A de dimensões d por r , um valor parâmetro chamado de *lora rank*, e em uma matriz B de dimensões r por d . Durante o treinamento, a entrada x passa pela matriz de pesos e, paralelamente, pelo adaptador do LoRA. Ao final, é somado os resultado de ambas partes e repassado à próxima camada (Figura 5).

Figura 5 – Matrizes LoRA A e B



Fonte: Elaborado pelo autor.

Esta decomposição reduz o tamanho de memória e armazenamento exigidos. Conforme o parâmetro r aumenta, melhor o desempenho do ajuste, porém a custa do espaço economizado pela decomposição.

2.5 Visual Language Model


Dentro dos *Multimodal Large Language Model*, a categoria de modelos *Visual Language Model* se define pela sua especialização em texto e imagem. A sua principal função é extrair informações de texto e de imagem simultaneamente. Assim, o modelo pode ser usado para responder sobre elementos da imagem, reconhecimento de imagem, gerar legendas descritivas ou categorizá-la com base no texto. A arquitetura de VLM essencialmente possui: um *text encoder* (essencialmente um tokenizador de texto), um *vision encoder* e um *projector*.

O *vision encoder* segmenta a imagem em pedaços menores (*patches*), extrai características visuais de cada um e os converte em tokens visuais. Em seguida, o *projector* mapeia esses tokens do espaço de representação visual (aprendido pelo *encoder*) para o espaço de representação textual do LLM, garantindo que as duas modalidades sejam compatíveis e gerando os *embeddings* (LI et al., 2025).

Uma técnica usual para treinar esta estrutura é o aprendizado contrastivo (*contrastive learning*). Esta abordagem ensina o componente a alinhar representações visuais e textuais em um espaço vetorial compartilhado. Durante o treinamento, o modelo aprende a maximizar a similaridade (como a similaridade de cosseno) entre os *embeddings* de um par (imagem, texto) semanticamente correto e a minimizar a similaridade com todos os pares incorretos (*negative samples*) dentro de um lote. O Contrastive Language-Image Pre-Training (CLIP) utilizou o aprendizado contrastivo em larga escala para criar *vision encoders* e texto cujas representações estão altamente alinhadas (RADFORD et al., 2021).

Ao final, para processar esta composição de texto e da imagem tratada, é passado para uma LLM pré-treinada (*backbone*) como na Figura 6.

Figura 6 – Esquema do VLM com *backbone*



Fonte: Elaborada pelo autor.

Embora existam outras abordagens para construir VLMs do zero (*from scratch*), como as baseadas puramente em *masking* (sem componentes pré-treinados). A abundância de LLMs de código aberto e de alto desempenho tornou a abordagem baseada em *backbone* pré-treinado mais prática e predominante na pesquisa e desenvolvimento de VLMs (BORDES et al., 2024).

Um exemplo notável é o VLM LLaVA (LIU et al., 2023), que utiliza o LLM LLaMA (TOUVRON et al., 2023) como base, adicionando apenas as camadas de processamento visual com o CLIP como *vision encoder*, o que viabiliza o desenvolvimento de modelos poderosos mesmo com recursos mais limitados.

3 Materiais e Métodos

Este capítulo detalha o conjunto de dados utilizado, as etapas de pré-processamento, a configuração experimental do treinamento e as métricas de avaliação empregadas.

3.1 Ambiente de execução

A plataforma Kaggle¹ será utilizada durante a experimentação inteira do trabalho. Esta plataforma online disponibiliza ambientes virtuais de desenvolvimento com notebooks na linguagem Python bem como *datasets* públicos. Sua escolha se deve ao fato de que também disponibiliza gratuitamente 30 horas semanais de GPUs como P100 ou duas T4.

O ambiente de desenvolvimento do trabalho contou com 57.6 GiB de armazenamento, 30 GiB de RAM e 2 GPUs T4 com 15 GiB de VRAM.

3.2 *Dataset*

Cohen et al. (2020), durante a pandemia, coletaram imagens de raio-X e tomografias computadorizadas de 412 pacientes em 26 países (distribuição na Tabela 1). A cada imagem há também dados como teste de sangue, sobrevivência do paciente, intubação e uma nota clínica. Esta foi a primeira coleção pública de imagens radiológicas para covid-19.

A Figura 7 exibe exemplos de raios-X acompanhados de suas respectivas notas clínicas. Essas notas podem detalhar o quadro clínico do paciente na admissão, condições pregressas, sintomas, resultados de exames (como testes de sangue) e, principalmente, uma descrição analítica da imagem radiológica.

O conjunto de dados não se limita apenas covid-19, incluindo também a identificação de diversas outras patologias. As categorias são definidas pela origem do patógeno: viral (incluindo covid-19 e outros 5 tipos), bacteriana (9 tipos), fúngica (2 tipos), além de casos de pneumonia lipoide, por aspiração e de origem desconhecida. Um mesmo paciente pode ter mais de uma amostra com uma imagem radiológica diferente. No total, há 951 amostras.

3.2.1 Pré-tratamento dos dados

Para este trabalho, os dados serão filtrados de modo que haja apenas três tipos: de admissão, de sintoma e de observação. A primeira se refere a informações do paciente que tangenciam o quadro, como histórico de tabagismo, ou condições clínicas como uso controlado


¹ Disponível em: <https://www.kaggle.com> Acesso em: 18 de novembro de 2025.

Tabela 1 – Total de pacientes com e sem covid-19 por região bem como quantos foram por RT-PCR.

Região	Sub-região	Total	covid-19	covid-19 por RT-PCR
África	Norte da África	5	0	0
Américas	América Latina/Caribe	5	3	1
	América do Norte	27	17	15
Ásia	Ásia Oriental	54	50	40
	Sudeste Asiático	9	8	8
	Sul da Ásia	15	14	14
	Ásia Ocidental	13	6	4
Europa	Europa Oriental	4	1	1
	Norte da Europa	31	22	18
	Sul da Europa	123	91	74
	Europa Ocidental	53	49	5
Oceania	Austrália/Nova Zelândia	42	1	2
Desconhecido	Desconhecido	31	19	0
Totais		412	281	182

Fonte: adaptado de [Cohen et al. \(2020\)](#).

Figura 7 – Mosaico com exemplos de raios-X e suas notas




Fonte: adaptado de [Cohen et al. \(2020\)](#).

de medicação, se é portador de HIV ou se tem asma. A segunda se refere aos sintomas do paciente como febre, tosse ou falta de ar. Por fim, o terceiro se refere a observações que descrevam ou complementem a análise da imagem associada. Como mostrado na Figura 8, após a extração, as *features* serão traduzidas para português.

O processo de extração seguirá restrições rigorosas para evitar viés no treinamento ([SHENG et al., 2019](#)). Informações demográficas (como local, sexo e idade) deverão ser

Figura 8 – Pipeline do pré-processamento dos dados



Fonte: Elaborada pelo autor

obrigatoriamente omitidas. Além disso, para evitar vazamento de dados no ajuste (*data leakage*), qualquer menção explícita ao diagnóstico de covid-19 será removida das notas.

Para a extração desses três tipos nas notas, foi usado o LLM Deepseek-R1 (DEEPSEEK-AI et al., 2025). No *prompt* foi utilizada a técnica de *few shot learning*. Assim, foram colocados no *prompt* nove exemplos de notas cruas e de como deveriam ser as informações coletadas, removendo informações como local e datas. Em algumas notas há o mesmo conteúdo, pois possuem o mesmo paciente de modo que alguns segmentos da nota como (a) e (b) ou 1 e 2 se referem a imagem. Para identificar a qual segmento da nota a imagem se refere, é passado o nome do arquivo da imagem, pois no nome há indicação de qual segmento é. O *prompt* usado:

Task: Read csv line related to image 'filename': row

Answer: Extract text segments with informations in a medical report into three categories: admission, patient's medical history; symptomatic, patient's symptoms and vital signs; and observation, a clinical read of patient's exam image and notes from it, patient's reminiscence from a previous surgery/operation like a clip in chest or image finding. Examples of text extraction: Example 1: "On January 22, 2020, a 65-year-old man with a history of hypertension, type 2 diabetes, coronary heart disease for which a stent had been implanted, and lung cancer was admitted to the emergency department of Cho Ray Hospital, the referral hospital in Ho Chi Minh City, for low-grade fever and fatigue. He had become ill with fever on January 17, a total of 4 days after he and his wife had flown to Hanoi from the Wuchang district in Wuhan, where outbreaks of 2019-nCoV were occurring. He reported that he had not been exposed to a "wet market" (a market where dead and live animals are sold) in Wuhan. Chest radiographs obtained on admission showed an infiltrate in the upper lobe of the left lung"has Admission: "history of hypertension, type 2 diabetes, coronary heart disease for which a stent had been implanted, and lung cancer", because it's previous his admission, Symptomatic: "low-grade fever and fatigue", Observation: "Chest radiographs obtained on admission showed an

infiltrate in the upper lobe of the left lung". Example 2: "diffuse infiltrates in the bilateral lower lungs"has Admission: "none", Symptomatic: "none", Observation: "diffuse infiltrates in the bilateral lower lungs". Example 3: "Case 2: chest x-ray obtained on Jan 6 (2A). The brightness of both lungs was decreased and multiple patchy shadows were observed; edges were blurred, and large ground-glass opacity and condensation shadows were mainly on the lower right lobe. Tracheal intubation could be seen in the trachea. Heart shadow roughly presents in the normal range. On the left side, the diaphragmatic surface is not clearly displayed. The right side of the diaphragmatic surface was light and smooth and rib phrenic angle was less sharp. Chest x-ray on Jan 10 showed worse status (2B)"has Admission: "none", Symptomatic: "none", and Observation: "The brightness of both lungs was decreased and multiple patchy shadows were observed; edges were blurred, and large ground-glass opacity and condensation shadows were mainly on the lower right lobe. Tracheal intubation could be seen in the trachea. Heart shadow roughly presents in the normal range. On the left side, the diaphragmatic surface is not clearly displayed. The right side of the diaphragmatic surface was light and smooth and rib phrenic angle was less sharp"; Example 4: "SARS in a 74-year-old man who developed symptoms 4 days after exposure. Anteroposterior radiograph obtained 5 days later shows a resolution of consolidation in the left lung but increased consolidation in the right lung"has Admission: "none", Symptomatic: "none", Observation: "resolution of consolidation in the left lung but increased consolidation in the right lung"; Example 5: "Productive cough with a sore throat for 1 week, no fever or chest pain, traveling to Macau from Wuhan 3 days prior, denied close contact with wet market. Multiple small bilateral areas of patchy confluent opacification, including a discrete rounded opacity in the right lower zone"has Admission: "none", Symptomatic: "Productive cough with a sore throat for 1 week, no fever or chest pain", Observation: "Multiple small bilateral areas of patchy confluent opacification, including a discrete rounded opacity in the right lower zone". "traveling to Macau from Wuhan 3 days prior, denied close contact with wet market"should be excluded because has location; Example 6: "63 year old man with night apnea in home CPAP. For 5 days fever, asthenia, pharyngodynia and diarrheal alvo. High PCR (16.27 mg / dL), normal hematocrit and procalcitonin. Extended and multiple bilateral parenchymal thickenings"has Admission: "night apnea in home CPAP", Symptomatic: "fever, asthenia, pharyngodynia and diarrheal alvo", "High PCR (16.27 mg / dL), normal hematocrit and procalcitonin", Observation: "Extended and multiple bilateral parenchymal thickenings". Example 7: "SARS in a 74-year-old man who developed symptoms 4 days after exposure. Anteroposterior radiograph obtained 1 day later shows diffuse persistent bilateral airspace disease. The patient died 13 days after exposure to SARS."has Admission:

"none", Symptomatic: "none", Observation: "Anteroposterior radiograph obtained 1 day later shows diffuse persistent bilateral airspace disease". Symptomatic has none because there is no concrete symptom described. Example 8: "SARS in a 73-year-old woman who presented 17 days after exposure. The chest radiograph obtained on admission (not shown) was normal. (a) Anteroposterior radiograph obtained 2 days after admission shows focal consolidation in the right lung. (b) Anteroposterior radiograph obtained 8 days later shows bilateral multifocal consolidation. (c) Anteroposterior radiograph obtained 8 days later shows diffuse airspace disease. The patient died 36 days after exposure to SARS."has Admission: "The chest radiograph obtained on admission (not shown) was normal", "Symptomatic: "none"; if the filename is "SARS-10.1148rg.242035193-g04mr34g09b-Fig9b-day19.jpeg"has the part 'Fig9b', indicating that is linked with part (b) on the note so Observation: "Anteroposterior radiograph obtained 8 days later shows bilateral multifocal consolidation.", but if the filename is "SARS-10.1148rg.242035193-g04mr34g09a-Fig9a-day17.jpeg", Observation: "Anteroposterior radiograph obtained 2 days after admission shows focal consolidation in the right lung", because is linked with (a) as the name has Fig9a-day17; Observation: "Anteroposterior radiograph obtained 8 days later shows diffuse airspace disease"if linked with (c) because "SARS-10.1148rg.242035193-g04mr34g09a-Fig9c-day27.jpeg"cite Fig9c, so on; Example 9: "Chest X-ray films of the case of COVID-19. (A) Hospital day 1: increased pulmonary infiltrations, esp. in left lung field (white arrows). (B) Hospital day 14: Resolution of pulmonary infiltrates at left lung field (white arrows)."has Admission: none, Symptomatic: none, Observation: "increased pulmonary infiltrations, esp. in left lung field (white arrows)"if filename indicate that is correlated with "(A)"(1-s2.0-S1684118220300608-main.pdf-001.jpg) or "Resolution of pulmonary infiltrates at left lung field (white arrows)."if indicate correlation with "(B)"(1-s2.0-S1684118220300608-main.pdf-002.jpg)"; Extract text segments with informations for each category without dates, address, disease diagnosis and patient's age or sex. The Answer must be EXACTLY in the following format (not in JSON or alternative format): Admission: text segment, Symptomatic: text segment, Observation: text segment; Return "none;"if don't have. Don't comment on answer.


A execução do modelo se deu pelo uso das ferramentas *Ollama* e *LangChain*. O *Ollama* é uma plataforma que simplifica o download, a configuração e a execução de LLMs, como o Deepseek-R1, de forma local. No contexto desta pesquisa, foi usado para fornecer o modelo diretamente dentro do ambiente do notebook do Kaggle. O *LangChain*, por sua vez, é um *framework* de desenvolvimento focado na criação de aplicações que utilizam LLMs. Ele atua como um gerenciador, sendo usado na pesquisa para estruturar a lógica da aplicação, manusear os prompts e facilitar a comunicação com o modelo que estava sendo executado via *Ollama*.

No exemplo da Figura 9, não há nenhuma informação de admissão, pois não há nada sobre condições pregressas. De sintomas, foi extraído que houve 4 dias de febre e tosse. De observação, a presença de opacidades, sua implicação e o aumento da densidade delas. Ressalta-se que foram deixados de fora os fatos de que o paciente era um homem de 35 anos, que foi socorrido em *Washington* e o dia em que ocorreu.

Apesar de coletadas, as informações estão todas em inglês. Na tarefa de tradução para o português, foi usado o LLM InternLM3 de 8 bilhões de parâmetros, modelo de alto desempenho e baixo custo computacional². Também foram utilizados o *Ollama* e *Langchain* para facilitar a aplicação. o prompt da tradução:

Task: Translate the following message to brazilian portuguese. Answer back the revised text without additional comments before or after, avoiding comments about how or which guidelines have been followed. Don't add comments Text: line Translated text:"

Figura 9 – Exemplo de extração



Fonte: adaptado de Cohen et al. (2020).

Por fim, o conjunto de dados será dividido em subconjuntos de treino (70%) e teste (30%). Será utilizada uma divisão estratificada para garantir que a distribuição de classes (positivos e negativos para covid-19) fosse preservada em ambos os conjuntos. Desse modo, tanto o treino quanto o teste mantiveram a proporção original de aproximadamente 72% de amostras positivas.

² Disponível em: <https://github.com/InternLM/InternLM> Acesso em: 18 de novembro de 2025.

3.3 Configuração experimental

É proposto, a técnica de ajuste fino Lora para que os VLMs apreendam a como relacionar dados multimodais. Para isso, o Unsloth será utilizado, uma biblioteca de código aberto projetada para otimizar drasticamente o processo de ajuste fino e aprendizado por reforço de modelos. Dos VLMs disponíveis no Unsloth para treinamento, o "*Qwen2.5-VL-7B-Instruct-bnb-4bit*" (TEAM, 2025) e o MedGemma3 de 4 bilhões de parâmetro, um modelo Gemma que recebeu um ajuste fino para se especializar em medicina, gerando melhores resultados em tarefas da área, (GOOGLE, 2025) serão utilizados, pois o ambiente de execução consegue suportar o processo de ajuste fino desses modelos.

A instrução usada no ajuste é "Analise a imagem fornecida e as informações clínicas do paciente. Com base apenas nesses dados, responda se o paciente apresenta diagnóstico de covid-19. Responda apenas com uma das opções: "Sim: covid" ou "Não: sem-covid". Informações clínicas: ". Para cada amostra, a instrução é concatenada as informações extraídas. Para efeito de comparação, será também avaliada o ajuste de VLMs com o conjunto em inglês com a instrução: "Analyze the provided image and the patient's clinical information. Based solely on this data, answer whether the patient has a Covid-19 diagnosis. Answer with only one of the options: "Yes: covid" or "No: no-covid". Clinical information:"

Além da análise multimodal, será conduzido a avaliação do desempenho de classificação com análises unimodais, ou seja, que use somente imagem e outra com somente texto para analisar. A instrução utilizada para imagem é "Analise a imagem fornecida. Com base apenas neste dado, responda se o paciente apresenta diagnóstico de Covid-19. Responda apenas com uma das opções: 'Sim: covid' ou 'Não: sem-covid'. Na de texto, será utilizada: 'Analise as notas clínicas fornecidas abaixo. Com base exclusivamente nas informações textuais (sintomas, histórico, observações, resultados de exames descritos), determine se o diagnóstico é Covid-19. Formato de Saída Obrigatório: Responda apenas com 'Sim: covid' ou 'Não: sem-covid'. Informações:"

3.4 Métricas

Essencialmente, a predição de diagnóstico é uma tarefa de classificação. No caso, há quatro resultados possíveis: verdadeiro positivo (VP), onde a amostra é corretamente rotulada como positiva; falso positivo (FP), onde a amostra é incorretamente rotulada como positiva, sendo, na verdade, negativa; verdadeiro negativo (VN), onde a amostra é corretamente rotulada como negativa; e falso negativo (FN), onde a amostra é incorretamente rotulada como negativa.

A acurácia é a métrica mais intuitiva para classificação, representando a proporção de predições corretas em relação ao número total de amostras. Ela mede o desempenho geral do modelo, conforme a Equação 3.1.

$$\text{Acurácia} = \frac{VP + VN}{VP + VN + FP + FN} \quad (3.1)$$

Contudo, a acurácia pode ser uma métrica enganosa em *datasets* desbalanceados. No caso deste trabalho (onde 72% das amostras são positivas), um modelo trivial que classificasse todas as amostras como positivas já alcançaria 72% de acurácia, embora falhasse completamente em identificar a classe negativa. Por essa razão, outras métricas são preferíveis.

A medida de precisão avalia a proporção de predições positivas que estavam, de fato, corretas. Isto é, mede a assertividade do modelo ao classificar uma amostra como positiva (Equação 3.2).

$$\text{Precisão} = \frac{VP}{VP + FP} \quad (3.2)$$

Já o *recall* (também chamado de revocação ou sensibilidade) avalia a abrangência do classificador, medindo quantas das ocorrências positivas reais foram corretamente identificadas pelo modelo (Equação 3.3).

$$\text{Recall} = \frac{VP}{VP + FN} \quad (3.3)$$

É possível que o classificador apresente uma alta precisão e baixo *recall*, indicando que ele é assertivo quando classifica uma amostra como positiva, mas falha em encontrar muitas delas. O contrário também é válido (baixa precisão e alto *recall*), situação em que o classificador encontra vários positivos, mas ao custo de classificar erroneamente muitos negativos como positivos.

Como ponderação entre as duas métricas, há o *F1-score*, uma média harmônica entre elas, definida pela Equação 3.4, que representa uma visão mais geral sobre a classificação (CASELI; NUNES, 2024). O *F1-score* é particularmente útil em *datasets* com proporções desiguais entre as classes, como o caso deste trabalho. Dado que o *F1-score* é baseado na precisão e no *recall*, ele ignora os VNs, focando no desempenho da classe positiva (VP, FP, FN), o que o torna uma métrica mais robusta do que a acurácia em cenários desbalanceados.

$$F_1 = \frac{2 \cdot \text{Precisão} \cdot \text{Recall}}{\text{Precisão} + \text{Recall}} \quad (3.4)$$

4 Resultados

Devido ao consumo intensivo de VRAM intrínseco aos VLMs, o trabalho enfrentou dificuldades com o tamanho dos modelos e o processo de ajuste. Apesar do Kaggle disponibilizar duas GPUs T4 com 15 GiB cada, não há meios estáveis no Unsloth para treinar usando paralelismo de placas de vídeo. Logo, o treino ficou restrito a apenas uma T4, ou seja, com 15 GiB de VRAM.

A configuração do ajuste fino foi definida de forma que não ultrapassasse a capacidade da memória da placa de vídeo. Em meio as tentativas, acabou se utilizando de um framework de treino (*SFTTrainer*) e as bibliotecas *trl* e *Unsloth* focadas em otimização de performance e eficiência de memória, permitindo a aplicação do PEFT/LoRA. A configuração do adaptador LoRA (Low-Rank Adaptation) utilizou uma dimensão de rank (r) igual a 16 e um fator de escala alpha de 16, com *dropout* nulo e sem o treinamento de termos de viés. O treinamento foi executado por 30 passos, utilizando o otimizador AdamW (fused) com taxa de aprendizado de 2×10^{-4} e agendamento do tipo cosseno (warmup de 3%). Para otimizar o uso de memória VRAM, ativou-se o gradient checkpointing, combinando um tamanho de lote de 4 por dispositivo com acumulação de gradientes em 4 passos (resultando em um lote efetivo de 16 amostras por atualização de pesos). O tamanho do lote por dispositivo foi minimizado, sendo esta redução compensada pela aplicação de múltiplos passos de acumulação de gradiente. Esta abordagem simula um lote efetivo maior, garantindo a estabilidade da atualização dos pesos ao passo que perde velocidade de processamento. A norma máxima do gradiente foi restrita a 0.3 e a reprodutibilidade foi garantida fixando-se a semente aleatória em 3407.

4.1 Em português

Primeiramente, foi conduzido os treinamentos em português. No caso do Qwen, é perceptível como o modelo naturalmente (com e sem ajuste) é capaz de considerar assertivamente positivos, variando na faixa dos 70%, como mostrado na Tabela 2.


A abrangência, por outro lado, é baixa na imagem e também no texto, não superando 15% de *recall* no sem ajuste, devido à baixa quantidade de positivos verdadeiros, como mostrado na matriz de confusão (Figura 10). A detecção de casos positivos, apesar da precisão, é muito limitada. No entanto, ao considerar ambas modalidades, há um crescimento de aproximadamente 14 pontos percentuais (p.p.) em relação a texto e 18 em relação a imagem. O F1-score, por consequência, também evoluiu 16 e 18 p.p. em relação a imagem e texto, respectivamente. A combinação das duas modalidades, neste caso, possibilitaram uma melhora mesmo sem o ajuste fino.

Tabela 2 – Métricas de Avaliação para o Modelo Qwen

Status	Modalidade	Acurácia	Precisão	Recall	F1-Score
Treinado	Apenas Imagem	0.4776	0.7245	0.4128	0.5259
	Apenas Texto	0.5020	0.7049	0.5000	0.5850
	Ambas	0.5429	0.7143	0.5814	0.6410
Sem Treino	Apenas Imagem	0.3510	0.7826	0.1047	0.1846
	Apenas Texto	0.3633	0.7353	0.1453	0.2427
	Ambas	0.4163	0.7101	0.2849	0.4066

Fonte: Elaborado pelo autor.

Figura 10 – Comparação das matrizes de confusão do Qwen.




Fonte: Elaborado pelo autor

Já no modelo ajustado, houve uma melhora substancial, com a exceção da precisão, em todas as métricas. O ajuste fino fez com que o modelo melhorasse a detecção de positivos e chegasse a quase 30 p.p. nos três tipos de análise. A Figura 11 descreve a função de perda durante o treinamento.

Diferentemente do Qwen, que é um modelo generalista, o MedGemma é um modelo

Figura 11 – Gráfico de perda por épocas do Qwen.



Fonte: Elaborado pelo autor

treinado para tarefas médicas, estando mais apto a classificações desse tipo. Como descrito na Tabela 3, as métricas do modelo sem ajuste ainda são consideravelmente superiores em relação ao Qwen, com exceção da precisão. Nesse caso, o MedGemma sacrifica um pouco da precisão para aumentar o escopo de positivos detectáveis, como visto na Figura 12.


Em relação a análise multimodal, ficou levemente abaixo em todas as métricas diante da análise de imagem e acima em relação a análise de texto. Contudo, ao treinar, cuja função de perda está representada na Figura 13, o F1-score, a métrica mais relevante, passa a ser de quase 75%, 9 p.p. acima do original e quase 11 p.p. acima do Qwen ajustado.

Tabela 3 – Métricas de Avaliação para o Modelo Medgemma

Status	Modalidade	Acurácia	Precisão	Recall	F1-Score
Treinado	Apenas Imagem	0.5959	0.7325	0.6686	0.6991
	Apenas Texto	0.5061	0.7684	0.4244	0.5468
	Ambas	0.6286	0.7120	0.7907	0.7493
Sem Treino	Apenas Imagem	0.5592	0.6905	0.6744	0.6824
	Apenas Texto	0.4327	0.6542	0.4070	0.5018
	Ambas	0.5469	0.6871	0.6512	0.6687


Fonte: Elaborado pelo autor.

Figura 12 – Comparação das matrizes de confusão do MedGemma.



Fonte: Elaborado pelo autor

Figura 13 – Gráfico de perda por épocas do Qwen.



Fonte: Elaborado pelo autor

4.2 Em inglês

De modo geral, o desempenho ficou abaixo em relação aos modelos em português. o Qwen, as métricas gerais progrediram quando treinado em relação ao sem treino, mas ainda abaixo do português (Tabela 4). A única métrica que exibiu uma queda após o treino foi a de precisão nas três modalidades, onde o modelo sem treino, em primeiro momento, apresentou valores impressionantes. A precisão na análise de imagem, por exemplo, chegou a 100%, porém isso se deve ao fato de que somente uma amostra predita foi dada como positiva (conforme na Figura 14), exibindo um *recall* ínfimo de 0,58%.


O treinamento permitiu ao Qwen ampliar justamente seu escopo de detecção de positivos, tanto na análise visual quanto na textual. Ressalta-se que a análise multimodal cresceu em 36 p.p. o *recall* e apresentou o melhor F1-score, após o Qwen aprender a relacionar as duas modalidades durante o treinamento.

Tabela 4 – Métricas de Avaliação para o Qwen em inglês

Status	Modalidade	Acurácia	Precisão	Recall	F1-Score
Treinado	Apenas Imagem	0.4713	0.7333	0.3860	0.5057
	Apenas Texto	0.3566	0.6750	0.1579	0.2559
	Ambas	0.4549	0.6610	0.4561	0.5398
Sem Treino	Apenas Imagem	0.3033	1.0000	0.0058	0.0116
	Apenas Texto	0.3566	0.7500	0.1228	0.2111
	Ambas	0.3443	0.7619	0.0936	0.1667

Fonte: Elaborado pelo autor.

Figura 14 – Comparação das matrizes de confusão do Qwen em inglês.



Fonte: Elaborado pelo autor


Na Tabela 5, o Medgemma ajustado sofreu uma queda na análise textual, tendo em vista o aumento na quantidade de falsos negativos (Figura 15). Apesar disso, a análise multimodal, mesmo sem treino, gera um leve crescimento no F1-score se comparada as monomodais e, após o treinamento, é bem maior.

Tabela 5 – Métricas de Avaliação para o Medgemma em inglês

Status	Modalidade	Acurácia	Precisão	Recall	F1-Score
Treinado	Apenas Imagem	0.4507	0.5983	0.5000	0.5447
	Apenas Texto	0.3361	0.7368	0.0819	0.1474
	Ambas	0.5041	0.6786	0.5556	0.6109
Sem Treino	Apenas Imagem	0.5533	0.7013	0.6316	0.6646
	Apenas Texto	0.4139	0.6373	0.3801	0.4762
	Ambas	0.5697	0.6919	0.6959	0.6939

Fonte: Elaborado pelo autor.

Figura 15 – Comparação das matrizes de confusão do MedGemma em inglês.



Fonte: Elaborado pelo autor

Os resultados em inglês apresentados foram abaixo do esperado, pois modelos de grande porte como o MedGemma e Qwen tem predominantemente em seu corpus de treino dados em inglês (LI et al., 2024). Assim, esperava-se um desempenho melhor em comparação com o ajuste em português.

Uma tentativa de remediação foi usar múltiplos *prompts* no treinamento. Para uma mesma imagem e nota, foram gerados cinco casos novos, diferenciando-se apenas pelo *prompt*. A expectativa era de que isso ajudasse os modelos a terem uma melhor apuração dos dados sob diferentes perspectivas. No caso, foram utilizados o *prompt* original e mais quatro:

- You are a helpful medical assistant. Is there Covid-19 in this image? You may write out your final answer X in the format "Final Answer X"being X "Yes: Covid"or "No: no-Covid". Consider extra informations:.
- Correlate the findings on this chest X-ray with the patient's symptoms and admission notes. Are these combined findings consistent with a COVID-19 diagnosis? Answer 'Yes: Covid' or 'No: no-Covid'.
- Is there Covid-19 in this image? Consider extra infos about the patient like admission (previous medical history), symptoms and observation (notes about image). You may write out your final answer X in the format "Final Answer X"being X "Yes: Covid"or "No: no-Covid".
- Analyze the following chest X-ray in conjunction with the patient's clinical information. Based on all the provided data, determine if the diagnosis is COVID-19. Respond only with 'Yes: Covid' or 'No: no-Covid'.

A Figura 16 mostra a comparação da perda no treinamento do MedGemma usando um *prompt* contra cinco. Ao longo de quase todas as épocas, o uso de apenas um *prompt* obteve menores perdas. De modo geral, o resultado foi contrário às expectativas, com o modelo alcançando um F1-score de 36,44% (Tabela 6), bem abaixo de 61% do MedGemma com apenas um único *prompt*.


Tabela 6 – Métricas de Avaliação para o Medgemma com múltiplos *prompts*.

Modalidade	Acurácia	Precisão	Recall	F1-Score
Apenas Imagem	0.4549	0.7317	0.3509	0.4743
Apenas Texto	0.4303	0.6860	0.3450	0.4591
Ambas	0.4139	0.7593	0.2398	0.3644

Fonte: Elaborado pelo autor.

O Qwen, por outro lado, teve uma melhora em relação ao treinamento anterior, ainda que o desempenho seja inferior ao do treinamento em português. Observa-se na Tabela 7 que o F1-score do novo modelo também permanece superior se comparado aos dos monomodais.

Figura 16 – Comparação da função peso no MedGemma usando um único *prompt* contra múltiplos em inglês.



Fonte: Elaborado pelo autor

A perda foi parelha entre o treinamento com um único *prompt* e com múltiplos, com uma leve vantagem na maioria das épocas para o único (Figura 17).


Tabela 7 – Métricas de Avaliação para o Qwen com múltiplos *prompts*.

Modalidade	Acurácia	Precisão	Recall	F1-Score
Apenas Imagem	0.4877	0.7447	0.4094	0.5283
Apenas Texto	0.4139	0.7917	0.2222	0.3470
Ambas	0.4754	0.6617	0.5146	0.5789

Fonte: Elaborado pelo autor.

Diante do exposto, a tarefa de classificação de covid-19 em inglês ficou aquém em relação a sua contraparte em português. Entretanto, a performance usando dados visuais e textuais combinados se mostrou superior a análise individual das partes, com a excessão do MedGemma com múltiplos *prompts*.

Figura 17 – Comparação da função peso no Qwen usando um único *prompt* contra múltiplos em inglês.



Fonte: Elaborado pelo autor

5 Conclusão

Este trabalho investigou o uso da multimodalidade, combinando dados de texto e imagem, especificamente no diagnóstico de covid-19. A abordagem multimodal apresentou um desempenho consistentemente superior quando comparada às análises unimodais (utilizando exclusivamente texto ou imagem). Isso demonstra que a fusão de diferentes tipos de dados permite ao modelo capturar padrões mais complexos e robustos, reforçando a viabilidade e a importância de investir em técnicas multimodais para o avanço do diagnóstico auxiliado por computador.

Considerando as limitações de processamento computacional deste estudo, sugere-se como melhoria futura investigar o impacto da multimodalidade em VLMs mais robustos, a exemplo do MedGemma de 27 bilhões de parâmetros (GOOGLE, 2025), ou em outros modelos. Adicionalmente, a validação dos resultados em repositórios com um volume de amostras superior ao utilizado neste trabalho seria de grande valia para testar a generalização dos modelos.

Para trabalhos futuros, recomenda-se a investigação das causas do desempenho inferior observado nos modelos treinados em inglês quando comparados aos treinados em português. Neste estudo, informações relevantes foram extraídas do dataset base e devidamente tratadas. Dessa forma, pesquisas futuras terão acesso a um conjunto de dados multimodal pronto para uso, mitigando preocupações com viés, especificamente a remoção de metadados (como local, datas e o próprio diagnóstico) que poderiam estar explícitos na parte textual. O dataset resultante, que inclui ID, sexo, idade, diagnóstico do paciente e as *features* separadas por colunas, está disponível publicamente no repositório do GitHub do autor¹. Adicionalmente, a versão original em inglês foi mantida pública sem tradução durante o desenvolvimento, permitindo estudos comparativos subsequentes. Este conjunto de dados constitui um recurso valioso para o avanço de novas pesquisas lusófonas na temática da multimodalidade aplicada ao diagnóstico da covid-19.

¹ Disponível em: <https://github.com/DanielH11/raio_x_covid_dataset> Acesso em: 18 de novembro de 2025.

Referências

ALSAAD, R.; ABD-ALRAZAQ, A.; BOUGHORBEL, S.; AHMED, A.; RENAULT, M.-A.; DAMSEH, R.; SHEIKH1, J. Multimodal large language models in health care: applications, challenges, and future outlook. *Journal of Medical Internet Research*, JMIR, v. 26, 2024.

AREVALO-RODRIGUEZ, I.; BUITRAGO-GARCIA, D.; SIMANCAS-RACINES, D.; ZAMBRANO-ACHIG, P.; CAMPO, R. D.; CIAPPONI, A.; SUED, O.; MARTINEZ-GARCÍA, L.; RUTJES, A. W.; LOW, N.; BOSSUYT, P. M.; PEREZ-MOLINA, J. A.; ZAMORA, J. False-negative results of initial rt-pcr assays for covid-19: a systematic review. *Plos One*, Plos, 2020.

BISHOP, C. M. *Pattern Recognition and Machine Learning*. [S.l.]: Springer, 2006.

BORDES, F.; PANG, R. Y.; AJAY, A.; LI, A. C.; BARDES, A.; PETRYK, S.; MAÑAS, O.; LIN, Z.; MAHMOUD, A.; JAYARAMAN, B.; IBRAHIM, M.; HALL, M.; XIONG, Y.; LEBENSOLD, J.; ROSS, C.; JAYAKUMAR, S.; GUO, C.; BOUCHACOURT, D.; AL-TAHAN, H.; PADTHE, K.; SHARMA, V.; XU, H.; TAN, X. E.; RICHARDS, M.; LAVOIE, S.; ASTOLFI, P.; HEMMAT, R. A.; CHEN, J.; TIRUMALA, K.; ASSOUEL, R.; MOAYERI, M.; TALATTOF, A.; CHAUDHURI, K.; LIU, Z.; CHEN, X.; GARRIDO, Q.; ULLRICH, K.; AGRAWAL, A.; SAENKO, K.; CELIKYILMAZ, A.; CHANDRA, V. An introduction to vision-language modeling. *arXiv*, 2024. Disponível em: <<https://arxiv.org/abs/2405.17247>>. Acesso em: 18 nov. 2025.

BOUSSEN, S.; CORDIER, P.-Y.; MALET, A.; SIMEONE, P.; CATALDI, S.; VAISSE, C.; ROCHE, X.; CASTELLI, A.; ASSAL, M.; PEPIN, G. Triage and monitoring of covid-19 patients in intensive care using unsupervised machine learning. *Computers in Biology and Medicine*, Elsevier, v. 142, p. 105192, 2022.

CASELI, H. M.; NUNES, M. G. V. (Ed.). *Processamento de Linguagem Natural: Conceitos, Técnicas e Aplicações em Português*. 3. ed. BPLN, 2024. ISBN 978-65-01-20581-6. Disponível em: <<https://brasileiraspln.com/livro-pln/3a-edicao/>>. Acesso em: 18 nov. 2025.

COHEN, J. P.; MORRISON, P.; DAO, L.; ROTH, K.; DUONG, T. Q.; GHASSEMI, M. Covid-19 image data collection: Prospective predictions are the future. *arXiv 2006.11988*, 2020. Disponível em: <<https://github.com/ieee8023/covid-chestxray-dataset>>. Acesso em: 18 nov. 2025.

DEEPSEEK-AI; GUO, D.; YANG, D.; ZHANG, H.; SONG, J.; ZHANG, R.; XU, R.; ZHU, Q.; MA, S.; WANG, P.; BI, X.; ZHANG, X.; YU, X.; WU, Y.; WU, Z. F.; GOU, Z.; SHAO, Z.; LI, Z.; GAO, Z.; LIU, A.; XUE, B.; WANG, B.; WU, B.; FENG, B.; LU, C.; ZHAO, C.; DENG, C.; ZHANG, C.; RUAN, C.; DAI, D.; CHEN, D.; JI, D.; LI, E.; LIN, F.; DAI, F.; LUO, F.; HAO, G.; CHEN, G.; LI, G.; ZHANG, H.; BAO, H.; XU, H.; WANG, H.; DING, H.; XIN, H.; GAO, H.; QU, H.; LI, H.; GUO, J.; LI, J.; WANG, J.; CHEN, J.; YUAN, J.; QIU, J.; LI, J.; CAI, J. L.; NI, J.; LIANG, J.; CHEN, J.; DONG, K.; HU, K.; GAO, K.; GUAN, K.; HUANG, K.; YU, K.; WANG, L.; ZHANG, L.; ZHAO, L.; WANG, L.; ZHANG, L.; XU, L.; XIA, L.; ZHANG, M.; ZHANG, M.; TANG, M.; LI, M.; WANG, M.; LI, M.; TIAN, N.; HUANG, P.; ZHANG, P.; WANG, Q.; CHEN, Q.; DU, Q.; GE, R.; ZHANG, R.; PAN, R.; WANG, R.; CHEN, R. J.; JIN, R. L.; CHEN, R.; LU, S.; ZHOU, S.; CHEN, S.; YE, S.; WANG, S.; YU, S.; ZHOU, S.; PAN,

S.; LI, S. S.; ZHOU, S.; WU, S.; YE, S.; YUN, T.; PEI, T.; SUN, T.; WANG, T.; ZENG, W.; ZHAO, W.; LIU, W.; LIANG, W.; GAO, W.; YU, W.; ZHANG, W.; XIAO, W. L.; AN, W.; LIU, X.; WANG, X.; CHEN, X.; NIE, X.; CHENG, X.; LIU, X.; XIE, X.; LIU, X.; YANG, X.; LI, X.; SU, X.; LIN, X.; LI, X. Q.; JIN, X.; SHEN, X.; CHEN, X.; SUN, X.; WANG, X.; SONG, X.; ZHOU, X.; WANG, X.; SHAN, X.; LI, Y. K.; WANG, Y. Q.; WEI, Y. X.; ZHANG, Y.; XU, Y.; LI, Y.; ZHAO, Y.; SUN, Y.; WANG, Y.; YU, Y.; ZHANG, Y.; SHI, Y.; XIONG, Y.; HE, Y.; PIAO, Y.; WANG, Y.; TAN, Y.; MA, Y.; LIU, Y.; GUO, Y.; OU, Y.; WANG, Y.; GONG, Y.; ZOU, Y.; HE, Y.; XIONG, Y.; LUO, Y.; YOU, Y.; LIU, Y.; ZHOU, Y.; ZHU, Y. X.; XU, Y.; HUANG, Y.; LI, Y.; ZHENG, Y.; ZHU, Y.; MA, Y.; TANG, Y.; ZHA, Y.; YAN, Y.; REN, Z. Z.; REN, Z.; SHA, Z.; FU, Z.; XU, Z.; XIE, Z.; ZHANG, Z.; HAO, Z.; MA, Z.; YAN, Z.; WU, Z.; GU, Z.; ZHU, Z.; LIU, Z.; LI, Z.; XIE, Z.; SONG, Z.; PAN, Z.; HUANG, Z.; XU, Z.; ZHANG, Z.; ZHANG, Z. *DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning*. 2025. Disponível em: <<https://arxiv.org/abs/2501.12948>>. Acesso em: 18 nov. 2025.

DEVLIN, J.; CHANG, M.-W.; LEE, K.; TOUTANOVA, K. Bert: Pre-training of deep bidirectional transformers for language understanding. In: *Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers)*. [S.l.: s.n.], 2019. p. 4171–4186.

GONG, Y.; LIU, G.; XUE, Y.; LI, R.; MENG, L. A survey on dataset quality in machine learning. *Information and Software Technology*, Elsevier, v. 162, p. 107268, 2023.

GOOGLE. *MedGemma Hugging Face*. 2025. Disponível em: <<https://huggingface.co/collections/google/medgemma-release-680aade845f90bec6a3f60c4>>. Acesso em: 18 nov. 2025.

HEIDARI, A.; NAVIMIPOUR, N. J.; UNAL, M.; TOUMAJ, S. Machine learning applications for covid-19 outbreak management. *Neural Computing and Applications*, Springer, v. 34, n. 18, p. 15313–15348, 2022.

HU, E. J.; SHEN, Y.; WALLIS, P.; ALLEN-ZHU, Z.; LI, Y.; WANG, S.; WANG, L.; CHEN, W. *LoRA: Low-Rank Adaptation of Large Language Models*. 2021. Disponível em: <<https://arxiv.org/abs/2106.09685>>. Acesso em: 18 nov. 2025.

HUANG, C.; WANG, Y.; LI, X.; REN, L.; ZHAO, J.; HU, Y.; ZHANG, L.; FAN, G.; XU, J.; GU, X.; CHENG, Z.; YU, T.; XIA, J.; WEI, Y.; WU, W.; XIE, X.; YIN, W.; LI, H.; LIU, M.; XIAO, Y.; GAO, H.; GUO, L.; XIE, J.; WANG, G.; JIANG, R.; GAO ZHANCHENG AND JIN, Q.; WANG, J.; CAO, B. Clinical features of patients infected with 2019 novel coronavirus in wuhan, china. *Lancet*, Elsevier, v. 395, n. 10223, p. 497–506, 2023.

HUNG, I. F.-N.; LUNG, K.-C.; TSO, E. Y.-K.; LIU, R.; CHUNG, T. W.-H.; CHU, M.-Y.; NG, Y.-Y.; LO, J.; CHAN, J.; TAM, A. R.; SHUM, H.-P.; CHAN, V.; WU, A. K.-L.; SIN, K.-M.; LEUNG, W.-S.; LAW, W.-L.; LUNG, D. C.; SIN, S.; YEUNG, P.; YIP, C. C.-Y.; ZHANG, R. R.; FUNG, A. Y.-F.; YAN, E. Y.-W.; LEUNG, K.-H.; IP, J. D.; CHU, A. W.-H.; CHAN, W.-M.; NG, A. C.-K.; LEE, R.; FUNG, K.; YEUNG, A.; WU, T.-C.; CHAN, J. W.-M.; YAN, W.-W.; CHAN, W.-M.; CHAN, J. F.-W.; LIE, A. K.-W.; TSANG, O. T.-Y.; CHENG, V. C.-C.; QUE, T.-L.; LAU, C.-S.; CHAN, K.-H.; TO, K. K.-W.; YUEN, K.-Y. Triple combination of interferon beta-1b, lopinavir, ritonavir, and ribavirin in the treatment of patients admitted to hospital with covid-19: an open-label, randomised, phase 2 trial. *The Lancet*, Elsevier, v. 395, n. 10238, p. 1695–1704, May 2020. ISSN 0140-6736. Disponível em: <[https://doi.org/10.1016/S0140-6736\(20\)31042-4](https://doi.org/10.1016/S0140-6736(20)31042-4)>. Acesso em: 18 nov. 2025.

JIANG, S.; SHI, Z.-L. The first disease x is caused by a highly transmissible acute respiratory syndrome coronavirus. *Virologica Sinica*, Springer, v. 35, n. 3, p. 263–265, 2020.

KUDO, T.; RICHARDSON, J. Sentencepiece: A simple and language independent subword tokenizer and detokenizer for neural text processing. *arXiv preprint arXiv:1808.06226*, 2018.

LI, C.; CHEN, M.; WANG, J.; SITARAM, S.; XIE, X. Culturellm: Incorporating cultural differences into large language models. *Neural Information Processing Systems*, NeurIPS, 2024.

LI, C.; WONG, C.; ZHANG, S.; USUYAMA, N.; LIU, H.; YANG, J.; NAUMANN, T.; POON, H.; GAO, J. Llava-med: Training a large language-and-vision assistant for biomedicine in one day. *Neural Information Processing Systems*, NeurIPS, 2023.

LI, Z.; WU, X.; DU, H.; NGHIEM, H.; SHI, G. Benchmark evaluations, applications, and challenges of large vision language models: A survey. *arXiv preprint arXiv:2501.02189*, v. 1, 2025.

LIU, H.; LI, C.; WU, Q.; LEE, Y. J. *Visual Instruction Tuning*. 2023. Disponível em: <<https://arxiv.org/abs/2304.08485>>. Acesso em: 18 nov. 2025.

LUPTON, D.; WILLIS, K. *The COVID-19 crisis*. [S.l.]: Routledge, 2021.

MOOR, M.; BANERJEE, O.; ABAD, Z. S. H.; KRUMHOLZ, H. M.; LESKOVEC, J.; TOPOL, E. J.; RAJPURKAR, P. Foundation models for generalist medical artificial intelligence. *Nature*, Nature Publishing Group UK London, v. 616, n. 7956, p. 259–265, 2023.

MOOR, M.; HUANG, Q.; WU, S.; MICHIIHIRO, Y.; ZAKKA, C.; DALMIA, Y.; REIS, E. P.; RAJPURKAR, P.; LESKOVEC, J. Med-flamingo: a multimodal medical few-shot learner. *Proceedings of Machine Learning Research*, Proceedings of Machine Learning Research, v. 225, n. 2, p. 353–367, 2023.

NALBANDIAN, A.; DESAI, A. D.; WAN, E. Y. Post-covid-19 condition. *Annual Review of Medicine*, Annual Reviews, v. 74, n. 1, p. 55–64, 2023.

ORTEGA-MARTÍN, M.; GARCÍA-SIERRA, Ó.; ARDOIZ, A.; ÁLVAREZ, J.; ARMENTEROS, J. C.; ALONSO, A. Linguistic ambiguity analysis in chatgpt. *arXiv preprint arXiv:2302.06426*, 2023.

PARTHASARATHY, V. B.; ZAFAR, A.; KHAN, A.; SHAHID, A. *The Ultimate Guide to Fine-Tuning LLMs from Basics to Breakthroughs: An Exhaustive Review of Technologies, Research, Best Practices, Applied Research Challenges and Opportunities*. 2024. Disponível em: <<https://arxiv.org/abs/2408.13296>>. Acesso em: 18 nov. 2025.

RADFORD, A.; KIM, J. W.; HALLACY, C.; RAMESH, A.; GOH, G.; AGARWAL, S.; SASTRY, G.; ASKELL, A.; MISHKIN, P.; CLARK, J.; KRUEGER, G.; SUTSKEVER, I. Learning transferable visual models from natural language supervision. In: MEILA, M.; ZHANG, T. (Ed.). *Proceedings of the 38th International Conference on Machine Learning*. PMLR, 2021. (Proceedings of Machine Learning Research, v. 139), p. 8748–8763. Disponível em: <<https://proceedings.mlr.press/v139/radford21a.html>>. Acesso em: 18 nov. 2025.

SAMUEL, A. L. Some studies in machine learning using the game of checkers. *IBM Journal of Research and Development*, v. 3, n. 3, p. 210–229, 1959.

- SAMUEL, A. L. Some studies in machine learning using the game of checkers. *IBM Journal of research and development*, p. 210–229, 1959.
- SHENG, E.; CHANG, K.-W.; NATARAJAN, P.; PENG, N. The woman worked as a babysitter: On biases in language generation. In: INUI, K.; JIANG, J.; NG, V.; WAN, X. (Ed.). *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*. Hong Kong, China: Association for Computational Linguistics, 2019. p. 3407–3412. Disponível em: <<https://aclanthology.org/D19-1339/>>. Acesso em: 18 nov. 2025.
- SHI, Y.; WANG, G.; CAI, X.-p.; DENG, J.-w.; ZHENG, L.; ZHU, H.-h.; ZHENG, M.; YANG, B.; CHEN, Z. An overview of covid-19. *Journal of Zhejiang University-SCIENCE B*, Springer, v. 21, n. 5, p. 343–360, 2020.
- SHOHAM, O. B.; RAPPOPORT, N. Cpllm: Clinical prediction with large language models. *PLOS Digital Health*, Public Library of Science, v. 3, n. 12, p. 1–15, 12 2024. Disponível em: <<https://doi.org/10.1371/journal.pdig.0000680>>. Acesso em: 18 nov. 2025.
- SINGHAL, K.; AZIZI, S.; TU, T.; MAHDAVI, S. S.; WEI, J.; CHUNG, H. W.; SCALES, N.; TANWANI, A.; COLE-LEWIS, H.; PFOHL, S. et al. Large language models encode clinical knowledge. *Nature*, Nature Publishing Group, v. 620, n. 7972, p. 172–180, 2023.
- SOARES, E.; ANGELOV, P.; BIASO, S.; FROES, M. H.; ABE, D. K. Sars-cov-2 ct-scan dataset: A large dataset of real patients ct scans for sars-cov-2 identification. *MedRxiv*, Cold Spring Harbor Laboratory Press, p. 2020–04, 2020.
- SOUSA, V. L. d.; OLIVEIRA, R. d. M. e. Os impactos da lei geral de proteção de dados (lgpd) no sistema de saúde brasileiro. *Revista JRG de Estudos Acadêmicos*, v. 7, n. 14, p. e141129, maio 2024. Disponível em: <<http://www.revistajrg.com/index.php/jrg/article/view/1129>>. Acesso em: 18 nov. 2025.
- TEAM, Q. Qwen2.5-VL. 2025. Disponível em: <<https://qwenlm.github.io/blog/qwen2.5-vl/>>. Acesso em: 18 nov. 2025.
- TIU, E.; TALUIS, E.; PATEL, P.; LANGLOTZ, C. P.; NG, A. Y.; RAJPURKAR, P. Expert-level detection of pathologies from unannotated chest x-ray images via self-supervised learning. *Nature Biomedical Engineering*, Nature, v. 6, n. 12, p. 1399–1406, 2022.
- TOUVRON, H.; LAVRIL, T.; IZACARD, G.; MARTINET, X.; LACHAUX, M.-A.; LACROIX, T.; ROZIÈRE, B.; GOYAL, N.; HAMBRO, E.; AZHAR, F.; RODRIGUEZ, A.; JOULIN, A.; GRAVE, E.; LAMPLE, G. LLaMA: Open and Efficient Foundation Language Models. 2023. Disponível em: <<https://arxiv.org/abs/2302.13971>>. Acesso em: 18 nov. 2025.
- TURING, A. M. Computing machinery and intelligence. *Springer Netherlands*, p. 23–65, 2009.
- VASWANI, A.; SHAZEER, N.; PARMAR, N.; USZKOREIT, J.; JONES, L.; GOMEZ, A. N.; KAISER, Ł.; POLOSUKHIN, I. Attention is all you need. *Advances in neural information processing systems*, v. 30, 2017.
- YAN, K.; LI, T.; MARQUES, J. A. L.; GAO, J.; FONG, S. J. A review on multimodal machine learning in medical diagnostics. *Math. Biosci. Eng.*, v. 20, n. 5, p. 8708–8726, 2023.

YANG, W.; SIRAJUDDIN, A.; ZHANG, X.; LIU, G.; TENG, Z.; ZHAO, S.; LU, M. The role of imaging in 2019 novel coronavirus pneumonia (covid-19). *European radiology*, Springer, v. 30, n. 9, p. 4874–4882, 2020.

YU, X.; ZHANG, Z.; NIU, F.; HU, X.; XIA, X.; GRUNDY, J. What makes a high-quality training dataset for large language models: A practitioners' perspective. In: *Proceedings of the 39th IEEE/ACM International Conference on Automated Software Engineering*. New York, NY, USA: Association for Computing Machinery, 2024. (ASE '24), p. 656–668. ISBN 9798400712487. Disponível em: <<https://doi.org/10.1145/3691620.3695061>>. Acesso em: 18 nov. 2025.

ZHANG, P.; WEI, Z.; CHE, C.; JIN, B. Deepmgt-dti: Transformer network incorporating multilayer graph information for drug–target interaction prediction. *Computers in biology and medicine*, Elsevier, v. 142, p. 105214, 2022.

ZHOU, S.; XU, Z.; ZHANG, M.; XU, C.; GUO, Y.; ZHAN, Z.; FANG, Y.; DING, S.; WANG, J.; XU, K.; XIA, L.; YEUNG, J.; ZHA, D.; CAI, D.; MELTON, G. B.; LIN, M.; ZHANG, R. Large language models for disease diagnosis: a scoping review. *npj Artificial Intelligence*, v. 1, n. 1, p. 9, Jun 2025. ISSN 3005-1460. Disponível em: <<https://doi.org/10.1038/s44387-025-00011-z>>. Acesso em: 18 nov. 2025.

ZOUHAR, V.; MEISTER, C.; GASTALDI, J. L.; DU, L.; VIEIRA, T.; SACHAN, M.; COTTERELL, R. A formal perspective on byte-pair encoding. *arXiv preprint arXiv:2306.16837*, 2023.