

UNIVERSIDADE ESTADUAL PAULISTA "JÚLIO DE MESQUITA FILHO"

FACULDADE DE CIÊNCIAS - CAMPUS BAURU

DEPARTAMENTO DE COMPUTAÇÃO

BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

JOÃO LUCAS CARDOSO CRIVELI

**APLICAÇÃO DE DADOS GEOESPACIAIS NA ANÁLISE DE RISCO
E SUPORTE À CONTRATAÇÃO DE SEGURO AGRÍCOLA**

BAURU

Novembro/2025

JOÃO LUCAS CARDOSO CRIVELI

APLICAÇÃO DE DADOS GEOESPACIAIS NA ANÁLISE DE RISCO E SUPORTE À CONTRATAÇÃO DE SEGURO AGRÍCOLA

Trabalho de Conclusão de Curso do Curso
de Bacharelado em Ciência da Computação
da Universidade Estadual Paulista “Júlio
de Mesquita Filho”, Faculdade de Ciências,
Campus Bauru.

Orientador: Prof. Dr. Clayton Reginaldo Pereira

BAURU

Novembro/2025

João Lucas Cardoso Criveli Aplicação de dados geoespaciais na análise de risco e suporte à contratação de seguro agrícola/ João Lucas Cardoso Criveli. – Bauru, Novembro/2025- 58 p. : il. (algumas color.) ; 30 cm.

Orientador: Prof. Dr. Clayton Reginaldo Pereira

Trabalho de Conclusão de Curso – Universidade Estadual Paulista “Júlio de Mesquita Filho”

Faculdade de Ciências

Bacharelado em Ciência da Computação, Novembro/2025.

1. Seguro Agrícola 2. Análise de risco 3. Inteligência Artificial 4. Banco de dados espacial 5. Aplicação Web

João Lucas Cardoso Criveli

Aplicação de dados geoespaciais na análise de risco e suporte à contratação de seguro agrícola

Trabalho de Conclusão de Curso do Curso de Bacharelado em Ciência da Computação da Universidade Estadual Paulista "Júlio de Mesquita Filho", Faculdade de Ciências, Campus Bauru.

Banca Examinadora

Prof. Dr. Clayton Reginaldo Pereira

Orientador

Departamento de Computação

Faculdade de Ciências

Universidade Estadual Paulista "Júlio de Mesquita Filho"

Profa. Dra. Simone das Graças Domingues Prado

Departamento de Computação

Faculdade de Ciências

Universidade Estadual Paulista "Júlio de Mesquita Filho"

Prof. Dr. Douglas Rodrigues

Departamento de Computação

Faculdade de Ciências

Universidade Estadual Paulista "Júlio de Mesquita Filho"

Bauru, 12 de novembro de 2025.

Aos meus pais, amigos, e a toda minha família que, com muito carinho e apoio, não mediram esforços para que eu chegasse até esta etapa de minha vida.

Agradecimentos

Quero começar agradecendo a Deus, por permitir que eu tivesse forças e condições para chegar até esse momento da vida, me mantendo no caminho correto para a realização de um sonho. Em seguida, agradeço ao meu pai e minha mãe, as pessoas que mais confiam no meu potencial, e estiveram ao meu lado sempre, não medindo esforços para que eu tivesse tudo o que precisava durante minha graduação. Agradeço ao meu orientador, Clayton, que não foi apenas um orientador, mas um parceiro de vida, que me deu diversas lições e proporcionou vários momentos felizes durante a graduação. Finalizo agradecendo aos amigos que fiz durante a faculdade, em especial aos do grupo "Clayton & Cia", por serem pessoas sensacionais, que se tornaram minha segunda família, e também estão ao meu lado nessa finalização. Obrigado a todos os envolvidos!

A tecnologia não é nada. O que é importante é que você tenha fé nas pessoas, que elas sejam basicamente boas e inteligentes, e se você lhes der ferramentas, elas farão coisas maravilhosas com elas.

Steve Jobs

Resumo

A agricultura é, e por muito tempo será, um meio primordial para que o ser humano consiga produzir insumos, fornecer alimentos e dar uso ao solo que habita. Dada essa importância, o setor agrícola busca diversos meios para garantir sua produção esperada, sendo um deles o seguro agrícola - modalidade de proteção financeira que estabelece acordos entre produtores rurais e seguradoras para garantir cobertura de ao menos parte da produção agrícola em caso de sinistros. Para viabilizar esses acordos, surge a figura da corretora de seguros, que conecta o produtor rural às seguradoras, e, neste processo, assume uma tarefa desafiadora: a avaliação de riscos para subsidiar a tomada de decisão das seguradoras. São diversos os fatores que o corretor deve analisar antes de enviar seu parecer, desde riscos que a localização da propriedade do produtor pode oferecer até as pendências fiscais que o interessado pelo seguro pode vir a ter. O processo torna-se particularmente desafiador quando cada verificação deve ser realizada em plataformas distintas e descentralizadas: websites governamentais, sistemas de análise de portarias, softwares especializados e bases de dados diversas. Com o propósito de otimizar e centralizar o processo de análise de risco, este projeto teve como objetivo desenvolver uma aplicação web que unifica todas as verificações necessárias em uma única plataforma. O desenvolvimento contou com o suporte de uma corretora de seguros parceira, que auxiliou revelando a rotina operacional, destacando dificuldades nos processos requeridos em uma análise de risco e providenciando dados para o treinamento de modelos de inteligência artificial. Ao final do desenvolvimento, esses objetivos foram atendidos e a ferramenta conseguiu reduzir para menos de 20 segundos o tempo necessário para se ter uma análise de risco completa. Esta otimização não apenas tornou o trabalho das corretoras mais eficiente e preciso, mas também contribuiu para facilitar o acesso dos produtores rurais ao seguro agrícola, promovendo maior segurança e sustentabilidade no setor.

Palavras-chave: Seguro Agrícola, Análise de risco, Inteligência Artificial, Banco de dados espacial, Aplicação Web.

Abstract

Agriculture is, and for a long time will be, a fundamental means for humans to produce inputs, provide food, and make use of the land they inhabit. Given its importance, the agricultural sector seeks various ways to ensure its expected production, one of which is agricultural insurance - a financial protection modality that establishes agreements between rural producers and insurance companies to guarantee coverage for at least part of the agricultural production in the event of claims. To facilitate these agreements, the role of the insurance broker emerges, connecting the rural producer to the insurers, and in this process, assuming a challenging task: risk assessment to subsidize the insurers' decision-making. There are several factors that the broker must analyze before submitting their opinion, ranging from risks that the location of the producer's property may offer, to potential tax liabilities that the interested party in the insurance might have. The process becomes particularly challenging when each verification must be performed on different and decentralized platforms: government websites, regulatory analysis systems, specialized software, and various databases. With the purpose of optimizing and centralizing the risk analysis process, this project aimed to develop a web application that unifies all the necessary verifications into a single platform. The development was supported by a partner insurance broker, which helped reveal the operational routine, highlighted difficulties in the processes required for risk analysis, and provided data for training artificial intelligence models. At the end of the development, these objectives were met, and the tool managed to reduce the time required to complete a full risk analysis to less than 20 seconds. This optimization not only made the brokers' work more efficient and precise but also helped to facilitate rural producers' access to agricultural insurance, promoting greater security and sustainability in the sector.

Keywords: Agricultural Insurance, Risk Analysis, Artificial Intelligence, Spatial Database, Web Application.

Lista de figuras

Figura 1 – Visão geral da análise de risco para seguro agrícola	18
Figura 2 – Visualização do NDVI sob área agrícola	23
Figura 3 – Exemplo de distância entre shapelet e série temporal	27
Figura 4 – Exemplo de árvore de decisão utilizando shapelets	28
Figura 5 – Estrutura da requisição á API de Consulta CND	33
Figura 6 – Processo de extração do NDVI	35
Figura 7 – Série temporal de NDVI	35
Figura 8 – Shapelet discriminativo da classe 0	37
Figura 9 – Shapelet discriminativo da classe 1	38
Figura 10 – Diagrama Entidade-Relacionamento simplificado do banco de dados.	42
Figura 11 – Fluxograma da comunicação entre Frontend, Backend e MQTT Broker	43
Figura 12 – Tela de Login	45
Figura 13 – Tela de Histórico de Análises	45
Figura 14 – Exemplo de Registro de Análise na Tela de Histórico	46
Figura 15 – Diálogo de Resultado da análise	46
Figura 16 – Resultado da Interação entre Frontend e Backend	47
Figura 17 – Diálogo para Nova Análise	48
Figura 18 – Seção de Clientes	49
Figura 19 – Diálogo de Clientes	49
Figura 20 – Tempo de execução das análises de risco	51
Figura 21 – Matriz de confusão do modelo de classificação de séries temporais	52
Figura 22 – Exemplo de amostra mal classificada pelo modelo	53

Lista de tabelas

Tabela 1 – Classes de Água Disponível (AD)	20
Tabela 2 – Endpoints da API	41
Tabela 3 – Entidades do Sistema	42

Lista de abreviaturas e siglas

AD	Água Disponível
API	Application Programming Interface
Cadin	Cadastro Informativo de Créditos não Quitados do Setor Público Federal
CND	Certidão Negativa de Débitos
DTW	Dynamic Time Warping
EMBRAPA	Empresa Brasileira de Pesquisa Agropecuária
FUNAI	Fundação Nacional dos Povos Indígenas
GEE	Google Earth Engine
HTTP	Hypertext Transfer Protocol
IBAMA	Instituto Brasileiro do Meio Ambiente e dos Recursos Naturais Renováveis
IBGE	Instituto Brasileiro de Geografia e Estatística
ICMBio	Instituto Chico Mendes de Conservação da Biodiversidade
IPHAN	Instituto do Patrimônio Histórico e Artístico Nacional
MAPA	Ministério da Agricultura e Pecuária
MMA	Ministério do Meio Ambiente
MQTT	Message Queuing Telemetry Transport
NDVI	Índice de Vegetação por Diferença Normalizada
ONG	Órgão Não Governamental
Proagro	Programa de Garantia da Atividade Agropecuária
SGBD	Sistema de Gerenciamento de Banco de Dados
Serpro	Serviço Federal de Processamento de Dados
SITS	Série Temporal de Imagens de Satélite
SQL	Structured Query Language
ZARC	Zoneamento Agrícola de Risco Climático

Sumário

1	INTRODUÇÃO	14
1.1	Problemática	15
1.2	Justificativa	15
1.3	Objetivos	16
1.3.1	Objetivo Geral	16
1.3.2	Objetivos Específicos	16
2	FUNDAMENTAÇÃO TEÓRICA	17
2.1	Seguro agrícola no Brasil e no mundo	17
2.2	Análise de risco na agricultura	18
2.2.1	Análise do local de plantio	18
2.2.2	Análise da adimplência fiscal do produtor	19
2.2.3	Análise do tipo de solo	19
2.2.4	Análise da semente	20
2.2.5	Análise do histórico de plantio	21
2.3	Índice de Vegetação por Diferença Normalizada	22
2.4	Bancos de Dados Espaciais	23
2.5	Séries Temporais	24
2.5.1	Definição de Série Temporal	24
2.5.2	Série Temporal de Imagens de Satélite	24
2.6	Classificação de Séries Temporais	25
3	MATERIAIS E MÉTODOS	29
3.1	Tecnologias utilizadas para as análises	29
3.2	Desenvolvimento das análises	29
3.2.1	Análise do local de plantio	29
3.2.1.1	Verificação de município	29
3.2.1.2	Verificação das áreas de embargo	30
3.2.2	Análise do tipo de solo	31
3.2.3	Análise da adimplência fiscal do produtor	32
3.2.4	Análise do histórico de plantio	32
3.2.4.1	Construção do conjunto de dados	32
3.2.4.2	Treinamento do modelo	36
3.2.5	Análise da Semente	39
3.3	Desenvolvimento da aplicação	40
3.3.1	Visão Geral	40

3.3.2	<i>Frontend</i>	40
3.3.3	<i>Backend</i>	40
3.3.3.1	Principais Tecnologias Utilizadas	40
3.3.3.2	Endpoints	41
3.3.4	Banco de Dados	41
3.3.4.1	Modelagem do Banco de Dados	41
3.3.5	Comunicação	42
3.3.6	Seções	44
4	ANÁLISE DE RESULTADOS	50
4.1	Análise de Desempenho Geral da Aplicação	50
4.2	Análise do Modelo de Classificação de Série Temporal	51
5	CONCLUSÃO	54
5.1	Trabalhos Futuros	54
	REFERÊNCIAS	56

1 Introdução

A agricultura, além de atividade econômica, é o alicerce da civilização humana. Desde os primórdios, a sobrevivência e o desenvolvimento das sociedades estiveram ligados à capacidade de cultivar a terra e produzir alimentos. Essa relação de dependência mútua moldou culturas, economias e o próprio crescimento populacional do planeta, consolidando a produção agrícola como a base fundamental para a segurança alimentar global. Analisando o cenário global atual, o Brasil emerge como um protagonista incontestável, um dos maiores celeiros do mundo. Com sua vasta extensão territorial e tecnologias avançadas, o país se consolidou como um provedor essencial para a estabilidade do abastecimento mundial.

Projeções do setor mostram que o papel do Brasil na alimentação do mundo é crucial. Somente a análise comparativa entre os anos 2020-21 e as projeções para 2030-31, realizada por [Gasques et al. \(2021\)](#), informa uma expectativa de crescimento da produção de grãos de 27,1% em uma década, para suprir a demanda global por alimentos e evitar crises de fome e tensões geopolíticas. É evidente, portanto, que a estabilidade da produção agrícola brasileira é de interesse não apenas nacional, mas de todo o planeta.

Apesar de sua importância, a agricultura é uma atividade de alto risco, sujeita a variáveis incontornáveis como pragas, doenças e eventos climáticos extremos. Essa vulnerabilidade coloca os produtores em uma situação de constante incerteza, afetando seus meios de subsistência e a segurança alimentar global. É nesse contexto de busca pela mitigação de riscos e pela garantia da segurança da produção que o seguro agrícola ganha destaque. Como citado em [Porth e Tan \(2015\)](#), essa ferramenta financeira oferece um mecanismo de proteção, compensando os prejuízos do agricultor em caso de sinistros e incentivando a produtividade, estabelecendo-se como um pilar de estabilidade para a cadeia produtiva.

Para facilitar a conexão entre produtores rurais e seguradoras, surge o papel do corretor de seguros, um intermediário entre as duas partes do contrato de seguro. É nesse processo de conexão, antes do seguro ser efetivado, o corretor precisa assumir um importante papel: fazer a análise de risco. Entende-se risco como a chance de algo indesejado ocorrer a alguém. O seguro agrícola oferece uma segurança ao produtor em relação a fatores externos, permitindo que ele tome riscos que, sem este apoio, não seriam tomados ([WÜRCH, 2022](#)). Para que esse acordo seja viável, as seguradoras precisam mensurar qual é o tamanho do risco que assumem ao assegurarem uma produção, tendo em vista que os possíveis prejuízos desse risco não mais recaem sobre apenas um indivíduo, mas agora são diluídos sobre diversos indivíduos.

1.1 Problemática

Uma análise de risco completa consiste nas 5 seguintes análises: análise do local de plantio, análise da adimplência fiscal do produtor, análise do tipo de solo da área de plantio, análise da semente que será utilizada na safra e análise do histórico de plantio daquela área. Cada uma dessas análises é feita em uma ferramenta diferente: websites governamentais, consultas em bases de dados públicas, softwares do tipo GIS (*Geographic Information System*), e outros softwares especializados. A execução dessas análises em locais diferentes faz com que o corretor de seguros gaste mais tempo, pois não consegue reaproveitar informações já preenchidas em outros locais.

A falta de unificação dessas análises também causa uma dificuldade para reuni-las e comprovar para a seguradora e para o produtor o parecer final da corretora, sendo necessário criar documentações muitas vezes sem padrões, onde os resultados individuais das análises são reunidos.

Uma outra problemática surge ao ponderar-se a crescente sofisticação das análises de risco no setor. Conforme evidenciado no estudo "Mapping global research on agricultural insurance", por [Vyas et al. \(2021\)](#), a área de seguros agrícolas enfrentará desafios cada vez mais complexos, especialmente em relação aos impactos das mudanças climáticas e à necessidade de avaliar culturas além dos tradicionais grãos e cereais. A ausência de uma plataforma integrada atualmente pode gerar obstáculos ainda maiores no futuro, quando as análises de risco exigirem a incorporação de um número crescente de variáveis e fontes de dados.

1.2 Justificativa

A presente pesquisa se justifica pela relevância de solucionar um problema concreto no mercado de seguros agrícolas, impactando diretamente a eficiência operacional e a competitividade de corretoras especializadas. Atualmente, a análise de risco onera as empresas, que alocam profissionais qualificados para verificações manuais e repetitivas em plataformas distintas.

Do ponto de vista econômico, a solução proposta mostra grande potencial de redução de tempo e custos para a realização das análises, traduzindo-se em maior agilidade na contratação de apólices e menor custo com mão de obra especializada. Para um mercado em crescimento constante no Brasil, impulsionado por programas como o Seguro Rural e a maior conscientização dos produtores sobre gestão de riscos, essa eficiência pode gerar uma vantagem competitiva para as corretoras que a adotarem.

Tecnicamente, a pesquisa contribui para o avanço de aplicações no agronegócio, demonstrando como a integração de sistemas de informação geográfica, sensoriamento remoto e bancos de dados governamentais pode resolver um problema complexo do setor de seguros.

Há também o desafio da criação de uma aplicação que suporte todos os diferentes tipos de tecnologia necessários para a realização das análises de riscos e também estabeleça bases concretas para que a adição de novas análises seja facilitada.

1.3 Objetivos

1.3.1 Objetivo Geral

O objetivo geral desse trabalho é construir uma aplicação que reúna todas as análises de risco em uma só plataforma, permitindo que as corretoras gastem menos tempo nessa etapa do processo do seguro agrícola e possam padronizar o modo como a análise é feita. Ao final do projeto, a ideia é reduzir drasticamente o esforço necessário para a realização dessa tarefa, mantendo a mesma qualidade e confiabilidade das análises.

1.3.2 Objetivos Específicos

- Explorar diferentes tecnologias que sejam capazes de realizar as análises de risco de forma confiável.
- Construção de uma aplicação completa, com interface amigável e gestão de informações eficiente.
- Integrar tarefas operacionais de uma corretora de seguros em uma única plataforma.
- Preparar um sistema capaz de receber atualizações constantes sem trabalho despendioso, através de componentizações e boas práticas de código.

2 Fundamentação Teórica

Este capítulo apresenta os conceitos fundamentais que embasam o desenvolvimento deste trabalho, fornecendo o referencial teórico necessário para a compreensão dos principais temas abordados na pesquisa.

2.1 Seguro agrícola no Brasil e no mundo

O seguro agrícola é um dos principais mecanismos de proteção contra as incertezas inerentes à produção rural, atuando como instrumento de mitigação de riscos e garantindo maior estabilidade econômica para produtores e instituições financeiras. No cenário internacional, países como Estados Unidos, Espanha e Japão já consolidaram modelos robustos de seguro agrícola, com forte participação governamental no subsídio dos prêmios ([GLAUBER, 2015](#)). Esses sistemas buscam equilibrar o alto custo da cobertura com a necessidade de difusão da proteção entre agricultores de diferentes portes.

Em termos globais, o mercado de seguros agrícolas demonstra um crescimento consistente, impulsionado pela intensificação dos eventos climáticos extremos e pela adoção de tecnologias como seguros baseados em índices. Em 2024, o valor do mercado foi estimado em aproximadamente USD 38,86 bilhões, com projeções de expansão para USD 51,37 bilhões até 2033, registrando uma taxa composta anual de crescimento de cerca de 3,2%, como mostrado em [Rai \(2025\)](#).

No Brasil, o desenvolvimento do seguro agrícola ocorreu de forma mais tardia, sendo impulsionado principalmente por políticas públicas implementadas a partir dos anos 2000, como o Programa de Subvenção ao Prêmio do Seguro Rural e o Programa de Garantia da Atividade Agropecuária (Proagro). Comparado ao mercado global, o mercado brasileiro passa por uma contração significativa na cobertura, com a área segurada caindo de 13,6 milhões de hectares em 2021 para pouco mais de 6,2 milhões em 2023, devido a cortes orçamentários no PSR que congelaram R\$ 445 milhões em 2025 ([WALENDORFF, 2025](#)). Essa redução representa o menor nível de cobertura em sete anos, deixando cerca de 90% dos produtores rurais sem proteção adequada contra riscos climáticos e operacionais.

Apesar da dependência de subsídios governamentais e da necessidade de maior inclusão de pequenos produtores, o mercado de seguros agrícolas no Brasil apresenta potencial de crescimento substancial, especialmente considerando a expansão do agronegócio, que cresceu 10,1% no segundo trimestre de 2025 em comparação ao período anterior ([GOVERNO FEDERAL, 2025a](#)). Medidas recentes, como propostas para tornar o seguro obrigatório para financiamentos rurais, podem mitigar esses obstáculos e elevar a penetração para níveis próximos aos de


economias desenvolvidas, promovendo maior resiliência no setor agropecuário.

2.2 Análise de risco na agricultura

A análise de risco na agricultura constitui um processo essencial para identificar, avaliar e mitigar as incertezas inerentes à produção rural, abrangendo fatores climáticos, biológicos, econômicos e operacionais. No contexto do seguro agrícola, essa análise é fundamental para determinar a viabilidade de uma apólice, garantindo que as seguradoras possam equilibrar o portfólio e minimizar perdas catastróficas, como as decorrentes de estiagens ou inundações.

As condições gerais de uma apólice de seguro agrícola, como as estabelecidas pela Sompó Seguros, enfatizam que a aceitação da proposta está sujeita à análise do risco, excluindo coberturas para eventos como guerras, rebeliões, contaminação radioativa e falhas de manejo, que representam riscos não seguráveis. Dentre os riscos descritos, este trabalho foca em cinco avaliações específicas: local de plantio, adimplência fiscal do produtor, tipo de solo, tipo de semente utilizada e histórico de cultivo da terra. A figura 1 exibe uma visão geral de quais são as análises de risco e os pontos importantes de cada uma.

Figura 1 – Visão geral da análise de risco para seguro agrícola



Fonte: Elaborada pelo autor

2.2.1 Análise do local de plantio

Esta análise considera fatores geográficos e climáticos para avaliar a suscetibilidade a eventos adversos, a coerência com o local declarado na proposta do seguro, e os impactos sociais e ecológicos que a formação de uma cultura agrícola naquele local pode ocasionar.

Para o primeiro passo desta análise, é preciso verificar se a localização da área não causa nenhum impacto social ou ecológico negativo. Em outros termos, a área não pode estar

localizada em nenhuma área de embargo federal ou estadual. Define-se área de embargo como áreas protegidas por fundações, órgãos governamentais ou ONGs (Órgãos Não Governamentais), onde não se pode realizar o cultivo de nenhuma cultura.

Também é necessária a conferência do município informado na proposta do seguro. A localização da área tem impacto direto na avaliação do risco, devido a fatores como diferentes aspectos climáticos e apoio econômico estatal oferecido ao produtor nos estados brasileiros. Outra verificação necessária é conferir se a área do produtor está localizada totalmente dentro da área do município informado, ou se está em uma área de divisa de municípios, o que pode acarretar alterações na precificação do seguro.

2.2.2 Análise da adimplência fiscal do produtor

Verifica se a pessoa física ou jurídica ligada à apólice do seguro não possui inadimplência no Cadastro Informativo de créditos não quitados do setor público federal (Cadin), em decorrência do disposto no artigo 6º da Lei 10.522, de 19 de julho de 2002 ([LEI... 2002](#)). Essa verificação é essencial para garantir a regularidade fiscal do proponente, mitigando riscos associados a obrigações não cumpridas com o setor público federal e assegurando a conformidade com as normas regulatórias aplicáveis ao setor de seguros agrícolas.

O Cadin constitui um banco de dados administrado pela Procuradoria-Geral da Fazenda Nacional, no qual são registrados os nomes de pessoas físicas e jurídicas que apresentam débitos vencidos e não pagos perante órgãos e entidades da administração pública federal ([GOVERNO FEDERAL, 2025b](#)). Criado com o objetivo de promover a transparência e o controle de créditos públicos, o Cadin facilita a identificação de inadimplentes, impedindo que esses participem de certas transações com o governo, como a obtenção de financiamentos, certificações ou contratos públicos. Essa ferramenta é regulamentada pela Lei nº 10.522/2002, cujo artigo 6º estabelece as diretrizes para a comunicação e o registro de pendências, reforçando a necessidade de verificação prévia em contextos como a subscrição de apólices de seguro, a fim de evitar exposições a riscos financeiros ou jurídicos.

2.2.3 Análise do tipo de solo

O tipo de solo é um fator determinante para a viabilidade da apólice de seguro. A Instrução Normativa SPA/MAPA nº 1, de 21 de junho de 2022, publicada no Diário Oficial da União em 22 de junho de 2022 ([AGRICULTURA, 2022](#)), estabelece o método oficial para a classificação do solo em função da sua Água Disponível (AD) no contexto do Zoneamento Agrícola de Risco Climático (ZARC). O conceito de Água Disponível é fundamental, pois expressa a quantidade de água que o solo é capaz de armazenar e disponibilizar às plantas, influenciando diretamente o risco climático associado às diferentes culturas agrícolas.

De acordo com a normativa, a classificação é realizada a partir da composição gra-

nulométrica do solo (proporção de areia, silte e argila) em amostras coletadas até 40 cm de profundidade. Com base nesses dados, o solo é enquadrado em classes de AD, expressas em milímetros de água por centímetro de solo (mm/cm). A tabela 1 apresenta os intervalos estabelecidos.

Tabela 1 – Classes de Água Disponível (AD)

Classe	Intervalo de AD (mm/cm)
AD1	0,34 – 0,45
AD2	0,46 – 0,60
AD3	0,61 – 0,79
AD4	0,80 – 1,05
AD5	1,06 – 1,39
AD6	≥ 1,40

Fonte: Instrução Normativa SPA/MAPA nº 1, de 21 de junho de 2022.

Na prática, a capacidade de retenção de água depende diretamente da textura do solo, isto é, da proporção entre partículas de diferentes tamanhos. Solos arenosos, caracterizados por partículas maiores (diâmetro entre 2,0 e 0,05 mm), possuem elevada macroporosidade, permitindo rápida infiltração e drenagem, mas baixa retenção de água disponível para as plantas. Em contraste, os solos argilosos, formados por partículas muito finas (diâmetro < 0,002 mm), apresentam alta capacidade de retenção de água, embora parte dessa água fique fortemente retida e não esteja disponível para o uso pelas raízes. Já os solos de textura média (franco-arenosos ou franco-argilosos) tendem a apresentar condições mais equilibradas, sendo considerados ideais para muitas culturas.

Essa diferenciação é relevante para o ZARC, pois a mesma quantidade de chuva pode ter efeitos muito distintos em regiões com solos de texturas diferentes. Enquanto em solos arenosos há maior risco de déficit hídrico devido à rápida perda de água, em solos argilosos há maior capacidade de armazenamento, reduzindo a vulnerabilidade da lavoura em períodos de estiagem.

No cenário atual do seguro agrícola no Brasil, cada seguradora possui as próprias regras de aceitação de tipos de solo. A seguradora Sompo Seguros, por exemplo, revelou, através de troca de *e-mails* com o autor, que, para a safra 2025/2026, solos do tipo AD1, AD2 e AD6 não serão aceitos.

2.2.4 Análise da semente

No momento da criação da proposta do seguro, o produtor informa quais sementes serão utilizadas no próximo período de plantio. É necessário realizar uma verificação para garantir que essas espécies seguem recomendações técnicas oficiais, no que se refere à quantidade, qualidade, variedade e sanidade, do MAPA ou da própria seguradora.

A homologação de sementes pelo MAPA é regulada pelo Sistema Nacional de Sementes e Mudas, instituído pela Lei nº 10.711/2003 ([BRASIL, 2003](#)), que estabelece normas para a produção, comercialização e utilização de sementes e mudas em todo o território nacional. O processo inicia-se com o registro do produtor no Registro Nacional de Sementes e Mudas, seguido pela inscrição do campo de produção no Sistema de Gestão da Fiscalização, onde o produtor autodeclara a conformidade com os requisitos legais. Para a qualidade, as sementes devem ser acompanhadas de documentos como Certificado de Sementes ou Termo de Conformidade, que atestam pureza, germinação e ausência de impurezas; quanto à variedade, elas devem pertencer a cultivares registradas no Registro Nacional de Cultivares, garantindo adaptação regional e produtividade; a sanidade é avaliada por meio de vistorias pré-colheita para detectar pragas ou doenças; e a quantidade é declarada em termos de área plantada e produção estimada, compatível com o potencial da cultivar. Após a inscrição, o MAPA pode realizar vistorias para aprovação ou reprovação, com o status "Inscrito" equivalente à homologação anterior, o que facilita o acesso a seguros agrícolas ao demonstrar compliance regulatório.

2.2.5 Análise do histórico de plantio

A análise do histórico de plantio da área envolve a revisão detalhada de ciclos produtivos anteriores, com o objetivo de confirmar que a cultura agrícola proposta não foi implementada em áreas classificadas como de primeiro ou segundo ano de plantio após a conversão de cerrado, mata nativa, mata ou pastagem. Essa verificação é crucial no processo de subscrição de apólices de seguro agrícola, pois busca mitigar exposições a riscos elevados associados a terras recém-convertidas, garantindo que a área segurada atenda a critérios de estabilidade agrônoma e regulatória. De acordo com as condições gerais de seguradoras como a Somp Seguros e a Brasilseg, a aceitação da proposta depende dessa análise para evitar coberturas em contextos de alta vulnerabilidade, alinhando-se às normas do MAPA.

Os riscos de segurar áreas de primeiro e segundo ano de plantio são multifacetados, abrangendo aspectos agrônomicos e financeiros que podem resultar em perdas significativas para as seguradoras e produtores. Agronomicamente, essas terras recém-desmatadas ou convertidas de pastagem apresentam maior suscetibilidade à erosão do solo, depleção de nutrientes e infestação por pragas e doenças, uma vez que o ecossistema ainda não está equilibrado, levando a produtividades inferiores e maior probabilidade de falhas na colheita. Por exemplo, o estudo de [Tabosa, Filho e Vasconcelos \(2021\)](#) indica que solos recém-convertidos podem exibir deficiências nutricionais iniciais, exigindo investimentos adicionais em correção, o que eleva o custo de produção e o risco de sinistros. Financeiramente, as seguradoras frequentemente excluem essas áreas de cobertura, como observado em cláusulas de políticas rurais que negam indenizações para eventos em terras de primeiro e segundo ano pós-cerrado ou pastagem, devido ao histórico de maior incidência de eventos climáticos adversos e menor resiliência da lavoura. Assim, essa análise não apenas protege o equilíbrio atuarial das seguradoras, mas também incentiva práticas

sustentáveis no agronegócio brasileiro, promovendo a longevidade da produção agrícola.

A análise do histórico de plantio da área pode ser complementada por meio de ferramentas avançadas de sensoriamento remoto, como o uso de séries temporais do Índice de Vegetação por Diferença Normalizada (NDVI). Essa abordagem permite avaliar a evolução da cobertura vegetal ao longo do tempo, identificando padrões que indicam se a área possui um histórico de plantio adequado, evitando coberturas em terras de primeiro ou segundo ano pós-conversão de cerrado, mata nativa ou pastagem.

2.3 Índice de Vegetação por Diferença Normalizada

O Índice de Vegetação por Diferença Normalizada é um dos índices espectrais mais utilizados na análise de dados de sensoriamento remoto aplicados ao monitoramento da vegetação. Esse índice foi desenvolvido com o objetivo de realçar a resposta espectral da vegetação saudável em relação a outros tipos de cobertura do solo, permitindo identificar padrões de vigor vegetativo e de biomassa em diferentes regiões.

O NDVI é calculado a partir da razão normalizada entre as refletâncias da vegetação na faixa do infravermelho próximo (NIR – *Near Infrared*) e na faixa do vermelho (RED), como descrito em [Jensen \(1996\)](#). A equação do cálculo do NDVI é expressa na Equação 2.1:

$$NDVI = \frac{(NIR - RED)}{(NIR + RED)} \quad (2.1)$$

Em que:

- *NIR* representa a refletância na região do infravermelho próximo, faixa em que a vegetação saudável apresenta alta refletância;
- *RED* representa a refletância na região do vermelho, faixa em que a vegetação saudável absorve fortemente a radiação devido à atividade fotossintética da clorofila.

O valor do NDVI varia entre -1 e $+1$. De acordo com [BURGOS \(2002\)](#), à medida que aumenta a quantidade de vegetação verde, aumenta a reflexão na banda do infravermelho próximo e diminui a reflexão na banda do vermelho, fazendo com que o aumento da razão seja potencializado, realçando assim a vegetação. Valores próximos de zero ou negativos geralmente correspondem a superfícies sem vegetação, como corpos d'água, solos expostos, áreas urbanas ou nuvens. Por outro lado, valores positivos mais elevados (tipicamente acima de 0,3) indicam maior vigor vegetativo, associado a áreas de vegetação densa e saudável. As nuvens refletem de forma semelhante no visível e no infravermelho próximo, portanto, espera-se que o valor do pixel seja bem próximo de zero. A figura 2 exibe como o índice é disperso sob uma área agrícola, tornando clara a diferença entre áreas com vegetação alta e saudável, e áreas sem vegetação plantada.

Figura 2 – Visualização do NDVI sob área agrícola



Fonte: [Pola \(2022\)](#)

2.4 Bancos de Dados Espaciais

Bancos de dados espaciais são sistemas de gerenciamento de dados projetados para armazenar, consultar e manipular informações que possuem referência geográfica ([GÜTING, 1994](#)). Diferentemente de bancos de dados tradicionais, que lidam principalmente com dados alfanuméricos, os bancos espaciais permitem o tratamento de geometrias como pontos, linhas e polígonos, associadas a sistemas de coordenadas. Dessa forma, viabilizam o armazenamento de dados complexos, como limites de propriedades, áreas de cultivo, cursos d'água, redes de transporte e outros elementos fundamentais para aplicações que envolvem o espaço geográfico.

A utilização desses bancos de dados é essencial em diversas áreas, como planejamento urbano, monitoramento ambiental, logística, análise de risco e, especialmente, na agricultura de precisão. Ao centralizar dados espaciais em uma estrutura robusta, é possível realizar consultas eficientes e análises complexas, como cálculo de áreas, detecção de interseções entre polígonos, medições de distâncias e geração de estatísticas sobre a cobertura do solo. Para este trabalho, um banco de dados espacial foi utilizado para as seguintes funções:

- Verificação de interseções e sobreposições entre polígonos (por exemplo, entre áreas agrícolas e zonas de restrição ambiental);
- Cálculo de distâncias e áreas geográficas com suporte a diferentes sistemas de projeção e referenciais;

- Operações de *buffer*, dissolução e união espacial, que permitem análises espaciais avançadas;
- Indexação espacial eficiente por meio da estrutura R-Tree, otimizando consultas em grandes volumes de dados.

2.5 Séries Temporais

2.5.1 Definição de Série Temporal

Uma série temporal é formalmente definida como uma sequência de valores observados em uma escala ordenada em relação ao tempo, onde o parâmetro temporal pode variar entre inteiros positivos e negativos ou todos os números reais ou subconjuntos destes, conforme definido em [Chatfield e Xing \(2019\)](#). Do ponto de vista matemático, uma série temporal representa uma realização específica de um processo estocástico, estabelecendo a relação fundamental onde “um processo estocástico está para uma série temporal assim como uma variável aleatória está para um número”.

Pode-se definir matematicamente uma série temporal $T = t_1, t_2, t_3, \dots, t_n$, onde cada t_i representa uma observação em um instante de tempo específico. Os pontos de tempo podem ser igualmente espaçados (séries temporais regulares) ou não (séries temporais irregulares), dependendo da frequência de coleta dos dados.

2.5.2 Série Temporal de Imagens de Satélite

Uma Série Temporal de Imagens de Satélite (SITS) é definida como um conjunto de imagens de satélite capturadas da mesma região geográfica em diferentes momentos temporais, organizadas sequencialmente por data para permitir a análise temporal. Tecnicamente, SITS constituem conjuntos de dados multidimensionais organizados como cubos de dados de observação da Terra, onde cada localização espacial é associada a uma série temporal que combina informações espectrais, espaciais e temporais em uma estrutura unificada ([SIMOES et al., 2021](#)).

A Equação 2.2 exibe a definição de uma SITS

$$f(x, y, t) \rightarrow \{v_1, v_2, \dots, v_n\} \quad (2.2)$$

onde (x, y) são coordenadas espaciais, t é tempo, e $\{v_1, v_2, \dots, v_n\}$ são valores espectrais das bandas. Esta estrutura permite representação dual: visão espacial como stack de imagens e visão temporal como grid de séries temporais.

As SITS diferem fundamentalmente das séries tradicionais pela complexidade dimensional: enquanto séries tradicionais são unidimensionais (tempo) com 1-3 variáveis típicas, as

satelitais são multidimensionais (espaço-tempo-espectro) com dezenas de bandas espectrais organizadas como tensores 4D (x, y, t , bandas).

Características temporais distintivas incluem:

- **Irregularidade temporal:** devido a cobertura de nuvens.
- **Sazonalidade múltipla:** com padrões fenológicos e climáticos sobrepostos
- **Auto-correlação espacial:** entre pixels vizinhos.
- **Não-estacionariedade:** com variação temporal das propriedades estatísticas por localização.

O processamento requer pré-processamento complexo, incluindo correção atmosférica, detecção de nuvens e harmonização espectral, além de métodos de análise conjunta que integram informações espaciais e temporais simultaneamente (GÓMEZ-CHOVA et al., 2015).

A aquisição de SITS envolve trade-offs de resolução entre temporal, espacial e espectral, limitações por cobertura de nuvens (>33% da superfície terrestre) e condições orbitais. O pré-processamento específico inclui correção atmosférica para remoção de efeitos de gases e aerossóis, detecção automática de nuvens, harmonização multi-sensores para integração de dados de diferentes plataformas e registro geométrico para alinhamento espacial preciso.

A preparação dos dados obtidos por imagens de satélites torna-se uma parte desafiadora para pesquisas que utilizam desta fonte de dados. O trabalho de Pelletier, Webb e Petitjean (2019), "Temporal convolutional neural network for the classification of satellite image time series", apresenta etapas de preparação como a regularização temporal, que converte coleções irregulares em cubos regulares com intervalos temporais fixos, projeção cartográfica comum e resolução espacial homogênea, aplicando interpolação ou gap-filling para dados faltantes. Esta estrutura organizada permite análises específicas como caracterização fenológica de ciclos de vegetação e detecção contínua de mudanças ambientais, estabelecendo as SITS como paradigma distinto que exige métodos especializados de análise temporal para monitoramento ambiental e análise de mudanças globais.

2.6 Classificação de Séries Temporais

A classificação de séries temporais refere-se ao processo de atribuir rótulos ou categorias a sequências de dados ordenados no tempo, com o objetivo de identificar padrões, tendências ou comportamentos característicos (DING et al., 2008) (KEOGH; KASETTY, 2002). Esse conceito é fundamental em diversas áreas, como finanças, saúde, meteorologia e, particularmente, na agricultura e sensoriamento remoto, onde séries temporais derivadas de índices como o NDVI são utilizadas para monitorar dinâmicas de uso do solo e culturas agrícolas. Por exemplo, o estudo

de [Nhongo et al. \(2017\)](#) sobre fenologia vegetal e séries temporais de NDVI permitiu caracterizar a sazonalidade da cobertura vegetal, identificando variações relacionadas a condições climáticas e incêndios antropogênicos, de acordo com o observado na Reserva do Niassa, Moçambique.


Entre os usos proeminentes da classificação de séries temporais na agricultura, destacam-se a identificação de tipos de culturas, o mapeamento de pastagens e a detecção de mudanças no uso do solo. Trabalhos como o de [Defeo et al. \(2016\)](#) demonstram a aplicação de séries temporais MODIS/NDVI para mapear pastagens, integrando dados multitemporais para melhorar a precisão em regiões agrícolas. Essa abordagem é essencial para políticas de seguro agrícola, onde a classificação precisa de séries temporais pode auxiliar na análise de riscos, como a verificação de histórico de plantio para evitar coberturas em áreas recém-convertidas. A técnica permite discriminar entre florestas nativas, plantações e pastagens degradadas, contribuindo para a sustentabilidade e gestão de recursos.

Dentre as técnicas de classificação de séries temporais, a utilização de shapelets destaca-se por sua capacidade de capturar padrões locais discriminativos. Introduzidos por [Ye e Keogh \(2009\)](#), shapelets são subsequências de séries temporais que são maximamente representativas de uma classe, permitindo a distinção entre categorias com base em formas locais, em vez de características globais. Formalmente, um shapelet é uma subsequência de comprimento l extraída de uma série temporal, cuja distância (geralmente Euclidiana) para outras séries permite uma divisão ótima do conjunto de dados, maximizando o ganho de informação. Podemos definir a distância de um shapelet S até uma série temporal T como a distância entre S e o melhor local de T onde S se encaixa. O ganho de informação é calculado de acordo com o exibido na Equação 2.3:

$$IG(S) = E(D) - \left(\frac{|D_1|}{|D|} E(D_1) + \frac{|D_2|}{|D|} E(D_2) \right) \quad (2.3)$$

onde $E(D)$ é a entropia do conjunto de dados D , e D_1 , D_2 são os subconjuntos resultantes da divisão baseada na distância ao shapelet. Desta forma, a maioria das séries temporais da classe D_1 estão próximas do shapelet, enquanto as de D_2 estão mais distantes. A figura 3 ilustra várias das definições explicadas até então. A série temporal T é exibida em azul, enquanto o shapelet S é destacado em vermelho. A distância entre o shapelet e a série temporal é representada pela linha tracejada preta, indicando o ponto de melhor ajuste.

Figura 3 – Exemplo de distância entre shapelet e série temporal



Fonte: Elaborada pelo autor

O processo de descoberta de shapelets envolve uma busca exaustiva por todas as subsequências possíveis em um intervalo de comprimentos definido (mínimo e máximo), avaliando cada candidata quanto ao seu poder discriminativo. Para cada subsequência, calcula-se a distância para todas as séries temporais no conjunto de treinamento, ordenando-as para encontrar o ponto de divisão ótimo que maximiza o ganho de informação. Embora o algoritmo *brute-force* seja computacionalmente intensivo, otimizações como o abandono precoce de distâncias (early abandon) e poda baseada em entropia admissível reduzem drasticamente o tempo de execução, permitindo aplicações em conjuntos grandes.

Na classificação, shapelets são integrados em árvores de decisão (BREIMAN et al., 2017), onde cada nó representa um shapelet e um limiar de distância. A Equação 2.4 exhibe o processo para determinar a distância D entre um shapelet S e uma série T .

$$D(S, T) = \min_{i=1, \dots, n-m+1} \sqrt{\sum_{j=1}^m (s_j - t_{i+j-1})^2} \quad (2.4)$$

- $T = (t_1, t_2, \dots, t_n)$ é a série temporal de comprimento n .
- $S = (s_1, s_2, \dots, s_m)$ é o *shapelet* aprendido (subsequência) de comprimento $m \leq n$.
- Para cada posição inicial i , considera-se a subsequência de T de comprimento m : $(t_i, t_{i+1}, \dots, t_{i+m-1})$.
- A expressão dentro da raiz representa a distância euclidiana entre S e a subsequência de T iniciando em i .
- $D(S, T)$ é a menor dessas distâncias — ou seja, a distância mínima entre o *shapelet* S e a série temporal T .


Para classificar uma nova série temporal, percorre-se a árvore comparando distâncias aos shapelets nos nós, até alcançar uma folha que indica a classe. Essa estrutura não apenas melhora

a precisão, mas também oferece interpretabilidade, pois os shapelets podem ser visualizados para entender padrões subjacentes, como períodos de baixa vegetação em NDVI indicativos de plantio recente. A figura 4 exemplifica uma árvore de decisão baseada em shapelets. O valor de X é definido empiricamente, baseado na distribuição das distâncias entre o shapelet e as séries temporais do conjunto de treinamento.

Figura 4 – Exemplo de árvore de decisão utilizando shapelets

Árvore de Decisão para série temporal T

A série T possui uma subsequência T_i cuja distância d até o shapelet S seja menor que X ?



Fonte: Elaborada pelo autor

As vantagens da técnica de shapelets incluem alta interpretabilidade, robustez a ruído e eficiência em classificação. Diferentemente de métodos baseados em vizinhos mais próximos ou DTW (Dynamic Time Warping), que consideram séries inteiras e podem ser sensíveis a distorções globais, shapelets focam em características locais, tornando-os ideais para dados ruidosos ou com variações irrelevantes. O próprio estudo de [Ye e Keogh \(2009\)](#) mostra que classificadores baseados em shapelets podem ser substancialmente mais rápidos que variantes rotacionalmente invariantes de DTW, mantendo ou superando a precisão em domínios como reconhecimento de gestos ou classificação de folhas.

A escolha pela classificação usando shapelets nesta monografia justifica-se pela necessidade de analisar séries temporais de NDVI para verificar histórico de plantio em seguros agrícolas. Essa técnica captura padrões locais indicativos de conversões recentes de solo, como quedas em NDVI pós-desmatamento, alinhando-se às exclusões de risco em apólices, conforme condições gerais de seguradoras. Sua interpretabilidade auxilia na validação de propostas, mitigando fraudes e promovendo sustentabilidade, com evidências de alta precisão em aplicações semelhantes corroborando sua adequação.

3 Materiais e Métodos

Este capítulo tem como objetivo mostrar quais foram os métodos e tecnologias utilizados em uma análise de risco para seguro agrícola completa, baseada em todas as análises descritas nesse projeto. Também será explicado o processo de construção da aplicação web, que unifica todas as análises e oferece uma interface simples e amigável aos usuários.

3.1 Tecnologias utilizadas para as análises

- **Linguagem de programação:** *Python 3.11.13*
- **Banco de dados:** *PostgreSQL*, com a extensão *PostGIS* para suportar operações com polígonos.
- **SGBD:** *pgAdmin4*

A linguagem *Python* foi escolhida por apresentar uma grande quantidade de pacotes disponíveis para importação, o que facilita no desenvolvimento do código e promove a rapidez da entrega. Quanto ao banco de dados, o *PostgreSQL* foi o escolhido pela sua tradição no mercado e por contar com a extensão *PostGIS*, que adiciona suporte avançado para o armazenamento, consulta e manipulação de dados geoespaciais. Por fim, a escolha do *pgAdmin4* como SGBD é justificada pela interface amigável e intuitiva.

3.2 Desenvolvimento das análises

Esta seção é destinada a mostrar a lógica e a tecnologia necessárias para a execução de cada uma das análises de risco consideradas por esta pesquisa.

3.2.1 Análise do local de plantio

3.2.1.1 Verificação de município

O objetivo da verificação de município é averiguar se a área do produtor rural está dentro da área do município que ele informou. Em primeiro lugar, são necessários os dados da área do produtor e, para isso, a corretora de seguros utiliza arquivos do tipo KML para esse controle.

Arquivos KML (*Keyhole Markup Language*) são arquivos de texto baseados em XML usados para representar dados geoespaciais. Eles foram criados originalmente pela empresa

Keyhole Inc. (mais tarde adquirida pelo Google) e se tornaram padrão para aplicações como Google Earth, Google Maps e outros softwares de Sistemas de Informação Geográfica (SIG/GIS).

No momento do primeiro contato entre a corretora e o produtor, antes da análise de risco ser iniciada, o produtor informa a localização de sua propriedade, e a corretora traça um polígono que represente a área (ou áreas) do produtor, utilizando softwares como *Google Earth Pro* ou *QGIS*. O polígono então é salvo para ser utilizado nesta e em outras verificações durante a análise de risco.

O primeiro passo é converter o arquivo KML para um outro formato: o arquivo GeoJSON. Estes são arquivos de texto baseados em JSON (JavaScript Object Notation), projetados para representar dados geoespaciais de forma simples. Por essa simplicidade e maior clareza das informações contidas nesse tipo de arquivo, optou-se por fazer essa conversão, não apenas na verificação de município, mas para todas que utilizam dados geoespaciais da área do produtor.

Em seguida, são necessárias informações do polígono que representa a área do município informado pelo produtor. Para tal, é utilizado o pacote python *geobr* ((IPEA), 2025), que contém *shapefiles* do Instituto Brasileiro de Geografia e Estatística (IBGE) e outros conjuntos oficiais de dados espaciais do Brasil. É utilizado o nome do município informado para filtrar dentre os *shapefiles* do pacote e encontrar o desejado.

A partir do momento em que se tem acesso às geometrias da área do produtor e do município informado, é feita a seguinte verificação: se a área do produtor está totalmente contida no município, então a verificação é aprovada. Caso apenas uma parte ou nenhuma parte da área do produtor esteja contida no município, a verificação é reprovada.

3.2.1.2 Verificação das áreas de embargo

Essa verificação foi dividida em 3 etapas:

1. Identificar quais são as áreas de embargo que precisam ser consideradas.
2. Encontrar uma maneira de ter acesso às suas geometrias
3. Identificar se há intersecções entre a área do produtor e alguma geometria de áreas de embargo.

Para o primeiro passo ser realizado, foi feito um levantamento sobre as principais organizações governamentais e institutos que fazem o controle de áreas protegidas no Brasil, de acordo com o estipulado pelo MAPA (MAPA, 2025). Caso a área do produtor seja localizada em alguma área protegida por esses órgãos, a apólice de seguro torna-se inválida. Esta pesquisa considerou os seguintes órgãos:

- FUNAI (Fundação Nacional dos Povos Indígenas)

- IBAMA (Instituto Brasileiro do Meio Ambiente e dos Recursos Naturais Renováveis)
- ICMBio (Instituto Chico Mendes de Conservação da Biodiversidade)
- IPHAN (Instituto do Patrimônio Histórico e Artístico Nacional)
- MMA (Ministério do Meio Ambiente)

Em seguida, foi necessário encontrar meios para acessar informações das áreas protegidas por esses órgãos. A estratégia adotada foi buscar os dados destas áreas via APIs públicas disponíveis na internet. APIs podem ser entendidas como “pontes” que permitem que aplicações, sistemas ou serviços troquem informações de maneira padronizada e segura.

O massivo número de dados retornados por essas APIs, aliado à falta de opções de filtragem, levou à decisão de criar um script em *Python* que realizasse consultas em todas as APIs uma única vez, salvando o resultado das buscas em um banco de dados local. Esta decisão permitiu que todas as geometrias das áreas de embargo fossem armazenadas localmente, tornando o acesso mais rápido.

Com as áreas de embargo salvas em um banco de dados espacial, a consulta para verificar se há intersecção entre a área do produtor e as áreas salvas pode ser feita através de *query SQL*, para aproveitar todas as ferramentas de tratamento de polígonos que a extensão *PostGIS* oferece.

Portanto, caso a consulta retorne que há qualquer intersecção entre a área do produtor e alguma das áreas de embargo salvas, a verificação é considerada reprovada. Caso contrário, a verificação é aprovada.

3.2.2 Análise do tipo de solo

Para a análise do tipo de solo foi utilizada a mesma lógica da análise das áreas de embargo. A diferença é que, ao invés de buscar por áreas protegidas, o objetivo é encontrar as geometrias do tipo de solo na área do produtor. Para isso, foi utilizada a API da *Embrapa* (Empresa Brasileira de Pesquisa Agropecuária), uma instituição pública de pesquisa científica vinculada ao MAPA ([EMBRAPA, 2025](#)). Dentre os vários *datasets* disponibilizados, existe o conjunto "*brasil-ad-solos*", que disponibiliza um conjunto de dados geoespaciais sobre a cobertura da terra no Brasil. Através dessa API, é possível obter informações detalhadas sobre os tipos de solo presentes em uma determinada área geográfica.

O procedimento aplicado foi o mesmo: utilizar a API uma única vez para salvar os dados em um banco de dados local. Esta API em específico retorna mais informações sobre os polígonos, como a descrição do tipo de solo e seu índice AD. Desta forma, ao realizar uma *query SQL* para encontrar quais polígonos possuem intersecções com a área do produtor, é possível retornar também essas informações adicionais.

A análise do solo, para esta pesquisa, sempre será aprovada. Isto porque o objetivo é apenas fornecer a informação para a corretora, pois cada seguradora tem suas próprias regras para quais solos são aceitos ou não.

3.2.3 Análise da adimplência fiscal do produtor

Para esta análise, o objetivo é verificar se o produtor rural está em dia com suas obrigações fiscais. Para isso, foi utilizado o serviço "Consulta CND" da *Serpro*. A *Serpro* (Serviço Federal de Processamento de Dados) é uma empresa pública vinculada ao Ministério da Economia do Brasil, especializada em soluções de tecnologia da informação para o setor público. Através deste serviço, é possível consultar a Certidão Negativa de Débitos (CND) de um contribuinte. A Consulta CND retorna certidões negativas de débito expedidas conjuntamente pela Secretaria Especial da Receita Federal do Brasil e pela Procuradoria-Geral da Fazenda Nacional, referente a todos os créditos tributários federais e à Dívida Ativa da União por elas administrados, de pessoas físicas, pessoas jurídicas e imóveis rurais ([SERPRO, 2025b](#)).

O procedimento para realizar a consulta é simples: é feita uma requisição do tipo POST à API, fornecendo no *body* informações do produtor, como o tipo de pessoa (física ou jurídica) e número de documento. A API retorna um JSON informando se já existe uma certidão negativa de débitos para aquele produtor. Caso exista, a análise é reprovada. Caso contrário, a análise é aprovada. A figura 5 mostra quais são os parâmetros exigidos pela API e qual é o retorno ao usuário.

Para evitar que uma consulta à API seja feita a cada nova análise, o resultado da consulta é salvo no banco de dados local. Desta forma, se o produtor já tiver sido consultado anteriormente, o sistema apenas verifica o banco local para saber se ele está em dia com suas obrigações fiscais. A consulta deve ser refeita apenas no início de uma nova safra, para garantir que o produtor continua adimplente.

3.2.4 Análise do histórico de plantio

Para tornar esse tipo de análise possível, esta pesquisa optou por criar um conjunto de dados próprios, baseados em dados fornecidos pela corretora parceira, para ser utilizado por um modelo de classificação de séries temporais de índice NDVI. Este é um tipo de série temporal que permite averiguar o uso da terra em um determinado local, durante determinado período de tempo. Esta subseção trata sobre a construção deste conjunto de dados e o treinamento do modelo criado.

3.2.4.1 Construção do conjunto de dados

O primeiro passo para a construção do conjunto de dados foi solicitar à corretora parceira arquivos no formato KML que possuíam polígonos de áreas de produtores reais. No

Figura 5 – Estrutura da requisição á API de Consulta CND



Fonte: Serpro (2025a)

total, foram obtidos 102 arquivos, sendo 55 de áreas que possuem histórico adequado de plantio, e 47 de áreas que não possuem histórico adequado. A definição de um histórico de plantio adequado e como ele pode ser identificado foram apresentados na fundamentação teórica desta pesquisa.

Para a próxima etapa da construção do dataset, foi desenvolvido um processo automatizado utilizando a plataforma *Google Earth Engine* (GEE) em conjunto com dados da missão Sentinel-2 do programa *Copernicus* da Agência Espacial Europeia. O GEE representa uma plataforma de computação em nuvem que disponibiliza acesso a petabytes de dados de sensoriamento remoto, permitindo análises em escala planetária através de processamento distribuído e otimizado.

A escolha da constelação Sentinel-2 fundamentou-se em suas características técnicas superiores para análises de vegetação, apresentando resolução espacial de 10 metros nas bandas do vermelho (B4) e infravermelho próximo (B8), essenciais para o cálculo do NDVI, além de uma revisita temporal de 5 dias considerando os dois satélites da constelação (Sentinel-2A e Sentinel-2B). Estas especificações proporcionam uma densidade temporal adequada para capturar variações fenológicas da vegetação ao longo do período de estudo.

O período temporal estabelecido para a coleta das séries compreendeu três anos anteriores à data de execução do processamento. A definição deste intervalo considerou a

necessidade de capturar múltiplos ciclos fenológicos completos, permitindo a identificação de variações sazonais consistentes, tendo em vista que as condições gerais das seguradoras não contemplam terras que estão no primeiro ou segundo ano de cultivo.

Para a delimitação espacial das áreas de interesse, foram utilizados arquivos no formato KML disponibilizados pela corretora parceira. O processo envolveu a conversão automática destes arquivos para o formato GeoJSON através da biblioteca GeoPandas, seguida de ajustes geométricos necessários para compatibilização com as especificações do Google Earth Engine.


Um aspecto fundamental na obtenção das séries temporais consistiu na implementação de filtros rigorosos de qualidade das imagens. Foi estabelecido um limiar máximo de 1% para a propriedade *CLOUDY PIXEL PERCENTAGE*, garantindo que apenas imagens com cobertura de nuvens mínima fossem incluídas no processamento. Este critério visa minimizar interferências atmosféricas que poderiam comprometer a qualidade dos valores de NDVI calculados, considerando que a presença de nuvens introduz ruídos significativos nas medições espectrais.

O processamento das imagens Sentinel-2 envolveu inicialmente a aplicação do fator de escala padrão (0.0001) aos valores digitais, convertendo-os para valores de refletância de superfície. Posteriormente, foi calculado o NDVI utilizando a fórmula clássica que relaciona as bandas do infravermelho próximo (B8) e vermelho (B4). Este índice foi adicionado como uma nova banda às imagens processadas, preservando as propriedades temporais originais.

Para cada imagem da série temporal, foi aplicado um redutor de média espacial sobre a geometria de cada polígono, utilizando uma escala de processamento de 20 metros. Esta abordagem permite obter um valor representativo do NDVI para toda a extensão da propriedade rural, reduzindo a variabilidade espacial interna e fornecendo uma métrica integrada da condição vegetativa da área.


A figura 6 ilustra o fluxo de trabalho adotado para a extração das séries temporais de NDVI. Para cada imagem disponível no período de interesse, o processo envolve a filtragem por data e qualidade, o cálculo do NDVI e a aplicação do redutor espacial para obter a média do índice sobre a área do polígono naquele dia. O resultado final é uma série temporal, como exibido na figura 7 de valores médios de NDVI para cada propriedade rural, representando a evolução fenológica ao longo do período analisado.

Figura 6 – Processo de extração do NDVI



Fonte: Elaborado pelo autor

Figura 7 – Série temporal de NDVI



Fonte: Elaborado pelo autor

Os dados extraídos foram organizados em estrutura tabular, onde cada linha representa uma propriedade rural e cada coluna corresponde a uma data específica de observação. O processo de pivotagem transformou a representação temporal vertical em uma matriz horizontal, facilitando análises subsequentes de séries temporais. Cada propriedade foi rotulada binariamente conforme sua classificação (1 para áreas com histórico adequado, 0 para áreas impróprias), permitindo análises supervisionadas posteriores.

O tratamento de qualidade dos dados envolveu a implementação de critérios estatísticos para remoção de observações inconsistentes e preenchimento de lacunas temporais. Foi estabelecido um limiar de tolerância de 80% para dados ausentes tanto em nível de colunas (datas) quanto de linhas (propriedades). Colunas temporais com proporção de valores nulos superior a este limiar foram removidas da análise, garantindo que apenas datas com cobertura amostral adequada fossem mantidas no dataset final. Similarmente, propriedades rurais que apresentaram proporção de dados ausentes superior ao limiar estabelecido foram excluídas do conjunto de dados. Este procedimento visa assegurar que as séries temporais mantidas possuam densidade suficiente de observações para análises estatísticas robustas e modelagem preditiva adequada.

A estruturação final do dataset envolveu a ordenação cronológica das colunas temporais, garantindo que a sequência temporal fosse preservada. A configuração final mantém as colunas de identificação da área no início, seguidas pelas colunas temporais ordenadas cronologicamente, e finalmente a coluna de rótulo classificatório.

Este processo automatizado resultou na geração de um dataset estruturado e padronizado, adequado para a aplicação de técnicas de análise de séries temporais e aprendizado de máquina, com controle de qualidade e tratamento sistemático de dados ausentes ou inconsistentes.

3.2.4.2 Treinamento do modelo

A classificação de séries temporais por meio da técnica de shapelets representa uma abordagem inovadora que combina extração de características discriminativas com aprendizado supervisionado. O algoritmo *Learning Shapelets*, definido em [Shah et al. \(2016\)](#), implementado neste trabalho utiliza uma abordagem de otimização conjunta, onde tanto os shapelets quanto o classificador são aprendidos simultaneamente através de um processo iterativo de otimização. Esta metodologia supera limitações das abordagens tradicionais de descoberta de shapelets por força bruta, que apresentavam complexidade computacional proibitiva para datasets de grande dimensionalidade.

Anteriormente ao processo de extração de shapelets, foi implementado um pipeline de pré-processamento para garantir a qualidade e consistência dos dados de entrada. A interpolação linear foi aplicada para preencher lacunas temporais presentes nas séries, utilizando valores adjacentes para estimar pontos faltantes. Este procedimento foi complementado por técnicas de preenchimento direcionais (*forward fill* e *backward fill*) para tratar valores ausentes residuais nas extremidades das séries.


A normalização por linha foi implementada através da aplicação de *min-max scaling* individual para cada série temporal, transformando os valores para o intervalo $[0, 1]$. Esta abordagem preserva as características morfológicas específicas de cada série, enquanto elimina variações de escala que poderiam comprometer o processo de descoberta de padrões discriminativos. A normalização individual é particularmente relevante neste contexto, considerando que as propriedades rurais podem apresentar diferentes níveis basais de NDVI devido a fatores ambientais e de manejo específicos.

O modelo *Learning Shapelets* foi configurado com parâmetros otimizados para o domínio específico das séries temporais de NDVI. Foi estabelecido o número de 10 shapelets por tamanho, permitindo diversidade suficiente de padrões discriminativos enquanto mantém a complexidade computacional controlada. O comprimento mínimo dos shapelets foi definido em 15 pontos temporais, correspondendo aproximadamente a períodos fenológicos significativos na escala temporal do dataset. O parâmetro *shapelet-scale* foi configurado em 4, definindo diferentes escalas de comprimento para os shapelets descobertos, permitindo a captura de

padrões tanto de curto quanto de médio prazo nas séries temporais.


As figuras 8 e 9 ilustram exemplos de shapelets discriminativos descobertos para cada classe. Pode-se observar o formato horizontal e contínuo do shapelet da classe 0, indicando uma ausência de variações fenológicas significativas, característica de áreas sem histórico adequado de plantio. Em contraste, o shapelet da classe 1 apresenta um padrão ascendente seguido de uma queda, refletindo o ciclo fenológico típico de culturas agrícolas com crescimento vigoroso e queda no período de colheita.

Figura 8 – Shapelet discriminativo da classe 0



Fonte: Elaborado pelo autor

Figura 9 – Shapelet discriminativo da classe 1



Fonte: Elaborado pelo autor

Após a descoberta dos shapelets, cada série temporal do dataset é transformada em um vetor de características através do cálculo de distâncias mínimas aos shapelets aprendidos. Para cada série temporal e cada shapelet, é computada a distância mínima utilizando *Dynamic Time Warping* (DTW), uma métrica que permite alinhamento temporal flexível entre subsequências.

A distância entre uma shapelet $S = (s_1, s_2, \dots, s_m)$ e uma série temporal $T = (t_1, t_2, \dots, t_n)$ utilizando DTW é definida a partir da matriz de custos acumulados $D \in R^{m \times n}$:

$$D(i, j) = (s_i - t_j)^2 + \min \begin{cases} D(i-1, j), \\ D(i, j-1), \\ D(i-1, j-1) \end{cases} \quad (3.1)$$

com condições iniciais:

$$D(1, 1) = (s_1 - t_1)^2 \quad (3.2)$$

$$D(i, 1) = (s_i - t_1)^2 + D(i-1, 1), \quad \forall i > 1 \quad (3.3)$$

$$D(1, j) = (s_1 - t_j)^2 + D(1, j-1), \quad \forall j > 1 \quad (3.4)$$

A distância DTW entre a shapelet S e a série temporal T é dada por:

$$DTW(S, T) = \sqrt{D(m, n)} \quad (3.5)$$

O processo de transformação percorre cada posição possível da série temporal, extraindo subsequências de comprimento igual ao shapelet e computando a distância DTW correspondente. A distância mínima encontrada representa a proximidade da série temporal ao padrão característico representado pelo shapelet. Este procedimento resulta em uma representação vetorial onde cada dimensão corresponde à distância mínima a um shapelet específico, transformando o problema de classificação de séries temporais em um problema de classificação tradicional em espaço euclidiano.

A etapa final do *pipeline* utiliza um classificador *Random Forest* aplicado ao espaço transformado de distâncias aos shapelets. A escolha desta técnica fundamenta-se em sua robustez contra *overfitting*, capacidade de lidar com características de diferentes escalas e interpretabilidade através da análise de importância das características.

3.2.5 Análise da Semente

Para determinar a homologação das sementes no contexto brasileiro e avaliar sua adequação para uso agrícola, foi adotada uma abordagem baseada em fontes oficiais. Inicialmente, acessou-se o portal do MAPA, especificamente a seção dedicada ao Programa Nacional de Zoneamento Agrícola de Risco Climático ([MINISTÉRIO DA AGRICULTURA E PECUÁRIA, 2025](#)), onde são divulgadas anualmente as portarias que listam as sementes homologadas. Nesse ambiente, foram baixadas as portarias referentes às culturas de soja, milho de primeira safra e milho de segunda safra para os estados de São Paulo, Paraná, Minas Gerais, Mato Grosso do Sul e Mato Grosso, selecionados como foco da pesquisa devido à sua relevância no agronegócio nacional.

No caso do milho, as portarias organizam as sementes por grupos, os quais representam variações em ciclos fenológicos e adaptações climáticas; no entanto, essa divisão não foi incorporada à análise de risco prévia, uma vez que sua importância se manifesta predominantemente no estágio pós-venda, relacionado ao manejo e ao desempenho produtivo, e não diretamente à avaliação inicial de viabilidade para fins de seguro agrícola. Já para a soja, as portarias apresentam uma classificação mais detalhada, dividindo as sementes por macrorregiões sojícolas e por grupos, o que demanda uma consideração espacial específica para garantir a compatibilidade com as condições locais. Para lidar com essa complexidade, foi obtida a relação oficial de macrorregiões sojícolas disponibilizada pelo MAPA, a qual foi integrada a um banco de dados local, permitindo o mapeamento geográfico das áreas.

Com base nessas portarias, procedeu-se à extração automatizada das sementes homologadas, registrando para cada uma delas atributos essenciais, como a cultura associada, o estado de homologação e, quando aplicável, a macrorregião específica. Esse processo resultou na construção de um repositório estruturado no banco de dados, que serve como base para consultas subsequentes. Assim, ao receber do usuário informações sobre o estado, a cidade e a cultura pretendida, o sistema realiza uma filtragem precisa, gerando uma lista de sementes

homologadas que atendem às condições informadas, alinhando-se às diretrizes regulatórias vigentes.

O resultado desta análise sempre será aprovado, pois existe uma restrição das opções apresentadas exclusivamente às sementes oficialmente homologadas; consequentemente, se uma semente buscada pelo usuário não figurar na lista resultante, é altamente provável que ela não atenda aos critérios de homologação estabelecidos pelo MAPA.

3.3 Desenvolvimento da aplicação

3.3.1 Visão Geral

Para tornar possível a integração de todas as validações desenvolvidas neste projeto, foi criada uma aplicação web que unifica todo o processo da análise de risco para o seguro agrícola. Esta seção trata dos aspectos fundamentais da aplicação e explica algumas decisões de arquitetura.

3.3.2 *Frontend*

O *frontend* corresponde à camada de interface da aplicação, sendo o ponto de contato direto entre o usuário e o sistema. Ele foi projetado com foco em simplicidade e clareza, de modo a oferecer uma experiência acessível para novos usuários e, ao mesmo tempo, possibilitar a adoção facilitada da solução em corretoras e instituições que atuam com seguro agrícola.

O desenvolvimento foi realizado utilizando *React 18* em conjunto com *TypeScript*, tecnologia amplamente empregada na construção de interfaces modernas e reativas. A estilização da aplicação foi conduzida com o uso do *Tailwind CSS*, que permite maior consistência visual e agilidade na prototipagem, aliado à biblioteca *Lucide React* para a inserção de ícones vetoriais, garantindo uma apresentação elegante e funcional.

3.3.3 *Backend*

O *backend* da aplicação foi desenvolvido como uma API REST utilizando o framework FastAPI, uma tecnologia moderna e de alta performance para a construção de serviços web em Python. Essa camada é responsável pela lógica de negócio, pelo processamento das análises e pela comunicação com o banco de dados, além de expor endpoints que permitem a interação com o *frontend* e outros sistemas externos.

3.3.3.1 Principais Tecnologias Utilizadas

- **FastAPI:** Framework principal para criação da API REST, com suporte nativo a tipagem, validação de dados e documentação automática;

- **SQLAlchemy:** ORM (*Object-Relational Mapping*) para modelagem e interação com o banco de dados relacional;
- **Pydantic:** Utilizado para validação, normalização e serialização de dados por meio de *schemas*;

3.3.3.2 Endpoints

A API oferece um conjunto de rotas organizadas por domínio, permitindo desde operações básicas de cadastro até análises avançadas. A listagem e documentação de todos os endpoints foi realizada no *Postman*, uma plataforma de desenvolvimento e testes de APIs. A tabela 2 exibe os principais *endpoints* oferecidos pelo *backend*.

Tabela 2 – Endpoints da API

Endpoint	Descrição
/clients	Operações de criação, listagem, atualização e remoção de clientes rurais
/estados	Gerenciamento de estados
/cidades	Gerenciamento de cidades
/culturas	Cadastro e manutenção de culturas
/sementes	Cadastro e manutenção de sementes
/analysis	Registro, consulta e atualização de análises geoespaciais e de risco

Fonte: Elaborada pelo autor

3.3.4 Banco de Dados

Para a camada de persistência de dados, foi utilizado o PostgreSQL, um sistema de gerenciamento de banco de dados relacional robusto e amplamente adotado em aplicações de alta complexidade. Para possibilitar o tratamento de dados espaciais, o banco foi estendido com a extensão PostGIS, que oferece suporte nativo a tipos geométricos e a funções espaciais avançadas, tornando-se a base ideal para aplicações geoespaciais.

3.3.4.1 Modelagem do Banco de Dados

Para o desenvolvimento do sistema foram criadas tabelas específicas, de modo a representar as entidades e relacionamentos do domínio de análise de risco agrícola. A tabela 3 exibe as principais entidades armazenadas no banco.


A figura 10 apresenta o diagrama entidade-relacionamento construído para o banco de dados da aplicação, destacando as principais tabelas e seus relacionamentos.

Tabela 3 – Entidades do Sistema

Entidade	Descrição
Análises	tabela principal do sistema, responsável por armazenar os resultados das análises de risco realizadas
Cientes	Cadastro de clientes e suas propriedades rurais
Cidades	Repositório de municípios, associado a estados e macrorregiões
Estados	Representação das unidades federativas
Macrorregiões	Divisão territorial em grandes regiões, utilizadas para validação de sementes
Culturas	Cadastro das culturas agrícolas consideradas nas análises
Sementes	Banco de sementes cadastradas e associadas às culturas

Fonte: Elaborada pelo autor

Figura 10 – Diagrama Entidade-Relacionamento simplificado do banco de dados.



Fonte: Elaborada pelo autor

A estrutura relacional, aliada ao suporte geoespacial do PostGIS, permitiu que a aplicação integrasse de forma consistente informações tabulares e espaciais, fornecendo a base para a realização das análises de risco agrícola de maneira precisa e escalável.

3.3.5 Comunicação

Na aplicação desenvolvida, foram utilizados dois tipos principais de protocolos de comunicação: o HTTP, empregado para as chamadas diretas entre o *frontend* e o *backend*, e o MQTT, voltado para a comunicação assíncrona e orientada a eventos.


O protocolo HTTP (*Hypertext Transfer Protocol*) foi utilizado como base para a implementação da *API REST*. Por meio dele, o *frontend* envia requisições ao *backend*, que

responde com os dados solicitados ou realiza operações de criação, atualização e remoção de registros. Esse modelo de comunicação *request-response* é adequado para operações síncronas, como o carregamento de mapas, a execução de análises geoespaciais e a gestão de usuários e clientes.

Já o protocolo MQTT (*Message Queuing Telemetry Transport*) foi adotado para suportar a comunicação assíncrona. O propósito principal da sua utilização é não fazer o *frontend* ficar aguardando o retorno do backend para exibir os resultados de uma nova análise de risco, tendo em conta que esse processo leva cerca de 40 segundos. Esse tempo de espera pode levar à falhas de *timeout* ou deixar a aplicação exposta à problemas por perda de conexão durante esse tempo.

Para isso, foi empregado o Mosquitto como *broker*, responsável por intermediar a troca de mensagens entre o publicador (*backend*) e o assinante (*frontend*). A figura 11 exibe um fluxograma com a sequência de comunicações entre *frontend*, *backend* e MQTT Broker.

Figura 11 – Fluxograma da comunicação entre Frontend, Backend e MQTT Broker



Fonte: Elaborada pelo autor

1. Logo que o usuário entra na aplicação, o *frontend* se inscreve no canal `"/analises/*"` do broker. Sempre que receber uma nova mensagem neste canal, o frontend analisa a mensagem, podendo atualizar a tela do usuário para exibir o diálogo de resultado da análise, ou exibir uma mensagem de erro ao usuário, informando a falta de sucesso durante o processamento.
2. Quando o usuário submete uma nova análise, o *frontend* faz uma requisição HTTP POST para o *backend*, fornecendo todos os dados que o usuário inseriu e possibilitando que ele inicie a análise de risco.

3. O *backend* verifica se ele recebeu tudo o que precisa e, em caso afirmativo, retorna para o *frontend* uma mensagem de sucesso, dizendo que colocou na fila de processamento a nova análise solicitada pelo usuário. O *frontend*, ao receber essa mensagem, exibe uma tela de carregamento, indicando que está aguardando a conclusão da análise.
4. Assim que o *backend* finaliza o processamento, seja por que concluiu todas as operações da análise ou devido a algum erro, ele publica uma mensagem no tópico "resultados".

Durante o desenvolvimento e os testes da aplicação, utilizou-se também a ferramenta MQTTX, que permitiu simular clientes, publicar mensagens em tópicos específicos e monitorar o fluxo de comunicação no ambiente experimental.

A utilização combinada de HTTP e MQTT possibilitou conciliar operações síncronas de consulta e gestão de dados com um mecanismo eficiente de atualização em tempo real.

3.3.6 Seções

A seguir, as seções produzidas para a aplicação serão apresentadas. A primeira, uma tela de login, foi feita para tornar possível um controle de usuários na aplicação. O FACSA possui dois tipos de usuários: *admin*, que conseguem visualizar informações de todos os usuários do sistema, e *corretor*, que pode ver apenas os dados que ele mesmo produziu na plataforma. Essa divisão foi pensada para possibilitar que haja um nível hierárquico dentro do sistema quando ele for utilizado em corretoras.

O sistema de gerenciamento de usuários utilizado pelo FACSA ainda é rudimentar. Os dados de login e senha são armazenados no banco, de forma criptografada. A figura 12 exibe a tela de login da aplicação, sendo esta a primeira tela com a qual o usuário tem um contato.


Ao se logar na aplicação, o usuário vai ter acesso à seção de histórico de análises. Esta seção exibe todas as análises de risco feitas por aquele usuário, de maneira paginada. Há opções de filtro para o usuário poder encontrar análises específicas, buscando por nome do cliente, resultado e data. A figura 13 exibe o design final desta tela.

Figura 12 – Tela de Login



Fonte: Elaborada pelo autor

Figura 13 – Tela de Histórico de Análises



Fonte: Elaborada pelo autor

Para cada análise, esta seção exibe informações gerais: resultado, nome do cliente, documento e data da avaliação, como exibido na figura 14. Desta forma, o usuário tem todas as informações e ferramentas para encontrar qualquer análise realizada com facilidade.

O número limitado de informações por análise que é exibido nesta tela é proposital, pois assim não é necessário realizar o download de todos os dados das análises exibidas, o que poderia causar uma lentidão indesejada na tela principal do sistema.


Figura 14 – Exemplo de Registro de Análise na Tela de Histórico

RESULTADO	NOME	DOCUMENTO	DATA DA AVALIAÇÃO	AÇÕES
Aprovado	João Lucas Criveli	54618455845	07/09/2025, 10:10	

Fonte: Elaborada pelo autor

Caso o usuário deseje ver o resultado completo da análise, ele pode clicar no botão com um ícone de olho que fica ao final da linha de cada análise. Quando pressionado, o frontend faz uma nova requisição ao backend, solicitando desta vez os dados completos daquela análise para poder exibir ao usuário. No diálogo aberto, exibido na figura 15, é exibido um *header*, que mostra o resultado final da análise e algumas informações sobre o cliente e a propriedade.

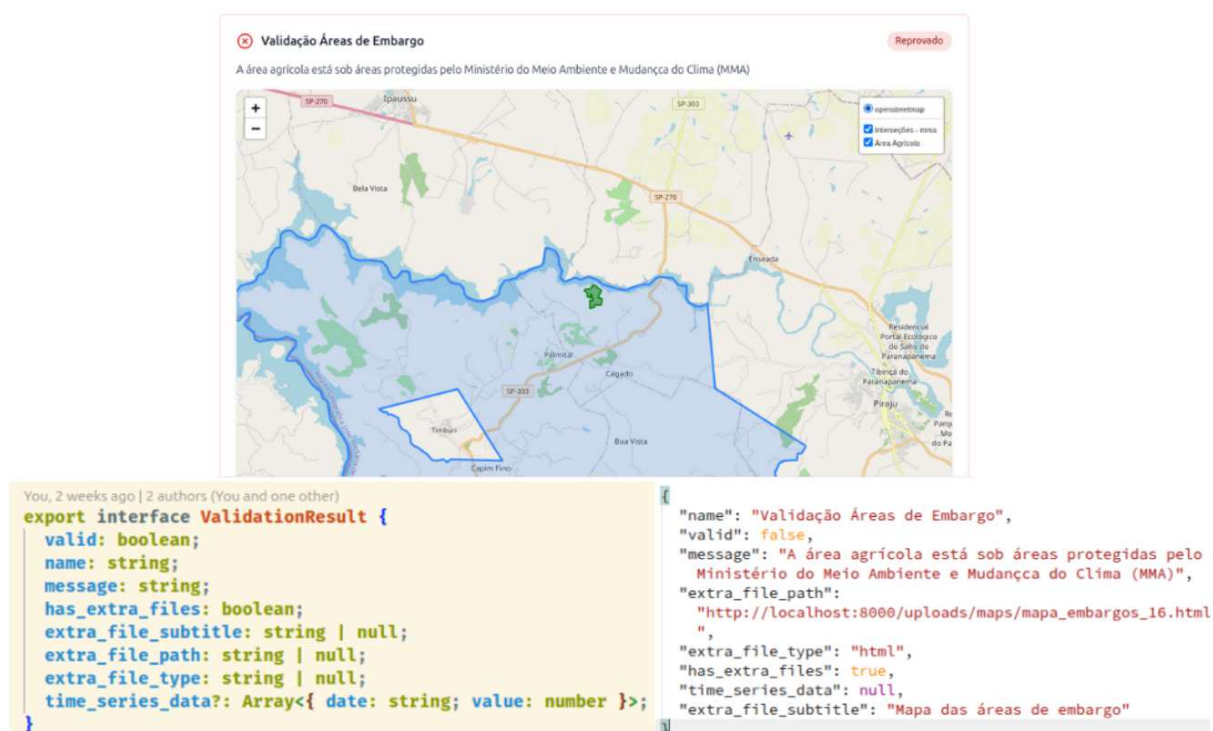
Figura 15 – Diálogo de Resultado da análise



Fonte: Elaborada pelo autor

Para este diálogo, todas as validações estão componentizadas. Desta forma, o frontend tem apenas o papel de montar e exibir a informação. Se uma validação irá exibir uma imagem, mapa, gráfico ou qualquer outro elemento diferente, o backend é quem vai informar o frontend sobre o que exibir. Essa estruturação do sistema foi pensada para tornar o código mais sustentável e para facilitar a implementação de novas análises futuramente. Como exemplo, a figura 16 exibe como a interação entre a interface estabelecida no frontend (código da esquerda) com a informação que o backend retornou (JSON à direita) forma o resultado visual de uma validação (imagem do diálogo no topo).

Figura 16 – Resultado da Interação entre Frontend e Backend



Fonte: Elaborada pelo autor

Ainda na seção de Histórico, há um botão no canto superior direito que possibilita a criação de uma nova análise de risco. Quando pressionado, um novo diálogo é aberto, exibindo todos os campos que o usuário deve preencher para poder prosseguir. A figura 17 exibe o diálogo e os campos necessários para uma nova análise. No total, são 5 campos do tipo lista e 1 campo do tipo arquivo. O usuário deve informar para qual cliente será realizada a análise - este cliente deve ter sido cadastrado anteriormente em uma outra seção da aplicação, o estado e município da propriedade, a cultura e a semente que será utilizada. O campo de arquivo serve para o usuário carregar um arquivo do tipo .KML contendo as informações sobre o polígono que contorna a área rural do cliente. Apenas quando todos estes campos forem preenchidos, o usuário pode submeter a análise e aguardar o resultado.

Há um controle de bloqueios dinâmico utilizado nesse diálogo que induz o usuário a preencher as informações seguindo uma ordem fixa: após escolher o cliente, apenas os campos de Estado e Cultura ficam disponíveis. Isso porque a lista de cidades, que estão salvas no banco de dados, só é carregada no campo de lista após a escolha do estado, para que só se tragam as cidades de um estado por vez, evitando muitos registros em um campo. A mesma lógica é utilizada para o campo de sementes: apenas quando o estado, cidade e cultura foram informados, o campo é disponibilizado, trazendo a lista de sementes homologadas para aquela região e cultura.

O cadastro de clientes é uma outra seção da aplicação, e ela foi desenvolvida para

Figura 17 – Diálogo para Nova Análise


Fonte: Elaborada pelo autor

possibilitar que um cliente seja cadastrado apenas uma vez, e então suas informações podem ser utilizadas nas análises de risco sem a necessidade de preenchimento a cada nova análise. Esta seção apresenta todas as funcionalidades de um CRUD clássico: visualizar, criar, atualizar e remover clientes. Foram inseridas no cadastro do cliente informações julgadas pela corretora parceira como primordiais para a realização da análise de risco e um possível contato com o cliente.

As informações dos clientes são exibidas em uma tabela, como exibido na figura 18. Para cada cliente, há um botão ao final da linha de seu registro para abrir um diálogo que permita ao usuário visualizar e editar seus dados, como exibido na figura 19. Para novos clientes, há um botão localizado no canto superior direito que abre o mesmo diálogo, porém totalmente limpo, para ser preenchido e salvo.


Com isso, a construção da aplicação foi finalizada. Destacado como o propósito das decisões tomadas durante todo o processo está a criação de um ambiente intuitivo, que pudesse atender às necessidades atuais de corretoras de seguro agrícola, e sólido, apto a receber atualizações constantes para atender futuras demandas do mercado.

Figura 18 – Seção de Clientes



Fonte: Elaborada pelo autor

Figura 19 – Diálogo de Clientes



Fonte: Elaborada pelo autor

4 Análise de Resultados

Esta seção apresenta uma avaliação dos resultados obtidos com o desenvolvimento e implementação da aplicação proposta para análise de risco em seguros agrícolas. Inicialmente, discute-se o desempenho geral da aplicação, com ênfase no tempo de execução das análises e uma comparação com os processos atuais adotados pela corretora parceira da pesquisa. Em seguida, examina-se especificamente o modelo de classificação de séries temporais desenvolvido, destacando métricas de desempenho, a matriz de confusão e exemplos de classificações incorretas, com análise dos possíveis motivos para tais erros. Essa análise visa demonstrar a eficiência e a precisão da solução proposta, identificando pontos fortes e oportunidades de melhoria para futuras iterações.

É importante salientar que os testes foram todos realizados em ambiente local. Os resultados apresentados podem variar quando a aplicação for implantada em um ambiente de produção, devido a fatores como carga de usuários, latência de rede e disponibilidade dos serviços externos integrados. Portanto, recomenda-se uma avaliação contínua do desempenho após a implantação para garantir que os objetivos de eficiência e precisão sejam mantidos.

4.1 Análise de Desempenho Geral da Aplicação


O desempenho geral da aplicação foi avaliado considerando o tempo total necessário para concluir uma análise de risco completa. Em testes realizados com dados simulados representativos de cenários reais, o tempo médio para processar uma proposta integral foi de aproximadamente 16.1 segundos, desde o envio dos dados até a exibição final dos resultados da análise para o usuário. Esse resultado representa uma redução significativa em comparação ao processo manual adotado pela corretora parceira, que, conforme relatos e observações durante a pesquisa, demanda em média 20 minutos por análise, envolvendo consultas manuais a bases de dados, verificações cruzadas e validações humanas.

Caso esse desempenho permaneça consistente em ambientes de produção, a aplicação poderá proporcionar uma melhoria substancial na eficiência operacional da corretora, permitindo que os analistas de risco se concentrem em tarefas mais estratégicas e menos repetitivas. Além disso, a rapidez na obtenção dos resultados pode melhorar a experiência do cliente, reduzindo o tempo de espera para a aprovação de suas propostas de seguro agrícola.

Ao desagregar o tempo de execução por componente individual, observou-se que a análise de semente não consome tempo de processamento, pois a verificação é feita enquanto o usuário preenche o formulário. Desta forma, quando a requisição chega ao *backend*, já sabe-se que a semente é válida. A análise de adimplência fiscal do produtor apresentou baixo

tempo de processamento, mas depende da eficiência de resposta da API disponibilizada pela SERPRO. Caso o serviço esteja lento ou indisponível, o tempo de resposta da aplicação pode ser impactado negativamente. A análise do tipo de solo e do local de plantio são realizadas com consultas ao banco de dados espacial, que realiza as operações de verificação de intersecção de polígonos entre a propriedade rural e outros polígonos de interesse, garantindo um retorno rápido. Para essas duas análises, também foi considerada a possibilidade de não utilizar bancos de dados espaciais e fazer as verificações utilizando apenas *Python*, mas esta abordagem aumentou substancialmente o tempo de processamento. Por fim, a análise de histórico de plantio da área é a que mais consome tempo, devido à necessidade de processamento de séries temporais de NDVI, extração e classificação dos dados de satélite. A figura 20 apresenta o tempo médio de execução de cada análise individualmente.

Figura 20 – Tempo de execução das análises de risco



Fonte: Elaborada pelo autor


4.2 Análise do Modelo de Classificação de Série Temporal

O modelo de classificação de séries temporais, baseado na técnica de shapelets, foi projetado para avaliar o histórico de plantio por meio de perfis de NDVI, identificando se áreas são adequadas para cobertura de seguro ao discriminar entre terras consolidadas e recém-convertidas. Os resultados principais indicam uma acurácia global de 86%, com precisão de 99% para classes de áreas consolidadas e 77% para áreas recém-convertidas, obtidos em um conjunto de teste com 102 amostras equilibradas.

A matriz de confusão, apresentada na figura 21, revela 10 verdadeiros positivos (áreas consolidadas corretamente identificadas), 8 verdadeiros negativos (áreas recém-convertidas corretamente excluídas), 3 falsos positivos (áreas recém-convertidas classificadas como consolidadas) e 0 falsos negativos (áreas consolidadas classificadas como recém-convertidas).

O modelo apresenta um viés em direção à classe positiva, ou seja, tende a superestimar a classificação de áreas como consolidadas. Essa tendência pode resultar em uma maior propensão a aprovar propostas de risco, priorizando a sensibilidade (recall) para a classe positiva em detrimento da precisão, o que demanda ajustes para equilibrar o desempenho e mitigar exposições desnecessárias.


Figura 21 – Matriz de confusão do modelo de classificação de séries temporais



Fonte: Elaborada pelo autor

A análise dos erros de classificação, especialmente os falsos positivos, sugere que a construção do dataset com áreas cujas imagens de satélite foram muito afetadas pela presença de nuvens pode ter introduzido ruídos nas amostras e influenciado negativamente no treinamento do modelo. Por exemplo, na amostra 85, exibida na figura 22, a série temporal apresenta lacunas significativas devido à cobertura de nuvens, o que pode ter levado o modelo a interpretar erroneamente o padrão como característico de uma área consolidada. Esse tipo de comportamento destaca a importância de uma curadoria rigorosa dos dados de entrada e a necessidade de técnicas adicionais de pré-processamento para mitigar os efeitos de interferências atmosféricas.

Figura 22 – Exemplo de amostra mal classificada pelo modelo



Fonte: Elaborada pelo autor

5 Conclusão

O presente trabalho teve como principal objetivo a utilização de dados geoespaciais para a análise de risco na contratação de seguros agrícolas, buscando oferecer uma abordagem técnica e automatizada para um processo tradicionalmente dependente de análises manuais e dispersas. Para alcançar esse propósito, foram desenvolvidos e integrados diversos módulos de validação, cada um explorando tecnologias distintas e complementares. Entre eles, destacam-se o uso de bancos de dados espaciais, capazes de armazenar e processar geometrias com alta eficiência; a realização de consultas automatizadas a APIs externas, voltadas à obtenção de informações fiscais dos produtores rurais; e a aplicação de modelos de classificação de séries temporais, que permitiram avaliar o histórico de uso da terra por meio do índice de vegetação NDVI, extraído de imagens de satélite.

Após a consolidação dessas validações, foi desenvolvida uma aplicação web que unifica todos os componentes do sistema em uma interface única e intuitiva. Essa plataforma permite que o usuário mantenha sua conta, cadastre clientes, gerencie propriedades rurais e realize análises de risco de forma integrada e automatizada. O sistema, portanto, atua como uma ponte entre as análises geoespaciais e a tomada de decisão no contexto do seguro agrícola.

Um dos principais resultados observados foi o ganho de tempo operacional proporcionado pela aplicação. Tarefas que anteriormente exigiam a manipulação manual de dados e a execução de múltiplas ferramentas agora são realizadas de maneira centralizada e automática. Essa integração não apenas reduz o tempo de análise, mas também diminui a ocorrência de erros humanos e aumenta a reprodutibilidade dos resultados.

Em síntese, o trabalho demonstrou a viabilidade e a relevância da integração de dados geoespaciais, algoritmos de processamento e tecnologias web no contexto do seguro agrícola. A solução desenvolvida contribui para a modernização dos processos de avaliação de risco, oferecendo uma base sólida para o aprimoramento contínuo do setor e abrindo espaço para futuras extensões, como o uso de dados em tempo real e modelos preditivos mais avançados.

5.1 Trabalhos Futuros

Apesar dos avanços alcançados, o trabalho apresenta diversas oportunidades para melhorias e expansões futuras. Entre as possíveis direções para trabalhos subsequentes, destacam-se:

- O *deploy* da aplicação em um ambiente de produção, permitindo a avaliação do desempenho e da escalabilidade do sistema em condições reais de uso.

- A ampliação do *dataset* utilizado para o treinamento do modelo de classificação de séries temporais, incluindo mais amostras e variáveis relevantes.
- A realização de estudos de caso adicionais com diferentes culturas e regiões geográficas, a fim de validar e ajustar a abordagem proposta em contextos variados.
- O desenvolvimento de funcionalidades adicionais na aplicação web, como dashboards interativos e relatórios automatizados, para melhorar a experiência do usuário e a apresentação dos resultados.

Referências

- AGRICULTURA, P. e. A. Brasil. Ministério da. *Instrução Normativa SPA/MAPA nº 1, de 21 de junho de 2022*. 2022. Diário Oficial da União, Seção 1, Brasília, DF, 22 jun. 2022. Acesso em: 16 set. 2025. Disponível em: <<https://in.gov.br/web/dou/-/instrucao-normativa-spa/mapa-n-1-de-21-de-junho-de-2022-409394106>>.
- BRASIL. *Lei nº 10.711, de 5 de agosto de 2003*. 2003. Diário Oficial da União, Brasília, DF, 6 ago. 2003. Acesso em: 16 set. 2025. Disponível em: <http://www.planalto.gov.br/ccivil_03/leis/2003/l10.711.htm>.
- BREIMAN, L.; FRIEDMAN, J.; OLSHEN, R. A.; STONE, C. J. *Classification and regression trees*. [S.l.]: Chapman and Hall/CRC, 2017.
- BURGOS, N. O papel do sensoriamento remoto na avaliação e no monitoramento dos processos de desertificação do semi-árido brasileiro. 2002.
- CHATFIELD, C.; XING, H. *The analysis of time series: an introduction with R*. [S.l.]: Chapman and hall/CRC, 2019.
- DEFEO, L. F.; ROCHA, J. V.; MANABE, V. D.; MELO, M. R. Utilização de série temporal modis/ndvi para mapeamento de pastagem. 2016.
- DING, H.; TRAJCEVSKI, G.; SCHEUERMANN, P.; WANG, X.; KEOGH, E. Querying and mining of time series data: experimental comparison of representations and distance measures. *Proceedings of the VLDB Endowment*, VLDB Endowment, v. 1, n. 2, p. 1542–1552, 2008.
- EMBRAPA. *Coleção de dados disponibilizados pela Embrapa*. 2025. Acesso em: 27 set. 2025. Disponível em: <<https://geoinfo.dados.embrapa.br/#/>>.
- GASQUES, J. G.; BASTOS, E. T.; TUBINO, M. A. A.; ARAUJO, W. V. d. Projeções do agronegócio: Brasil 2020/2021 a 2030/31-projeções de longo prazo. Ministério da Agricultura e Pecuária, 2021.
- GLAUBER, J. W. Agricultural insurance and the world trade organization. IFPRI Discussion Paper 1473, 2015.
- GÓMEZ-CHOVA, L.; TUIA, D.; MOSER, G.; CAMPS-VALLS, G. Multimodal classification of remote sensing images: A review and future directions. *Proceedings of the IEEE*, IEEE, v. 103, n. 9, p. 1560–1584, 2015.
- GOVERNO FEDERAL. *Agro cresce mais de 10% no segundo trimestre de 2025*. 2025. Acesso em: 16 set. 2025. Disponível em: <<https://www.gov.br/agricultura/pt-br/assuntos/noticias/agro-cresce-mais-de-10-no-segundo-trimestre-de-2025>>.
- GOVERNO FEDERAL. *Cadastro Informativo de Créditos Não Quitados do Setor Público Federal*. 2025. Acesso em: 16 set. 2025. Disponível em: <<https://www.gov.br/pgfn/pt-br/servicos/orgaos-publicos-e-parceiros/cadin>>.
- GÜTING, R. H. An introduction to spatial database systems. *the VLDB Journal*, Springer, v. 3, n. 4, p. 357–399, 1994.

(IPEA), I. de P. E. A. *Dados Geográficos Brasileiros (geobr)*. 2025. Acesso em: 13 set. 2025. Disponível em: <<https://basedosdados.org/dataset/49ace9c8-ae2d-454b-bed9-9b9492a3a642?table=3880670f-eceb-47ec-802b-4579ee62ae3b>>.

JENSEN, J. R. *Introductory digital image processing: a remote sensing perspective*. 1996.

KEOGH, E.; KASETTY, S. On the need for time series data mining benchmarks: a survey and empirical demonstration. In: *Proceedings of the eighth ACM SIGKDD international conference on Knowledge discovery and data mining*. [S.l.: s.n.], 2002. p. 102–111.

LEI nº 10.522, de 19 de julho de 2002. 2002. Acesso em: 08 out. 2025. Disponível em: <http://www.planalto.gov.br/ccivil_03/leis/leis_2002/l10522.htm>.

MAPA. *Áreas Protegidas no Brasil*. 2025. Acesso em: 27 set. 2025. Disponível em: <<https://www.gov.br/mma/pt-br/assuntos/biodiversidade-e-biomas/areas-protegidas>>.

MINISTÉRIO DA AGRICULTURA E PECUÁRIA. *Portarias de Zoneamento Agrícola de Risco Climático*. 2025. Acesso em: 28 set. 2025. Disponível em: <<https://www.gov.br/agricultura/pt-br/assuntos/riscos-seguro/programa-nacional-de-zoneamento-agricola-de-risco-climatico/portarias>>.

NHONGO, E. J. S.; FONTANA, D. C.; GUASSELLI, L. A.; ESQUERDO, J. C. D. M. Caracterização fenológica da cobertura vegetal com base em série temporal ndvi/modis na reserva do niassa-moçambique. *Revista brasileira de cartografia*. Vol. 69, n. 6 (2017), p. 1175-1187, 2017.

PELLETIER, C.; WEBB, G. I.; PETITJEAN, F. Temporal convolutional neural network for the classification of satellite image time series. *Remote Sensing*, MDPI, v. 11, n. 5, p. 523, 2019.

POLA, G. *Índices de Vegetação: IFV, VARI, NDVI e NDRE*. 2022. Acesso em: 08 out. 2025. Disponível em: <<https://mappa.ag/blog/indices-de-vegetacao-ifv-vari-ndvi-e-ndre/>>.

PORTH, L.; TAN, K. S. Agricultural insurance. more room to grow. *The Actuary Magazine*, v. 12, n. 2, p. 1–3, 2015.

RAI, R. *Agriculture Insurance Market Size, Share Trends Analysis Report*. 2025. Acesso em: 16 set. 2025. Disponível em: <<https://straitresearch.com/report/agriculture-insurance-market>>.

SERPRO. *API Center Serpro*. 2025. Acesso em: 27 set. 2025. Disponível em: <<https://apicenter.estaleiro.serpro.gov.br/documentacao/consulta-cnd/pt/demonstracao/>>.

SERPRO. *Serpro*. 2025. Acesso em: 27 set. 2025. Disponível em: <<https://www.serpro.gov.br/>>.

SHAH, M.; GRABOCKA, J.; SCHILLING, N.; WISTUBA, M.; SCHMIDT-THIEME, L. Learning dtw-shapelets for time-series classification. In: *Proceedings of the 3rd IKDD Conference on Data Science, 2016*. [S.l.: s.n.], 2016. p. 1–8.

SIMÕES, R.; CAMARA, G.; QUEIROZ, G.; SOUZA, F.; ANDRADE, P. R.; SANTOS, L.; CARVALHO, A.; FERREIRA, K. Satellite image time series analysis for big earth observation data. *Remote Sensing*, MDPI, v. 13, n. 13, p. 2428, 2021.

TABOSA, F. J. S.; FILHO, J. E. R. V.; VASCONCELOS, D. Impacto do seguro agrícola na produtividade uma avaliação regional no brasil. *Revista de Política Agrícola*, 2021.

VYAS, S.; DALHAUS, T.; KROPFF, M.; AGGARWAL, P.; MEUWISSEN, M. P. Mapping global research on agricultural insurance. *Environmental Research Letters*, IOP Publishing, v. 16, n. 10, p. 103003, 2021.

WALENDORFF, R. *Governo mantém bloqueio a um terço da verba para seguro rural em 2025*. 2025. Acesso em: 16 set. 2025. Disponível em: <<https://globorural.globo.com/economia/noticia/2025/08/governo-mantem-bloqueio-a-um-terco-da-verba-para-seguro-rural-em-2025.ghtml>>.

WÜRCH, E. P. Precificação do seguro agrícola no brasil: uma análise da influência do zoneamento agrícola de risco climático nas taxas praticadas pelo mercado. 2022.

YE, L.; KEOGH, E. Time series shapelets: a new primitive for data mining. In: *Proceedings of the 15th ACM SIGKDD international conference on Knowledge discovery and data mining*. [S.l.: s.n.], 2009. p. 947–956.