

**UNIVERSIDADE ESTADUAL PAULISTA "JÚLIO DE MESQUITA FILHO"**

**FACULDADE DE CIÊNCIAS - CAMPUS BAURU**

**DEPARTAMENTO DE COMPUTAÇÃO**

**BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO**

**LEONARDO SILVA DE OLIVEIRA**

**AUXÍLIO AO DIAGNÓSTICO DE ELA E AVC ATRAVÉS DE  
EXPRESSÃO FACIAL**

**BAURU**

**Julho/2022**

LEONARDO SILVA DE OLIVEIRA

## **AUXÍLIO AO DIAGNÓSTICO DE ELA E AVC ATRAVÉS DE EXPRESSÃO FACIAL**

Trabalho de Conclusão de Curso do Curso  
de Ciência da Computação da Universidade  
Estadual Paulista “Júlio de Mesquita Filho”,  
Faculdade de Ciências, Campus Bauru.

Orientadora: Dra. Simone das Graças  
Domingues Prado

Coorientador: Guilherme Camargo de Oliveira

O48a

Oliveira, Leonardo Silva de

Auxílio ao Diagnóstico de ELA e AVC através de Expressão Facial  
/ Leonardo Silva de Oliveira. -- Bauru, 2022

43 p. : il., tabs., fotos

Trabalho de conclusão de curso (Bacharelado - Ciência da  
Computação) - Universidade Estadual Paulista (Unesp), Faculdade de  
Ciências, Bauru

Orientadora: Simone das Graças Domingues Prado

Coorientador: Guilherme Camargo de Oliveira

1. Aprendizado de máquina. 2. Diagnóstico auxiliado por  
computador. 3. Esclerose Lateral Amiotrófica. 4. Actions Units. 5.

~~Inteligência Artificial. I. Título.~~

Sistema de geração automática de fichas catalográficas da Unesp. Biblioteca da Faculdade de  
Ciências, Bauru. Dados fornecidos pelo autor(a).

Essa ficha não pode ser modificada.

Leonardo Silva de Oliveira

## **Auxílio ao Diagnóstico de ELA e AVC através de Expressão Facial**

Trabalho de Conclusão de Curso do Curso de Ciência da Computação da Universidade Estadual Paulista "Júlio de Mesquita Filho", Faculdade de Ciências, Campus Bauru.

Banca Examinadora

---

**Dra. Simone das Graças Domingues Prado**

Orientadora

Universidade Estadual Paulista "Júlio de Mesquita Filho"

Faculdade de Ciências

Departamento de Ciência da Computação

---

**Prof. Dr. Kelton Augusto Pontara da Costa**

Universidade Estadual Paulista "Júlio de Mesquita Filho"

Faculdade de Ciências

Departamento de Ciência da Computação

---

**Prof. Dr. João Paulo Papa**

Universidade Estadual Paulista "Júlio de Mesquita Filho"

Faculdade de Ciências

Departamento de Ciência da Computação

Bauru, \_\_\_\_\_ de \_\_\_\_\_ de \_\_\_\_\_.

*Eu dedico este trabalho à minha mãe e à minha vó, que transpiram alegria em qualquer conquista minha.*

# Agradecimentos

Eu agradeço primeiramente à minha família, meu pai, minha irmã e minha mãe. Agradeço meu pai, Marcos Paulo, por tentar me ensinar a levar a vida um pouco mais leve do que eu geralmente levo. Agradeço minha irmã Maria Caroline por ser uma amiga incrível, tive o privilégio de a ver crescer e me orgulho completamente de todo o amor e carinho que dei e recebi dela, minha amiga pra todo sempre. Agradeço a minha mãe, Andreia Cristina, que é a pessoa que eu mais vi lutar nos poucos anos de minha existência, ela fez e faz tudo por mim, sem ela não teria chegado a lugar nenhum, seu amor me fortalece e sempre damos boas risadas com apelidos inventados. Obrigado, sem vocês eu não teria chegado aqui, essa conquista não é só minha, mas de todos vocês.

Agradeço ao meu coorientador Guilherme Camargo, que me ajudou de uma maneira imensurável, e me guiou em momentos de incerteza.

Agradeço profundamente a professora Simone das Graças Domingues, que me ajudou e foi paciente comigo em vários momentos, e que me deu forças com os mais simples elogios.

Agradeço a todos os professores da UNESP, que de forma direta e indireta transmitiram seus conhecimentos durante toda a minha graduação.

Agradeço aos verdadeiros amigos que fiz durante a minha graduação, eu espero sempre poder andar de bicicleta com vocês. Agradeço também a Sarah Affonço por ter me ajudado em vários momentos, ter ouvido minhas ligações no auge das crises de ansiedade e ter me dado bronca quando precisava. Agradeço também a Bruna Mendonça, por também me ajudar e oferecer ajuda em tudo que faço, e agradeço por ter trazido um "tico" de cor de volta à minha vida.

Agradeço muito a Eide Tierno, que me incentivou, me deu bronca, me mostrou que o medo não passa de um sentimento besta que muita das vezes nos paralisa, ela me ajudou muito a crescer como pessoa.

Agradeço muito a minha vó, Elza Teixeira, que hoje está impossibilitada de ler esse texto ou assistir minha apresentação, mas que indiscutivelmente torce pra mim em todos os aspectos de minha vida, ela me ensinou muito e o amor que eu tenho por aprender também vem dela, que tinha seu caderno exposto como o melhor caderno da escola.

# Resumo

O presente trabalho foca em verificar a possibilidade do auxílio ao diagnóstico de pessoas que possuem ou não doenças neurológicas através do estudo das expressões faciais. O trabalho utiliza a ferramenta de extração de *Action Units* (*py-feat*) para extrair informações de alguns vídeos, para serem analisados onde nesses vídeos voluntários realizaram algumas tarefas de fala ou movimento olhando para a câmera. Através desses *actions units* extraídos, uma análise exploratória foi feita dos dados extraídos e alguns testes de predição de classificação de algoritmos específicos de aprendizado de máquina para classificar quais dos pacientes possuía ou não algum tipo de doença. Por fim, o trabalho apresenta a conclusão com base nos resultados que apresentaram pontuações altas para tarefas e algoritmo específicos e depois alguns possíveis trabalhos futuros.

**Palavras-chave:** Aprendizado Artificial, Reconhecimento Facial, Diagnóstico de doenças neurológicas, Actions Units, Inteligência Artificial, Ciência de Dados

# Abstract

The present work focuses on verifying the possibility of aiding the diagnosis of people who have or do not have neurological diseases through the study of facial expressions. The work uses the Action Units extraction tool (py-feat) to extract information from some videos, where volunteers perform some speech or movement tasks looking at the camera so they can be analyzed. Through these extracted *actions units*, an exploratory analysis was made of the extracted data and some classification prediction tests of specific machine learning algorithms to classify which of the patients had or did not have some type of disease. Finally, the work presents the conclusion based on the results that presented high scores for specific tasks and algorithm and then some possible future work.

**Keywords:** Machine Learning, Facial Recognition, Neurological disorders diagnoses, Actions Units, Artificial Intelligence, Data Science.

# Lista de figuras

|                                                                                             |    |
|---------------------------------------------------------------------------------------------|----|
| Figura 1 – Função Logística . . . . .                                                       | 16 |
| Figura 2 – Classes separadas linearmente . . . . .                                          | 17 |
| Figura 3 – Classes separadas por SVM . . . . .                                              | 17 |
| Figura 4 – Uma árvore de decisão pra distinguir certos animais . . . . .                    | 18 |
| Figura 5 – Exemplo dos modelos em uma análise dos dados de PIB per capita . . . . .         | 20 |
| Figura 6 – Separação dos dados em <i>5-fold cross-validation</i> . . . . .                  | 21 |
| Figura 7 – Validação cruzada com grupos . . . . .                                           | 22 |
| Figura 8 – Fluxo de processamento de Reconhecimento Facial . . . . .                        | 23 |
| Figura 9 – Demonstração do AU04 . . . . .                                                   | 27 |
| Figura 10 – Retrato executando AU04 . . . . .                                               | 27 |
| Figura 11 – Pontuação AU com py-feat . . . . .                                              | 27 |
| Figura 12 – Quadros extraídos dos vídeos . . . . .                                          | 29 |
| Figura 13 – Mapa de Calor médio das pontuações dos AU por tarefa . . . . .                  | 31 |
| Figura 14 – Tamanho do banco de dados para cada agrupamento . . . . .                       | 33 |
| Figura 15 – Gráfico de caixa dos AU agrupados por média e variância. . . . .                | 33 |
| Figura 16 – Pontuação de teste do agrupamento por média . . . . .                           | 34 |
| Figura 17 – Pontuação de teste de agrupamento por variância . . . . .                       | 34 |
| Figura 18 – Pontuação teste da média por grupo, tarefa e algoritmo . . . . .                | 35 |
| Figura 19 – Pontuação teste da variância por grupo, tarefa e algoritmo . . . . .            | 36 |
| Figura 20 – Pontuação de teste com os AUs destacados - média . . . . .                      | 37 |
| Figura 21 – Pontuação de teste com os AUs destacados - Variância (Fora de escala) . . . . . | 37 |
| Figura 22 – Pontuação de todas as tarefas por agrupamento médio . . . . .                   | 38 |
| Figura 23 – Pontuação de todas as tarefas por agrupamento da variância . . . . .            | 38 |

# Lista de tabelas

|                                                         |    |
|---------------------------------------------------------|----|
| Tabela 1 – Distribuição dos vídeos. . . . .             | 26 |
| Tabela 2 – Descrição dos AUs . . . . .                  | 28 |
| Tabela 3 – Distribuição de quadros por tarefa . . . . . | 28 |

# Lista de abreviaturas e siglas

|      |                                                |
|------|------------------------------------------------|
| DN   | Doença Neurológica                             |
| DA   | Doença de Alzheimer                            |
| DP   | Doença de Parkinson                            |
| ELA  | Esclerose Lateral Amiotrófica                  |
| AVC  | Acidente Vascular Cerebral                     |
| FACS | Sistema de Codificação da Ação Facial          |
| AU   | Unidades de Ação Facial - <i>Actions Units</i> |
| SVM  | Máquinas de Vetores de Suporte                 |
| AM   | Aprendizado de Máquina                         |
| RL   | Regressão Logística                            |
| FA   | Florestas Aleatórias                           |
| CV   | Validação cruzada                              |
| GS   | Grupo Saudável                                 |
| ADA  | Classificador <i>AdaBoost</i>                  |

# Sumário

|            |                                                               |           |
|------------|---------------------------------------------------------------|-----------|
| <b>1</b>   | <b>INTRODUÇÃO</b>                                             | <b>12</b> |
| <b>2</b>   | <b>FUNDAMENTAÇÃO TEÓRICA</b>                                  | <b>14</b> |
| <b>2.1</b> | <b>Aprendizado de Máquina</b>                                 | <b>14</b> |
| 2.1.1      | Aprendizado Supervisionado                                    | 14        |
| 2.1.2      | Generalização, Sobreajuste e Sub-Ajuste                       | 19        |
| 2.1.3      | Técnicas de validação de modelos                              | 20        |
| <b>2.2</b> | <b>Reconhecimento de Expressão Facial</b>                     | <b>22</b> |
| <b>2.3</b> | <b>Extração de AUs</b>                                        | <b>23</b> |
| <b>2.4</b> | <b>Expressão Facial em pacientes com doenças neurológicas</b> | <b>24</b> |
| <b>3</b>   | <b>METODOLOGIA</b>                                            | <b>26</b> |
| <b>3.1</b> | <b>Base de dados</b>                                          | <b>26</b> |
| <b>3.2</b> | <b>Extração das Unidades Faciais</b>                          | <b>27</b> |
| <b>3.3</b> | <b>Algoritmos Implementados</b>                               | <b>29</b> |
| <b>3.4</b> | <b>Preparação dos dados</b>                                   | <b>29</b> |
| <b>4</b>   | <b>RESULTADOS E DISCUSSÃO</b>                                 | <b>31</b> |
| <b>5</b>   | <b>CONCLUSÃO</b>                                              | <b>39</b> |
| <b>5.1</b> | <b>Trabalhos futuros</b>                                      | <b>39</b> |
|            | <b>REFERÊNCIAS</b>                                            | <b>40</b> |

# 1 Introdução

Doenças neurológicas (DN) afetam drasticamente a vida das pessoas, prejudicando os movimentos do corpo e o bem-estar social (ORGANIZATION, 2006). As doenças neurológicas em que a degeneração física e/ou mental é progressiva e ainda não possuem cura, são chamadas de doenças neurodegenerativas. A doença de Alzheimer (DA), Doença de Parkinson (DP), Esclerose Lateral Amiotrófica (ELA) são exemplos conhecidos de doenças neurodegenerativas. DA é a forma de demência mais comum entre 60% a 80% de todos os casos de demência, atingindo uma estimativa de 24 milhões de pessoas globalmente (ERKKINEN; KIM; GESCHWIND, 2017). DP é a segunda doença mais comum entre as DN depois de DA, com uma porcentagem de 0.3% na população geral, 1% com mais de 60 anos e 3% em pessoas com mais de 80 anos (ERKKINEN; KIM; GESCHWIND, 2017).

Dentre os sintomas motores e não-motores, a perda de expressão facial é comum em diferentes doenças neurológicas. Por exemplo, pacientes positivos para a doença Esclerose Lateral Amiotrófica (ELA) apresentam fraqueza e atrofia muscular, como dificuldade no controle dos músculos faciais e movimentos da língua (SIQUEIRA et al., 2016). Além disso, o Acidente Vascular Cerebral (AVC), afeta partes do cérebro responsáveis pelos movimentos faciais (JACOBSEN; ANDRADE, 2017). Finalmente, a doença de Parkinson também causa a rigidez dos músculos faciais.

Com o avanço da análise de expressão facial no reconhecimento de emoções e o rápido aumento de celulares e computadores com câmeras de vídeo integradas, diferentes autores utilizam técnicas de visão computacional e aprendizado de máquina para auxiliar os médicos no diagnóstico de diversas doenças (ALI et al., 2021; CLARK; CRONIN-GOLOMB, 2008; PRADI et al., 2016). O desenvolvimento de uma ferramenta que consegue identificar doenças neurológicas através de vídeos gravados do rosto auxiliaria no diagnóstico e monitoramento de diversos pacientes ao redor do mundo.

O exame de expressões faciais com vídeo é uma técnica não invasiva para o diagnóstico de DNs. Um benefício da análise de vídeo é que os pacientes em potencial não precisam estar perto de um neurologista para receber um diagnóstico. A detecção de doenças pela análise da expressão facial tem o potencial de transformar a vida de pessoas que necessitam de isolamento físico ou estão imóveis, pois um simples vídeo gravado do rosto do indivíduo pode ser enviado pela internet. Além disso, essa técnica pode auxiliar muitos indivíduos carentes, pois a falta de interação direta com um neurologista reduz o gasto.

Os movimentos faciais transmitem informações sobre o humor, propósito e estado físico de uma pessoa e são críticas para a pesquisa da cognição humana e processos associados. Para codificar o movimento de músculos faciais específicos, o Sistema de Codificação da Ação Facial

(*Facial Action Coding System* - FACS) foi criado em 1978 pelos psicólogos americanos Paul Ekman e Wallace V. Friesen e consistia em 46 Unidades de Ação (*Actions Units* - AU) (EKMAN; FRIESEN, 1978). Esta técnica tornou-se posteriormente famosa por estudar expressões faciais. Em 2011, Hamm J. criou um método para estimar FACS (HAMM et al., 2011). Desde então, FACS tem sido objeto de mais estudos em medicina comportamental. Recentemente, AU foram introduzidas para identificar pessoas com doenças neurológicas.

Ali et al. (2021) mediram a variância dos AUs para distinguir entre indivíduos saudáveis e com DP. A acurácia da predição foi equivalente à dos métodos baseados em sintomas motores. Um classificador automático treinado com o Máquina de Vetores de Suporte (*Support Vector Machines* - SVM) obteve 95,6% de acerto nas variações das unidades de ação. Embora essa abordagem tenha um resultado promissor, os autores conduziram o experimento apenas sobre a DP. Mais experimentos são necessários para estudar o verdadeiro potencial das unidades de ação para distinguir diferentes DN que afetam a expressão facial.

Este trabalho de conclusão de curso diz respeito ao estudo aprofundado das AUs em pacientes com ELA e AVC. Tendo como objetivo verificar a possibilidade de identificação de certas DNs através da análise das unidades de ação extraídos por vídeo. Para validar a abordagem proposta, foi utilizado a ferramenta *open-source* e gratuita *py-feat* (CHEONG et al., 2022) para a extração dos AUs, foram utilizadas as bibliotecas *seaborn* (WASKOM, 2021) e *matplotlib* (HUNTER et al., 2022) para a análise inicial dos dados e a biblioteca *scikit-learn* (COURNAPEAU et al., 2022) para a aplicação dos algoritmos de Aprendizado de Máquina (AM) utilizados neste trabalho.

Após a introdução a estruturação deste estudo segue da seguinte forma: a Seção 2 deste estudo apresenta uma fundamentação teórica em AM, os tipos de aprendizado dos algoritmos de AM, alguns dos classificadores e seus métodos de validação, uma breve explicação reconhecimento facial, extração dos AUs e um pouco das doenças que podem causar uma paralisia facial. A metodologia é apresentada na seção 3 e os resultados obtidos são apresentados na seção 4. Na quinta seção é apresentado a conclusão do trabalho e uma subseção logo após de trabalhos futuros.

## 2 Fundamentação Teórica

Neste capítulo serão apresentados alguns conceitos estudados de aprendizado de máquina, assim como alguns algoritmos e métodos de validação dos mesmos. Também são apresentados o fluxo geral do reconhecimento facial, brevemente sobre o básico do sistema de classificação de micro-expressões faciais e da extração dos AUs, alguns conceitos médicos sobre determinadas doenças neurológicas.

### 2.1 Aprendizado de Máquina

O aprendizado de máquina é uma área que aborda modelos matemáticos que se ajustam de acordo com a distribuição dos dados. É conhecida por não envolver programação explícita, por exemplo, não há necessidade de escrever cláusulas de condições e repetições (GÉRON, 2019). Existem diversas aplicações que utilizam o aprendizado de máquina, desde recomendações automáticas de filmes, séries, músicas e até organização automática de imagens (MÜLLER; GUIDO, 2016).

A subseção a seguir apresenta os principais algoritmos utilizados para classificação e apresenta brevemente os seus conceitos.

#### 2.1.1 Aprendizado Supervisionado

Os algoritmos de aprendizado que utilizam dados rotulados são classificados como algoritmos de *Aprendizado Supervisionado*. O usuário alimenta o algoritmo com o par de entrada e saída de dados para o qual será atribuído um valor numérico ou uma classe. A função do algoritmo é mapear um conjunto de dados para um rótulo, ou seja, determinar uma forma de prever qual o rótulo de saída com base em uma entrada informada. O nome supervisionado é devido a necessidade dos dados já estarem previamente rotulados, dessa forma há uma "supervisão" do acerto do aprendizado. Além disso, uma analogia pode ser feita dos dados rotulados sendo com os gabaritos, em que os modelos supervisionados precisam do gabarito para se ajustar.

Por exemplo, tratando o problema de classificação de e-mails como *spam* utilizando métodos supervisionados. Um usuário fornece um número grande de emails com a informação se esses emails são *spam* ou não. Dessa forma, ao inserir um novo email o modelo realiza a predição se ele pertence a classe de *spam* ou não (MÜLLER; GUIDO, 2016).

De modo geral, o objetivo é encontrar a relação de uma variável aleatória  $Y \in R$  e um vetor de atributos  $x = (x_1, \dots, x_d) \in R$ , que se busca estimar a função de regressão.

$$r(\mathbf{x}) := E[Y|X = x] \quad (2.1)$$

A equação 2.1 é uma forma de escrever uma generalização do problema de aprendizado de máquina onde se  $Y$  for uma variável quantitativa é um problema de regressão, mas se  $Y$  for uma variável qualitativa então o problema é de classificação, como o exemplo do email (IZBICKI; SANTOS, 2020).

De forma concisa, no aprendizado supervisionado, os dados fornecidos ao treinamento do algoritmo já possuem o resultado esperado. Esses resultados podem ser chamados de rótulos. Uma tarefa típica do algoritmo supervisionado é a classificação. Utilizando classes para separar determinados dados, como por exemplo: e-mails, é possível determinar quais desses dados podem ou não ser spam (GÉRON, 2019).

## Regressão Linear

O modelo de regressão linear faz uma previsão calculando uma soma ponderada das características de entrada mais uma constante chamada de termo de polarização (também chamada de coeficiente linear), e como o próprio nome diz, esse é um problema de regressão (GÉRON, 2019).

$$\hat{y} = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n \quad (2.2)$$


- $\hat{y}$  é o valor previsto
- $n$  é o número de características
- $x_1$  é o valor da  $i$ -ésima característica
- $\theta_j$  é o parâmetro do modelo  $j$  (incluindo o termo de polarização  $\theta_0$  e os pesos das características  $\theta_1, \theta_2, \dots, \theta_n$ )

Infelizmente quando existem muitas covariáveis, ou seja, muitas características dos dados a regressão linear tende a não performar muito bem, devido ao super-ajuste (2.1.2) e à variância extremamente alta (IZBICKI; SANTOS, 2020).

## Regressão Logística

Certos algoritmos de regressão também podem ser utilizados para classificação. A Regressão Logística (RL) é muito utilizada para calcular a probabilidade de uma classe possuir uma instância. O modelo prevê que a instância realmente pertence à classe se a probabilidade calculada for maior que 50% (chamado de classe positiva, rotulada com "1") ou caso a

Figura 1 – Função Logística



Fonte: [Géron \(2019\)](#)

probabilidade for menor que 50%, então a instância não pertence a classe (rotulado então como "0"). Desta forma, o método é transformado em um classificador binário. ([Géron, 2019](#)).

Assim como um modelo de Regressão Linear, os modelos de RL calcula uma soma ponderada das características de entrada, porém ao invés de retornar o resultado imediatamente gera uma logística desse resultado (2.3) ([Géron, 2019](#)).

$$\hat{p} = h_{\theta}(\mathbf{x}) = \sigma(\theta^T \cdot \mathbf{x}) \quad (2.3)$$

Essa logística, também chamada de *logit* subscrita  $\sigma(\cdot)$  é uma função *sigmóide*, que mostra um número entre 0 e 1. É possível ver na equação 2.4 e na figura 1.

$$\sigma(t) = \frac{1}{1 + e^{-t}} \quad (2.4)$$

Assim que a probabilidade  $\hat{p} = h_{\theta}(x)$  for estimada em que, de que  $\mathbf{x}$  pertence à classe positiva, a previsão da classe pode ser feita facilmente através da equação 2.5


$$\hat{y} = \begin{cases} 0 & \text{se } \hat{p} < 0.5 \\ 1 & \text{se } \hat{p} \geq 0.5 \end{cases} \quad (2.5)$$

Portanto quando a  $\hat{p} \geq 0.5$  então a regressão logística prevê que  $\mathbf{x}$  realmente pertence à classe positiva, e caso  $\hat{p} < 0.5$  então ([Géron, 2019](#)).

## Máquinas de Vetores de Suporte

[Cortes e Vapnik \(1995\)](#) propuseram uma metodologia de classificação chamada de Máquinas de Vetores de Suporte. Eles funcionam de uma maneira diferente dos outros classificadores. Imagine uma situação de um modelo linear conseguindo separar corretamente as classes dos dados, como por exemplo na figura 2.


Figura 2 – Classes separadas linearmente



Fonte: IzBicki e Santos (2020)

O modelo satisfaz o problema, porém a SVM procura margens mais distantes de todos os pontos observados quando há mais de uma solução dentro do espaço possível. Os pontos utilizados (figura 3) para definir as margens são chamados de vetores de suporte (IZBICKI; SANTOS, 2020).

Figura 3 – Classes separadas por SVM



Fonte: IzBicki e Santos (2020)

O exemplo foi de uma solução que poderia ser linearmente separável. Porém, isso não é frequente, o SVM na verdade propõe uma generalização do problema descrito, onde mais de

uma solução seria possível (IZBICKI; SANTOS, 2020).


O SVM podem ser utilizada tanto para tarefas de classificação, quanto para tarefas de regressão e é um dos algoritmos mais eficazes (GÉRON, 2019).

## Árvores de Decisão

As árvores de decisão são muito utilizadas em problemas de classificação e tarefas de regressão. De modo geral, as árvores de decisão montam uma hierarquia de perguntas "se/então" levando até à decisão.

Essas perguntas são semelhantes as perguntas que seriam feitas num jogo de adivinhação onde cada pergunta feita só pode ser respondida com "sim" ou "não". Por exemplo, imagine uma situação onde seja necessário distinguir esses quatro animais: tubarão, elefante, pavão, papagaio. O objetivo é obter as respostas corretas com a menor quantidade de perguntas "se/então". Uma forma de iniciar seria perguntar se o animal possui penas, se a resposta for sim, então agora é possível encontrar uma outra pergunta que distingue o pavão do papagaio. Uma pergunta seria se o animal voa, se a resposta for sim então o animal é o papagaio, se não então o animal é o pavão. Se o animal não possuir penas, então agora é encontrar uma pergunta que distingue o tubarão do elefante. Por exemplo, se o animal possui nadadeiras, caso a resposta for sim, então o animal é o tubarão, se a resposta for não então seria o elefante (MÜLLER; GUIDO, 2016).

Figura 4 – Uma árvore de decisão pra distinguir certos animais



Adaptado de Müller e Guido (2016)

Na figura 4 cada bloco representa uma pergunta ou um bloco terminal (também chamado de *folha*) que contém uma resposta.

## Florestas Aleatórias

Embora interpretar uma árvore de decisão de complexidade baixa seja simples, o modelo resultante é sensível aos dados de entrada. Outro ponto negativo é que esse algoritmo tende a sobreajustar nos dados de treinamento 2.1.2. Portanto, as florestas aleatórias são uma forma de endereçar e corrigir esse problema.

Uma Floresta Aleatória (FA) é um conjunto de árvores de decisão, onde cada árvore de decisão é treinada em um conjunto do treinamento. A ideia é que cada árvore de decisão faça um bom trabalho gerando um modelo enquanto há um sobreajuste em uma parte dos dados de treinamento. Dessa forma quando há várias árvores de decisão, cada uma terá o seu super-ajuste em diferentes partes dos dados de treinamento, o super-ajuste geral é diminuído com a média dos resultados de cada árvore (MÜLLER; GUIDO, 2016).

### 2.1.2 Generalização, Sobreajuste e Sub-Ajuste

Em situações de aprendizado de máquina supervisionado, o ideal seria um modelo conseguir realizar previsões precisas em cima de dados novos que possui as características semelhantes dos dados de treinamento. Se um modelo atingir esse objetivo, ou seja, se em novos dados ele performar bem, o modelo **generaliza** bem (*generalize*) (MÜLLER; GUIDO, 2016).


Existem situações que ao tentar construir um modelo mais complexo, o algoritmo pode performar muito bem no conjunto de dados de treinamento, e ter uma precisão muito baixa ou nula em dados novos, com características semelhantes aos dados de treinamento, à essa situação é chamado de **Sobreajuste** (*overfitting*). Em contrapartida, quando um modelo muito simples é escolhido, ele pode acabar não captando todas as características importantes que ele precisaria para classificar corretamente os dados, tendo uma performance ruim até no conjunto de treinamento, ou seja o **Sub-Ajuste** (*underfitting*) (MÜLLER; GUIDO, 2016).

IzBicki e Santos (2020) mostram uma visão um pouco mais matemática, onde é dito que em problemas de função de regressão é comum ajustar vários modelos até encontrar um com o melhor poder preditivo.

$$g(x) = \beta_0 + \sum_{i=1}^p \beta_i x^i, \text{ para } p \in \{1, 4, 50\} \quad (2.6)$$

Na equação 2.6 estão sendo testados três situações de regressão polinomial, uma de 1°, outra de 4° e uma de 50°. Esses graus representam as características do algoritmo, então o modelo que tem somente 1° é muito simples e não prevê todos os atributos importantes dos dados, o modelo com 50° é extremamente complexo e ficará "viciado" nos dados de treinamento, enquanto o modelo com 4° performa bem no exemplo em (IZBICKI; SANTOS, 2020).

Figura 5 – Exemplo dos modelos em uma análise dos dados de PIB per capita



Fonte: IzBicki e Santos (2020)

Na figura 5, o modelo de 1°, representado pela cor verde, forma uma reta onde suas previsões não são coerentes com os dados reais, o modelo de 50°, forma uma linha cheia de curvas, atingindo vários pontos dos dados de treinamento e por isso não sendo coerente com novos dados, já o modelo de 4° forma uma linha coerente com os dados, já que fica visualmente mais próxima dos dados reais do que os outros dois modelos (IZBICKI; SANTOS, 2020).

### 2.1.3 Técnicas de validação de modelos

Uma forma de validação dos algoritmos supervisionados é separando o conjunto de dados em subconjuntos de treinamento e teste, e então avaliar a performance do modelo treinado com o subconjunto de dados de teste, já que a pontuação de treinamento não é relevante. O objetivo dessa separação seria para testar a pontuação do modelo em novos dados que ainda não foram vistos pelo algoritmo. Uma forma de avaliar a performance é usando a precisão, onde os verdadeiros positivos serão divididos pela soma dos verdadeiros positivos mais os falsos positivos, como mostrando na equação 2.7 (MÜLLER; GUIDO, 2016).


$$precisão = \frac{VP}{VP + FP}. \quad (2.7)$$

Onde VP é o número de verdadeiros positivos, e FP é o número de falsos positivos (GÉRON, 2019).

## Validação Cruzada

Validação cruzada (*Cross-validation* - CV), é um método estatístico mais minucioso e estável para avaliar a performance geral de um algoritmo de AM, do que a separação do conjunto de dados em treinamento e teste. O uso mais comum da CV é o tipo *k-fold cross-validation*, onde *k* é um número especificado pelo usuário, geralmente 5 ou 10. Quando executando um *5-fold cross-validation*, os dados são primeiramente divididos em 5 partes de (aproximadamente) mesmo tamanho chamados de *folds*. Em seguida a validação será feita em 5 etapas, onde a primeira etapa usará o *fold* 1 como dados de teste e os *folds* de 2 à 5 como dados de treinamento. Na próxima etapa o *fold* 2 será usando como dados de teste e os *folds* 1, 3, 4 e 5 como dados de treinamento. O processo se repete usando os *folds* 3, 4 e 5 como dados de treinamento até que as etapas sejam concluídas. A cada etapa a precisão é calculada usando o *fold* de teste respectivo e no final o algoritmo possui as 5 precisões de cada etapa (MÜLLER; GUIDO, 2016). O processo pode ser visualizado na figura 6.

Figura 6 – Separação dos dados em *5-fold cross-validation*



Fonte: Adaptado de Müller e Guido (2016)

## Benefícios da validação cruzada

A validação cruzada trás vários benefícios do que simplesmente separar o conjunto de dados entre treinamento e teste. Dependendo da forma em que esses dados sejam separados, os piores casos do conjunto de dados pode acabar todos no subconjunto de teste, fazendo com que a precisão resultado final do algoritmo não seja muito bom. Entretanto, quando aplicada, a validação cruzada vai treinar o modelo com *folds* diferentes do conjunto de dados e testá-los com um *fold* de teste diferente a cada etapa. Dessa forma os piores casos do conjunto de dados serão usados tanto para o treinamento como para o teste do modelo em situações diferentes, provendo uma melhor generalização do modelo em relação aos dados (MÜLLER; GUIDO, 2016).

## Leave-one-out cross validation


Outro método para verificação do algoritmo bastante usado é o *leave-one-out*, em português *deixe-um-de-fora*. Pode-se imaginar o *leave-one-out* como uma validação *k-fold*

*cross-validation* onde os *folds*, ao invés de serem um subconjunto dos dados é na verdade somente um valor. Esse tipo de validação pode consumir muito do tempo quando aplicado em conjuntos de dados muito grandes, porém podem prover uma melhor estimativa para conjunto de dados pequenos (MÜLLER; GUIDO, 2016).

## Validação cruzada com grupos

Outro caso muito comum é quando existem grupos no conjunto de dados que estão muito interligados entre si. Por exemplo, na construção de um sistema de reconhecimento de emoções através de fotos de faces, de pessoas diferentes demonstrando várias emoções. O objetivo será identificar as emoções de pessoas que não estão no conjunto de dados de treinamento, é possível usar os métodos de validação cruzada num situação como essa, porém é bastante provável que fotos da mesma pessoa estejam tanto no conjunto de treinamento como de teste, dessa forma será muito mais fácil para o modelo identificar as emoções nas fotos do grupo de teste do que realmente uma outra foto completamente a parte desse conjunto. Para corretamente validar, é necessário assegurar que os conjuntos de treinamento e dados possuem fotos de diferentes pessoas. Para atingir tal objetivo, é possível utilizar a *validação cruzada com grupos*, onde o algoritmo receberá um vetor como parâmetro que indicará como conjunto deve ser corretamente dividido (MÜLLER; GUIDO, 2016). Observe a figura 7 como exemplo.

Figura 7 – Validação cruzada com grupos




Adaptado de Müller e Guido (2016)

## 2.2 Reconhecimento de Expressão Facial

O reconhecimento facial é um problema de reconhecimento de padrões visuais, onde tendo como uma representação um objeto tridimensional sujeito à variações de luz e ambiente, a face do indivíduo precisa ser identificada baseada em imagens adquiridas (LI; JAIN, 2011).

Um sistema de reconhecimento facial, de maneira geral consiste em 4 módulos conforme desenhado na figura 8, são os módulos de *Localização do rosto*, *normalização*, *extração de características* e *similaridade*. Esses 4 módulos são explicados abaixo.

Figura 8 – Fluxo de processamento de Reconhecimento Facial



Adaptado de [Li e Jain \(2011\)](#)

*Localização da face* destaca o rosto do indivíduo do fundo da imagem, caso a análise esteja sendo feita em vídeos, cada detecção precisa ocorrer em vários frames do vídeo. A localização da face gera uma boa estimativa da posição e escala do rosto na imagem, porém é a demarcação do rosto que provê mais detalhes como a posição dos olhos, da boca, etc ([LI; JAIN, 2011](#)).

A *normalização da face* é aplicado para normalizar o rosto geometricamente e fotometricamente. A necessidade desta etapa é justificada pois é esperado que os algoritmos de identificação facial consigam identificar os rostos com diferenças de iluminação e poses ([LI; JAIN, 2011](#)).

A *extração de características* é aplicado após o rosto normalizado para extrair as informações importantes para a distinção das faces de diferentes pessoas. Essa extração é usada para a etapa de similaridade ([LI; JAIN, 2011](#)).

*Similaridade* é a etapa onde as informações extraídas são comparadas com uma ou mais imagens e/ou vídeos de um banco de dados. Os resultados podem ser sim ou não, quando a comparação é de um pra um, ou de um para vários a saída do algoritmo é a identidade da pessoa quando uma equivalência existir uma confiança do algoritmo para tal identificação ([LI; JAIN, 2011](#)).

## 2.3 Extração de AUs

Paul Ekman, junto com os autores Wallace V. Friesen e Joseph C. Hager, desenvolveram FACS. O FACS ensina como reconhecer e pontuar um AU, que representa a ativação de determinados músculos da face que produzem mudanças temporárias na aparência do rosto ([EKMAN; FRIESEN; HAGER, 2002](#)).

Diversos estudos utilizam o FACS para obter os AUs e a partir delas, analisar indivíduos ou respostas de acordo com esses dados. Alguns exemplos são os do âmbito investigativo que podem analisar a expressão facial de indivíduos buscando por possíveis mentiras, ou

tentativas de enganação como em [Avola et al. \(2019\)](#). No caso do trabalho de [Waters \(1987\)](#) o conhecimento dos AUs permitiu a criação de um modelo de animação tridimensional de expressões faciais. Na área medica, os trabalhos que utilizam a análise de AUs para auxiliar em algum diagnóstico vem crescendo nos ultimos anos, um exemplo é o caso de [Lints-Martindale et al. \(2007\)](#) que utilizam dos AUs para identificar a dor em pacientes que sofrem de demência, com ou sem DA.

Esses trabalhos que utilizam os AUs para serem desenvolvidos, precisam de ferramentas que permitem a extração dessas unidades através de um sistema computacional, já que a identificação de cada movimento pelo pesquisador individualmente demorará muito sem o conhecimento prévio do sistema completo. Trabalhos como [Tian, Kanade e Cohn \(2001\)](#), [Valstar e Pantic \(2006\)](#), [Tang, Liu e Metaxas \(2007\)](#), [Khademi, Manzuri-Shalmani e Kiaei \(2010\)](#) e outros, propõe métodos e alternativas computacionais para extrair tais AUs. O trabalho de [Li et al. \(2013\)](#) propõe até uma estrutura de dependência entre os AUs ao invés de serem lidas individualmente. Isso evidencia a dificuldade de acesso de outros pesquisadores à tais métodos, já que existem diversos trabalhos diferentes com propostas diferentes, e que para serem usados precisam ser montados e treinados com os banco de dados com os quais eles foram treinados em seus devidos trabalhos. Apesar de possível, isso cria uma barreira grande para o desenvolvimento de outros trabalhos.

Uma forma de contornar essa situação seria utilizando ferramentas de extração já prontas disponíveis na internet, ou tendo um banco de dados em comum entre todos os trabalhos para a comparação de tais resultados, um exemplo de banco de dados online seria o [Pantic et al. \(2002\)](#), porém o acesso à ele deve ser requisitado para os donos. Dentre essas ferramentas disponíveis online, existem algumas que são pagas, como *Affectiva* ([KALIOUBY; PICARD, 2022](#)), *Noldus* ([NOLDUS, 2022](#)), e outras gratuitas como, *OpenFace* ([AMOS; LUDWICZUK; SATYANARAYANAN, 2016](#)), *face-api.js* ([MÜHLER, 2020](#)) e *py-feat* ([CHEONG et al., 2022](#)). Tais software pagos são mais utilizados no meio industrial e/ou comercial já que o acesso para pesquisadores pode não ser possível. Dentre as opções de ferramentas gratuitas, o *py-feat* possui artefatos para extração de características faciais como o *OpenFace*, só que provê outras possibilidades de pré processamento e análises que o *OpenFace* não possui ([CHEONG et al., 2021](#)).

## 2.4 Expressão Facial em pacientes com doenças neurológicas

A paralisia facial, é conceituada como um estado reversível ou irreversível onde os músculos da face perdem seu tônus, podendo ocorrer devido à alterações no sétimo par de nervos cranianos. Há diversas causas da paralisia, como infecções, síndromes, tumores, AVCs, lesões cirúrgicas, origem congênita, entre outros fatores. Indivíduos com paralisia facial apresentam comprometimento funcional e psicossocial, devido ao comprometimento motor,

seja pela expressão reduzida, assimetria facial ou pela diminuição da mobilidade dos músculos (BATISTA, 2011).

A ELA, conceituada como uma doença neuro degenerativa incapacitante e irreversível, portanto um distúrbio progressivo que leva a degeneração do sistema motor inferior e superior sem acometer a atividade intelectual e cognitiva do paciente. Estudos mostram que sua causa tem forte influência pela genética do indivíduo. Sintomas como dificuldade de fala e alimentação estão presentes e são fortes indicativos de ELA, assim como dificuldades com movimentos com braços e ombros e perda de movimentos finos, como habilidade de pinçamento, quando em casos avançados, o paciente pode apresentar dificuldade respiratória (SOUZA; SILVA, 2019).

O AVC é classificado pela organização mundial da saúde, como distúrbios focais e/ou globais da função cerebral, tendo sua duração igual ou superior a 24 horas e deve ter origem vascular, com alterações cognitivas e sensório-motor conforme a extensão da lesão. O sintoma mais prevalente e indicativo de AVC é a dormência da face, perna e/ou braço, até mesmo da lateral total do corpo, podendo evoluir para confusão mental, alterações cognitivas, dificuldade de fala e compreensão, deglutição, tontura até uma lesão muito grave que pode levar a morte súbita (LOPES; MENDES, 2013).

## 3 Metodologia

O projeto é descrito em 4 etapas principais: Extração dos AUs, análise desses dados, a implementação de alguns algoritmos de Machine Learning e a análise desses resultados obtidos.

### 3.1 Base de dados

Esta pesquisa foi realizada utilizando *Toronto Neuroface Dataset*, uma base única (até o momento de desenvolvimento deste trabalho não há nenhuma outra base semelhante no mundo) e pública para o estudo de expressões faciais em pacientes com doenças neurológicas. A base inclui vídeos dos rostos de pessoas saudáveis (chamado de Grupo saudável - GS), pacientes com AVC e pacientes com ELA realizando tarefas.

Foi pedido à cada participante realizar algumas tarefas falando e não falando, que são usadas durante a exameção clínica oro-facial. Elas eram 10 repetições da frase "*Buy Bobby a Puppy*" numa velocidade confortável de fala e volume (chamados aqui essa tarefa de **NORMAL**). Repetições da sílaba /pa/ quantas vezes possíveis em um único suspiro (**PA**). Repetições da palavra /pataka/ quantas vezes possíveis em um único suspiro (**PATAKA**). Realizar o movimento de "bico" com os lábios (como se estivesse assoprando uma vela (**BLOW**) 5 vezes e como se estivesse beijando um bebê (**KISS**) 5 vezes. Abrir o máximo possível a mandíbula 5 vezes (**OPEN**). Formando um sorriso sem abrir os lábios 5 vezes (**SPREAD**). Realizar um sorriso bem grande (**BIGSMILE**) 5 vezes e levantar as sobrancelhas 5 vezes (**BROW**) ([BANDINI et al., 2021](#)).

Tabela 1 – Distribuição dos vídeos.

| Tarefa          | ELA | GS | AVC | Total |
|-----------------|-----|----|-----|-------|
| <b>KISS</b>     | 11  | 11 | 14  | 36    |
| <b>OPEN</b>     | 11  | 11 | 14  | 36    |
| <b>SPREAD</b>   | 11  | 11 | 14  | 36    |
| <b>PA</b>       | 10  | 11 | 14  | 35    |
| <b>PATAKA</b>   | 10  | 11 | 14  | 35    |
| <b>NORMAL</b>   | 9   | 11 | 14  | 34    |
| <b>BLOW</b>     | 6   | 7  | 11  | 24    |
| <b>BROW</b>     | 4   | 4  | 7   | 15    |
| <b>BIGSMILE</b> | 4   | 3  | 3   | 10    |
|                 |     |    |     | 261   |

Fonte: Elaborado pelo autor.

### 3.2 Extração das Unidades Faciais

A extração das unidades faciais foi feita utilizando a ferramenta gratuita *py-feat*, que permite através de seus métodos disponíveis inserir o vídeo ou imagem a ser analisado e passar os parâmetros disponíveis.

Numa primeira instância para análise e teste da ferramenta foi utilizado um vídeo do autor deste trabalho realizando o AU04 de acordo com o manual do FACS ([EKMAN; FRIESEN; HAGER, 2002](#)), que pode ser observado na figura 9. No autorretrato (Figura 10) o autor executou os comandos presentes no manual para realizar a AU04. No resultado obtido pelo *py-feat*, foram pontuados outras unidades de ação além do AU04, porém o AU04 é a unidade de ação que mais pontuou.

Figura 9 – Demonstração do AU04




Fonte: [Ekman, Friesen e Hager \(2002\)](#)

Figura 10 – Retrato executando AU04



Fonte: autorretrato do autor

Figura 11 – Pontuação AU com *py-feat*



Fonte: Elaborado pelo autor.

O algoritmo foi executado em cada vídeo e os resultados dos AUs foram salvos em uma planilha. Onde cada linha é um quadro (do inglês *frame*) e as colunas são: o diagnóstico do paciente, a tarefa realizada no vídeo, o código de identificação do paciente e os valores de zero à um da pontuação das unidades de ação facial extraídos.

O que cada AU representa pode ser visto na tabela 2, e as quantidades de quadros resultantes da extração desses dados podem ser vistos na tabela 3.

Tabela 2 – Descrição dos AUs

| <b>AU</b> | <b>Descrição</b>                 |
|-----------|----------------------------------|
| AU01      | Elevação de sobrancelha interna  |
| AU02      | Elevação de sobrancelha externa  |
| AU04      | Abaixar a sobrancelha            |
| AU05      | Elevação da pálpebra superior    |
| AU06      | Elevação de sobrancelha          |
| AU07      | Contrair bem as pálpebras        |
| AU09      | Encolher o nariz                 |
| AU10      | Elevação do lábio superior       |
| AU11      | Aprofundador do Sulco Nasolabial |
| AU12      | Sorriso                          |
| AU14      | Estreitamento lateral dos lábios |
| AU15      | Sorriso invertido                |
| AU17      | Levantar o queixo                |
| AU20      | Esticar os lábios                |
| AU23      | Comprimir os lábios              |
| AU24      | Pressionar os lábios             |
| AU25      | Abertura dos lábios              |
| AU26      | Abaixar a mandíbula              |
| AU28      | Sugar os lábios                  |
| AU43      | Piscar                           |


Adaptado de [Ekman, Friesen e Hager\(2002\)](#)

Tabela 3 – Distribuição de quadros por tarefa

| <b>Tarefa</b>   | <b>ELA</b> | <b>GS</b> | <b>AVC</b> | <b>Total</b> |
|-----------------|------------|-----------|------------|--------------|
| <b>KISS</b>     | 5552       | 5819      | 7886       | 19257        |
| <b>OPEN</b>     | 6371       | 5825      | 8614       | 20810        |
| <b>SPREAD</b>   | 8156       | 7185      | 9784       | 25125        |
| <b>PA</b>       | 7566       | 11555     | 12729      | 31850        |
| <b>PATAKA</b>   | 6933       | 10647     | 10924      | 28504        |
| <b>NORMAL</b>   | 17680      | 16810     | 24551      | 59041        |
| <b>BLOW</b>     | 3109       | 4112      | 6356       | 13577        |
| <b>BROW</b>     | 1564       | 1829      | 3795       | 7188         |
| <b>BIGSMILE</b> | 1958       | 1485      | 1057       | 4500         |
|                 |            |           |            | 209852       |

No total são 209852 linhas da tabela resultante da extração com o *py-feat*, dentre todas as tarefas as que mais possui quadros é a tarefa normal, logo abaixo é possível verificar a comparação dos quadros por tarefa e por grupo (Figura 12).

Figura 12 – Quadros extraídos dos vídeos



Fonte: Elaborado pelo autor

### 3.3 Algoritmos Implementados

Os dados foram preparados (3.4) e inseridos em 4 algoritmos diferentes, o desempenho de cada um deles foi analisado usando a precisão 2.7, Foi avaliado o treinamento por tarefa, utilizando a validação cruzada com o parâmetro *leave-one-out*. Essa validação retorna a pontuação do algoritmo em relação ao treinamento do modelo e do teste, cada uma dessas pontuações foram salvas em uma planilha para serem analisadas nos resultados.

- Regressão Logística
- Florestas Aleatórias
- Máquinas de Vetores de Suporte
- Classificador AdaBoost (ADA)

Durante o estudos dos algoritmos de classificação, os quatro acima foram utilizados para os exercícios de entendimento do aprendizado de máquina, por esse motivo eles foram selecionados para serem executados neste trabalho.

### 3.4 Preparação dos dados

Os dados para serem inseridos nos algoritmos listados acima foram agrupados por identificador de paciente e tarefa, sendo calculada a média e a variância de todos os AUs desse paciente realizando tal tarefa. Ou seja, um paciente realizando uma tarefa nos dados originais possui  $x$  linhas na saída da extração pelo *py-feat*, ao final do agrupamento essa quantidade  $x$  de linhas vira 1 linha onde cada AU teve sua média calculada através de todas as  $x$  linhas, e outra linha para a variância de cada AU calculado para todas as  $x$  linhas. Então, por exemplo,


uma pessoa do grupo saudável realizando a tarefa **NORMAL** possui 1 linha com a média de todos os seus AUs calculados e outra linha para a variância de todos os seus AUs calculados.

Como foram utilizados os algoritmos de aprendizado supervisionado, cada linha agrupada por paciente e tarefa teve um rótulo atribuído, esse rótulo foi o seguinte 1, 2 ou 3, cada número representando um dos três grupos de paciente, GS, ELA e AVC. Para inserir esses dados nos algoritmos foram geradas quatro bases de dados, onde a primeira e a segunda base agrupam suas linhas pela média, a terceira e a quarta agrupam pela variância. A primeira base e a terceira base concatenam as linhas agrupados do GS e grupo com ELA e a segunda e quarta base concatenam as linhas agrupados do GS com o grupo com AVC.

## 4 Resultados e Discussão

Este capítulo introduz os resultados experimentais dos diferentes algoritmos implementados, bem como uma análise exploratória dos dados.

Figura 13 – Mapa de Calor médio das pontuações dos AU por tarefa



Fonte: Elaborado pelo autor

A figura 13 mostra a média por tarefa de cada AU, o mapa de calor a, b e c referenciam o GS, ELA e AVC respectivamente. Com esse mapa de calor é possível verificar quais dos AU mais pontuaram de cada grupo. É interessante observar que os mapas de calor (b) e (c) tem uma tonalidade um pouco inferior que o do (a), caracterizado pela cor mais escura nas colunas AU01, AU10, AU12, AU14, AU15, AU17.

Por exemplo, todas as pontuações do AU15 no (b) são menores que o (a), ao comparar


com o (c) todas as pontuações do AU15 são menores ou igual ao do (a), e ao comparar o (b) com o (c), o (c) pontuou maior que todas as pontuações do (b). Comparando o AU10, o (b) com exceção da primeira linha, pontuou inferior ao (a), já comparando o (a) com o (c) as maiores pontuações foram do (c) com exceção das linhas das tarefas **OPEN** e **PA**, e nas pontuações do AU10 comparando o (b) com o (c), com exceção da primeira linha o (b) pontuou inferior que o (c). Para uma terceira comparação, o AU06, novamente o (b) pontuou menos que todos as pontuações do (a), ao comparar o (a) com o (c) as linhas **BIGSMILE** e **NORMAL** pontuam mais no (c) e as outras são menores ou iguais, já ao comparar o (b) com o (c), o (b) pontuou menos em todas as linhas do que o (c). No caso da comparação dos AUs AU15, AU10 e AU06 as maiores pontuações são do (a) seguido por (c) e depois por (b). Alguns dos AUs em todos os grupos e em todas as tarefas pontuam muito baixo, como no caso do AU09, AU20, AU28 e AU43, caracterizado pelas colunas azuis no mapa de calor. Essa análise é interessante pois visualmente os mapas (b) e (c) tem uma tonalidade mais azulada que o (a) e ao olhar os valores das pontuações essa característica é justificada, já que realmente as pontuações são mais baixas em (b) e (c), sendo (b) a que menos pontuou dentre todas. De certa forma podemos dizer que os mapas de calor mostram que:

$$(a) \geq (b) > (c) \quad (4.1)$$

A figura 14 mostra as quantidades do banco de dados para cada tarefa, como explicado na seção 3.4 o agrupamento foi por paciente/tarefa e 4 base de dados foram geradas. Como a diferença da base 1 e 2 para a base 3 e 4 são somente a estatística calculada entre todos os AUs, a quantidade de dados da base 1 é igual a base 3 e a quantidade de dados da base 2 é igual a base 4, para cada tarefa. Por exemplo, na primeira coluna do gráfico, que representa a tarefa **KISS**, é mostrado que a base 1 onde a comparação é feita entre o grupo saudável e o grupo com AVC possui 25 linhas de dados, onde 11 são do grupo saudável e 14 são do grupo com AVC, como pode ser verificado na tabela 1, a segunda base de dados para a tarefa **KISS** possui 11 para o GS e 11 para o grupo com ELA, gerando um total de 22 linhas do banco de dados. As tarefas **KISS**, **OPEN**, **SPREAD** possuem a mesma quantidade de itens, totalizando 47 linhas contando com as duas comparações de grupos. As tarefas **PATAKA**, **PA**, possuem 46 linhas de dados e a tarefa **NORMAL** possui 45 linhas de dados. As tarefas **BLOW**, **BROW** e **BIGSMILE**, devido à nem todos os pacientes terem realizado todas as tarefas possuem menos linhas de dados em comparação aos outros, por esse motivo somente as tarefas **KISS**, **OPEN**, **SPREAD**, **PATAKA**, **PA** e **NORMAL** serão analisadas.


Os valores médios e de variância podem ser observados na figura 15. A figura possui 2 gráficos, o primeiro gráfico é do agrupamento por média e o segundo é por variância. Com o intuito de identificar diferenças relevantes, os gráficos de caixa apresentados mostram os valores distintos dos AUs por grupo (GS, ELA, AVC), onde alguns dos AUs se destacam. Chamados de AUs destacados, eles são: AU06, AU07, AU09, AU10, AU12, AU24, AU25, AU26, AU28 e

Figura 14 – Tamanho do banco de dados para cada agrupamento



Fonte: Elaborada pelo autor

Figura 15 – Gráfico de caixa dos AU agrupados por média e variância.




Fonte: Elaborado pelo autor

AU43. O AU43, por exemplo no gráfico de caixa da média os quadrados do grupo GS, ELA e AVC estão mais distantes do que o AU11, que possui valores muito próximos, essa diferença talvez seja mais relevante do que os valores do AU11 que são muito próximos.


Utilizando os dados montados conforme descrito (3.4), a pontuação de teste dos quatro algoritmos de AM pode ser observado na figura 16. O eixo x do gráfico na figura 16 são as tarefas realizadas, onde cada tarefa possui quatro pontuações representados pelos retângulos coloridos, sendo elas ADA (Azul), RL (Laranja), FA(Verde) e SVM (vermelho), essa disposição

Figura 16 – Pontuação de teste do agrupamento por média



Fonte: Elaborado pelo autor

Figura 17 – Pontuação de teste de agrupamento por variância




Fonte: Elaborado pelo autor

dos dados também se repete na figura 17, 20 e 21. O gráfico da figura 16 é referente ao agrupamento por média do paciente/tarefa. As duas pontuações mais altas foram a da RL na tarefa OPEN e o ADA na tarefa KISS, respectivamente com os valores 0.64 e 0.63. É possível observar que nenhuma pontuação de teste passou de 0.7. A figura 17 mostra a pontuação de teste em relação à variância das AUs por paciente/tarefa. Em alguns casos a pontuação é maior como na tarefa PA e com o algoritmo de RL, cuja pontuação é de 0.67, é a mais alta pontuação entre todos do agrupamento por variância e maior que o agrupamento por média.

Apesar das figuras 16 e 17 demonstrarem as pontuações gerais por tarefa, os mapas

Figura 18 – Pontuação teste da média por grupo, tarefa e algoritmo



Fonte: Elaborado pelo autor


de calor retratados nas figuras 18 e 19 mostram as pontuações pelos grupos separados. Por exemplo, a figura 18(a) mostra a pontuação teste dos algoritmos implementados das tarefas selecionadas e da comparação GS e ELA. A figura 18(b) é semelhante à figura 18(a) porém sua comparação é GS e AVC.

Interessante observar que na comparação GS e ELA a tarefa SPREAD tem uma pontuação alta nos classificadores RL, FA, SVM. O FA pontuou bem nas tarefas SPREAD, PATAKA e OPEN, já o SVM pontuou alto na tarefa SPREAD e manteve uma pontuação mediana nas outras tarefas, inclusive na tarefa NORMAL, que pontuou muito baixo em todos os classificadores. Na comparação grupo saudável e AVC, de maneira geral ele pontuou menos que o anterior, tendo como valor mais alto 0.68, ao contrário do mapa anterior que teve a maior pontuação como 0.77. O classificador FA que pontuou bem no primeiro, agora teve uma pontuação bem abaixo de antes. O classificador ADA foi o que se manteve melhor nessa comparação.

Ao analisar a pontuação dos algoritmos dos dados agrupados por variância, o cenário mudou um pouco. As pontuações gerais abaixaram um pouco, exceto por alguns pontos que se destacam. Por exemplo, na comparação GS e ELA, a tarefa OPEN teve um destaque, onde pontuou bem em RL, FA e **teve sua maior pontuação com o SVM de 0.82**, porém o SVM não pontuou tão bem nas outras tarefas. Já a comparação grupo saudável e AVC, teve alguns pontos de destaque como o classificador ADA nas tarefas OPEN, NORMAL e KISS, a tarefa PA pontuou bem com os classificadores RL e SVM.

Todos esses gráficos foram analisados com as pontuações dos algoritmos tendo como as

Figura 19 – Pontuação teste da variância por grupo, tarefa e algoritmo




Fonte: Elaborado pelo autor

características de seus dados todos os AUs disponíveis da extração. Porém, como foi comentado e como mostra a figura 15 alguns dos AUs se destacam. Pensando na distinta diferenças do GS, ELA e AVC para esses AUs, os algoritmos foram executados novamente tendo como as características dos dados somente esses 10 AUs, ao invés dos iniciais 20.


Assim como anteriormente foram analisados as pontuações dos valores médios e variância. A figura 20 mostra a pontuação com relação aos dados médios com os AUs destacados. Algumas tarefas ele pontuou mais do que a mesma análise anterior, como no caso da tarefa NORMAL, que anteriormente havia pontuado um valor médio de 0.48 entre os 4 algoritmos, e com os AUs destacados a pontuação média dessa tarefa é de 0.585. Comparando então a pontuação da tarefa NORMAL pelo agrupamento da variância, na figura 21, a diferença é ainda maior, tendo a sua pontuação média entre os quatro algoritmos igual a 0.315 enquanto no agrupamento por variância com todos os AUs a pontuação era de 0.44.

Figura 20 – Pontuação de teste com os AUs destacados - média




Fonte: Elaborado pelo autor

Figura 21 – Pontuação de teste com os AUs destacados - Variância (Fora de escala)




Fonte: Elaborado pelo autor

Figura 22 – Pontuação de todas as tarefas por agrupamento médio



Fonte: Elaborado pelo autor

Figura 23 – Pontuação de todas as tarefas por agrupamento da variância



Fonte: Elaborado pelo autor

Para comparar a pontuação dos algoritmos com todos os AUs e com os AUs destacados a figura 22 mostra as pontuações de treinamento e teste dos quatro algoritmos, sendo a coluna azul a pontuação com todos os AUs e a coluna laranja sendo a pontuação com somente os AUs destacados. O classificador ADA e FA tiveram um sobreajuste nos treinamentos, caracterizado pela pontuação máxima de treinamento, tanto com os AUs destacados como com todos os AUs, porém as pontuações de teste se mantêm próximas, tendo como diferença 2, 2, 0 e 5 centésimos dos algoritmos ADA, RL, FA, SVM. Essa diferença de centésimos também acontece com as pontuações em relação à variância, como mostrado na figura 23.

## 5 Conclusão

Este trabalho apresentou uma análise exploratória e as pontuações de alguns algoritmos de AM aplicados à classificação se um indivíduo possui ou não uma doença neurológica analisando os AUs extraídos das expressões feitas durante algumas tarefas realizadas em vídeo. A proposta obteve resultados interessantes. A pontuação de cada um dos algoritmos aplicados tanto ao agrupamento por média como variância, ficou próxima do 50% de acerto, ao realizar a média de todas as situações descritas para cada algoritmo. Porém, ao diminuir o nível de observação as pontuações melhoram. Por exemplo, ao comparar o GS e o grupo com ELA, o algoritmo SVM obteve a pontuação mais alta de todos com 0.82 ao olhar a variância de todos os AUs na tarefa OPEN. Isso sugere que determinadas abordagens podem trazer pontuações mais altas.

Apesar de haver uma grande quantidade de quadros extraídos do banco de dados de vídeos, o agrupamento final feito neste trabalho acabou por gerar um banco de dados pequeno para ser analisado pelos algoritmos de AM. Isso traz alguns problemas para um algoritmo de AM, pois quanto maior a quantidade de dados melhor o modelo fica.

### 5.1 Trabalhos futuros

Para trabalhos futuros, o desenvolvimento de um algoritmo capaz de realizar a distinção das doenças de Alzheimer, ELA e pessoas com AVC seria um trabalho interessante como sequência deste. Outra possibilidade de trabalho seria a expansão do banco de dados com novas coletas e/ou criação de dados sintéticos. Assim como a seleção dos AUs mais relevantes na execução dos algoritmos.

# Referências

- ALI, M. R.; MYERS, T.; WAGNER, E.; RATNU, H.; DORSEY, E.; HOQUE, E. Facial expressions can detect parkinson's disease: preliminary evidence from videos collected online. *NPJ digital medicine*, Nature Publishing Group, v. 4, n. 1, p. 1–4, 2021. Disponível em: <<https://www.nature.com/articles/s41746-021-00502-8>>. Acesso em: 22 de Julho de 2022.
- AMOS, B.; LUDWICZUK, B.; SATYANARAYANAN, M. *Open Face*. 2016. Disponível em: <<https://cmusatyalab.github.io/openface/>>. Acesso em: 15 de Julho de 2022.
- AVOLA, D.; FORESTI, G. L.; CINQUE, L.; PANNONE, D. Automatic deception detection in rgb videos using facial action units. Association for Computing Machinery, 2019. Disponível em: <<https://dl.acm.org/doi/pdf/10.1145/3349801.3349806>>. Acesso em: 22 de Julho de 2022.
- BANDINI, A.; GUARÍN, D. L.; KULKARNI, M.; LIM, D.; BOULOS, M. I.; ZINMAN, L.; YUNUSOVA, Y.; TAATI, B. A new dataset for facial motion analysis in individuals with neurological disorders. 2021. Disponível em: <<https://slp.utoronto.ca/faculty/yana-yunusova/speech-production-lab/datasets/>>. Acesso em: 22 de Julho de 2022.
- BATISTA, K. T. Paralisia facial: análise epidemiológica em hospital de reabilitação. *Revista Brasileira de Cirurgia Plástica*, 2011. Disponível em: <<https://www.scielo.br/j/rbcp/a/yKPjVRpLbc9VvmlL9tjmgNn/?format=pdf&lang=pt>>. Acesso em: 19 de Julho de 2022.
- CHEONG, J. H.; XIE, T.; BYRNE, S.; CHANG, L. J. Py-feat: Python facial expression analysis toolbox. *Computer Vision and Pattern Recognition*, 2021. Disponível em: <<https://arxiv.org/ftp/arxiv/papers/2104/2104.03509.pdf>>. Acesso em: 15 de Julho de 2022.
- CHEONG, J. H.; XIE, T.; BYRNE, S.; CHANG, L. J. *py-feat website*. 2022. Disponível em: <<https://py-feat.org/pages/intro.html>>. Acesso em: 15 de Julho de 2022.
- CLARK, U. S.; CRONIN-GOLOMB, S. N. abd A. Specific impairments in the recognition of emotional facial expressions in parkinson's disease. *Neuropsychologia*, Elsevier, 2008. Disponível em: <<https://www.sciencedirect.com/science/article/abs/pii/S0028393208001115>>. Acesso em: 22 de Julho de 2022.
- CORTES, C.; VAPNIK, V. Support-vector networks. *Machine Learning*, 1995. Disponível em: <<https://link.springer.com/article/10.1007/BF00994018>>. Acesso em: 16 de Julho de 2022.
- COURNAPEAU, D.; BRUCHER, M.; PEDREGOSA, F.; VAROQUAUX, G.; GRAMFORT, A.; MICHEL, V. *Scikit-learn*. 2022. Disponível em: <<https://scikit-learn.org/stable/index.html>>. Acesso em: 15 de julho de 2022.
- EKMAN, P.; FRIESEN, W. V. Facial action coding system. *Environmental Psychology & Nonverbal Behavior*, 1978.
- EKMAN, P.; FRIESEN, W. V.; HAGER, J. C. *Facial Action Coding System The Manual*. [S.l.]: Research Nexus division of Network Information Research Corporation, 2002. ISBN 0-931835-01-1.

ERKKINEN, M. G.; KIM, M.-O.; GESCHWIND, M. D. Clinical neurology and epidemiology of the major neurodegenerative diseases. Cold Spring Harbor Perspectives in Biology, 2017. Disponível em: <<https://pubmed.ncbi.nlm.nih.gov/28716886/>>. Acesso em: 22 de Julho de 2022.

GÉRON, A. *Mãos à Obra: Aprendizando de Máquina com Scikit-Learn & TensorFlow*. [S.l.]: Alta Books Editora, 2019. ISBN 978-85-508-0381-4.

HAMM, J.; KOHLER, C. G.; GUR, R. C.; VERMA, R. Automated facial action coding system for dynamic analysis of facial expressions in neuropsychiatric disorders. *Journal of neuroscience methods*, Elsevier, v. 200, n. 2, p. 237–256, 2011.

HUNTER, J.; DALE, D.; FIRING, E.; DROETTBOOM, M. *matplotlib*. 2022. Disponível em: <<https://matplotlib.org/>>. Acesso em: 15 de julho de 2022.

IZBICKI, R.; SANTOS, T. M. dos. *Aprendizado de máquina: uma abordagem estatística, 1a edição*. [s.n.], 2020. ISBN 978-65-00-02410-4. Disponível em: <<http://www.rizbicki.ufscar.br/AME.pdf>>. Acesso em: 22 de Julho de 2022.

JACOBSEN, M.; ANDRADE, D. C. de. *Paralisia facial pode ser revertida. Conheça suas principais causas e seus sintomas*. 2017. Disponível em: <<https://www.hospitalsiriolibanes.org.br/sua-saude/Paginas/paralisia-facial-pode-ser-revertida.aspx>>. Acesso em: 22 de Julho de 2022.

KALIOUBY, R. el; PICARD, R. *Affectiva*. 2022. Disponível em: <<https://www.affectiva.com/>>. Acesso em: 15 de Julho de 2022.

KHADEMI, M.; MANZURI-SHALMANI, M. T.; KIAEI, M. H. K. A. A. Recognizing combinations of facial action units with different intensity using a mixture of hidden markov models and neural network. Multiple Classifier Systems, 2010. Disponível em: <[https://link.springer.com/chapter/10.1007/978-3-642-12127-2\\_31](https://link.springer.com/chapter/10.1007/978-3-642-12127-2_31)>. Acesso em: 20 de Julho de 2022.

LI, S. Z.; JAIN, A. K. Handbook of face recognition. In: \_\_\_\_\_. Boston, MA: Springer US, 2011. cap. Introduction, p. 18–19. ISBN 978-0-85729-931-4. Disponível em: <<https://link.springer.com/book/10.1007/978-0-85729-932-1>>. Acesso em: 10 de Julho de 2022.

LI, Y.; MAVADATI, S. M.; MAHOOR, M. H.; JI, Q. A unified probabilistic framework for measuring the intensity of spontaneous facial action units. IEEE, 2013. Disponível em: <<https://ieeexplore.ieee.org/document/6553757>>. Acesso em: 21 de Julho de 2022.

LINTS-MARTINDALE, A. C.; HADJISTAVROPOULOS, T.; BARBER, B.; GIBSON, S. J. A psychophysical investigation of the facial action coding system as an index of pain variability among older adults with and without alzheimer's disease. Pain medicine, 2007. Disponível em: <<https://academic.oup.com/painmedicine/article/8/8/678/1909796?login=false>>. Acesso em: 20 de Julho de 2022.

LOPES, S. C. de S.; MENDES, V. L. F. *Diretrizes de Atenção à Reabilitação da Pessoa com Acidente Vascular Cerebral*. Ministério da Saúde, 2013. ISBN 978-85-334-2083-0. Disponível em: <[https://bvsms.saude.gov.br/bvs/publicacoes/diretrizes\\_atencao\\_reabilitacao\\_acidente\\_vascular\\_cerebral.pdf](https://bvsms.saude.gov.br/bvs/publicacoes/diretrizes_atencao_reabilitacao_acidente_vascular_cerebral.pdf)>. Acesso em: 16 de Julho de 2022.

MÜHLER, V. *face-api.js*. 2020. Disponível em: <<https://justadudewhohacks.github.io/face-api.js/docs/index.html>>. Acesso em: 15 de Julho de 2022.

MÜLLER, A. C.; GUIDO, S. *Introduction to Machine Learning with Python. A guide for data scientists*. O'Reilly Media, Inc., 2016. ISBN 978-1-449-36941-5. Disponível em: <<https://www.oreilly.com/library/view/introduction-to-machine/9781449369880/>>. Acesso em: 22 de Julho de 2022.

NOLDUS, L. *Noldus*. 2022. Disponível em: <<https://www.noldus.com/>>. Acesso em: 15 de Julho de 2022.

ORGANIZATION, W. H. *Neurological Disorders public health challenges*. [s.n.], 2006. ISBN 378929241563369. Disponível em: <<https://www.who.int/publications/i/item/9789241563369>>. Acesso em: 5 de Julho de 2022.

PANTIC, M.; VALSTAR, M.; RADEMAKER, R.; MAAT, L. *MMI Facial Expression Database*. 2002. Disponível em: <<https://paperswithcode.com/dataset/mmi>>. Acesso em: 20 de Julho de 2022.

PRADI, T.; SILVA, L.; BELLON, O. R. P.; DÓRIA, G. M. S. Ferramentas de computação visual para apoio ao treinamento de expressões faciais por autistas: uma revisão de literatura. ANAIS DO SEMINÁRIO INTEGRADO DE SOFTWARE E HARDWARE (SEMISH), 2016. Disponível em: <<https://sol.sbc.org.br/index.php/semish/article/view/9525>>. Acesso em: 22 de Julho de 2022.

SIQUEIRA, S. C.; VITORINO, P. V. de O.; PRUDENTE, C. O. M.; SANTANA, T. S. de; MELO, G. F. de. Qualidade de vida de pacientes com esclerose lateral amiotrófica. 2016. Disponível em: <<http://periodicos.ufc.br/rene/article/view/19230>>. Acesso em: 22 de Julho de 2022.

SOUZA, M. S. G. *VIVENDO COM ESCLEROSE LATERAL AMIOTRÓFICA: RELATO DE CASO*. Monografia (Graduação) — Faculdade Doctum de Serra, Serra, 2019. Disponível em: <<https://dspace.doctum.edu.br/bitstream/123456789/2678/1/VIVENDO%20COM%20ESCLEROSE%20LATERAL%20AMIOTR%C3%93FICA%20RELATO%20DE%20CASO.pdf>>. Acesso em: 19 de Julho de 2022.

TANG, P.; LIU, Q.; METAXAS, D. N. Boosting coded dynamic features for facial action units and facial expression recognition. IEEE, 2007. Disponível em: <<https://doi.org/10.1109/CVPR.2007.383059>>. Acesso em: 20 de Julho de 2022.

TIAN, Y. li; KANADE, T.; COHN, J. F. Recognizing action units for facial expression analysis. IEEE, 2001. Disponível em: <<https://ieeexplore.ieee.org/abstract/document/908962>>. Acesso em: 22 de Julho de 2022.

VALSTAR, M.; PANTIC, M. Fully automatic facial action unit detection and temporal analysis. IEEE, 2006. Disponível em: <<https://ieeexplore.ieee.org/document/1640595>>. Acesso em: 22 de Julho de 2022.

WASKOM, M. *seaborn*. 2021. Disponível em: <<https://seaborn.pydata.org/>>. Acesso em: 15 de julho de 2022.

WATERS, K. A muscle model for animating three-dimensional facial expression. Computer Graphics, 1987. Disponível em: <<https://dl.acm.org/doi/abs/10.1145/37402.37405>>. Acesso em: 10 de Julho de 2022.